

学校代码: 10223

分类号: S515

学 号: ZS228385

密 级: 公开



黑龍江八一農墾大學

专业学位硕士学位论文

基于 YOLOv8 轻量化小目标检测模型的应用研究

研 究 生: 王一格

指导教师: 王雪 副教授 李鑫 副高级工程师

类别(领域): 农业硕士(农业工程与信息技术)

培养方式: 全日制

培养学院: 信息与电气工程学院

中国·大庆

2025. 06

University code: 10223
Graduate number: ZS228385

Classified code: S515
Confidential degree: Publicity



Heilongjiang Bayi Agricultural University

Doctor (Master) Dissertation

Application research of lightweight small target detection model based on YOLOv8

Postgraduate:	Wang Yige
Supervisor:	Associate professor Wang Xue, Engineer Li Xin
Major:	Master of Agriculture (Agricultural Engineering and Information Technology)
Research direction:	full-time
College:	School of Information and Electrical Engineering

Daqing China
Jun. 2025

目 录

1 绪论.....	1
1.1 研究背景.....	1
1.2 研究目的和意义.....	1
1.2.1 研究目的.....	1
1.2.2 研究意义.....	2
1.3 国内外研究现状.....	2
1.3.1 目标检测算法研究现状.....	3
1.3.2 目标检测算法在农业上的应用研究现状	5
1.3.3 小目标检测研究现状.....	7
1.4 研究目标、内容和技术路线	8
1.4.1 研究目标.....	8
1.4.2 研究内容.....	9
1.4.3 研究方案及技术路线.....	10
2 方法与数据.....	13
2.1 基于 YOLOv8 的目标检测算法	13
2.2 基于卷积的目标检测算法	16
2.3 基于 SSD 的目标检测算法	18
2.4 数据集的构建.....	19
2.4.1 数据采集.....	19
2.4.2 多样化数据示例.....	19
2.4.3 数据标注.....	20
2.5 评价指标.....	21
2.5.1 准确度(Precision).....	21
2.5.2 召回率(Recall).....	21
2.5.3 平均精度 AP(Average Precision).....	22
2.5.4 平均精度均值(m AP@0.5)	22
2.5.5 计算量(GFLOPS).....	22
2.5.6 参数量(Params)	22
2.6 本章小结.....	22
3 基于注意力机制的 YOLOv8 小目标检测模型改进研究.....	25
3.1 注意力机制.....	25
3.1.1 CBAM 注意力模块.....	25
3.1.2 SA 注意力模块.....	27
3.1.3 CA 通道注意力	29

3.1.4 SE 注意力模块	31
3.1.5 EMA 注意力机制	32
3.2 不同注意力机制的对比分析	35
3.3 基于 EMA 注意力机制改进的 YOLOv8 小目标检测模型的构建	35
3.4 实验与分析	37
3.4.1 实验环境及参数设置	37
3.4.2 模型性能分析	37
3.4.3 不同训练轮数对比分析	38
3.4.4 模型的对比分析	39
3.5 本章小结	40
4 基于 YOLOv8 的轻量级谷子种穴内小目标检测模型	41
4.1 改进模型的创建	41
4.1.1 C2f 模块改进优化	42
4.1.2 添加 BiFPN 特征融合结构	44
4.1.3 添加检测头	46
4.2 实验与分析	47
4.2.1 模型性能分析	47
4.2.2 模型的对比分析	49
4.2.3 消融实验结果分析	49
4.3 成穴性结果与分析	50
4.4 本章小结	51
5 种穴内谷子目标的检测系统	53
5.1 系统总体设计	53
5.1.1 系统开发工具	53
5.1.2 系统总体架构设计方案	53
5.2 系统功能的实现	54
5.2.1 注册登录模块的实现	54
5.2.2 谷子检测模块的实现	55
5.2.3 检测结果展示模块的实现	56
5.2.4 检测结果保存模块的实现	57
5.3 本章小结	58
6 结论与展望	59
6.1 结论	59
6.2 展望	60
参考文献	61

摘要

谷子的高效种植是谷子资源储备工作的基础，种穴内谷子的准确识别对于实现高效优质发展建设谷子种植具有十分重要的意义。本文提出基于 YOLOv8 轻量化种穴内谷子检测模型的应用研究。在机械化穴播过程中，种穴内谷子数量与穴孔大小直接影响作物生长和产量。传统人工检测方法存在效率低、成本高等缺陷。因此为实现智能化农业种植，降低劳动力成本，提高谷子产量，为此，本文主要研究工作如下：

(1) 针对 YOLOv8 在复杂场景下对小目标的特征捕捉能力不足，不能精准地识别与定位目标等问题，提出一种基于 EMA (Efficient Multi-scale Attention) 注意力机制的小目标改进方法。该方法通过构建多尺度并行子网络结构，融合通道与空间信息，增强跨维度特征交互能力。具体实现包括在 YOLOv8 主干网络中嵌入 EMA 模块；利用全局平均池化和全连接层动态调整通道权重；优化多尺度特征表达能力。实验结果表明，改进后模型在参数量不变的情况下 YOLOv8 的 mAP@0.5 从原始的 92.5% 提升到 93.5%。

(2) 针对谷子多粒穴播机在复杂背景下播种时，种子在种穴内易被遮挡，种穴内分布情况不易明确，难以实现快速反馈检测结果等问题，提出一种基于 YOLOv8 的轻量级谷子多粒穴播种穴内小目标检测算法 B-YOLOv8。为了捕捉更多的细节信息，在骨干网络中引入多尺度注意力机制 (Exponential Moving Average, EMA)，以增强模型对小目标特征的提取能力。同时，为了降低模型的计算负担，构建 C2f-faster 模块，用 Faster Block 模块替换 C2f 中的 Bottleneck，以减少冗余计算和内存访问时间；为了增强模型多尺度特征融合能力，采用特征金字塔网络结构改进 YOLOv8 的颈部网络，以提高小目标检测精度；为了进一步增强小目标敏感度，在特征层上添加 160×160 微小物体的检测头，以提高检测效果。实验结果表明相比于 YOLOv8 原始模型，B-YOLOv8 模型的平均精度均值 mAP@0.5 提高了 3.89%，参数量降低了 4.86%，算法检测速度提高了 4.59%；能够为谷子多粒穴播机的智能化应用提供一种新的信息反馈方法。

(3) 搭建基于谷子小目标检测算法的识别分类系统。对谷子的数量、穴孔大小进行提取融合，设计包含图像识别和目标检测两种功能人机交互界面，快速实现种穴内谷子图像的识别与分类检测，提高模型使用效率。降低劳动成本及智慧农业种植具有较高的研究价值。

关键词：多粒穴播，小目标检测，YOLO，多尺度注意力机制，轻量化模型

Abstract

The efficient planting of millet is the basis of millet resource reserve, and the accurate identification of millet in the seed hole is of great significance for the realization of efficient and high-quality development and construction of millet planting. In this thesis, we propose the application of a lightweight small target detection model in seed holes based on YOLOv8. In the process of mechanized hole sowing, the number of millet in the hole and the size of the hole directly affect the crop growth and yield. Traditional manual detection methods have the disadvantages of low efficiency and high cost. Therefore, in order to realize intelligent agricultural planting, reduce labor costs and improve millet yield, the main research work in this thesis is as follows:

(1) In order to solve the problems of YOLOv8's insufficient ability to capture the features of small targets in complex scenes, and the inability to accurately identify and locate targets, a small target improvement method based on Efficient Multi-scale Attention (EMA) attention mechanism was proposed. In this method, a multi-scale parallel sub-network structure is constructed to fuse channel and spatial information to enhance the interaction ability of cross-dimensional features. The specific implementation includes embedding the EMA module in the YOLOv8 backbone network; The channel weights are dynamically adjusted by using the global average pooling and fully connected layers. Optimize the ability to express multi-scale features. Experimental results show that the mAP@0.5 of YOLOv8 increases from 92.5% to 93.5% under the same number of parameters.

(2) In order to solve the problems that the seeds are easy to be blocked in the seed hole, the distribution in the seed hole is not easy to be clear, and it is difficult to achieve rapid feedback detection results when the multi-grain seeding machine of millet is sown under complex background, a lightweight small target detection algorithm B-YOLOv8 in the seeding hole of multi-grain foxtail of millet based on YOLOv8 was proposed. In order to capture more detailed information, an exponential moving average (EMA) mechanism was introduced into the backbone network to enhance the model's ability to extract small target features. At the same time, in order to reduce the computational burden of the model, the C2f-faster module was constructed, and the Bottleneck in C2f was replaced by the Faster Block module to reduce the redundant computing and memory access time. In order to enhance the multi-scale feature fusion ability of the model, the feature pyramid network structure was used to improve the neck network of YOLOv8 to improve the detection accuracy of small targets. In order to further enhance the sensitivity of small targets, 160×160 detection heads of small objects were added to

the feature layer to improve the detection effect. Experimental results show that compared with the original YOLOv8 model, the average accuracy of the B-YOLOv8 model is increased by 3.89% mAP@0.5, the number of parameters is reduced by 4.86%, and the detection speed of the algorithm is increased by 4.59%. It can provide a new information feedback method for the intelligent application of multi-grain seeder of millet.

(3) A recognition and classification system based on millet small target detection algorithm was built. The number of foxtail millet and the size of the holes were extracted and fused, and two human-computer interaction interfaces including image recognition and object detection were designed to quickly realize the recognition and classification detection of foxtail images in the burrows and improve the efficiency of the model. Reducing labor costs and planting smart agriculture have high research value.

Key Words: Millet multi-grain sowing, Small target detection, YOLO, Multi-scale attention mechanism, Lightweight model

1 绪论

1.1 研究背景

谷子作为（*Setaria italica* Beauv.）中国传统特色作物，具有抗旱耐瘠、营养均衡、粮饲兼用、文化深厚等特点^[1]。拥有 7000 多年的栽培历史，在我国农业生产中占据重要地位^[2]。目前，我国谷子产量约占全球总产量的 80%，主要分布在黄河以北的干旱、半干旱地区。然而受政策、环境等因素影响，种植面积已从建国初期的 1000 万公顷锐减至约 80 万公顷^[3]。谷子机械化收获过程中籽粒损失、谷壳破损、含杂质对小米品质也会有负面影响等问题^[4]。随着健康饮食理念的普及，谷子的营养价值日益受到重视，其产量与质量对相关产业发展具有重要影响。

掌握了解谷子种植过程中的各种情况以及其在种穴内的分布状态，已成为谷子研究领域的一个关键方向，也是影响谷子种植高效、高质量发展的关键。而对谷子的准确识别是谷子的重点之一。为保证出苗率及播种质量，田间常采用多粒穴播。相较于传统的谷子播种方式，穴播可实现谷子的定量播种^[5]提高谷子成活率，保证谷子植株个体生长的一致性^[6]，多粒穴播时谷子在种沟内自然下落成穴，成穴性受到排种器一次排种数量、排种器的转速以及环境风速与机械速度等因素影响。种子检测的速度及准确率是智能化农业机械发展的关键保障因素之一。由于谷子个体较小且形态具有不规则性^[7]，在复杂自然环境中，易出现漏播重播等现象，同时传统检测方法容易出现种穴内图像漏检误检率高、目标定位不精确、无法快速准确地检测成穴性等问题^[8]。随着计算机算力的提升，深度学习技术广泛应用于目标检测领域^[9]，基于深度学习的目标检测算法是解决该问题的有效办法之一。

深度学习的图像识别技术具备自动分析和识别大量图像的能力^[10]。相较于常规手段，本研究采用的智能技术突破了专业壁垒与技术复杂性的限制。基于深度学习的架构设计，系统能够自动捕获目标图像的深层特征，并通过多层次表征学习来解析特征变体，最终达成高精度的视觉分析与模式辨识。具体到谷物种穴识别领域，该方法通过构建端到端的识别模型，提升传统人工检测效率；为农民提供了更准确的决策支持和高效的种植方式。为精准农业实践提供了可量化的技术支撑。

1.2 研究目的和意义

1.2.1 研究目的

谷物是我国重要的粮食作物，其播种方式以条播和撒播为主，但实践表明这两种播种

方式都会使得播种出苗后定株非常困难^[11], 不仅造成种子资源浪费, 更引发人力与物资投入成本上升^[12]。谷物种籽单粒破土能力具有先天性弱势特征, 致使单粒精密播种也不适合谷子农艺种植特征, 且易诱发缺苗断垄等生产问题。研究表明, 谷物种籽萌发需依赖“群体破土”效应, 要求相邻种籽在一定空间范围内形成协同破土机制, 这是保障出苗率的关键生物力学特性^[13]。基于此农艺规律, 将传统均匀条播改良为多点匀距-局部集群播种模式, 可有效强化种穴顶土优势, 进而实现节种省工、免间苗和高产目标^[14]。然而, 现有目标检测方法在处理谷物种穴等小目标时普遍存在特征语义信息衰减及空间定位精度下降等技术瓶颈, 导致检测结果存在漏检率高与误检率波动大等问题。

本研究以 YOLOv8 网络架构优化为核心, 重点针对种穴内谷物种籽小目标检测任务, 通过改进特征提取网络与特征融合机制, 着力解决现有方法存在的语义信息丢失与漏检问题。研究创新点在于结合谷物种籽“群体破土”的生物力学特性, 构建适用于多点匀距播种模式的深度学习检测模型, 突破传统人工统计方法效率瓶颈, 在保持实时检测性能优势的基础上显著提升检测准确率, 为谷子精量播种装备研发提供可靠的技术支撑与理论依据。

1.2.2 研究意义

目前, 农业生产朝着智能化、可持续化方向发展, 谷子的高效种植是粮食高产量的重点之一, 在计算机视觉领域, 小目标检测的重要性不言而喻。传统的人工操作不仅成本较高并且通常会错误判断谷子位置, 除此之外, 现有的检测方法在处理小目标的尺寸变化、密集分布以及不规则排列等复杂情况时, 常常会遭遇漏检和误检的困境。为攻克这些难题, 本研究深入探索了小目标检测性能优化可行性, 以提高小目标检测精度, 对与谷子种子相似的较小的杂物进行精准识别分类, 实现种穴内种子分布情况的准确识别, 有效降低谷子资源的损失, 为田间复杂环境下的种子快速检测提供理论和技术支持, 也为相关领域的深入探索与持续发展给予了有益启示

1.3 国内外研究现状

20 世纪中期, 目标检测技术吸引了国内外众多学者的目光, 相关的初步探索与应用由此展开。该技术具备实时检测能力、能适应复杂环境、灵敏度高且成本较为低廉等突出特性。凭借这些显著优势, 目标检测技术在农业检测领域逐渐发挥重要作用, 逐步发展成为农业检测中一项关键且无法替代的技术手段。

1.3.1 目标检测算法研究现状

目标检测算法作为计算机视觉领域的核心技术，近年来在深度学习驱动下取得了显著进展。根据网络架构的演进特征，当前主流方法可分为两阶段检测算法、单阶段检测算法两大研究方向，各类型算法在精度与效率的平衡中持续优化。

（1）两阶段目标检测算法

两阶段检测算法通过区域建议与特征精调的双阶段处理机制，在复杂场景中展现出较强的特征表征能力。Tian 等^[15]在 Faster R-CNN 框架中引入多尺度特征增强模块，通过构建跨层特征交互网络，将苹果病害检测的 mAP 提升至 91.6%。针对农业场景中目标尺度变异大的挑战，Chang 等^[16]提出了一种结合条件随机场（CRF）特征图与 Mask R-CNN 的声纳图像鱼类分割方法，通过 CRF 预处理增强图像边缘特征，再利用 Mask R-CNN 进行高精度实例分割，有效解决了声纳图像中因低对比度和噪声干扰导致的鱼类轮廓模糊问题。值得关注的是，Transformer 架构的引入为两阶段算法带来新的突破，Xu^[17]构建的 TransDet 模型通过自注意力机制重构特征空间关系，在小麦病害数据集中实现 93.2% 的检测精度，较传统方法提升 4.3 个百分点。He 等^[18]基于卷积神经网络提出 SPP-Net 算法，SPP-Net 使用了空间金字塔结构，只提取一次特征，大大减少了计算量，提高了运行速率。Ross Girshick 等^[19]继承 R-CNN 并采纳 SPP-Net 的特点，基于候选区域的提取方法提出 Fast R-CNN，同时网络通过双层分支输出，其训练速度和测试速度较 R-CNN 有较大提升。与 SPPnet 相比，Fast R-CNN 训练 VGG16 的速度提高了 3 倍，测试速度提高了 10 倍。Ren 等^[20]进一步提出了 Faster R-CNN，在 Fast R-CNN 基础上添加区域建议网络，替代了传统的特征提取方法，提高了网络的训练速度。针对 Faster R-CNN 需要对每个 ROI（感兴趣区域）进行大量重复计算的问题，2016 年 Dai 等提出 R-FCN 方法^[21]，引入位置敏感分数图，以解决在图像分类中图片自身的变化不会更改图片属性的问题，达到计算权值能在整幅图像上共享的目的。

（2）单阶段目标检测算法

One-Stage 目标检测算法典型代表为 YOLO（You Only Look Once）系列和 SSD 系列算法。2016 年 Redmon 等人提出 YOLO 算法（YOLO v1）^[22]，开创性地将检测问题转化为回归问题，使用卷积神经网络完成目标类别的判定和边界的预测，可实现目标实时检测，开启了目标检测 One Stage 算法的新纪元。Redmon 等针对 YOLO v1 存在的不足，从训练策略、网络结构、多尺度检测等多方面改进，陆续提出了 YOLO9000^[23]（YOLOv2）以及 YOLOv3^[24]，以提升 YOLO 算法的性能。YOLOv2 采用 Batch Normalization 对网络进行

优化, 借鉴 Faster RCNN 去掉全连接层, 使用 Anchor Boxes 预测 Bounding Boxes。YOLOv3 相较于 YOLOv2, Backbone 使用了更大的网络结构 Darknet-53。Neck 层选取了 FPN 结构, 融合了各类尺度的特征信息, 提高了模型对于小型目标的识别能力。Bochkovskiy 等人^[25]借鉴 CSPNet Darknet53 改进了 YOLOv4, CSP 结构在下采样后先将输入特征图用两个卷积层划分成两个部分 Part1 与 Part2, CSP^[26]结构的引入显著减少了特征提取网络的参数量和计算所需的时间成本, 同时保证网络的能力提升。Neck 层引入采用了 SPP (Spatial Pyramid Pooling) 结构, 改进了特征融合的效果。Head 层中损失函数优化为 CIoU, 改进了边界框回归的准确性。之后 YOLOv5^[27]进一步采用了轻量级网络结构, Neck 层引入了 PANet 结构, 改进了特征融合的效果。Head 层使用了 GIoU 损失函数, 提高了目标检测的精度和速度。YOLOv6^[28]和在前代的基础上, 进一步改进了骨干网络, 通过引入更复杂的模块和连接方式来增强特征提取的能力; YOLOv7^[29]是一种单阶段目标检测模型, 具备快速和准确的目标检测能力。此网络架构包含轻量级骨干网络 CSPDarknet53、特征金字塔网络 FPN、空间金字塔池化层 SPP, 采用融合交叉熵与均方误差损失函数的组合损失函数。CSPDarknet53 负责初步特征提取, FPN 强化多尺度特征表达, SPP 提升特征全局感知。组合损失函数综合分类与回归优势, 全面衡量误差, 助力网络优化参数, 提升目标检测性能。

Liu 等人^[30]提出 SSD (Single Shot Multibox Detector) 算法, 将 Faster R-CNN 中提取多种候选区域作为感兴趣区域 (ROI) 的思想与 YOLO 中回归的思想结合, 一定程度上解决 YOLO 算法对小目标识别以及尺度不敏感的缺陷。但 SSD 模型中存在检测框反复检测同一物体的情况, 加大了模型的计算难度, Jeong 等^[31]提出了 RSSD 算法来解决上述问题, 用 ResNet 替换 VGGNet 的主干网, 适用于分类器网络中的权值共享, 提高训练速度。Fu 等^[32]提出了 DSSD 算法, 基于 ResNet101 主干网络, 引入去卷积实现上采样, 提升小目标的检测精度。但检测速度变慢。Li 等^[33]结合 FPN 的思想提出了 FSSD 算法, FSSD 是在特征融合模块中, 将不同尺度不同层的特征连接起来, 由下采样块生成新的特征金字塔, 被馈送到多盒检测器以预测最终检测结果。2019 年, Shen 等^[34]融合 SSD 和 DenseNet 的思想提出 DSOD 算法, 该算法不需要额外的数据或预先训练的模型, 减少了参数数量。但是通过骨干网络和预测层中的分层密集连接实现的深度监控, 造成特征冗余, 增加了模型的计算量。同年, Yi 等^[35]提出 ASSD, 在特征图的空间中建立特征关系, 借助全局关系信息, ASSD 学习在特征图上突出有用区域, 同时抑制不相关信息, 从而为目标检测提供可靠的依据。

1.3.2 目标检测算法在农业上的应用研究现状

在目标检测领域，一阶段检测算法以 SSD^[36-37]、YOLO^[38-39]系列为主要基础模型。YOLO(You Only Look Once)系列算法以高效的特点著称，能够在保持较高检测精度的同时，实现快速的处理速度，使得它在实际应用中得到广泛应用^[40]。

Chen, S.等^[41-42]使用优化的 YOLOv8 模型实现了对郑单 958 玉米种子内部裂缝的图像识别。它有效地解决了与玉米种子有限的透光性、裂缝定位困难和算法泛化问题相关的挑战。优化后的 YOLOv8 模型的平均精度 (AP) 值比原始模型高 3.1%。此外，通过应用图像增强，AP 值增加了 1.8%。所提方法在单粒种子检测实验中对完整或破碎种子的平均识别准确率为 99.66%，平均识别准确率为 99.87%，平均识别召回率为 99.48%，平均单帧图像检测时间为 7.49 ms。

Chen, J.等^[43]提出了一种基于 YOLOv8n-Pose 的改进 YOLOv8-GP (YOLOv8-Grape and picking point) 模型，以解决葡萄串和采摘点同时检测的问题。实验结果表明，YOLOv8-GP 在葡萄串检测方面实现了 89.7% 的 AP, Params 的数量减少了 47.73 %，模型复杂度计算量为 6.1G。总之，YOLOv8-GP 提供了出色的检测性能。

Solimani 等^[44]提出基于改进 YOLOv8 模型的番茄植株检测方法，引入了一种新的数据平衡方法来克服数据不平衡的问题。该模型可有效检测番茄植株中的花、果实和节点。该模型显著增强了算法在复杂环境中检测不同大小物体的能力。增强目标类的识别能力，提高整体检测性能。

例如 Liu 等^[45]提出了改进 YOLO V3 模型在番茄叶片病害数据集上进行了测试，将构建真实自然环境下的番茄病虫害数据集，利用图像金字塔优化 Yolo V3 模型的特征层，实现多尺度特征检测，提高 Yolo V3 模型的检测精度和速度，准确快速地检测番茄病虫害的位置和类别。获得了具有较高检测精度和检测速度的优异结果。

Li 等^[46]提出一种名为 YOLO-JD 深度学习检测模型用于从图像中检测黄麻病害，用于从图像中检测黄麻病害。在 YOLO-JD 的主架构中，我们集成了沙钟特征提取模块 (SCFEM)、深沙钟特征提取模块 (DSCFEM) 和空间金字塔池化模块 (SPPM) 三个新模块，以有效提取图像特征。YOLO-JD 实现了最佳的检测准确率，mAP@0.5 为 96.63%。

Zhang 等^[47]提出了一种 SE-YOLOv5x 模型用于杂草作物分类和生菜田间定位检测研究，展示了 SE-YOLOv5x 对莠苣和杂草的分类和莠苣本地化的能力，为杂草自动化控制提供了理论和技术支持。SE-YOLOv5x 模型对田间莠苣茎出苗点位置的检测准确率为 97.14%，单幅图像平均检测时间 11ms，具有较好的实时性。展示了 SE-YOLOv5x 对莠苣和杂草的分

类和莠苣本地化的能力，为杂草自动化控制提供了理论和技术支持。

在 2020 年，Kuznetsova 等^[48]研究人员基于 YOLOv3 算法，研发了一款适用于苹果采摘的机器视觉系统。与同类型系统相比，该系统在准确率与误检率这两项关键指标上，均展现出明显优势，它的平均检测耗时仅 19 毫秒，充分彰显了其具备出色的稳定性与可靠性。

公徐路等^[49]提出一种改进 YOLOv5s 模型的轻量化苹果叶片小目标病害检测方法，为解决自然环境中苹果叶片病害检测场景复杂、小目标病害检测难度高以及模型参数大无法在移动端和嵌入式设备部署等问题，该方法将 YOLOv5s 的骨干网络更改为 ShuffleNet v2 轻量化网络，引入 CBAM（convolutional block attention module）注意力模块使模型关注苹果叶片小目标病害，添加改进 RFB-s 支路获取多尺度特征，提高苹果叶片病害检测精度，试验表明改进后的 YOLOv5s 模型在其 mAP@0.5 提升了 0.8 个百分点，每秒传输帧数 FPS 达到 175 帧/s，参数量减少了 6.17 MB，计算量减少了 13.8 G。

王梦妮等^[50]针对现有的目标检测算法检测茶叶嫩芽的精度较低，为提高茶叶嫩芽的检测精度，该研究提出一种基于改进 YOLOv5s 网络模型的茶叶嫩芽检测算法。实验数据显示，相较于原模型，经优化所得到的 Tea-YOLOv5s 在准确率、召回率以及平均精度值上，分别提升了 4.4、0.5 以及 4.0 个百分点。

范天浩等^[51]为提高金银花采摘机器人的工作效率和采摘精度，实现将模型方便快速部署到移动端，该研究提出一种基于改进 YOLOv5s 的轻量化金银花识别方法。采用 EfficientNet 的主干网络来更替 YOLOv5s 的 Backbone 层，同时在优化后的 Backbone 层中融入原 YOLOv5s 的 SPPF 特征融合模块。这一举措有效削减了模型的参数量与计算量，模型权重也得以降低。实验数据表明，改进后的轻量化模型参数量仅为 3.89×10^6 M，占原始 YOLOv5s 模型的 55.5%；计算量仅 7.8 GFLOPs，为原始模型的 49.4%。值得一提的是，其精确度与平均精度分别达到 90.7% 和 91.8%，不仅提升了检测精度，还显著减少了模型的参数量与计算量。该研究成果为后续金银花采摘机器人的识别工作以及在移动端的部署提供了关键参考与有力依据。

陈禹等^[52]针对现有目标检测模型对自然环境下茶叶病害识别易受复杂背景干扰、早期病斑难以检测等问题，该研究提出了 YOLOv5-CBM 茶叶病害识别模型。YOLOv5-CBM 构建于 YOLOv5s 模型之上。该模型选用加权双向特征金字塔（BiFPN）充当网络的 Neck 部分，以此优化特征处理流程。并在检测端新增一个小目标检测头，解决了茶叶病害初期病斑较小容易出现漏检的问题。结果表明，改进后 YOLOv5-CBM 平均精度分别提高了 1.9

和 0.9 个百分点, 对不同病害检测的平均精度均值达到了 97.3%, 检测速度为 8 ms/幅, 该模型具有较高的识别准确率与较强的鲁棒性^[13]。

刘冰杰等^[53]针对现有田间杂草识别模型复杂、准确率不高等问题, 研究玉米田间杂草识别算法, 通过准确识别杂草图像, 为提高田间杂草防控效果提供理论与技术支持。建立了 YOLOv3、YOLOv5、SSD 目标检测模型, 并进行了模型训练。针对幼苗这类小型目标易漏检的问题, 选取玉米田中常见的杂草种类作为测试数据集, 检测精度分别达到 73.4%、91.4%、90.7%。

王卫星等^[54]为实时准确地检测到自然环境下背景复杂的荔枝病虫害, 提出基于改进 YOLOv4 的荔枝病虫害检测模型, 使用更轻、更快的轻量化网络 GhostNet 作为主干网络提取特征, 并结合 GhostNet 中的核心设计引入更低成本的卷积 Ghost Module 代替颈部结构中的传统卷积, 得到轻量化后的 YOLO v4-G 模型。改进后的模型准确且快速地检测出图像中的病虫害目标, 检测精度为 90.42%, 较改进前平均检测精度提升 4.13%, 检测速度提升 38%。

姚涛等^[55]提出了一种基于改进 YOLOv7-seg 的黄花菜目标检测与实例分割算法模型, 通过引入卷积块注意力模块 (Convolutional Block Attention Module, CBAM) 降低背景等干扰因素的影响, 在 ELAN (efficient layer aggregation networks) 模块中采用 PConv (partial convolution) 替换原有的 3×3 卷积层, 减少冗余计算和内存访问, 提升对目标黄花菜特征提取的能力。改进后的模型平均精度为 93%, 相比原始模型提升 2.7 个百分点; 改进后的模型减少了漏检、误检等情况, 对目标定位更加精准, 为后续黄花菜智能化采摘实际应用提供理论支持。

马超伟等^[56]提出的轻量化 YOLOv8 模型专注于小麦病害检测, 使用 PP-LCNet 模型替换 YOLOv8 网络结构的骨干网络, 减少模型参数量, 在颈部网络部分添加全局注意力机制 (global attention mechanism, GAM) 模块, 同时引入轻量级通用上采样内容感知重组 (content-aware reassembly of features, CARAFE) 模块, 改进后模型的参数量相比原 YOLOv8n 模型降低了 12.5%, 平均精度均值 1.9 个百分点。

1.3.3 小目标检测研究现状

由于小目标检测对精度和速度都有较高要求, 在通常情况下小目标图像背景复杂、成像距离远、小目标尺寸小、缺少目标的纹理特征, 因此对小目标的精确识别和定位存在一定的难度^[57-58]。近几十年来人们对这一领域进行了大量的研究, 2016 年, Chen 等^[59]提出

了基于深度学习的小目标检测网络，通过引入小目标检测数据集以及数据集的评估指标，从相对大小出发将同类目标中目标框面积占总面积小于 0.58% 的部分定义为小目标。Pang 等^[60-61]提出基于多尺度融合的 Faster-RCNN 的小目标检测方法，提高了无人机对地面车辆目标的检测精度。Li 等^[62]提出了构建轻量的并行混合注意力模块抑制图像中复杂背景和负样本的干扰，同时通过调整下采样倍数，来保证传递更多的信息，但像船类等密集小目标分布方向具有任意性，易造成预测框重叠，导致水平检测框无法精确定位目标位置。Xie 等^[63]提出了 DroneYOLO（You Only Look Once）模型，设计了新的 MAFF 特征融合模块和 ML-FPN 结构，用于提高对小目标的关注度，但是模型参数较多、计算量大、实时性较低。Ni 等^[64]提出了一种基于金字塔共生特征架构的小目标检测算法，提取出更多的边缘和纹理信息，但复杂背景下的检测效果仍然不甚理想。小目标检测仍是计算机视觉中一个富有挑战的难题，如何对小目标进行快速、准确的智能化检测具有重要意义^[65-66]。

综上所述，深度学习在目标检测领域显著提升了目标识别的准确性，在多个领域中均取得了显著的应用成果，但仍存在以下不足：

（1）小目标检测性能受限：YOLO 系列现有模型在多次下采样过程中容易丢失小目标的细节特征，导致漏检率高、定位精度差。尤其在农业场景中，谷子种穴等微小目标（直径不足 5mm）常因杂草遮挡、光照不均或土壤背景干扰而难以被有效识别。模型对重叠目标的边界区分能力较弱，易产生误检或检测框偏移；动态农田环境中光照变化、运动模糊等干扰因素会显著降低模型鲁棒性，传统数据增强方法难以覆盖真实场景的多样性。

（2）尽管 YOLOv8 等模型优化了实时性，但针对轻量化部署仍存在参数量大、计算资源消耗高的问题。小目标特征保留能力弱、复杂遮挡场景适应性差、轻量化与精度难以兼得以及农业场景数据依赖性高等方面。

这些不足制约了深度学习在农业实际场景中的落地应用，需通过多尺度特征优化、轻量化网络设计及小样本学习等方法实现突破。

1.4 研究目标、内容和技术路线

1.4.1 研究目标

本研究面向谷子机械化多粒穴播的智能化检测，针对种穴内小目标检测存在特征易丢失、模型复杂度高、实时性不足等关键问题，构建轻量化高精度检测体系。具体研究目标包括：

（1）建立多尺度特征增强机制

针对小目标在图像中占比过小且极易受到环境干扰、容易造成检测器的误检和漏检等问题，实验以机械穴播拍摄的图像数据为研究对象，提出基于 EMA 注意力机制的特征提取优化方法，解决复杂农田场景下谷子小目标特征易受背景干扰、语义信息丢失的问题，实现模型在保持参数量不变条件下检测精度的提升，构建适用于农业场景的特征表达范式。

（2）构建轻量化实时检测模型

基于 YOLOv8 为主的单阶段目标检测算法研发 B-YOLOv8 轻量化检测架构，通过 Faster Block 模块重构、BiFPN 特征融合优化及检测头扩展设计，达成模型参数量降低、推理速度提升的目标，形成适用于农机嵌入式部署的轻量高精度检测模型。

（3）实现智能化检测系统集成

开发种穴检测人机交互系统，集成目标计数、穴径分析、播种质量评估等功能模块，构建播种参数动态优化决策支持体系。通过目标检测结果分析验证谷子成穴性能以及解决农作时种子是否需要补苗等实际问题。

本研究通过算法-模型-系统的协同创新，形成面向智慧农业的小目标检测技术解决方案，为谷子精准播种装备研发提供理论与技术支撑。

1.4.2 研究内容

本研究以 YOLOv8 目标检测框架为基础，针对多粒穴播场景下谷子种穴内小目标检测的技术瓶颈，开展轻量化模型构建与检测系统开发研究。主要研究内容包含以下三个层面：

（1）基于多尺度注意力机制的特征提取优化研究

针对复杂农田环境中谷子小目标特征易被背景干扰的问题，提出 EMA（Efficient Multi-scale Attention）注意力机制改进方法。通过构建多尺度并行子网络架构，建立跨维度的特征交互通道，实现通道权重动态调整与空间特征协同优化。在 YOLOv8 主干网络中嵌入 EMA 模块，利用全局平均池化与全连接层进行特征重标定，增强模型对微小目标的特征聚焦能力。通过消融实验验证模块有效性，对比不同注意力机制对检测精度（mAP@0.5）、参数量（Params）及计算量（GFLOPS）的影响，建立适用于农业场景的特征增强范式。

（2）轻量化检测模型 B-YOLOv8 的架构创新

面向农业设备嵌入式部署需求，针对光照不均或土壤背景干扰等外界因素，导致目标谷子在种穴内难以被精准有效识别的问题，构建轻量级谷子种穴检测模型 B-YOLOv8。在骨干网络设计中，采用 Faster Block 替代 C2f 模块的 Bottleneck 结构，通过深度可分离卷积

与参数共享策略降低计算复杂度。颈部网络引入双向特征金字塔 BiFPN 结构，建立跨层特征加权融合机制，解决多尺度特征信息衰减问题。检测头部分新增 160×160 微小目标检测层，结合动态特征缩放技术提升小目标敏感度。通过对比实验分析模型轻量化效果，验证改进模型在检测精度（提升 3.89%）、参数量（降低 4.86%）及推理速度（提高 4.59%）等方面的综合性能优势。

（3）智能化检测系统的工程化实现

基于改进算法构建种穴检测系统，开发包含图像采集、特征分析、结果反馈的功能模块。设计多粒度检测人机交互界面，集成目标计数、穴径测量、分布可视化等核心功能。通过田间试验验证系统在复杂光照、遮挡条件下的鲁棒性，建立检测结果与播种质量的映射关系模型，为播种参数优化提供数据支撑。满足穴播机实时作业需求，显著降低人工巡检强度。

本研究通过算法创新与系统集成，形成“特征增强-模型优化-系统实现”的逻辑层次，为解决农业场景小目标检测难题提供新的方法，为智慧农业装备研发奠定理论基础。

1.4.3 研究方案及技术路线

（1）图像采集和预处理。设备采用鸭嘴式谷子穴播机，富士 XS20 相机 1850 数码镜头和 realme gt3、华为 mate60rs、iphone 12、iphone 15pro max 等智能机器，时间为 2024 年 4 月 15 日至 7 月 19 日，时段为 08:00—11:30 和 13:00—17:30。为采集自然环境下不同尺度和光照强度下的图像，拍摄时设备与种穴内的距离为 15~20 cm，并在晴天、阴天和雨后 3 种不同天气采集图像，且包含背阳、向阳等角度，以还原实际场景下的检测。最终采集到种穴内谷子图像共 1 500 幅，如图 1 所示。数据按 8:1:1 的比例分为训练集、验证集和测试集，并保证三者之间无重复图像。使用软件 Labelimg 标注，使矩形中包含的背景区域尽可能少。数据集中目标的标注宽度集中在 0.075 以内，标注高度集中在 0.06 以内，符合小目标的定义^[67]。

（2）基于注意力机制的 YOLOv8 的目标检测算法研究。YOLOv8 作为一种高效的目标检测模型，已被广泛应用于多种视觉任务。然而，为了进一步提升模型的检测性能，尤其是在复杂场景下的小目标检测能力，通过在 YOLOv8 模型中引入 EMA 注意力机制，通过对比实验，评估引入不同注意力机制后的模型性能，包括检测精度（mAP@0.5）、参数量（Params）、计算量（GFLOPs），析其在检测精度、计算效率等方面的表现。验证其对模型性能的有效性。

(3) 基于改进 YOLOv8 谷子目标检测模型。以 YOLOv8 为基础网络框架，主要从主干网络，颈部网络，小目标头这几方面进行研究，以预处理后的数据集为研究对象进行训练。首先，在主干网络中添加 EMA 注意力模块，通过增加对于谷子目标的关注来增强模型识别能力；其次用 Faster Block 模块替换 C2f 中的 Bottleneck，在保持较高检测速度的同时，提高整体检测性能；第三，在颈部网络中添加跨尺度连接方式和加权特征融合方法，将深层语义和浅层定位信息进行多尺度特征融合，用以避免因种子尺寸较小、导致种子特征信息丢失，造成漏检；最后，通过增加小目标检测头，获取更多小目标特征信息以提高不同尺度下谷子种子检测的准确率。通过比较改进后模型 B-YOLOv8 与各模型准确率 (Precision, P)、召回率 (Recall, R) 以及平均精度均值 (average mean Precision, mAP@0.5) 为基础评等评价指标，以验证改进后模型效果优异性。研究技术路线如图 1-1 所示。




图 1-1 技术路线图

Fig. 1-1 Technical roadmap

2 方法与数据

在计算机视觉研究范畴中，物体检测技术发挥着关键作用，鉴于物体的外观、形状以及姿态呈现出丰富的多样性，加之光照条件变化、遮挡等干扰因素的影响，想要准确地识别与定位目标对象变得极为复杂棘手。故而，一个出色的目标检测算法务必具备强大的学习能力与高度的适应性，以此应对各类复杂状况，保障在不同场景下都能达成精确的目标检测。该领域持续深入的研究与蓬勃发展，有力地推动了技术的革新，为自动化视觉识别和智能处理奠定了坚实的基础。

2.1 基于 YOLOv8 的目标检测算法

YOLO 系列通过 Backbone、Neck、Head 的模块化架构持续优化，在嵌入式部署中兼具实时性与轻量化优势。使得后续 YOLO 系列在保持实时性的同时，不断提升了模型性能和泛化能力，本研究选取 YOLOv8 进行优化，以提升谷子种穴小目标检测性能。

YOLOv8 由 ultralytics 公司于 2023 年 1 月推出的，称目标检测领域的 SOTA 模型。作为对过往 YOLO 系列进行深度改良与创新的结晶，YOLOv8 汲取了领域内最新理念，整合了前沿深度学习技术成果，对原有架构和算法进行革新，使其检测精度、速度等关键指标得以提升，进一步巩固了在目标检测领域的领先地位。最终在目标检测任务里达成更为卓越的成效。作为一阶段检测算法的代表，YOLO 通过端到端的回归建模方式简化了传统两阶段目标检测算法的流程，实现了目标定位和类别判定的同步处理。该算法的核心是将输入图像划分为 $S \times S$ 的网格单元，每个单元直接预测目标的边界框坐标和类别概率分布。这种“只看一次”(You Only Look Once)的设计避免了传统方法中复杂的候选框生成步骤，显著提升了检测效率。YOLOv8 结构图如图 2-1 所示。




图 2-1 YOLOv8 的结构图

Fig. 2-1 Structure diagram of YOLOv8

在 Input 层，从 YOLOv4 版本开始，YOLO 系列算法开始集成了如 Mosaic、Self-Adversarial Training 等多种创新的图像增强技术，以进一步提升模型的性能^[68-70]。在 YOLOv8 里，借鉴了 YOLOX 的一项重要实操经验，即在训练的最后 10 个 epoch 时段，停用 Mosaic 增强。此调整策略促使模型在训练的后半程，能更聚焦于对细粒度特征的学习，进而切实提升检测的精准度。具体而言，这种后期停用 Mosaic 增强的方式，避免了因过度增强对模型学习细粒度信息造成的干扰，让模型能够更深入地挖掘图像细节特征，从而在目标检测时能够更准确地识别和定位目标，优化了模型在训练后期的性能表现。

在 Backbone 层 YOLOv8 主干网络和 Neck 部分采用了 C2f 结构^[71]，取代了 YOLOv5 中的 C3 结构^[72,73]。C3 模块采用三级卷积层 (Conv) 的级联架构，融入了 CSPNet 的特征分流机制，并结合了残差连接的设计思想。该模块的主特征通路采用 Bottleneck 单元构建，其深度可根据超参数 n 进行动态配置。相较而言，C2f 模块采用双卷积层结构，并创新性地整合了多路分支网络。该模块的关键创新在于通过级联各 Bottleneck 阶段的输出特征，形成更具多样性的特征表征空间。这种特征聚合机制不仅增强了梯度传播的异质性，更重要的是实现了跨层次特征的深度整合。值得注意的是，YOLOv8 框架针对各基准模型的特征通道维度进行了系统性的参数优化。摒弃了以往统一参数设置应用于所有模型的做法。C3 和 C2f 结构具体呈现形式如图 2-2 所示。




图 2-2 C3 结构和 C2f 结构图

Fig. 2-2 C3 structure and C2f structure diagrams

SPPF 模块是对传统空间金字塔池化(SPP)结构的改进版本。在 YOLO 目标检测框架中，SPP 结构主要用于提升网络对输入图像尺度变化的鲁棒性，该技术最早应用于 YOLOv3 版本以优化检测效果。其核心机制采用多尺度并行池化策略，通过设置不同尺度的池化核（如 1×1 、 3×3 、 5×5 等）对特征图进行同步处理，最终将各分支输出特征进行融合。这种架构设计具有双重优势：一方面统一了特征输出的维度，突破了传统卷积操作对输入尺寸的限制；另一方面实现了多尺度特征的融合，有效增强了模型对不同尺度目标的识别能力，进而显著改善了整体检测性能。而 SPPF 模块正是在 SPP 模块这些特性的基础上，进一步对结构进行优化，使其在性能上有望实现新的突破。

在 YOLO 目标检测框架中，SPPF 结构对传统多尺度卷积核配置进行了改进，采用三个相同的 5×5 卷积核替代了原先不同尺度的卷积核组合。这一改进的理论基础在于：通过级联两个 5×5 卷积层可以获得与 9×9 卷积层等效的感受野，而三个 5×5 卷积层的叠加则能达到 13×13 卷积层的视觉感知范围。相较于直接采用大尺寸卷积核，这种小卷积核级联方案具有双重优势：首先显著减少了参数计算量，其次大幅提高了运算效率。对比实验数据显示，在输入条件相同的情况下，虽然 SPP 和 SPPF 模块的输出特征保持高度一致，但后者在前向推理速度上实现了二倍的提升。SPPF 模块通过对卷积核的创新性调整，在不影响输出结果的前提下，显著提升了模块运行效率，为目标检测任务提供了更高效的处理方案。

在 Neck 层，YOLOv8 中采用了 FPN 结合 PAN 的模块，该设计通过自上而下的语义特征传递与自下而上的细粒度特征补充，构建了多层次的特征交互体系。这种双向特征融合策略使模型能够在各个尺度层面捕获更加全面的特征表达。在检测对象尺寸变化较大的复杂场景下，这种架构设计展现出显著优势，有效提高了模型对不同尺度目标的识别精度。

通过 FPN+PAN 模块构建起的双向信息流机制，YOLOv8 有效整合了不同方向的信息，弥补了单一信息流的局限性，使得网络在面对复杂多变的目标时，能够依据全面的特征信息做出更准确的判断，增强了模型在复杂场景下的检测性能。

在 Head 层，解耦头 YOLOv8 借鉴了 YOLOX 中“解耦头”的设计^[74,75]，即模型的头部被分成两个独立的部分，一个用于分类任务，另一个用于回归任务。YOLOv8 采用解耦策略，将分类头与回归头分开。其中，分类头聚焦于识别物体所属类别，回归头则承担物体空间定位职责，包括确定位置与尺寸。该方法的显著优势在于，能够让每个头针对各自负责的任务进行专项优化，进而提升在专业领域的性能表现。解耦头的设计赋予了模型更高的灵活性，可对分类和定位分别展开独立调整，使模型能更好地适配多样化的应用场景。如图 2-3 所示。




图 2-3 检测头

Fig. 2-3 Detection head

anchor-free 的 YOLOv8 创新性地引入了 anchor-free 理念。所谓“anchor-free”，即摒弃以往目标检测中借助预定义锚框的方式来开展目标检测工作。YOLOv8 采用基于 YOLOv2 回归策略的无锚框检测机制。其技术实现主要包含以下步骤：首先对输入图像进行多尺度网格化处理，随后在每个网格单元中直接回归目标的几何位置、所属类别及检测置信度等核心参数。这种创新性的检测框架将目标识别问题转化为端到端的回归任务，完全摒弃了传统锚框的使用，不仅大幅减少了模型的计算复杂度，同时显著降低了内存资源的占用。这种革新性的策略，简化了检测流程，提升了检测效率，为目标检测领域带来新的发展思路。

2.2 基于卷积的目标检测算法

Faster R-CNN 作为 Fast R-CNN 的优化版本，其创新点主要体现在新增的区域提议网

络（Region Proposal Network, RPN）模块。该模块通过端到端训练方式自动生成候选检测区域，取代了传统选择性搜索（Selective Search）等耗时方法。特别值得注意的是，RPN能够与 Fast R-CNN 检测网络共用底层卷积特征，这种特征共享机制显著提升了整体检测效率。如图 2-4 所示，该算法架构将 RPN 与 Fast R-CNN 有机结合，形成统一的深度学习框架。




图 2-4 Faster R-CNN 网络结构图

Fig. 2-4 Faster R-CNN network structure diagram

Faster R-CNN 作为两阶段检测算法的代表，通过区域提议网络（RPN）与检测网络协同工作实现高精度目标检测。其核心流程分为两个阶段，首先生成候选区域（Region Proposals），随后对候选区域进行分类和位置修正。

区域提议网络（RPN）通过滑动窗口在特征图上生成锚框（Anchor），并计算每个锚框包含目标的置信度。锚框的生成公式为：

$$A = \{(x, y, w, h) \mid w = s_k \cdot \sqrt{r}, h = s_k / \sqrt{r}\} \quad (2.1)$$

其中 s_k 为基准尺度， r 为长宽比（通常取 1:1, 1:2, 2:1）。RPN 的损失函数由分类损失（二分类交叉熵）和回归损失（Smooth L1）组成：

$$L_{RPN} = \frac{1}{N_{cls}} \sum_i L_{cls}(p_i, p_i^*) + \lambda \frac{1}{N_{reg}} \sum_i p_i^* L_{reg}(t_i, t_i^*) \quad (2.2)$$

其中 p_i 为预测置信度， t_i 为边界框偏移量， λ 为平衡系数。

检测网络对 RPN 生成的候选区域进行 RoI 池化，提取固定尺寸特征后通过全连接层完成分类和回归。Faster R-CNN 在 PASCAL VOC 数据集上达到 76.4% 的 mAP，但其两阶段设计导致检测速度较低（7 FPS），且参数量高达 137M，难以满足农业机械的实时性需求。

Faster R-CNN 凭借其独特的两阶段检测机制，在检测准确率和处理效率之间实现了良

好平衡。该算法在 PASCAL VOC、COCO 等权威基准测试中均展现出卓越的检测性能，确立了其在目标检测领域的重要地位。更重要的是，Faster R-CNN 所提出的区域提议网络（RPN）与检测网络协同优化的设计范式，为后续研究提供了重要的技术参考，极大地促进了目标检测领域的创新发展。这种框架设计不仅解决了传统方法在精度和速度上的矛盾，还为深度学习时代的目标检测算法奠定了理论基础和实践方向。

2.3 基于 SSD 的目标检测算法

SSD（Single Shot MultiBox Detector）目标检测框架最早由 W.Liu 等学者在 2016 年公开发表。作为深度学习背景下典型的单阶段检测模型，该算法创新性地采用多尺度特征融合策略，通过统一的网络架构同步实现目标定位与类别识别双重任务。如图 2-5 所示，其技术突破主要体现在利用分层特征金字塔结构进行检测，这种设计显著提升了模型对不同尺寸目标的识别能力。从网络组成来看，该架构包含四个关键模块：基础特征提取网络、多尺度特征层、检测子网络以及定位分类联合优化模块。其中，前两个模块构成系统的特征表示基础，后两个模块则分别负责生成初始检测结果和进行结果精修。




图 2-5 SSD 网络结构图

Fig. 2-5 SSD network structure diagram

SSD（Single Shot MultiBox Detector）通过多尺度特征图实现高效检测。其网络结构在 VGG16 基础上构建 6 级特征金字塔（38×38 至 1×1），每层特征图关联不同尺度的默认框（Default Box）。默认框的尺度计算采用线性递增策略：

$$s_k = s_{min} + \frac{s_{max} - s_{min}}{m - 1}(k - 1) \quad (2.3)$$

其中 $s_{min} = 0.2$ ， $s_{max} = 0.9$ ， m 为特征图层数。

损失函数结合分类损失（交叉熵）与定位损失（Smooth L1）：

$$L = \frac{1}{N} \left(\sum_i L_{cls}(c_i, c_i^*) + \alpha \sum_i L_{loc}(l_i, l_i^*) \right) \quad (2.4)$$

$\alpha=1$ 用于平衡两项损失。SSD 在 VOC2007 数据集上达到 74.3% mAP, 检测速度 58 FPS, 但其浅层特征图 (38×38) 分辨率不足, 导致谷子种子 (像素占比 $< 0.1\%$) 漏检率达 31.2%。相较于两阶段检测模型 (如 Faster R-CNN), SSD 无需区域提议 (Region Proposal) 步骤, 在保持较高检测精度的同时大幅提升推理速度, 尤其适用于实时检测场景 (如视频监控、自动驾驶)。然而, SSD 对小目标检测的敏感性依赖于特征图的分层设计, 由于低层特征的非线性拟合程度较差, 无法有效的检测出小目标物体, 从而导致了小目标物体的精度较差。

2.4 数据集的构建

2.4.1 数据采集

谷子数据集的采集设备为鸭嘴式谷子穴播机和富士 XS20 相机 1850 数码镜头, realme gt3、华为 mate60rs、iphone 12、iphone 15pro max 等智能设备, 分别在时段为 08:00—11:30 和 13:00—17:30。为采集自然环境下不同尺度和光照强度下的图像, 拍摄时设备与种穴内的距离为 15~20 cm, 最终采集到种穴内谷子图像共 1 500 幅, 按 8:1:1 划分出训练集、测试集和验证集, 形成对应的种穴谷子图像数据集; 如图 2-6 所示。




图 2-6 数据采集流程
Fig. 2-6 Data collection process

2.4.2 多样化数据示例

本次试验使用的图像数据为实地拍摄所得, 拍摄地点为黑龙江八一农垦大学, 并在不同光照, 环境下采集种穴内谷子图像, 以还原实际场景下的检测。图 2-7 为部分采集到的图像数据。




图 2-7 不同场景下谷子分布图像

Fig. 2-7 Images of foxtail distribution in different scenes

2.4.3 数据标注

本研究采用 LabelImg 1.8.6 版本对采集的种穴内谷子图像进行标准化标注，Labeling 的标注如图 2-8 所示。标注流程严格遵循计算机视觉领域的目标检测任务规范：首先构建包含“谷子”类别的标签体系，其中“谷子”类别的边界框需精确框选单个谷粒。针对小目标检测的特殊需求，标注策略采用高精度定位模式，要求标注人员在 4 倍图像放大状态下进行像素级框选，确保目标框中心坐标误差小于 3 个像素。

在标注质量控制方面，完成初步标注后，再进行交叉校验，采用 Kappa 系数评估标注一致性（Kappa=0.92）。对于存在争议的标注样本，通过多视角图像比对达成一致。标注结果显示，目标面积占比小于图像总面积的 0.1%，符合国际通行的小目标定义标准。

为增强模型对复杂场景的适应能力，标注数据经过系统化的增强处理：采用随机旋转、高斯噪声、亮度调整等增强手段，在保持标注框几何属性的前提下扩展数据集规模。标注数据最终按 8:1:1 比例划分为训练集、验证集和测试集，三类数据集的标注目标数量分布、光照条件及背景复杂度均保持统计一致性。

本数据集包含晴天、阴天、雨后三种典型农田光照条件的均衡样本分布。该标注体系为第四章的模型优化提供了可靠的数据基础。




图 2-8 Labelimg 标注
Fig. 2-8 Labelimg annotation

2.5 评价指标

2.5.1 准确度 (Precision)

用于表示检测结果中真正例的比例，即检测为正例的样本中有多少是真正的正例。精确率可以使用以下公式计算，如式 (2.5) 所示，其中，TP 表示真正例，FP 表示假正例。

$$P = \frac{TP}{TP + FP} \quad (2.5)$$

2.5.2 召回率 (Recall)

用于衡量检测算法能够正确找到真实目标的能力。召回率可以使用以下公式计算，如式 (2.6) 所示，其中，FN 表示假反例。

$$R = \frac{TP}{TP + FN} \quad (2.6)$$

2.5.3 平均精度 AP (Average Precision)

它针对单个类别，衡量的是模型在各个召回率水平下的平均精确度。AP 通过计算精确度—召回率曲线 (Precision - Recall curve) 所覆盖的面积得出。正因如此，AP 能够全面反映模型针对正类预测的总体质量。通常情况下，AP 值越高，意味着模型的预测精准度越高。关于精度值的具体计算公式如 (2.7) 所示。

$$AP = \int_0^1 P(R) dR \quad (2.7)$$

2.5.4 平均精度均值 (mAP@0.5)

在目标检测中，使用 IoU 阈值等于 0.5 时的对应 mAP。mAP@0.5:0.95 是指在目标检测中，从 0.5 到 0.95，步长 0.05 上的各个 IoU 阈值的平均 mAP。mAP@0.5 和 mAP@0.5:0.95 是目标检测任务中的核心检测指标，用于反应目标检测算法效果的优劣。如式 (2.8) 所示，其中 C 表示需要识别的类别量，AP_i 表示对应第 i 个类别的平均精确度。

$$mAP = \frac{1}{C} \sum_{i=1}^C AP_i \quad (2.8)$$

2.5.5 计算量 (GFLOPS)

作为衡量模型计算复杂度的关键指标，一般而言，模型的计算复杂度与所需计算资源呈正相关。即计算复杂度越高，意味着模型在运行过程中每秒钟要处理海量的浮点运算任务，这就使得模型执行时对计算资源的需求愈发庞大。

2.5.6 参数量 (Params)

用于指代模型里可学习参数的总量。一般来说，模型的复杂程度与其所包含的可学习参数数量紧密相关。当 Params 数值较大，即模型中可学习参数总数较多时，往往反映出模型架构更为复杂。这是因为更多的参数意味着模型具备更强的表达能力，能够学习到更丰富、更细致的特征和模式，但同时也增加了模型训练的难度以及过拟合的风险。

2.6 本章小结

本章系统梳理了目标检测算法的研究进展。首先，阐述 YOLOv8 的核心思想及其对深

度学习模型性能的优化作用；其次，对比分析深度学习方法（Faste-RCNN 和 SSD）的特点及局限性；最后，介绍目标检测的关键评价指标，为后续模型改进与实验验证提供理论依据。这些研究为基于 YOLOv8 的注意力机制优化奠定了重要基础。

3 基于注意力机制的 YOLOv8 小目标检测模型改进研究

当前主流目标检测算法为追求高精度，普遍采用庞大复杂的网络结构，难以在移动终端和嵌入式设备等资源受限场景中部署。为此，研究者提出轻量化模型，通过简化结构和减少参数量，以更低计算成本实现高效推理。本章基于 YOLOv8 模型，针对其特征提取能力不足的问题，引入 EMA 多尺度注意力机制进行改进。实验表明，改进后的模型能同时适应不同尺寸目标的检测需求，在复杂场景中实现更高精度和鲁棒性，同时保持轻量化特性，适用于边缘设备部署。

3.1 注意力机制

注意力机制可以使模型选择性地关注感兴趣的区域或特征，注意力机制会忽略大量不相关的干扰信息，而集中注意力于某一部分重要数据^[76-78]。对各卷积通道的资源予以合理分配，助力模型有效抑制无关信息。在目标检测场景里，此机制能够协助模型从海量数据中精准筛选出关键信息，进而提升识别的精准程度。通过有针对性地为卷积通道调配资源，模型能够更高效地过滤掉干扰信息，聚焦于关键数据，使得目标检测过程中的信息处理更为精准、高效，显著增强了模型识别目标的能力。常见注意力机制有三种类型，分别是空间注意力机制、通道注意力机制和混合注意力机制^[79]。

由于谷子极易受到环境因素的干扰，运用注意力机制能够让模型有针对性地聚焦于谷子特征，有助于提升谷子目标检测的精准度。为提升 YOLOv8 在种穴内谷子检测方面的性能表现，降低种子形状不规则以及环境干扰带来的不利影响，可考虑引入注意力机制来实现性能优化。通过这种方式，让模型在面对复杂环境和不规则种子形状时，能够更有效地识别谷子，提升检测的准确性和稳定性。

3.1.1 CBAM 注意力模块

CBAM（Convolutional Block Attention Module）注意力机制于 2018 年由 Woo 等人提出，用于增强卷积神经网络性能，在集中于重要特征信息的同时，可以降低模型的运算量，加快模型收敛速度^[80]。图 3-1 呈现了 CBAM（Convolutional Block Attention Module）注意力机制的整体结构设计。该机制由两个互补的子模块构成：通道注意力子模块负责在通道维度上进行特征选择，而空间注意力子模块则致力于捕捉特征图的空间相关性。这两个组件通过级联方式协同作用，实现了对特征信息的全方位关注。具体而言，该机制能够

智能地分配计算资源，优先处理具有高信息量的通道和关键空间区域。其核心在于动态调节各特征通道和空间位置的权重系数，从而弱化非关键特征的干扰。这种设计显著提升了网络的特征表征能力。值得强调的是，该方法在保持模型轻量化的同时，实现了模型性能的显著增强。




图 3-1 CBAM 注意力机制模块
Fig. 3-1 CBAM attention module

通道注意力机制的核心功能是通过评估特征通道的重要性来优化特征表达。如图 3-2 所示，在 CBAM 框架中，该模块首先对输入特征图 F 执行两种池化操作，全局最大池化提取各通道的峰值特征，全局平均池化获取通道的统计特征。这两个特征向量随后被送入共享权重的 MLP 网络，学习生成通道权重。经过 Sigmoid 函数激活后，得到归一化的通道注意力权重 M_c 。最终，通过 Hadamard 乘积将权重 M_c 与原始特征图 F 相结合，产生增强后的特征表示 F' 。这一过程使网络能够自适应地突出关键通道的特征响应。该机制的数学表达详见公式（3.1）。

$$M_c(F) = \sigma \left(W_1 \left(W_0 \left(F_{avg}^c \right) \right) + W_1 \left(W_0 \left(F_{max}^c \right) \right) \right) \quad (3.1)$$

式中：其中， F_{avg}^c 和 F_{max}^c 分别指代经全局平均池化操作后得到的特征以及经最大池化操作获取的特征。




图 3-2 通道注意力单元
Fig. 3-2 Channel attention Unit

在构建空间注意力特征图的过程中，该机制深入剖析特征图各部分在空间上的联系，引导网络将资源倾斜至重要区域，从而优化输入数据的处理流程，提升对关键信息的捕捉效率。同样也是使用学到的权重对原始特征进行加权，但不同通道注意力机制的是，空间注意力机制主要聚焦的图像中有用的信息在哪^[81]。空间注意力机制的结构图如图 3-3 所示。




图 3-3 空间注意力机制架构图

Fig. 3-3 Spatial attention mechanism architecture diagram

空间注意力的运作流程如下：初始阶段，针对尺寸为 $H \times W \times C$ 的输入特征图 F ，分别开展通道维度的全局最大池化与全局平均池化操作，以此对通道规模进行压缩，最终获得两个尺寸均为 $H \times W \times 1$ 的特征图。随后，将经全局最大池化和全局平均池化处理后的结果，依据通道维度进行拼接（concat），此时得到的特征图尺寸变为 $H \times W \times 2$ 。紧接着，运用 7×7 的卷积核对拼接后的结果实施降维处理，使其转化为单通道的特征图，即尺寸变为 $H \times W \times 1$ 。在此基础上，借助 Sigmoid 激活函数，深入挖掘空间元素间的依存关系，进而生成空间维度的权重，标记为 M_S 。凭借这些空间权重，模型得以精准定位有用信息所处位置，从而促使模型更加关注这些关键信息。

综上所述，空间注意力的具体计算公式见（3.2）

$$M_S(F) = \sigma(f^{7 \times 7}[F_{avg}^S; F_{max}^S]) \quad (3.2)$$

总体而言，CBAM 将通道注意力与空间注意力这两种机制融合起来。通过这样的整合，能够助力卷积神经网络更深入地理解输入数据内的特征信息，并更为高效地加以运用。这使得卷积神经网络能够更为精准地抓取数据里的核心关键特征。在实际应用中，这种融合机制让模型在处理复杂数据时，从通道维度和空间维度同时发力，优化对特征的感知与分析过程，全面提升模型对关键信息的捕捉能力。

3.1.2 SA 注意力模块

为构建高效实用的注意力模型，SA（Shuffle Attention）创新性地整合了双重注意力机制。该机制首先将输入特征的通道维度划分为若干子组，随后对这些分组特征实施并行计算处理。针对每个子特征组，SA 采用特征重排单元（Shuffle Unit）来挖掘空间与通道维度间的关联特性。完成各子组处理后，通过通道混洗操作促进组间特征信息的充分交流。

SA 模块的设计融合了多项优化策略，采用分组卷积降低计算复杂度；基于组归一化（GN）实现空间注意力建模；参考 SENet 的通道注意力设计思路；引入通道混洗机制加强组间特征融合。这种多策略协同的设计方案，有效实现了模型计算效率与识别准确率的

优化平衡。通过这一系列设计，SA 在提升计算效率的同时，保障了对关键特征的有效捕捉，优化了模型性能。如图 3-4 所示。




图 3-4 SA 注意力机制架构图

Fig. 3-4 SA Attention mechanism architecture diagram

首先将输入的特征图 $X_k \in R^{C \times H \times W}$ 划分为多个组， $X = [X_1, \dots, X_G]$, $X_k \in R^{C \times H \times W}$

在训练进程开启时，模型逐步对各细分特征所蕴含的特定语义信息予以识别。随后，运用注意力机制，依据各细分特征的重要程度，为其赋予相应权重。在此期间，特征数据会沿着通道维度分解为两个分支。其中一个分支致力于探寻通道之间的关联互动，进而构建出基于通道的注意力特征图；而另一个分支则聚焦于挖掘空间维度的关系，成功生成基于空间的注意力特征图。通过这样的设计架构，模型得以将注意力高度集中于图像内关键区域的识别以及精准定位，极大地提升了对图像信息的处理与理解能力，使其在图像分析任务中能够更高效地提取关键信息，优化模型的整体表现，公式如（3.3）所示分别是：

$$X_{K1}, X_{K2} = [X_1, \dots, X_G], X_k \in R^{C \times H \times W} \quad (3.3)$$

在通道注意力模块的运作中，率先采用全局平均池化手段。此操作通过计算特征图中各通道的均值，将全局信息融入其中。在这一环节，每个通道所蕴含的二维空间信息得以压缩，达成从二维空间信息向全局信息的降维转换。具体计算公式呈现于式（3.4），这种降维处理，让模型能够更高效地捕捉通道维度的关键信息，为后续注意力权重的计算与分配奠定基础，优化了模型对通道特征的处理流程。

$$s = F_{gp}(X_{k1}) = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W X_{k1}(i, j) \quad (3.4)$$

接着使用 sigmoid 激活函数处理这些全局信息，会生成一个精简的特征表示。在这个

过程中, sigmoid 会将全局信息的每个元素压缩到 0 和 1 之间的值。这样的操作产生了一组权重, 这些权重描绘了每个通道相对于其他通道的重要性。如公式 (3.5) 所示:

$$X'_{k1} = \sigma(F_c(s)) \cdot X_{k1} = \sigma(W_1 s + b_1) \cdot X_{k1} \quad (3.5)$$

在空间注意力模块的处理流程中, 首先对输入特征图 X_{k2} 实施分组归一化 (Group Normalization, GN) 操作。该方法将特征通道划分为若干独立组别, 并在各组内部进行标准化处理, 以保留特征的空间分布特性。随后, 经过归一化的特征通过一个参数化的全连接层 $F_c(\cdot)$ 进行特征增强, 该变换层包含可学习的权重矩阵 W_2 和偏置项 b_2 , 用于建模空间位置间的相关性。通过 sigmoid 激活函数处理后, 生成空间注意力权重矩阵, 该矩阵量化了各空间位置的特征重要性。最终, 原始特征图 X_{k2} 与该权重矩阵进行逐元素相乘, 实现对关键空间区域的强化表达。这一过程的数学描述详见公式 (3.6) 和 (3.7)。

$$X'_{k2} = \sigma(W_2 \cdot GN(X_{k2}) + b_2) \cdot X_{k2} \quad (3.6)$$

$$X'_k = [X'_{k1}, X'_{k2}] \in R^{C/2 \times G \times H \times W} \quad (3.7)$$

其中, $W_2 \in R^{C/2 \times G \times H \times W}, b_2 \in R^{C/2 \times G \times H \times W}$

3.1.3 CA 通道注意力

在 CA 注意力机制提出之前, 通道注意力类型的注意力机制一般是采用池化特征向量的方式来保留通道特征, 而 CA 注意力机制将该过程分解为沿两个方向聚合特征的特征编码过程^[82], 其结构如图 4-3 所示。这设计的巧妙之处在于捕获距离方向的特征的同时, 又可以保留住待检测特征的位置信息。得到两个方向的特征图后形成一对方向感知和位置敏感的特征图, 这样设计的好处在于在计算量并不复杂的情况下, 同样可以起到获取网络所提取的特征。为提取图像在宽度和高度上的特征, 需要将输入特征矩阵分成纵横两个方向后的矩阵再进行全局平均池化。具体而言, 纵横方向的操作流程分别如公式 (3.8) 和公式 (3.9) 所示, 其中, W 为横向方向代表宽度, H 为纵向方向代表高度。

$$z_c^h(h) = \frac{1}{W} \sum_{0 \leq i \leq W} |x_c(h, i)| \quad (3.8)$$

$$z_c^w(w) = \frac{1}{H} \sum_{0 \leq j \leq H} |x_c(j, w)| \quad (3.9)$$

将两方向的特征向量拼接后,即可得到完整的视野特征,将该特征矩阵进行 1×1 的卷积操作,使得维度缩小为 C/r 倍,之后通过 BN 处理的特征图 F_1 作为传入参数进行非线性化,得到尺寸大小为 $1 \times (W+H \times C/r)$ 的特征图 f ,求解过程如公式 (3.10) 所示:

$$f = \delta \left(F_1 \left(\left[z^h, z^w \right] \right) \right) \quad (3.10)$$

将特征图 f 进行 1×1 的卷积以得到横纵两个方向上的特征图 F_h 和 F_w 并进行非线性化后,可得到特征图在高度方向的注意力权重 g_h 和在宽度方向的注意力权重 g_w 。如公式 (3.11) 所示。

$$\begin{cases} f^h = \delta \left(F_h \left(f^h \right) \right) \\ g_w = \delta \left(F_w \left(f^w \right) \right) \end{cases} \quad (3.11)$$

宽度和高度通道上带有注意力权重的特征图的流程如公式如 (3.12) 所示,CA 注意力机制算法的结构示意图如图 3-5 所示。

$$y_c(i, j) = x_c(i, j) \times g_c^h(i) \times g_c^w(j) \quad (3.12)$$




图 3-5 CA 注意力机制架构图

Fig. 3-5 CA Attention mechanism architecture diagram

基于上述内容,CA 注意力机制的优势在于较低计算复杂性的情况下,对通道的位置信息编码使得改进后的检测模型能够捕获到更多的位置信息量。CA 注意力机制的优势主要有以下几点:既能获取横纵方向的位置特征又能获取通道特征,这一设计能够助力检测模型更为精准地对目标进行定位与识别。而且,该注意力机制模块在设计上极为灵活且轻量化,能够便捷地融入网络的核心架构之中。

3.1.4 SE 注意力模块

SE (Squeeze-and-Excitation) 注意力机制是一种用于增强深度神经网络表示能力的注意力机制, 由 Jie Hu 等人在 2018 年提出^[83]。该机制借助动态学习输入特征图各通道间的权重, 促使模型将关注点更多地置于有效特征之上, 减少无关特征带来的干扰, 以此提升模型整体性能。其具体的结构图示于图 3-6, 主要涵盖压缩 (Squeeze) 和激励 (Excitation) 操作关键环节。




图 3-6 SE 注意力机制架构图

Fig. 3-6 SE Attention mechanism architecture diagram

首先, 在压缩阶段, 对输入的特征图 (U) 进行全局平均池化, 将特征图 ($H \times W \times C$) 压缩成一个单一的数值 ($1 \times 1 \times C$)。通过这个过程得到通道间的全局特征, 即通过对每个通道全局信息的提取, 获得特征图的全局描述。计算公式如式 (3.13) 所示:

$$z_c = F(u_c) = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W u_c(i, j), z \in R^c \quad (3.13)$$

式中: H —高度; W —宽度; z_c —第 c 个通道的压缩权重; $u_c(i, j)$ —输入特征图 U 的某个像素点。

随后进入激励阶段, 在此阶段引入了两个全连接层。其中一个全连接层负责对激活通道的权重展开学习, 另一个则专注于学习对通道信息进行重新缩放。通过这一系列操作, 使得模型在处理通道信息时能够更好地挖掘数据中的潜在模式, 增强对通道特征的刻画能力, 为后续更为精准地计算与分配注意力权重提供有力支撑, 进一步优化模型在通道注意力模块上的性能表现。第二个全连接层将此信息映射回原始通道数量的维度, 并再次通过激活函数 (如 Sigmoid) 将其缩放到 $[0, 1]$ 范围内, 得到权重系数。计算公式如式 (3.14) 所示:

$$s = F_{ex}(z, W) = \sigma(g(z, W)) = \sigma(W_2 \text{ReLU}(W_1 z)) \quad (3.14)$$

式中: $W_1, W_2 \in R^{\frac{c}{r} \times c}$; $W_1, W_2 \in R^{\frac{c}{r} \times c}$; z 为压缩操作的结果; W 为每个通道生成的权重; σ 为 Sigmoid 激活函数。

在完成压缩与激励相关操作后，把激励阶段所产生的权重参数与输入特征图（U）实施乘法运算。借助这一运算过程，实现对各通道特征的重新加权处理，进而再次获取蕴含通道关联性的特征图 $\tilde{X}$ 。通过这种方式，着重凸显重要特征，同时削弱那些相对不重要的特征。最终促使网络能够更为聚焦于对任务执行有积极作用的信息，有效提升网络在处理任务时对关键信息的捕捉与利用效率，优化整体任务处理效果。计算公式如式（3.15）所示：

$$\tilde{X} = F_{scale}(u_c, s_c) = u_c \cdot s_c \quad (3.15)$$

式中： u_c 为未压缩前的特征图； s_c 为各通道的权重参数；

SE 能够引导模型在训练期间更为关注关键特征。凭借这一特性，模型的表征能力与泛化能力得以显著提升。值得一提的是，SE 注意力机制具备轻量化的突出优势。具体而言，在增加极少量计算量的情况下，该机制便能助力模型达成更优的检测成效。

3.1.5 EMA 注意力机制

EMA 多尺度特征融合机制为模型赋予了同时捕捉大尺度和小尺度特征信息的能力。这一特性显著增强了模型对不同尺寸目标的检测性能。在谷子目标检测场景中，该机制使得模型能够更有效地处理不同尺度以及相互遮挡的目标，从而大幅提升检测精度。如图 3-7 所示，EMA 机制的运算流程中，Matmul 表示矩阵内积操作；X Avg Pool 表示一维水平全局池化；Y Avg Pool 表示一维垂直全局池化；Re-weight 则指权值重新分配。公式（3.16）描述了在高度 H 方向上对通道 C 进行一维水平全局池化的过程，其中 X_C 表示第 C 个通道的输入特征，C 为通道数量，W 为宽度，H 为高度。公式（3.17）则展示了在宽度 W 方向上对通道 C 进行一维垂直全局池化的过程。

分组归一化层（Groups）的操作流程如下：首先，将输入特征分割成若干组，然后沿着高度和宽度方向进行池化操作，从而得到两个一维向量。接下来，将这两个向量进行拼接并转换为二维矩阵，随后通过 Sigmoid 函数进行激活处理，再与原始特征图进行逐元素相乘，最终生成加权特征图。这一过程通过局部跨通道学习特征，实现了多尺度特征的融合，显著提升了不同通道之间的交互能力。此外，通过使用 1×1 和 3×3 的卷积核分别提取特征，再将不同尺度的特征信息进行拼接融合，实现了信息的互补，进一步优化了特征提取的效果。通过这一系列复杂且有序的操作，EMA 机制显著优化了模型对谷子目标检测的性能。

$$Z_c^H(H) = \frac{1}{W} \sum_{0 \leq j \leq W} X_c(H, j) \quad (3.16)$$

$$Z_c^W(W) = \frac{1}{H} \sum_{0 \leq j \leq H} X_c(j, W) \quad (3.17)$$




图 3-7 EMA 的整体架构图

Fig. 3-7 The overall architecture diagram of EMA

EMA 采用并行子结构，这一设计能助力网络减少顺序处理环节，避免网络深度过度增加。以输入特征图 $C \times H \times W$ 为例，这里的 C 、 H 、 W 分别对应通道数、高度与宽度。EMA 会依据跨通道维度，将输入特征图 X 划分成 G 个子特征，以此学习多样的语义信息。为探寻通道间的依赖关系，同时降低计算成本，EMA 在 1×1 分支分别从两个空间方向对通道进行编码，具体借助两个一维全局平均池化操作。在 3×3 分支，则通过堆叠一个 3×3 卷积核，来捕获多尺度特征。在整个特征变换过程中，EMA 通过跨域信息聚合，能够更为精准地获取图像中待检测目标的特征，有效削弱图像内干扰因素的影响，尤其在小目标检测方面，大幅提升了检测精度。

具体而言，针对 1×1 支路输出的全局空间编码，采用二维全局平均池化操作。如公式 (3.18) 所示，该公式所表达的正是二维全局池化过程。通过这样一系列的操作，EMA 显著优化了特征处理流程，增强了模型在目标检测任务中的性能表现。

$$Z_c = \frac{1}{H \times W} \sum_j^H \sum_i^W X_c(i, j) \quad (3.18)$$

相较于传统二维全局平均池化（公式 3.18），分解式空间编码具有双重优势：保留位置敏感性，独立编码高度/宽度方向信息，避免二维池化的位置信息丢失。增强方向辨别力：对谷子种子的轴向排列特征具有更强的表征能力。

在通道交互阶段构建双分支结构实现跨尺度特征融合，在局部交互分支中采用 1×1 卷积建立紧致通道关联：

$$F_{local} = \sigma(W_1 * [Z_h; Z_w]) \quad (3.19)$$

在全局交互分支中通过 3×3 空洞卷积（dilation=2）捕获多尺度上下文

$$F_{global} = \sigma(W_3 * (W_2 * [Z_h; Z_w])) \quad (3.20)$$

公式中 $W_1 \in \mathbb{R}^{C \times C/r}$ ， $W_2 \in \mathbb{R}^{C/r \times C}$ ， $W_3 \in \mathbb{R}^{C \times C}$ 为可学习参数矩阵 r 为压缩比（默认为 16）， σ 为 Sigmoid 激活函数。然后通过加权拼接实现多尺度特征聚合

$$M = \alpha \odot F_{local} + \beta \odot F_{global} \quad (3.21)$$

其中 α, β 为自适应权重参数，通过门控机制学习

$$\alpha = \frac{e^{W_\alpha[F_{local}]}}{e^{W_\alpha[F_{local}]} + e^{W_\beta[F_{global}]}} \quad \beta = 1 - \alpha \quad (3.22)$$

设输入特征张量 X 经 EMA 处理后的输出为 $\hat{X}$ 则有： $\hat{X} = X \otimes M$ 其中 $\otimes$ 表示逐通道相乘。根据矩阵微分法则，梯度传播路径满足

$$\frac{\partial \mathcal{L}}{\partial X} = \frac{\partial \mathcal{L}}{\partial \hat{X}} \cdot \left(M + X \odot \frac{\partial M}{\partial X} \right) \quad (3.23)$$

由于 M 通过 sigmoid 函数约束在 (0,1) 区间，该机制可视为自适应的特征选择器，在反向传播中梯度幅度与特征重要性呈正相关，符合注意力机制的理论预期。

与 SE、CBAM 等经典注意力机制相比，EMA 的多尺度建模，通过空洞卷积分支显式建立空间金字塔结构，在同等参数量下感受野扩大至 5×5 （传统方法为 3×3 ）；方向敏感性，双向池化编码使小目标定位误差降低；在动态权重上，门控融合机制使模型在复杂背景下提升对谷子特征的关注度，该理论推导通过严格的数学建模阐明了 EMA 机制提升小目标检测性能的内在机理，与第四章消融实验中 3.89% 的 mAP 提升形成严密的理论-实

验印证体系。

3.2 不同注意力机制的对比分析

从表 3-1 的实验数据结果可以看出，在相同的实验条件下，将 Convolutional Block Attention Module (CBAM)、Shuffle Attention(SA)、EMA、CA 和 SE 注意力机制模块分别嵌入到 YOLOv8 的特征提取网络中，对比实验结果如表所示。

表 3-1 注意力机制对比
Table 3-1 Comparison of attention mechanisms

Attention	Params	GFLOPs	mAP@0.5
YOLOv8	11.1M	28.4	92.5
YOLOv8+CBAM	11.3M	28.6	93.2
YOLOv8+SA	11.1M	28.4	92.9
YOLOv8+EMA	11.1M	28.8	93.5
YOLOv8+CA	11.1M	28.8	92.7
YOLOv8+SE	11.1M	28.4	92.6

表 3-1 可以看出，与原始 YOLOv8 模型相比，嵌入 CBAM 的模型的 mAP@0.5 值上升了 0.7%，参数量增加 0.2M。嵌入 SA 的模型在参数量和计算量不变的情况下 mAP@0.5 比原始网络提升了 0.4%。嵌入 CA 和 SE 模型的 mAP@0.5 分别上升了 0.2%，0.1%。

相较于其他注意力机制，EMA 模块在保持参数量不变的情况下表现较好，mAP@0.5 从基准的 92.5 提升至 93.5，计算量仅增加 0.4 GFLOPs。该模块通过多尺度并行子网络结构，有效融合通道和空间信息，能够有效捕获跨维度交互作用，增强特征表示的能力，在提升小目标检测精度的同时控制了计算成本。相比其他注意力机制 EMA 显著改善了播种均匀性和检测准确性，适用于复杂背景下的多尺度特征提取。

3.3 基于 EMA 注意力机制改进的 YOLOv8 小目标检测模型的构建

在目标检测任务中，需在满足实时性约束条件下实现检测精度最大化。现有研究表明，注意力机制通过特征重标定策略显著提升模型表征能力，但其架构设计仍存在优化空间。典型地，SE (Squeeze-and-Excitation) 模块虽通过全局平均池化建立通道依赖关系，却因缺乏对跨通道交互的显式建模，且采用全局空间压缩策略导致位置敏感性缺失；改进型 CBAM (Convolutional Block Attention Module) 虽通过标准卷积操作实现通道降维，并引入空间注意力子模块，但其通道注意力机制受限于一维卷积的局部感受野，仅能捕获局部通道依赖关系。

鉴于此, 本文提出采用高效多尺度注意力机制 EMA (Efficient Multi-scale Attention)。该模块通过分层多分支结构实现跨尺度特征交互, 采用并行空洞卷积构建多级感受野, 从而增强模型对尺度变化目标的鲁棒性表征能力。该方法在保持计算复杂度线性增长的同时, 通过参数共享机制优化特征融合过程, 最终在计算效率与检测精度之间实现最优平衡。

同时为进一步提升模型对谷子对象的特征提取能力, 本文基于 EMA 构建改进的 YOLOv8 小目标检测模型, 在原模型主干网络多个 Conv、C2f 模块和 SPPF 的基础上将 EMA 注意力模块嵌入到 YOLOv8 算法的主干特征提取网络当中。该改进方案通过并行多分支结构构建跨尺度特征交互通道, 利用空洞卷积的扩张率差异形成多级感受野。在特征提取阶段, EMA 模块通过通道注意力子网络动态校准特征响应, 采用空间注意力机制实现关键区域聚焦。具体而言, 网络通过通道维度权重重标定抑制背景噪声干扰, 结合空间维度显著性图谱增强谷穗形态特征。

在 YOLOv8 算法的运行流程里, 主干特征提取网络承担着从输入图像中抽取出关键基础特征的重要职责。SPPF 模块通过串联三个 5×5 最大池化层构建空间金字塔结构, 其输出特征包含从 5×5 到 13×13 的多尺度感受野信息。

$$F_{SPPF} = \text{Concat}(\text{MaxPool}_5^{(1)}, \text{MaxPool}_5^{(2)}, \text{MaxPool}_5^{(3)}) \quad (3.19)$$

这些特征虽能覆盖不同尺寸目标, 但在实际检测中, 小目标的细粒度特征 (如谷子种子的纹理边缘) 易被大感受野的池化操作平滑化。EMA 模块的跨维度交互机制能动态调整通道权重, 强化关键特征通道:

$$w_c = \sigma(FC(GAP(F_{SPPF}))) \quad (3.20)$$

$$F_{EMA} = F_{SPPF} \otimes w_c \quad (3.21)$$

借助 EMA 注意力模块, 网络在执行特征提取任务时, 可对不同尺度、不同重要程度的特征给予差异化关注。对于与目标紧密相关的关键特征, 予以强化突出; 对于干扰性或冗余性特征, 则适当弱化。增强网络对谷子对象的特征提取能力, 显著提升了谷子目标检测精度。基于注意力机制的目标改进模型如图 3-8 所示。




图 3-8 基于注意力机制的目标改进模型

Fig. 3-8 Goal improvement model based on attention mechanism

3.4 实验与分析

3.4.1 实验环境及参数设置

实验运行操作系统为 Windows10，采用 Python3.8、CUDA11.6、Pytorch1.13.0 深度学习框架开发环境，在 NVIDIA GEFORCE RTX 4070Ti 显卡上进行训练。输入图片调整尺寸至 640 像素×640 像素，Batchsize 设置为 15，初始学习率为 0.01，使用余弦退火策略调整学习率，共训练 120 个 epoch。

3.4.2 模型性能分析

为系统评估改进模型的收敛特性，本研究构建了多维度收敛行为对比实验框架。选取基准 YOLOv8 模型及其 EMA 增强型变体（YOLOv8+EMA）作为研究对象，通过监测准确率(Precision)、召回率(Recall)、平均精度均值 mAP@0.5 及 mAP@0.5:0.95 四项核心指标，建立模型训练动态的量化分析体系。

实验通过构建指标收敛曲线实现模型性能的系统评估：基准模型的收敛轨迹如图 3-9 所示，改进型模型收敛过程则分别如图 3-10 所示。通过解析两组收敛曲线的动态演化规律，可精确刻画不同模型在训练周期内各指标参数的梯度变化特征，定量分析模型收敛动力学差异，有效揭示了 EMA 模块对网络参数优化路径的调控作用。




图 3-9 YOLOv8 模型形成的收敛特性图

Fig. 3-9 The convergence characteristic graph generated by the YOLOv8 model




图 3-10 YOLOv8+EMA 模型形成的收敛特性图

Fig. 3-10 The convergence characteristic graph generated by the YOLOv8+EMA model

在对种穴内谷子数据集上两个模型的训练集与验证集 loss 曲线展开对比后，研究发现，EMA 模块的引入显著提升了 YOLOv8 模型的性能，呈现出更为出色的数值结果。进一步对比四项性能度量指标曲线可知，相较于 YOLOv8 模型，融入 EMA 的 YOLOv8+EMA 模型在精确率与召回率这两大核心评估指标上表现更为优异，综合以上观察，YOLOv8+EMA 模型不仅提高了模型的检测精度，还增强了模型的泛化能力，使其更适合在实际应用中使用。

3.4.3 不同训练轮数对比分析

将 YOLOv8-EAM 在不同训练轮次下的对比数据整理结果详见表 3-2。

表 3-2 训练轮数对比		
Table 3-2 Comparison of the number of training rounds		
训练轮数	mAP@0.5	FPS
100	89.8	101
120	93.5	106
140	93.8	108
160	93.9	109
180	94.0	110
200	94.1	111
220	94.2	112
240	94.3	113
260	94.4	114
280	94.5	115

在不同的训练轮次中，使用了 mAP 和 FPS 两个指标对模型进行训练和评估。mAP@0.5 指标反映了模型在目标检测任务中的准确性和泛化能力，而 FPS 指标则展示了模型的运行速度和效率。

本研究对改进后的 YOLOv8-EAM 模型进行了多轮次训练实验，系统记录了其性能指标随着训练时长变化。目标检测的平均精度与训练轮次呈显著正相关关系。这一结果表明，随着训练时间的增加，模型可以更好地学习和理解数据集中的特征信息，从而提高检测精度。

值得注意的是，模型 FPS 同样表现出随训练轮次增加而改善的趋势，使得计算图执行效率得到改善。然而，深入的实验分析发现，当训练轮次超过 160 epoch 后，mAP@0.5 指标的边际提升幅度降至 0.1% 以内，同时出现了验证集损失震荡现象。这暗示着模型可能开始进入过拟合风险区域。进而影响模型的泛化能力和运行速度。因此，在选择训练轮次时，需要综合考虑模型的性能表现和训练时间。

3.4.4 模型的对比分析

为进一步验证改进模型对谷子小目标图像检测的性能优势，选择 Faster-RCNN、SSD、YOLOv3、YOLOv4、和 YOLOv8 等模型进行了对比实验，在相同数据集上进行训练。性能对比如表 3-3 所示。根据表中的对比实验可知，改进后算法 mAP@0.5 值和检测速度均优于其他模型，并且参数量较小，YOLOv8+EMA 算法 mAP@0.5 值与 Faster R-CNN 算法相比提高了 36.8%，参数量减少了 73.88 个百分点。YOLOv8+EMA 算法 mAP@0.5 值

与 SSD 相比提高了 33.3%，参数量减少了 57.63 个百分点。YOLOv8+EMA 算法 mAP@0.5 值与 YOLOv3、YOLOv4、YOLOv5s 相比分别提高了 21.5%、19.1%、9.22%。相比于 YOLOv7-tiny 模型，虽然改进后的模型计算量有所提高，但参数量分别降低了 33.64%，其平均精度提高了 3.7 个百分点。相比较基础网络，YOLOv8+EMA 模型参数量不变的情况下精度提高了 1%。

实验结果说明改进算法具有较高的小目标检测的精度，具有良好的实时检测性能，可以帮助谷子穴播机实现复杂的种穴图像的实时检测能力，并满足轻量化和高精确率的需求。

表 3-3 模型对比
Table 3-3 Model comparison

方法	mAP @0.5 (%)	Params/M	FLOPs/G
YOLOv8	92.5	11.1	28.4
Faster-RCNN	68.3	42.5	127.51
SSD	70.1	26.2	80.2
YOLOv3	76.9	80.3	93.6
YOLOv4	78.5	71.3	43.8
YOLOv5s	85.6	9.1	22
YOLOv7-tiny	90.1	73.4	18.3
YOLOv8+EMA	93.5	11.1	28.8

3.5 本章小结

本章针对 YOLOv8 模型在复杂场景下小目标检测性能不足的问题，提出基于 EMA 注意力机制的改进方案，并设计实验验证 EMA 对于增强模型对小目标特征的捕捉能力的有效性。实验数据显示，改进后的 YOLOv8+EMA 模型在保持参数量基本不变的前提下，mAP@0.5 达到 93.5%，较原模型提升 1 个百分点，显著改善密集遮挡场景下的检测鲁棒性。同时满足在移动端部署的需求，对于种穴内目标检测取得了良好的检测效果。

4 基于 YOLOv8 的轻量级谷子种穴内小目标检测模型

第三章通过引入 EMA 注意力机制，验证了多尺度特征交互在增强小目标特征捕捉能力方面的有效性，但仅限于主干网络末端的局部优化。为实现谷子多粒穴播成穴性的实时精准检测，本章面向 YOLOv8 架构展开多维度结构优化，通过主干网络 EMA 嵌入、Faster Block 模块替换、Bi-FPN 颈部重构及微目标检测头扩展等结构优化，构建 B-YOLOv8 模型，实现种穴内谷子检测精度与速度的协同提升。

4.1 改进模型的创建

为了提高检测模型在种穴复杂环境下对小目标的检测性能，提出一种基于 YOLOv8 的小目标检测模型 B-YOLOv8，改进前后的对比如图 4-1 所示。

B-YOLOv8 模型针对 YOLOv8 网络架构实施了系统性优化，在主干网络层面，通过嵌入高效多尺度注意力机制（EMA）构建跨通道交互模块，增强网络对谷子目标的多尺度特征表征能力；采用 C2f-Faster 模块替代原始 C2f 结构，通过引入部分卷积（PConv）策略降低参数冗余，实现计算效率与模型精度的平衡优化。在特征融合层面，重构颈部网络为双向特征金字塔结构（Bi-FPN），建立深层语义特征与浅层定位信息的动态权重关联机制。检测头部分增设高分辨率小目标检测分支，形成 80×80 、 40×40 、 20×20 、 160×160 四级级联检测体系，以提升模型对微小目标的细粒度特征捕捉能力。




图 4-1 YOLOv8 改进前后网络结构对比图

Fig. 4-1 Comparison of the network structure before and after the improvement of YOLOv8

4.1.1 C2f 模块改进优化

针对 YOLOv8 基础模型中 C2f 模块存在的计算冗余问题, 本研究提出将 Faster Block 模块引入 C2f 结构, 构建新型 C2f-faster 特征提取模块。

YOLOv8 里的 C2f 模块, 即“CSP Bottleneck with 2 Convolutions”模块, 运用了 CSP 网络结构的设计理念。该模块主要用于构建 Backbone, 承担图像特征提取的关键任务。如图 4-2 所示原始 C2f 模块采用多分支 Bottleneck 堆叠结构, 通过 split 操作将输入特征划分为主辅双路径: 主路径进行常规卷积操作, 辅路径通过 n 个 Bottleneck 单元实现特征深化。这种设计虽能有效聚合多尺度特征, 但其 Bottleneck 结构的 3×3 深度卷积与逐点卷积组合仍存在参数冗余, 特别是在处理小目标特征时容易产生无效特征传递。




图 4-2 C2f 模块结构图

Fig. 4-2 The structural diagram of the C2f module

FasterNet 的创新设计为突破上述限制提供了理论框架 (图 4-2)。该网络通过部分卷积 (Partial Convolution, 简称 PConv) 技术实现计算效率的质变突破, 其核心策略在于仅对 $1/4$ 输入通道执行常规卷积运算, 其余通道保持激活状态, 在 80×80 特征图分辨率下将单层计算量锐减 76.3%。跨通道特征重组机制采用动态通道混洗与权重重标定技术, 一方面维持了输入输出特征的维度一致性, 另一方面在显著降低计算量的同时, 完整保留了原始特征空间的信息完整性。

需要特别说明的是, 虽然 75% 的特征通道未在初始阶段进行卷积处理, 但这些通道信息并未被丢弃。实际上, 这些保留的原始特征在后续的 1×1 卷积层中扮演着关键角色, 通过跨通道信息交互有效挖掘深层特征, 既优化了特征提取过程的质量, 又提高了计算效率。这种创新性的设计带来了双重优势, 在显著减少计算复杂度的同时, 保持了较高的浮点运算效能。尤为关键的是, 该技术通过整合全部通道的特征信息, 确保了模型识别精度的稳定性。具体实现机制可参见图 4-3 的详细示意图。




图 4-3 PConv 结构图

Fig. 4-3 The structural diagram of the principle of PConv

如图 4-4 所示，将部分卷积 PConv 应用于 YOLOv8 模型中，以取代原有的 Bottleneck 模块，从而有效降低模型的计算负担。




图 4-4 改进前后模块对比图

Fig. 4-4 Improved before and after module comparison chart

设输入特征图 $X \in \mathbb{R}^{H \times W \times C}$ ，卷积核参数 $W \in \mathbb{R}^{K \times K \times C_p \times C_o}$ ，其中 $C_p = \lfloor \lambda C \rfloor$ 为部分卷积通道数（ $\lambda \in (0, 1]$ 为通道保留率）， C_o 为输出通道数。部分卷积的运算过程可分解为：

将输入特征图按通道维度分割为激活区与保留区：

$$X = [X_{active}, X_{passive}] \quad \text{where} \quad \begin{cases} X_{active} \in \mathbb{R}^{H \times W \times C_p} \\ X_{passive} \in \mathbb{R}^{H \times W \times (C - C_p)} \end{cases} \quad (4.1)$$

仅对激活通道执行空间卷积：

$$Y_{active} = W \otimes X_{active} + b \quad (4.2)$$

其中偏置项 $b \in \mathbb{R}^{C_o}$ ，输出维度 $Y_{active} \in \mathbb{R}^{H' \times W' \times C_o}$ 。

通过通道拼接整合处理结果：

$$Y = [Y_{active}, X_{passive}] \in \mathbb{R}^{H' \times W' \times (C_o + C - C_p)} \quad (4.3)$$

设标准卷积计算量为：

$$\mathcal{C}_{std} = H'W'C_o(K^2C) \quad (4.4)$$

部分卷积计算量降为：

$$\mathcal{C}_{pconv} = H'W'C_o(K^2C_p) \quad (4.5)$$

当取 $\lambda = 0.25$ 理论计算量缩减 75%。在 YOLOv8 的 C2f 模块中，将原始 Bottleneck 的 3×3 DWConv 替换为 PConv 后，在单层计算量的对比中 DWConv 的计算量（GFLOPs）为 1.45，参数量（M）为 0.73；而使用部分卷积操作 $Pconv(\lambda = 0.25)$ ，其计算量（GFLOPs）为 0.32，参数量（M）为 0.18。

上述数学建模表明，通过部分卷积的通道选择性处理，能够在保持特征完整性的前提下实现显著的计算效率提升，为后续的轻量化改进奠定理论基础。

将 C2f 模块里的 Bottleneck 模块替换成 Faster Block 模块后，新结构命名为 C2f - Faster 模块。为了最大限度地实现模型的轻量化，选择将原模型主干网络中的所有 C2f 模块替换为经过轻量化改进的 C2f-Faster 模块。C2f - Faster 模块的图示见图 4-5 所示。




图 4-5 C2f-faster 模块结构图
Fig. 4-5 C2f-faster module structure diagram

4.1.2 添加 BiFPN 特征融合结构

在 YOLOv8 颈部网络中引入 BiFPN 结构，主要基于以下三方面考量：首先，谷子种穴图像中存在显著的多尺度特性，既有密集分布的小目标群体，也存在因播种深度差异形成的尺度变化，BiFPN 的双向特征传播机制能有效整合不同感受野的特征信息；其次，种穴内谷粒常因土壤覆盖产生部分遮挡，BiFPN 的跨层连接设计增强了特征表示对局部遮挡

的鲁棒性；最后，通过可微分权重的引入，网络能够动态调整各特征层的融合权重，在硬件资源受限条件下实现计算效率与检测精度的最优平衡。

在目标检测领域，跨尺度特征融合效率直接影响模型表征能力，传统金字塔结构(FPN)受限于单向特征交互与等权融合策略，难以实现多分辨率特征的最优聚合，同时双向特征金字塔结构(PANet)虽在 FPN 基础上引入自底向上的增强路径，但不同尺度特征图的融合采用简单的相加操作，未能充分考虑各特征层的贡献差异。加权双向特征金字塔网络(BiFPN^[84,85])，通过引入可学习的特征权重和跨尺度捷径连接，显著提升了多尺度特征的融合质量。

BiFPN 的核心创新在于构建了高效的双向跨尺度特征融合机制。该网络首先对传统 FPN 结构进行拓扑优化，删除仅具有单一输入边的节点以简化计算流程，同时在原始输入节点与输出节点间建立跨层残差连接。这种结构设计允许网络在特征融合过程中保留更多原始特征信息，有效缓解了深层网络中的梯度消失问题。对于输入特征集 $\{P_{in}^1, P_{in}^2, \dots, P_{in}^n\}$ ，BiFPN 通过公式 (4.6) 所示的加权融合策略进行特征聚合：

$$P_{out}^l = \mathcal{F} \left(\sum_i w_i \cdot \mathcal{R}(P_{in}^i) \right) \quad (4.6)$$

针对多尺度特征间存在的分辨率差异及表征分布不均衡问题，BiFPN 引入可学习的特征权重参数（式 4.7），通过自适应加权融合策略消除跨尺度特征传递中的信息偏差，增强网络对异构特征的表征能力。该机制使模型能动态调整不同层级特征的贡献度，实现多尺度特征的最优组合。

$$P_i^{td} = \text{Conv} \left(\frac{w_1 P_i^{in} + w_2 \cdot \text{Re size}(P_{i+1}^{in})}{W_1 + W_2 + c} \right) \quad (4.7)$$

多尺度特征融合方法 Bi-FPN，能够在不增加成本的情况下融合不同分辨率的特性^{[86][22]}。结合 Bi-FPN 的思想，在 YOLOv8 基础上，增加了新的跨尺度连接方式和特征融合方法，形成了 B-YOLOv8 的特征融合网络，增强特征融合效果^[87]。三种特征融合网络结构对比如图 4-6 所示。可以看出，B-YOLOv8 在 Bi-FPN 基础上进一步添加了跨尺度连接方法，允许特征从一个深度双向流动到另一个深度，并在原始输入节点和输出节点之间添加 1 条额外的 1×1 卷积路径，将特征提取网络中的特征直接与自底向上路径中的特征进行融合，使网络在保留更多浅层语义信息的同时也不丢失过多相对深层的语义信息，在不增加成本的情况下融合更多特征。




图 4-6 三种特征融合网络结构对比图
Fig. 4-6 Comparison diagram of the network structure of the fusion of three features

4.1.3 添加检测头

YOLOv8 目标检测网络采用多尺度特征融合架构，其检测层输出包含三种不同分辨率的特征图： 80×80 （高分辨率）、 40×40 （中分辨率）和 20×20 （低分辨率），分别负责识别不同尺度的目标物体。在高分辨率特征层（ 80×80 ）中，每个特征点对应原始图像 8×8 像素区域的特征表示。但实际检测场景中，谷物种穴等微小目标的物理尺寸往往不足 8×8 像素，这使得深层网络难以有效提取其精细特征。由于深层特征图的感受野较大，对小尺度目标的特征响应较弱，最终导致网络对微小目标的识别性能出现明显下降，漏检现象较为严重。

针对上述问题，本文在检测头模块增设 160×160 分辨率的专用预测分支，与原有检测层构成四级预测体系，增加小目标检测层之后的模型结构图如 4-7 所示。




图 4-7 小目标检测结构图
该分支通过特征金字塔下采样通道实现跨层级特征传播，建立多尺度特征间的双向交互机制，增强网络对微小目标的表征能力，能够将微小目标的精细特征信息通过下采样通道有效地传播至多个不同尺度的特征层级。这种跨尺度特征交互设计显著强化了网络的特

征整合效能,使模型能够更加高效地融合多分辨率特征表征。

4.2 实验与分析

4.2.1 模型性能分析

针对谷子多粒穴播成穴性实时检测,选择 YOLOv8 作为基础模型,经过优化后的 YOLOv8 模型命名为 B-YOLOv8 模型。为了验证这些改进带来的性能提升,基于种穴内谷子数据集开展了消融实验与对比实验。

(1) PR、mAP@0.5 对比图

在谷子数据集上,YOLOv8 改进前以及改进后的模型所生成的 PR 曲线与 mAP@0.5 曲线详见图 4-8。




图 4-8 PR、mAP@0.5 曲线对比图

Fig. 4-8 PR and mAP@0.5 curve comparison chart

通过 PR 曲线分析可知,相较于原始的 YOLOv8 模型,改进后的 B-YOLOv8 模型在谷子检测方面的 AP 值有所提升,尤其在小目标谷子的检测精度上,实现了显著的提高。总体来看,B-YOLOv8 模型相比于 YOLOv8 模型的精确率以及召回率均为上升趋势,说明改进方法对于种穴内谷子小目标的检测精度确实有提升。

(2) 收敛曲线对比图

为评估改进后模型在训练过程中的收敛表现,本研究对基准 YOLOv8 架构与优化后的 B-YOLOv8 版本进行了系统的对比研究。首先,通过分析边界框回归损失、目标置信度损失和分类损失的变化趋势,深入考察了两个模型在训练阶段的稳定性和收敛特性。进一步基于精确率、召回率以及 mAP@0.5 和 mAP@0.5:0.95 量化检测性能收敛过程,全面评估模型优化效果。具体的收敛过程可视化结果如图 4-9 (原始模型) 图 4-10 (优化模型)。




图 4-9 YOLOv8 模型收敛曲线图

Fig. 4-9 Convergence plot generated by the YOLOv8 model




图 4-10 B-YOLOv8 模型生成的收敛曲线图

Fig. 4-10 Convergence plot generated by the B-YOLOv8 model

在通过对谷物种穴数据集的训练集和验证集损失曲线进行系统分析，研究发现原始 YOLOv8 架构及其改进版本 B-YOLOv8 均表现出良好的收敛特性，损失值维持在较低水平。值得注意的是，在置信度损失这一关键指标上，B-YOLOv8 展现出具有统计学意义的微小优势。深入分析四项核心性能指标的演变趋势可见，改进后的 B-YOLOv8 在精确度和召回率两个维度均实现了性能提升。此外，该优化模型的收敛过程表现出更好的平滑性和稳定性。基于以上实证数据可以证实，B-YOLOv8 在模型收敛特性方面确实取得了实质性改进。

4.2.2 模型的对比分析

为进一步验证改进模型对谷子小目标图像检测的性能优势，选择 Faster-RCNN、SSD、YOLOv3、YOLOv4、YOLOv5s、YOLOv6、YOLOv7-tiny 和 YOLOv8 等模型进行了对比实验，在相同数据集上进行训练。性能对比如图 4-11 所示。




图 4-11 对比实验结果

Fig. 4-11 Compare the results of the experiment

根据图中的对比实验可知，B-YOLOv8 算法 mAP@0.5 值和检测速度均优于其他模型，并且参数量较小，只有 YOLOv5s 的参数量略微优于 B-YOLOv8。mAP@0.5 值比 Faster-RCNN 算法提高了 27.8%，比 YOLOv5s 提高了 12.27%。FPS 值高于 Faster-RCNN 算法 3.56 倍，高于 YOLOv5s 18.75%。实验结果说明改进算法降低参数的同时，具有较高的小目标检测的精度和检测速度，具有良好的实时检测性能，可以帮助谷子穴播机实现复杂的种穴图像的实时检测能力，并满足轻量化和高精确率的需求。

4.2.3 消融实验结果分析

为了验证模块的改进效果，设置了 10 组消融实验，实验结果如表 4-1 所示。从表中可以看出，虽然不同改进阶段的模型精度均有一定程度的提升，但是，改进单个模块的情况下，mAP@0.5 值的提升程度均在 1.84% 以下，只有引入 C2f-faster 模块时，模型性能有大幅度的提升，参数量降低了 11.42% 的同时模型检测速度提升了 14.68%。说明 C2f-faster 的引入确实能够增加模型的轻量化。从 E、F 和 G 模型的表现可以看出，在单个改进模块的基础上增加改进策略的模型 mAP@0.5 值均有提升，模型对小目标特征的捕捉进一步增强。

从 H 模型可以看出改进后的模型 mAP@0.5 提升了 1.72%。融合了所有改进模块的 B-YOLOv8 算法的 mAP@0.5 值提升最为显著,提高了 3.89%,同时参数量减少了 4.86%,检测速度提升了 4.59%。实验结果验证了模型的改进策略是有效的,在增加模型检测精度的同时实现了轻量化和检测速度的提升,能够满足谷子在种穴内实时检测的要求。

表 4-1 消融实验结果
Table 4-1 Results of ablation experiment

方法	EMA	C2f-faster	BiFPN	检测头	P (%)	R (%)	mAP@0.5 (%)	参数量	FPS
YOLOv8					76.1	97.0	92.5	11.12	109
A	√				76.4	97.1	93.5	11.17	106
B		√			77.1	97.6	94.2	9.85	125
C			√		76.8	97.5	93.9	11.14	106
D				√	76.5	97.3	93.8	10.24	102
E	√	√			77.3	98.2	95.1	10.24	120
F		√		√	77.5	98.5	95.6	9.72	118
G			√	√	77.1	97.8	94.5	10.30	105
H		√	√	√	77.7	98.6	95.9	10.39	110
Ours	√	√	√	√	77.8	98.7	96.1	10.58	114

4.3 成穴性结果与分析

通过计算穴孔大小 D 与合格率,对种穴内谷子的成穴情况进行判断分析,进一步验证改进模型的检测结果。将 YOLOv8 和 B-YOLOv8 模型的检测结果与人工方法获得的穴孔大小 D 和籽粒数进行对比分析,穴孔大小误差图以及粒数误差情况分别如图 4-12、图 4-13 所示。预测集中随机选择 30 组数据进行对照。由图 4-12 可以看出, B-YOLOv8 的穴孔大小误差较人工检测相差很小,平均误差值为 0.3cm,低于 YOLOv8 模型 39 个百分点。由图 4-13 可以看出 B-YOLOv8 合格率为 60%且穴粒数与实际穴粒数也基本一致,一致程度达到 76.6%。而 YOLOv8 合格率为 40%,与实际穴粒数的一致性仅为 46.6%,改进后模型计算准确性更高,且指标均展现出明显优势。结合指标综合评价改进模型成穴性的计算结果更接近人工统计结果,能够准确判断谷子多粒穴播的成穴性。




图 4-12 穴孔大小误差对比结果

Fig. 4-12 Comparison results of hole size error




图 4-13 粒数误差对比结果

Fig. 4-13 Particle number error comparison results

4.4 本章小结

本章提出基于 YOLOv8 的改进型检测框架 B-YOLOv8, 针对多粒穴播场景的小目标检测问题实施三重优化: 在主干网络嵌入轻量化注意力模块以增强细节特征保留能力; 于颈部网络构建多层次特征交互结构, 提升小目标特征表征的鲁棒性; 增设 160×160 高分辨率检测分支构建专用小目标检测体, 同时通过设计对比试验、消融实验以及成穴性结果与分析进一步说明了所构建模型对多粒穴播情况的判断准确率显著提升为谷子图像识别提供了可靠的数据支撑和理论依据。

5 种穴内谷子目标的检测系统

在第三章和第四章研究的基础上,进一步开发了一套基于 YOLOv8 算法的种穴内谷子目标检测系统。本系统以 PyQt5 为框架,搭建了一个人机交互窗口,提供了直观的操作界面和功能模块。系统的主要功能模块包括:注册登录模块,谷子检测模块,检测结果展示模块,检测结果保存模块四个功能模块组成。

5.1 系统总体设计

5.1.1 系统开发工具

本研究采用基于 Qt 库的跨平台 Python 框架 PyQt5 进行系统开发,利用其丰富的图形界面组件和功能模块,成功构建了种穴内谷子目标检测系统的可视化操作界面,实现了用户友好的桌面应用程序开发

PyQt 作为一款基于 Qt 库的 Python 框架,专注于图形用户界面(GUI)的创建工作。Qt 库本身是跨平台的 C++ 应用开发框架,具备广泛的适用性。PyQt 允许开发者运用 Python 语言对 Qt 库进行调用,进而获取丰富多样的功能与组件,其中涵盖窗口、按钮、菜单、对话框以及布局管理等。借助这些元素,开发者能够打造出现代化的桌面应用程序,构建出用户体验良好的图形界面。不仅如此,PyQt 还支持与数据库、网络、线程等模块进行集成。与此同时,其拥有丰富的文档资源以及活跃的社区支持,这极大地助力开发者构建更为复杂且功能完备的应用程序。

5.1.2 系统总体架构设计方案

谷子目标检测系统应具备四大关键功能。其一为登录与注册功能,旨在为用户提供身份验证与账号创建途径,保障系统使用的安全性与用户操作的可追溯性;其二是谷子检测功能,借助特定算法与模型,针对谷子目标展开精准检测与识别;其三为检测结果展示功能,能够以直观清晰的方式,将目标检测所得结果呈现给用户,方便其查看与理解;其四是检测结果保存功能,负责把检测结果妥善存储至指定位置,以便后续查询、分析及数据留存。该系统的总体架构详见图 5-1。




图 5-1 种穴内谷子目标的检测系统框架图

Fig. 5-1 Framework diagram of the detection system of millet targets in seed holes

5.2 系统功能的实现

5.2.1 注册登录模块的实现

本研究基于 PyQt5 技术框架构建用户登录与注册模块，采用 MVC 分层架构实现界面与业务逻辑解耦。

在 Windows11 系统的 PyQt 环境里，依据系统总体架构，着手搭建基于深度学习的种穴内谷子目标检测系统的注册与登录界面。此过程起始于系统登录，用户通过登录页面进入系统。该模块允许用户通过注册账号和密码进行登录，确保系统的安全性。用户可以创建个人账户，保存个人设置和检测历史记录，便于后续的数据分析和处理。主要包括注册账号、用户名、密码、确认密码等。

本模块的实现通过 PyQt5 GUI 框架，搭建数据安全层、数据持久层和业务逻辑层来具体实现相关功能，该实现方案通过控件组合验证、数据加密传输、事务性数据库操作等技术手段为后续目标检测功能模块提供了可靠的权限管理基础，模块开发技术栈结构图如图 5-2 所示：




图 5-2 注册登录模块实现技术栈

Fig. 5-2 Registration and login module implementation technology stack

5.2.2 谷子检测模块的实现

该模块是系统的核心功能，利用改进后的 YOLOv8 模型对种穴内的谷子进行实时检测。用户登录系统后，映入眼帘的便是系统主界面。此界面集成了三大核心功能，分别为目标检测功能、检测结果展示功能以及结果保存功能。

在谷子目标检测功能方面，用户可通过主界面的文件导入选项，灵活选择基于图片的谷子目标检测模式，或是基于相机的谷子目标检测模式。这一设计充分考虑了不同使用场景下用户的多样化需求，无论是已拍摄好的图片，还是实时通过相机获取的影像，都能精准应用于谷子目标检测任务。

本模块基于 B-YOLOv8 轻量化模型构建目标检测核心，采用多模态输入适配架构实现检测功能。通过 PyQt5 的相关功能派生检测主界面，集成创建功能面板。采用工厂模式构建输入源选择器，支持动态加载图片和相机流两种检测模式。其模块实现技术栈如图 5-3 所示：




图 5-3 谷子检测模块实现技术栈
Fig. 5-3 Grain detection module implementation technology stack

5.2.3 检测结果展示模块的实现

在系统主界面用户可以通过摄像头或上传图像的方式输入待检测的种穴图像。完成图片导入操作后，系统将自动识别图像中的谷子种子，并在界面上实时显示检测结果。种穴内谷子目标的数量及坐标位置等信息得以准确在图中输出。工作人员借助检测系统所呈现的这些信息，能够迅速定位并查找谷子目标相关数据，从而便捷、高效地对谷子的成穴性做出快速判断，如图 5-4 所示，为部分复杂场景（如雨天、多杂草）下的检测效果图。





图 5-4 检测结果视图
Fig. 5-4 Detection results view

5.2.4 检测结果保存模块的实现

检测结果展示区域，会清晰呈现种穴内谷子目标的各项关键信息，如目标数量、置信度以及目标所处位置等。这些详细的数据展示，为用户深入了解检测结果提供了有力支撑，帮助用户快速掌握谷子目标的分布状况及检测的可靠程度。至于结果保存功能，操作十分便捷。用户只需点击主界面上的保存按钮，系统便会自动将检测生成的相关文件，妥善保存至名为 save-data 文件夹中，如图 5-5 所示。



图 5-5 结果保存视图

Fig. 5-5 Result saving view

5.3 本章小结

本章基于改进的 YOLOv8 算法构建了种穴内谷子目标检测系统，实现了从算法模型到工程化应用的转化。系统采用 PyTorch 深度学习框架与 PyQt 框架，构建了包含用户交互、图像处理、结果可视化及数据存储的多模块协同体系，并通过系统功能测试验证系统完整性与高效性。本系统的工程化落地验证了改进算法在实际应用场景中的有效性，为智慧农业装备的智能化升级提供了可靠的技术支撑。

6 结论与展望

6.1 结论

谷子作为我国农业领域的关键作物，在农业生产体系中占据着举足轻重的地位。其产量状况，不仅对农业经济的发展态势有着显著影响，更与国民经济的稳定及长远发展紧密相连。由于谷子个体较小且形态具有不规则性，种穴内图像漏检或误检率高、目标定位不精确、导致无法快速准确地检测成穴性等问题，同时为提升在复杂场景下小目标检测的性能，切实保障谷子产量，确保能够及时且高效地对种穴内谷子开展检测工作，提高播种效率的同时提高作物产量，本研究经过考量与筛选，选定了在模型轻量化特性和检测准确率方面达成良好平衡的 YOLOv8 网络模型，将其作为开展谷子目标识别工作的基础网络架构，开展了优化改进工作，使建立的模型能够准确判断谷子多粒穴播的成穴性，并成功将改进后的模型应用于实际检测系统之中。通过研究获得以下结论：

（1）针对种穴内谷子目标数据数量较少的问题，通过翻转、平移、旋转、等操作将数据进行扩增，为谷子识别模型的训练创造了充分的数据条件，同时使用 Labelimg 软件进行标注建立种穴内谷子目标数据集。

（2）为了提高 YOLOv8 模型的目标检测性能，引入 EMA 注意力机制增强模型的多尺度特征融合能力，提高检测的精度。将 CBAM、SA、CA、SE 四种注意力机制分别嵌入模型中进行比较，实验结果表明，引入 EMA 注意力机制后的 YOLOv8 模型在检测精度等方面优于其他模型，改进后 YOLOv8 模型的检测精度较原始模型提高了 1 %。

（3）为了提高种穴内谷子目标的检测精度，针对谷子多粒穴播成穴性实时检测，提出基于 YOLOv8 的轻量级谷子多粒穴播种穴内小目标检测算法 B-YOLOv8。对引入 EMA 注意力机制后的 YOLOv8 模型，将 Faster Block 模块替换 C2f 中的 Bottleneck，在颈部网络中添加跨尺度连接方式和加权特征融合方法，将深层语义和浅层定位信息进行多尺度特征融合，最后，通过增加小目标检测头，获取更多小目标特征信息以提高不同尺度下谷子种子检测的准确率。为验证经优化的 B-YOLOv8 模型所具备的性能优势，选择 Faster-RCNN、SSD、YOLOv3、YOLOv4 等经典模型进行了对比实验，结果显示 B-YOLOv8 算法 mAP@0.5 值和检测速度均优于其他模型，并且参数量更小。为了进一步验证模块的改进效果，设置了 10 组消融实验。实验结果表明，融合了所有改进模块的 B-YOLOv8 算法的 mAP@0.5 值提升最为显著，提高了 3.89%，同时参数量减少了 4.86%，检测速度提升了 4.59%，验证了 B-YOLOv8 模型在增加模型检测精度的同时实现了轻量化和检测速度的提升，可以减

少因种子尺寸较小、导致种子特征信息丢失，造成漏检等问题，能够满足谷子在种穴内实时检测的要求。

（4）基于以上研究内容，设计并开发了基于 YOLOv8 算法的种穴内谷子目标检测系统，系统提供了目标检测功能、检测结果展示功能三项基本功能，用户完成图片导入操作后，种穴内谷子目标的数量及坐标位置等信息得以准确在图中输出，用户可以通过摄像头或上传图像的方式输入待检测的种穴图像。用户借助系统精准的识别结果，能够迅速掌握谷子目标信息，进而快速采取针对性的应对措施，有效提升谷子种植管理的效率与质量。

6.2 展望

伴随人工智能技术的持续进步，借助目标检测技术实施谷子检测，验证了在谷子目标识别中改进后模型准确率得到有效提升，减少大量训练时间和内存消耗。但在未来研究过程中还有很大的改进和优化空间，主要包括如下几个方面：

（1）扩大研究范围：未来可以将基于 YOLO 目标检测算法应用于其他农作物的识别中，如水果、水稻等。这样可以拓宽研究领域，进一步提高目标识别的准确性和效率。

（2）提高模型泛化能力：文中所使用的数据增强方法相对简单，这在一定程度上可能限制了模型在实际应用中的泛化能力。实际农业环境中，种穴内谷子的背景会更加复杂和多变。因此，针对实际应用场景中的复杂性，未来将进一步探索更多增强模型鲁棒性的方法。

（3）添加嵌入式设备测试：在模型方面，本研究现阶段聚焦于算法层面的创新，未来可以添加嵌入式设备（如 Jetson Nano）的部署测试数据，分析算力需求与成本节约比例。

总之，未来的研究可以进一步探索 YOLO 目标检测在农作物种植识别中的应用，并结合其他深度学习算法、先进的监测技术，以提高对农作物识别的准确性、实时性和可靠性。

参考文献

- [1] 李顺国, 刘斐, 刘猛, 等. 中国谷子产业和种业发展现状与未来展望[J]. 中国农业科学, 2021, 54(3): 459-470.
- [2] 贾冠清, 刁现民. 中国谷子种业创新现状与未来展望[J]. 中国农业科学, 2022, 55(4): 653-665.
- [3] 白晓雷, 柴晓娇, 王显瑞, 等. 谷子不同机械化收获方式比较试验[J]. 现代农业科技, 2023, (7):5-8.
- [4] 张东光, 郭玉明, 李洵泽. 小籽粒谷物精少量播种机研究现状与进展[J]. 当代农机, 2008(4):69-70.
- [5] 李彦平, 卢琦, 安邦, 等. 燕麦穴播排种器的设计与试验[J]. 农机化研究, 2022, 44(12):156-162.
- [6] 张青松, 余琦, 王磊, 等. 油菜勺式精量穴播排种器设计与试验[J]. 农业机械学报, 2020, 51(06): 47-54+64.
- [7] 衣淑娟, 孙亭瀚, 陈涛, 等. 谷子穴播机勺链式导种装置设计与试验[J]. 农业机械学报, 2024, 55(08): 39-52.
- [8] 刘华钰, 衣淑娟, 陈涛, 等. 鸭嘴式谷子穴播排种器设计与试验研究[J]. 农机化研究, 2023, 46(10): 111-119.
- [9] 宋怀波, 尚钰莹, 何东健. 果实目标深度学习识别技术研究进展[J]. 农业机械学报, 2023, 54(1): 1-19.
- [10] 孙红, 乔金博, 李松, 等. 基于深度学习的玉米拔节期冠层识别[J]. 农业工程学报, 2021, 37(21):53-61.
- [11] Davenport T H, Ronanki R. Artificial intelligence for the real world[J]. Harvard business review, 2018, 96(1): 108-116.
- [12] 秦理平, 马过胜, 贾可. 2BG-6 型可调控专用谷子精少量播种机试验研究[J]. 农业技术与装备, 2012 (20): 78-80.
- [13] 杨延兵, 秦岭, 高凤菊, 等. 穴距与单穴株数对夏谷产量及相关性状的影响[J]. 山东农业科学, 2012, 44(10): 58-60.
- [14] 涂成凤, 易安林, 姚涛, 等. 轻量化 YOLOv5n 的高精度垃圾检测算法[J]. Journal of Computer Engineering & Applications, 2023, 59(10).
- [15] Tian L, Zhang H, Liu B, et al. VMF-SSD: A Novel v-space based multi-scale feature fusion SSD for apple leaf disease detection[J]. IEEE/ACM Transactions on Computational Biology and Bioinformatics, 2022, 20(3): 2016-2028.
- [16] Chang C, Wang Y-P, Cheng S-C. Fish Segmentation in Sonar Images by Mask R-CNN on Feature Maps of Conditional Random Fields[J]. Sensors. 2021; 21(22):7625.
- [17] Xu X, Zhang H, Ma Y, Liu K, Bao H, Qian X. TranSDet: Toward Effective Transfer Learning for Small-Object Detection[J]. Remote Sensing. 2023; 15(14):3525.
- [18] He K, Zhang X, Ren S, et al. Spatial pyramid pooling in deep convolutional networks for visual recognition[J]. IEEE transactions on pattern analysis and machine intelligence, 2015, 37(9): 1904-1916.
- [19] Girshick R. Fast R-CNN, 1440–1448[J]. New York: IEEE, 2015.
- [20] Ren S, He K, Girshick R, et al. Faster r-cnn: Towards real-time object detection with region proposal networks[J]. Advances in neural information processing systems, 2015, 28.

- [21] Dai J, Li Y, He K, et al. R-fcn: Object detection via region-based fully convolutional networks[J]. Advances in neural information processing systems, 2016, 29.
- [22] REDMON, DIVVALA, GIRSHICK, et al. You Only Look Once: Unified, Real-Time Object Detection[C]. Computer Vision & Pattern Recognition, 2016.
- [23] Redmon J, Farhadi A. YOLO9000: better, faster, stronger[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 7263-7271.
- [24] Redmon J, Farhadi A. Yolov3: An incremental improvement[J]. arXiv preprint arXiv:1804.02767, 2018.
- [25] Bochkovskiy A, Wang C Y, Liao H Y M. Yolov4: Optimal speed and accuracy of object detection[J]. arXiv preprint arXiv:2004.10934, 2020.
- [26] WANG, LIAO, WU, et al. CSPNet: A new backbone that can enhance learning capability of CNN[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition workshops, 2020:390-391.
- [27] Jocher G, Stoken A, Borovec J, et al. ultralytics/yolov5: v3. 1-bug fixes and performance improvements[J]. Zenodo, 2020.
- [28] Li C, Li L, Jiang H, et al. YOLOv6: A single-stage object detection framework for industrial applications[J]. arXiv preprint arXiv:2209.02976, 2022.
- [29] WANG, BOCHKOVSKIY, LIAO. YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2023:7464-7475.
- [30] Liu W, Anguelov D, Erhan D, et al. Ssd: Single shot multibox detector[C]//Computer Vision—ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11–14, 2016, Proceedings, Part I 14. Springer International Publishing, 2016: 21-37.
- [31] Jeong J, Park H, Kwak N. Enhancement of SSD by concatenating feature maps for object detection[J]. arXiv preprint arXiv:1705.09587, 2017.
- [32] Fu C Y, Liu W, Ranga A, et al. Dssd: Deconvolutional single shot detector[J]. arXiv preprint arXiv:1701.06659, 2017.
- [33] Li Z, Yang L, Zhou F. FSSD: feature fusion single shot multibox detector[J]. arXiv preprint arXiv:1712.00960, 2017.
- [34] Shen Z, Liu Z, Li J, et al. Object detection from scratch with deep supervision[J]. IEEE transactions on pattern analysis and machine intelligence, 2019, 42(2): 398-412.
- [35] Yi J, Wu P, Metaxas D N. ASSD: Attentive single shot multibox detector[J]. Computer Vision and Image Understanding, 2019, 189: 102827.
- [36] LOU, HUANG, FANG, et al. Measuring loblolly pine crowns with drone imagery through deep learning [J]. Journal of Forestry Research, 2021, 33(1):227-238.
- [37] LIU, ANGUELOV, ERHAN, et al. Ssd: Single shot multibox detector[C]. Computer Vision—ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11–14, 2016, Proceedings, Part I 14, 2016:21-37.
- [38] CHEN, LU, LIU, et al. Detecting Citrus in Orchard Environment by Using Improved YOLOv4[J].

- Scientific Programming, 2020, 2020(1):1-13.
- [39] HAN, CHANG, WANG. You only look once: unified, real-time object detection[J]. Procedia Computer Science, 2021, 183(1):61-72.
- [40] 文韬, 王天一, 黄诗锐, 等. 基于改进 YOLOv8 的农作物与藜草检测算法: MES-YOLO [J]. 计算机工程与科学, 1-13.
- [41] CHEN, LI, ZHANG, et al. Soft X-ray image recognition and classification of maize seed cracks based on image enhancement and optimized YOLOv8 model[J]. Computers and Electronics in Agriculture, 2024, 216:108475.
- [42] YANG, WANG, NIE, et al. A Lightweight YOLOv8 Tomato Detection Algorithm Combining Feature Enhancement and Attention[J]. Agronomy, 2023, 13(7):1824.
- [43] CHEN, MA, HUANG, et al. Efficient and lightweight grape and picking point synchronous detection model based on key point detection[J]. Computers and Electronics in Agriculture, 2024, 217:108612.
- [44] SOLIMANI, CARDELLICCHIO, DIMAURO, et al. Optimizing tomato plant phenotyping detection: Boosting YOLOv8 architecture to tackle data complexity[J]. Computers and Electronics in Agriculture, 2024, 218:108728.
- [45] Liu J, Wang X. Tomato diseases and pests detection based on improved Yolo V3 convolutional neural network[J]. Frontiers in plant science, 2020, 11: 898.
- [46] Li D, Ahmed F, Wu N, et al. Yolo-JD: A Deep Learning Network for jute diseases and pests detection from images[J]. Plants, 2022, 11(7): 937.
- [47] ZHANG, SU, ZHANG, et al. SE-YOLOv5x: An Optimized Model Based on Transfer Learning and Visual Attention Mechanism for Identifying and Localizing Weeds and Vegetables[J]. 2022, 12(9):2061.
- [48] Kuznetsova A, Maleva T, Soloviev V. Using YOLOv3 algorithm with pre-and post-processing for apple detection in fruit-harvesting robot[J]. Agronomy, 2020, 10(7): 1016.
- [49] 公徐路, 张淑娟. 基于改进 YOLOv5s 的苹果叶片小目标病害轻量化检测方法[J]. 农业工程学报, 2023, 39(19):175-184.
- [50] 王梦妮, 顾寄南, 王化佳, 等. 基于改进 YOLOv5s 模型的茶叶嫩芽识别方法[J]. 农业工程学报, 2023, 39(12):150-157.
- [51] 范天浩, 顾寄南, 王文波, 等. 基于改进 YOLOv5s 的轻量化金银花识别方法[J]. 农业工程学报, 2023, 39(11):192-200.
- [52] 陈禹, 吴雪梅, 张珍, 等. 基于改进 YOLOv5s 的自然环境下茶叶病害识别方法[J]. 农业工程学报, 2023, 39(24):185-194.
- [53] 刘冰杰, 周雅楠, 周小辉, 等. 基于深度学习的玉米田间杂草识别模型研究[J]. 河南农业大学学报, 2024, 58(02):279-286.
- [54] 王卫星, 刘泽乾, 高鹏, 等. 基于改进 YOLO v4 的荔枝病虫害检测模型[J]. 农业机械学报, 2023, 54(05):227-235.
- [55] 姚涛, 谈志鹏, 程娥, 等. 基于改进 YOLOv7-seg 的黄花菜检测分割识别算法[J]. Transactions of the Chinese Society of Agricultural Engineering, 2024, 40(9).

- [56] 马超伟, 张浩, 马新明, 等. 基于改进 YOLOv8 的轻量化小麦病害检测方法[J]. 农业工程学报, 2024, 40(05):187-195.
- [57] 康鑫英, 张德育, 王君. 压缩 SSD 低空小目标检测算法研究[J]. 沈阳理工大学学报, 2022, 41(6): 1-5.
- [58] PENG H, ZHANG Y F, YANG S, et al. Battlefield image situational awareness application based on deep learning[J]. IEEE Intelligent Systems, 2020, 35(1): 36-43.
- [59] CHEN C Y, LIU M Y, TUZEL O, et al. R-CNN for small object detection[C]//Proceeding of Asian Conference on Computer Vision, 2016, 10115: 214-230.
- [60] Pang J, Chen K, Shi J, et al. Libra r-cnn: Towards balanced learning for object detection[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 821-830.
- [61] 王君, 张德育, 康鑫英. 改进 Faster-RCNN 的低空小型无人机检测方法[J]. 沈阳理工大学学报, 2021, 40(4): 23-28.
- [62] 李嘉新, 侯进, 盛博莹, 等. 基于改进 YOLOv5 的遥感小目标检测网络[J]. 计算机工程, 2023, 9(2): 1-11.
- [63] 谢椿辉, 吴金明, 徐怀宇. 改进 YOLOv5 的无人机影像小目标检测算法[J]. 计算机工程与应用, 2023, 59(9): 198-206.
- [64] 倪浩鹏. 基于深度学习的红外小目标检测关键算法研究[D]. 南京: 南京邮电大学, 2022.
- [65] 张艳珠, 包慧哲, 于长海, 等. 基于无人机图像地面建筑物目标检测算法研究[J]. 沈阳理工大学学报, 2023, 42(4): 1-6, 14.
- [66] 商俊燕. 基于深度学习的遥感图像微小目标检测方法研究[J]. Computer Measurement & Control, 2022, 30(10).
- [67] Chen C, Liu M Y, Tuzel O, et al. R-CNN for Small Object Detection[C]//Asian Conference on Computer Vision. Springer, Cham, 2016. DOI:10.1007/978-3-319-54193-8_14.
- [68] 罗会兰, 彭珊, 陈鸿坤. 目标检测难点问题最新研究进展综述[J]. Journal of Computer Engineering & Applications, 2021, 57(5).
- [69] Bochkovskiy A, Wang C Y, Liao H Y M. Yolov4: Optimal speed and accuracy of object detection[J]. arXiv preprint arXiv:2004.10934, 2020.
- [70] 张旭娟. 基于图像识别的垃圾分类深度学习模型研究[J]. 西北师范大学.
- [71] 冷睿轩. 基于 YOLOv8 的输电线路异物识别算法应用[D]. 东北农业大学, 2023.
- [72] 黄志添, 谢怡宁, 赵晶, 等. 融合递归特征金字塔的病原微生物检测[J]. Journal of Harbin University of Science & Technology, 2023, 28(5).
- [73] 刘俊明, 孟卫华. 基于深度学习的单阶段目标检测算法研究综述[J]. 航空兵器, 2020, 27(3): 44-53.
- [74] Ge Z, Liu S, Wang F, et al. Yolox: Exceeding yolo series in 2021. arXiv 2021[J]. arXiv preprint arXiv:2107.08430, 2021, 8430.
- [75] Aubard M, Antal L, Madureira A, et al. Knowledge distillation in yolox-vit for side-scan sonar object detection[J]. arXiv preprint arXiv:2403.09313, 2024.
- [76] Lin Y, Zheng L, Zheng Z, et al. Improving person re-identification by attribute and identity learning[J].

- Pattern recognition, 2019, 95: 151-161.
- [77] SUN, ZHENG, YANG, et al. Beyond part models: Person retrieval with refined part pooling (and a strong convolutional baseline)[C]. Proceedings of the European conference on computer vision (ECCV), 2018:480-496.
- [78] ZHENG, DENG, SUN, et al. Pyramidal person re-identification via multi-loss dynamic training[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2019:8514-8522.
- [79] 蔡舒妤, 闫子砚, 师利中. 基于改进 YOLOv4 的航空发动机损伤检测方法[J]. 现代制造工程, 2023, 509(2): 99.
- [80] WOO, PARK, LEE, et al. Cbam: Convolutional block attention module[C]. Proceedings of the European conference on computer vision (ECCV), 2018:3-19.
- [81] RONNEBERGER, FISCHER, BROX. U-net: Convolutional networks for biomedical image segmentation[C]. Medical image computing and computer-assisted intervention—MICCAI 2015: 18th international conference, Munich, Germany, October 5-9, 2015, proceedings, part III 18, 2015:234-241.
- [82] HOU, ZHOU, FENG. Coordinate attention for efficient mobile network design[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2021:13713-13722.
- [83] HU, SHEN, SUN. Squeeze-and-excitation networks[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2018:7132-7141.
- [84] Hua F. Improved Surface Defect Detection of YOLOV5 Aluminum Profiles based on CBAM and BiFPN[J]. Int. Core J. Eng, 2022, 8(12): 264-274.
- [85] ZHANG, LUO, SUN, et al. Bfr-retinanet: An improved retinanet model for vehicle detection in aerial images[C]. International Conference on Algorithms and Architectures for Parallel Processing, 2021:18-32.
- [86] ANNAVARAPU, PARISAPOGU, KEETHA, et al. A Bi-FPN-Based Encoder-Decoder Model for Lung Nodule Image Segmentation[J]. Diagnostics ,2023, 13(8):1406.
- [87] Qi Z, Hua W, Zhang Z, et al. A novel method for tomato stem diameter measurement based on improved YOLOv8-seg and RGB-D data[J]. Computers and Electronics in Agriculture, 2024, 226: 109387.