

硕士专业
王桦彬

基于 YOLO 模型的芝麻田间杂草检测研究

2023

硕士专业
学位论文

基于 YOLO 模型的芝麻田间杂草 检测研究

王桦彬

廣西大學

二〇二三年六月

分类号 TP391.41

学校代码 10593

密级 公开

学号 2011391089

硕士专业学位论文

基于 YOLO 模型的芝麻田间杂草 检测研究

RESEARCH ON WEED DETECTION IN SESAME FIELDS BASED ON YOLO MODEL

作者姓名: 王桦彬

指导教师: 陈继清 副教授

企业导师: 谭文举 教授级高级工程师

专业名称: 机械

研究方向: 机器视觉

所在学院: 机械工程学院

论文答辩日期 2023 年 6 月 1 日 学位授予日期 2023 年 6 月 21 日

答辩委员会主席 莫以为 教授

广西大学学位论文原创性和使用授权声明

本人声明所呈交的论文，是本人在导师的指导下独立进行研究所取得的科研成果。除已特别加以标注和致谢的地方外，论文不包含任何其他个人或集体已经发表或撰写的研究成果，也不包含本人或他人为获得广西大学或其它单位的学位而使用过的材料。与我一同工作的同事对本论文的研究工作所做的贡献均已在论文中作了明确说明。

本人在导师指导下所完成的学位论文及相关的职务作品，知识产权归属广西大学。本人授权广西大学拥有学位论文的部分使用权，即：学校有权保存并向国家有关部门或机构送交学位论文的复印件和电子版，允许论文被查阅和借阅，可以将学位论文的全部或部分内容编入有关数据库进行检索和传播，可以采用影印、缩印或其它复制手段保存、汇编学位论文。

本学位论文属于：

☐ 保密，在 年解密后适用授权。

☒ 不保密。

(请在以上相应方框内打“√”)

论文作者签名：王梓彬

日期：2023.6.23

指导教师签名：何建青

日期：2023.6.23

基于 YOLO 模型的芝麻田间杂草 检测研究

摘 要

芝麻是世界重要的油料作物，也是我国四大油料作物之一。由于芝麻的高营养价值，其被广泛运用与各类食品之中。在芝麻种植过程中，除草是一个非常关键的步骤。现阶段的芝麻农田除草方式主要是进行大范围的除草剂喷洒。但随着除草剂的大面积喷洒，不仅造成资源的浪费，还会出现农药残留、环境破坏等危害。因此，实现芝麻农田杂草的精准施药对于芝麻种植产业具有重要意义。对杂草进行精准施药的关键点在于精确获得农田环境中杂草的位置信息。然而现有深度学习模型对杂草检测存在精度较低、速度较慢和鲁棒性不足等问题，因此本文提出引入注意力机制、多尺度结构融合和简化卷积计算等方案对深度学习模型进行了精度优化与轻量化研究，开发了相应的图像检测算法。本文的主要研究内容如下：

(1)针对 YOLOv4 模型总体检测精度不足问题，提出在主干网络层和特征融合层之间的 SPP 结构中引入注意力机制；在该结构处利用局部注意力池化以达到了池化与注意力机制的双重作用；此外对局部注意力池化中的逻辑模块进行研究，采用不同注意力模块在局部注意力池化中发挥逻辑模块作用；此外针对杂草目标大小规格不一导致检测精度不足问题，提出利

用自适应空间特征融合结构对 YOLOv4 特征融合层进行改进。实验结果表明,所提的检测精度优化模型 YOLO-sesame 网络优于 YOLOv4 模型,对芝麻的检测精度为 96.50%、对杂草的检测精度为 97.09%、mAP 为 96.79%,分别比 YOLOv4 模型高了 9.75%、3.45%与 6.60%。

(2)针对 YOLOv4 模型检测速度较慢问题,对模型采取了简化卷积计算的轻量化改进方案,分别使用分组卷积、深度可分离卷积和条件参数化卷积对 YOLOv4 特征融合层中的大部分卷积方式进行更替。实验结果表明使用分组卷积与条件参数化卷积进行轻量化的效果较好,使用分组卷积($g=8$)轻量化的模型 FLOPs 为 21.68GB,检测速度为 FPS43.9,比 YOLOv4 模型降低了 27.7%的 FLOPs,检测速度提高了 19.3%;使用条件参数化卷积轻量化的模型 FLOPs 为 20.50GB,检测速度为 FPS46.2,比 YOLOv4 模型降低了 31.6%的 FLOPs,检测速度提高了 25.5%。

(3)综合了对 YOLOv4 模型进行精度优化与轻量化方案后,提出两个改进模型: YOLO-sesame-G 与 YOLO-sesame-C。YOLO-sesame-G 对芝麻杂草检测的 mAP 为 95.82%,FPS 为 41.5; YOLO-sesame-C 对芝麻杂草检测的 mAP 为 97.13%,FPS 为 42.7。所提出的两个模型在拥有对芝麻杂草检测较高精度的同时保持着不错的检测速度,可以满足实际杂草检测需求。

(4)从硬件与软件两方面搭建了芝麻杂草检测平台,以用于验证本文所提检测方案的实际表现。所搭建的芝麻杂草检测平台支持图像检测方式与视频检测方式,且允许使用摄像头对实时获取的视频进行检测。

关键词: 机器视觉 深度学习 精确施药 芝麻作物 杂草检测 YOLOv4

RESEARCH ON WEED DETECTION IN SESAME FIELDS BASED ON YOLO MODEL

ABSTRACT

Sesame is an important oil crop in the world and one of the four major oil crops in China. Due to its high nutritional value, sesame is used in a wide range of food products. Weeding is a crucial step in the sesame cultivation process. At this stage, the main method of weeding sesame fields is to spray herbicides on a large scale. However, with the extensive spraying of herbicides, not only are resources wasted, but pesticide residues and environmental damage can also occur. Therefore, the sesame cultivation industry needs to achieve precision weed application on sesame farmland. The key point for accurate weed application is to accurately obtain information on the location of weeds in the farmland environment. However, existing deep learning models have problems such as low accuracy, slow speed, and lack of robustness for weed detection. Therefore, this paper proposes the introduction of an attention mechanism, multi-scale structure fusion, and simplified convolutional computation to optimize the accuracy and lightweight of deep learning models, and develops the corresponding image detection algorithm. The main research content of this paper is as follows:

(1) To address the problem of insufficient overall detection accuracy of the YOLOv4 model, an attention mechanism was introduced into the SPP structure between the backbone network layer and the feature fusion layer; local attention pooling was used in this structure to achieve the dual role of pooling and attention mechanism; in addition, the logic module in local attention pooling was investigated, and different attention modules were used to play the role of the logic module in local attention pooling. In addition, we propose to improve the YOLOv4 feature fusion layer by using an adaptive spatial feature fusion structure to address the problem of insufficient detection accuracy due to the varying sizes of weed targets. The experimental results show that the proposed YOLO-same network outperforms the YOLOv4 model, with 96.50% detection accuracy for sesame, 97.09% detection accuracy for weeds, and 96.79% detection accuracy for mAP, which are 9.75%, 3.45% and 6.60% higher than the YOLOv4 model respectively.

(2) To address the slow detection speed of the YOLOv4 model, a lightweight improvement scheme was adopted to simplify the convolution calculation, using grouped convolution, depth-separable convolution, and conditional parametric convolution to replace most of the convolution methods in the YOLOv4 feature fusion layer respectively. The experimental results show that lightweighting using grouped convolution and conditional parametric convolution is more effective. The FLOPs of the model lightened using grouped convolution ($g=8$) are 21.68GB and the detection speed is 43.9 FPS, which is

27.7% lower FLOPs and 19.3% faster than the YOLOv4 model; the model lightened using conditional parametric convolution. The FLOPs were 20.50GB and the detection speed was FPS 46.2, a 31.6% reduction in FLOPs and a 25.5% improvement in detection speed over the YOLOv4 model.

(3) Two improved models, YOLO-sesame-G and YOLO-sesame-C, were proposed after combining accuracy optimization and lightweight solutions for the YOLOv4 model. mAP for sesame weed detection was 95.82% and FPS was 41.5 for YOLO-sesame-G, while mAP for sesame weed detection was 97.13% and FPS was 42.7 for YOLO-sesame-C. The proposed two models can meet the practical weed detection needs by maintaining good detection speed while having high accuracy for sesame weed detection.

(4) A sesame weed detection platform was built in both hardware and software to verify the practical performance of the proposed detection solution. The sesame weed detection platform supports both image and video detection methods and allows the use of cameras to detect the video acquired in real-time.

KEY WORDS:Machine vision; Deep learning;Precise application; Sesame crops;Weed detection; YOLOv4

目 录

摘 要.....	I
ABSTRACT.....	III
第一章绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	2
1.2.1 基于传统机器学习的机器视觉在杂草检测方面的研究现状.....	2
1.2.2 基于深度学习的机器视觉在杂草检测方面的研究现状.....	4
1.2.3 机器视觉在芝麻杂草检测方面的研究现状.....	6
1.3 亟待解决的问题.....	6
1.4 本文主要研究内容和技术路线.....	6
1.5 论文内容安排.....	7
第二章 目标检测数据集制作与检测性能评估指标.....	10
2.1 田间芝麻幼苗及其同期杂草图像采集.....	10
2.2 图像数据预处理.....	11
2.2.1 图像亮度调整的数据增强.....	12
2.2.2 图像模糊的数据增强.....	12
2.2.3 图像旋转、翻转和噪声的数据增强.....	13
2.3 图像标注与数据集制作.....	15
2.4 目标检测的性能评估指标.....	15
2.5 本章小结.....	18
第三章 基于 YOLOV4 模型芝麻苗与杂草检测精度研究.....	19
3.1 YOLOv4 算法模型分析.....	19
3.1.1 输入端.....	21
3.1.2 主干网络层.....	21
3.1.3 特征融合层.....	21
3.1.4 检测头.....	22
3.2 YOLOv4 模型注意力机制的引入.....	23
3.2.1 SPP 结构.....	24
3.2.2 局部注意力池化.....	24
3.2.3 局部注意力池化中的逻辑模块.....	25
3.3 自适应空间特征融合结构.....	28
3.4 算法模型实验环境与实验参数.....	29

3.5 实验结果与分析	30
3.5.1 基于局部注意力池化在不同逻辑模块表达下对芝麻杂草检测精度的影响	30
3.5.2 引入自适应空间特征融合结构 YOLOv4 模型对芝麻杂草检测精度的影响	32
3.5.3 综合局部注意力池化与自适应空间特征融合的模型对芝麻与杂草检测效果	34
3.6 本章小结	36
第四章 芝麻杂草检测模型轻量化研究	38
4.1 普通卷积	38
4.2 分组卷积	40
4.3 深度可分离卷积	41
4.4 条件参数化卷积	42
4.5 简化卷积计算的轻量化实验	44
4.6 实验结果与讨论	45
4.7 本章小结	47
第五章 芝麻杂草检测方案实验分析与平台搭建	48
5.1 芝麻杂草检测方案实验分析	48
5.1.1 检测模型精度改进与轻量化前后实验对比	48
5.1.2 与其他模型检测效果对比	50
5.1.3 芝麻杂草检测方案总结	53
5.2 芝麻杂草检测平台搭建	54
5.2.1 图像采集硬件设备	54
5.2.2 图像处理平台	55
5.2.3 检测平台行走机构	55
5.2.4 检测软件系统设计	57
5.3 芝麻杂草检测平台实验结果与分析	59
5.4 本章小结	61
第六章 总结与展望	62
6.1 总结	62
6.2 论文主要创新点	63
6.3 展望	63
参考文献	64
致谢	71
攻读硕士学位期间的主要科研成果	72

第一章绪论

1.1 研究背景及意义

芝麻自史前时代就在世界各热带地区种植，是世界上重要的油料作物之一，含油量可高达 55%。芝麻的主要产品为全籽、籽油和籽粕^[1]。由于芝麻的营养价值高，还被广泛运用于各类食品之中，如芝麻酱、芝麻油、芝麻面包等。此外，在现代医学理论中，芝麻还对人的身体有着抗氧化、清除自由基、降血脂血压血糖等功效^[2]。在中医的观点中，芝麻有滋养肝肾，润燥滑肠的功效^[3]。从芝麻中提取的两种芝麻素也有着不错的医学价值。

在我国，芝麻主要种植作为油料作物，是我国四大油料作物的佼佼者。根据华经产业研究院发布的《2022-2027 年中国芝麻行业市场运行现状及投资规划建议报告》^[4]中统计，2020 年我国芝麻种植面积为 281.17 千公顷，相较 2017 年的 227.66 千公顷上升了 23.5%，产量达到了 45.7 万吨。随着乡村振兴战略的实施，以及特色产业发展政策的支持，预计在五年之内，我国的芝麻产量还将稳步增长。

在芝麻种植期间，杂草带来的危害是这一种植过程之中不可避免的问题。农田杂草问题是农作物生产中最为常见的一种生物灾害之一。首先杂草会与农作物争夺水分、养分^[5]等资源；其次，许多杂草都是农作物病菌、细菌或害虫的中间寄主，能传播病虫害^[6]。杂草在资源、病虫害等方面间接或直接危害农作物，最终将会影响到农作物的品质与产量^[7]。而除草也将会产生额外的生产成本^[10]。芝麻田间杂草种类繁多，如有马唐、香附子、苍耳、野艾蒿等。芝麻在生产过程之中对杂草的竞争很敏感。由于芝麻在苗期的生长速度缓慢，与杂草的竞争力较低，所以更需要人为地在苗期对芝麻进行杂草的管理措施。如果在芝麻的出苗期到始花期之间不对杂草加以控制，芝麻产量可能减少 75%^[11]。

现阶段，常见的除草方式包括人工除草、机械除草与化学除草^[12]。人工除草作为最基础的除草方式，主要依靠农民在农田之中搜寻杂草，并通过自身人力来拔除或者铲除杂草，准确率较高。但由于比较依赖劳动力，而且仅适用于小范围除草，目前正逐渐被其他效率更高的除草方式取代。机械除草是农民使用农业机械设备进行操作，通过除草机械的割刀等工具来清除杂草。一般适用于整齐的田间行列或者草地之上^[13]，效率较人工除草高。但由于农田环境复杂，不同环境需要不同的除草设备，泛用性不高。化学除草则是将化学除草剂施用在杂草上，通过除草剂的化学药性来杀灭杂草。相较其他除草方式来说有着效率高，效果好，适用范围广，节约劳动力等特点^[14]，成为目前现代化农业防治杂草的最主要手段。当下使用化学除草的主要方式是向农田大面积喷洒除草剂来达到除草的目的^[15]。但是随着除草剂的大面积喷洒，不但是对资源的浪费^[16]，还会造成

农药残留、环境破坏等危害^[17]。

为了解决以上农药滥用问题,需要将容易滥用农药的施药方式从大面积的喷洒方式改进为精确施药方式,即只对杂草植株进行除草剂的施用。精准施药是精准农业当中重要的一环。精准农业^[19]作为目前世界各国农业的重点关注方向,具有很高的研究价值和应用价值。精准农业是建立在高新技术之上的高科技农业^[20],通过各类传感器来精密计算出种植农作物所需的化肥、水分、农药等资源的需求量,极大程度节约了各类原料投入,大大降低了生产成本的同时有效提高了土地资源的利用率^[21]。中国耕地面积广,耕地种类多且环境复杂,对发展精确农业有较高的需求。

对杂草的精确识别是精确施药的前提。目前国内外识别杂草主要有人工识别法、遥感监测法、光谱检测法、机器视觉法^[22]。其中,人工识别法主要依靠人工去分辨眼前的植株是属于作物或者杂草。这种方式费时费力,难以在大面积农田实施,且需要一定农业知识足以区分杂草和作物幼苗;卫星遥感图像是通过卫星遥感方式来获取农田区域的作物分布图像,在图像上来识别出作物以及杂草。然而卫星遥感图像分辨率普遍不高,适合运用在大面积高密度的农田进行杂草检测,在小面积和低密度的农田的环境之下对杂草检测的效果较差,无法满足精准农业的需求^[23];光谱检测法是通过多光谱相机获取农田图像图像,经由多光谱图片来区分出作物与杂草的差别。而多光谱设备价格昂贵,不利于普及^[24];通过机器学习法来识别杂草则需要训练一个相对应的模型来使其可以通过图像来成功区分作物和杂草^[25]。机器视觉法又分基于传统机器学习的杂草特征检测法和基于深度学习的卷积网络识别法。传统机器学习方法来检测杂草需要人为地根据作物与杂草之间存在不同的图像表现来提取相应的特征。深度学习则无需人为提取目标的特征,只需将大量带标签图像输入到模型之中,让模型自行学习图像中被标记出来的植株特征,以此达到区分作物与杂草的目的,更为方便与高效^[26]。

1.2 国内外研究现状

机器视觉主要的研究内容是通过计算机来模拟人的视觉功能,从而使其能够在客观事物的图像中提取相关信息,进行处理并加以理解,最终用于实际检测、测量和控制等任务之中^[29]。机器视觉技术的研究应用已拓展到农业领域,覆盖到农业生产品的产前、产中、收获与产后四个阶段^[30],包括了分选、加工、收获、播种、除草等各个方面^[31]。本文所涉及的正是机器视觉在农业除草方面的应用。基于传统机器学习的机器视觉和基于深度学习的机器视觉两种类型均在杂草检测方面有所表现。

1.2.1 基于传统机器学习的机器视觉在杂草检测方面的研究现状

在传统的机器视觉方面,需要人工提取提取颜色特征、形状特征、纹理特征、空间信息等特征作为检测杂草的依据^[32]。

一般来说,RGB 颜色空间是最为广泛使用的颜色空间,很适合色彩展示,但因为 R、

G、B 三个分量之间相关性很高,故不适合用于分析和分割^[33]。Tang 等人^[34]由于农田图像主要是绿色分量,将 RGB 空间转换为其他空间,利用 YCrCb 颜色空间和 Cg($Cg = G - Y$)分量描述绿色作物特征,进行不同光照条件下的绿度检测;而在 Hamuda 等人^[35]的观点中,HSV 颜色空间更符合人类的颜色感知,并且对光照变化更为稳健。通道与光照水平相关,这是自动确定光照相关阈值的良好选择;研究人员还将 HSI 和 YCrCb 颜色空间用于绿色分割^[36];为了满足颜色分布均匀性的要求,Bai 等人^[39]为了满足颜色分布均匀性的要求,选择了 Lab 颜色空间对光照变化的水稻和棉花图像进行分割;类似地,Yu 等人^[40]在其研究中建立了一个高斯混合模型,用于描述作物像素的分布,以适应室外环境。他们将不同的颜色空间组合在一起,以获得更多可用的颜色特征;朱伟星等人^[41]使用 Lab 颜色空间中的 a 作为特征量,用最大类间方差法进行阈值分割,获得与小麦交叠情况下的杂草图像。

对于植物来说,生物形态学是指植物或其任何部分的形状和结构。形态特征,特别是形状特征,对于人类专家识别植物物种起着重要作用,因此也可以用于杂草检测的图像分析^[42]。通常,形状特征可以大致分类为使用形状测量和索引的特征,以及通过分割图像的变换生成的形状描述符^[44]。形状测量包括周长、直径、短轴长度、长轴长度和面积等。而基于这些测量数据,不同的形状指数是由至少两种测量方法的简单组合而成,如形状因子^[45]、MEC^[46]、圆形度^[47]等。与基于区域的形状测量和索引相比,通过变换生成的形状因子通常部署分割区域的边界或轮廓信息并且需要复杂的计算。因此,它们通常被称为基于区域的形状描述符。胡的矩不变量(MI)是一种流行的形状描述符,它是基于形状边界和内部区域信息创建的归一化函数^[48]。此外,还有诸如傅里叶描述符^[50]、基于区域的邻接描述符^[51]等形状描述符用于杂草的检测与分类。

纹理分析是用于检测图像中目标或感兴趣区域的最重要特征之一,已广泛应用于图像处理中提取有用信息。对于纹理特征的提取,可以在特征提取的步骤之前,将图像转到不同的空间,其坐标系统具有与纹理特征密切相关的解释,常用的变换方法是曲线变换和小波变换^[52]。Chaki 等人^[54]将植物叶片灰度图像与实验确定参数的 Gabor 滤波器进行卷积,产生一组复信号,得到实部和虚部。在 Gabor 滤波过程之后,从虚信号中计算出灰度共生矩阵(GLCM),然后计算出一组基于 GLCM 的特征。与 Gabor 滤波器相比,Haar 滤波器更容易导通,Bakhshipour 等人^[55]对灰度图像进行单层 Haar 离散小波分解,得到 4 个子图像,分别代表近似图像、垂直细节、水平细节和对角细节,然后从四个子图像中提取 GLCM 纹理;Sujaritha 等人^[56]也将旋转不变小波特征用于杂草检测,基于 Radon 变换的方法是获得这些特征的可靠方法。它极大地减少了特征的数量,并能快速检测图像的各个方向。Radon 变换可以揭示旋转对输入图像和输出图像的影响,然后利用小波函数将 Radon 输出分解为不同的子带,然后计算每个子带的能量和均匀性等纹理特征。Curvelet 变换将图像分解为不同的尺度和角度,有利于特征提取;Kumar 等人^[57]和 Prema 等人^[53]对植物图像采用基于 wrapping 的 curvelet 变换,该变换是一个多尺度金

字塔，在低频水平上包含不同的方向和位置，得到了正向和反向的 curvelet 变换。然后从曲波变换后的图像中提取出棱角纹理模式，用于农作物和杂草的识别；Asnor Juraiza Ishak 等人^[58]提出了一种图像分析技术，利用 Gabor 小波和梯度场分布技术的组合来提取新的特征向量集对杂草进行分类。

基于形态和颜色特性的植物识别方法容易受到田间内和生长季节植物外观变化的影响，因此检测方法不可靠。相比之下，作物的播种方式更加稳定。对于大多数作物来说，它们是在事先模式的行中播种或种植的，空间上下文或位置信息有助于提高识别精度^[59]。对于大麦和小麦等连续播种的谷物，相邻作物之间没有明显的距离，可以通过确定作物行的中心线和边缘来有效地检测行间杂草。两行作物之间的所有绿色植物都被视为杂草。Wu 等人^[60]基于位置和边缘特征筛选行间杂草。利用像素直方图方法设置作物行中心线，利用 Roberts 边缘检测算子确定作物行边缘。从中心线开始，确定像素属于作物或杂草，直到到达作物行边缘；Liu^[61]通过三个主要步骤检测行间杂草。首先，采用列求和和一阶导数边缘检测方法确定作物行的中心部分。其次，假设行内杂草、与作物重叠或非常接近作物的杂草叶很少且可以忽略，则将每个检测到的作物行连接为一个区域。最后，通过比较作物行和杂草的面积来检测杂草，因为每个作物行是一个区域，并且该区域的面积远大于杂草的面积。可以看出，利用空间上下文检测行间杂草的关键步骤是确定作物行和行边界。已经有非常多方法来确定作物行，其中 Hough 变换经常被使用^[62]。Hough 变换是基于作物行对应计数的累积计算。它的设计是为了处理因种子萌发不良或其他因素导致作物中缺少作物植株的停种作物株系^[63]。在之后被改进为 Double Hough 变换^[64]和基于梯度的随机 Hough 变换^[65]用于杂草检测。

在提取完有效特征之后，传统机器学习方法的最后一步是使用合适的分类器为不同识别目标进行分类。李慧等人^[66]提棉花及伴生杂草的形状、纹理、颜色等特征后，使用主成分分析法减少特征向量空间维数后，使用支持向量机完成了棉花与伴生杂草的分类；唐晶磊等人^[67]利用近红外波段的光谱特性，使用阈值法完成了植株与土壤的分割，使用最大投票机制算法构造决策二叉树实现分类；Wu 等人^[68]将杂草图像转换为灰度图后做小波分解，将参数导入 BP 网络中对玉米田中常见的五种杂草进行检测；Ahmad 等人^[69]提出一种基于小波变换的杂草检测算法。利用分割算法将杂草图像进行分割后提取的最高信息系数作为杂草的特征送入 KNN 分类器来检测杂草；赵川源等人^[70]在提出一种基于多光谱图像和数据挖掘的杂草多特征检测方法时，发现 C4.5 算法的平均检测率高于 BP 算法和 SVM 算法。

1.2.2 基于深度学习的机器视觉在杂草检测方面的研究现状

传统方法中杂草特征提取主要依赖人工设计的提取器，需要有专业知识、复杂的调参过程及大量的时间，同时每个方法都是针对具体应用，其泛化能力及鲁棒性较差。而深度学习对于目标的特征提取是自动进行的，在处理了传统方法存在问题的同时，有效减少了特征工程工作量的同时并且提高了研究中分类和预测问题的性能。

Potena 等人^[71]利用两种不同的 CNN 处理 RGB 图像和近红外图像来快速准确地检测作物和杂草。使用一个轻量级的 CNN 进行快速和稳健的植被分割,然后使用一个更深层次的 CNN 对提取的像素进行作物和杂草分类,这项工作提供了一种新颖的无监督数据集汇总算法,该算法可自动从大型数据集中,挑选出信息量最大的子集用以描述原始数据集;Milioto 等人^[72]将现有植被指数与 CNN 网络相结合,将植被指数作为网络的输入进行训练来检测田间杂草,该网络是一个端到端的编解码语义分割网络,具有卷积层、池层、剩余可分离瓶颈、池索引、编码特征量和非耦合层。该方法工作频率约为 20 Hz,适用于现场在线分类。此外,所提出的方法可以作为训练集中未表示的图像的鲁棒特征提取器,只需要很少的数据来适应新的环境;Dyrmann 等人^[73]训练了一个完全基于 GoogLeNet 体系结构的 CNN,以检测遮叶谷物作物中的杂草位置,召回率为 46.3%,准确率为 86.6%。但这些方法缺乏通用性,仅限于特定的训练数据集;Jiang 和 Li^[74]提出一种基于改进深度卷积神经网络的田间棉花秧苗检测与计数算法,从多个实验田中采集到 75 个原始视频数据,模型的 F1 值达到 0.727。但是算法所用的数据集在复杂性上存在缺陷,如果在数据采集阶段,采集不同的拍摄角度、更极端的光照情况、更多遮挡和更多的植被类型,将对算法的泛化性和鲁棒性的进步有巨大帮助;Yu 等人^[75]研究了多种基于深度卷积神经网络的草坪杂草检测算法,得出 DetectiNet 的性能优于 GoogLeNet 和 VGGNet,其 F1 值大于 0.99,可有效检测多种不同生长期、生长密度和植物形态的阔叶杂草;王术波等^[76]提出一种基于卷积神经网络的杂草分类和密度测算方法,使用卷积神经网络训练数据集,使用 Softmax 回归完成 6 类植物的分类;孙俊等^[77]提出了一种空洞卷积与全局池化相结合的多尺度特征融合卷积神经网络检测模型,使用全局池化取代全连接层减少网络参数,实现作物幼苗跟杂草的检测;Huang 等人^[78]提出一种全卷积神经网络方法,利用迁移学习来提高杂草特征的提取能力,采用 Skip-architecture 结构来优化网络模型以实现杂草的实时分割检测;张乐等^[79]采用 Faster R-CNN 来检测在油菜田中被植株遮挡的杂草;彭明霞等^[80]对经典 Faster R-CNN 模型进行改进,通过融合特征金字塔网络对区域建议网络进行优化来检测棉田杂草;王红等^[81]改进了 UNet 网络,通过带有动态权重和双注意力模块的 UNet 网络来对田间杂草进行实时分割;权龙哲等^[82]在 Mask R-CNN 网络的基础上改进了主干网络、锚定框、非极大值抑制等,对玉米田杂草进行实例分割;王宇^[83]提出了 YOLOv5s 的改进模型 CABi-YOLOv5s,其对小麦田的杂草检测 AP 值达到 86.8%;李彧等^[84]使用 UNet 网络进行玉米田间杂草检测,克服阴晴光照和地膜等影响实现了对杂草的准确快速检测,其验证集的检测正确率为 96.13%;刘港^[85]研究改进了 SSD 网络,在自然环境下对甜菜田杂草检测的平均精度均值达到 88.84%;宋珂^[86]对 YOLOv3 模型进行改进,对北方旱作农田杂草进行检测,该改进模型对多种杂草的检测平均精度均值为 80.92,相较原版 YOLOv3 模型提高了 4.09%;尚文卿等^[87]基于 Faster R-CNN 模型,改进了双阈值非极大值抑制的同时将多种模型的区域建议网络进行移植,最终实现了对杂草检测 96.58%的检测精度;杨承林^[88]基于

Vision Transformer 模型, 结合了卷积神经网络的层次化结构提出了新的网络模型, 该网络模型对杂草叶片数目分类的准确性达到 74.05%。

1.2.3 机器视觉在芝麻杂草检测方面的研究现状

目前在芝麻苗期杂草检测的方面上, 机器视觉的应用并不多, 仍有较大研究的空间。S. Imran Moazzam^[89]等人提出了一个智能 SesameWeedNet-2 卷积神经网络和一个基于碎片化图像的分类方法。利用无人机收集到来自空中的芝麻田图像数据, 将这些收集到的图像分割为一张张 31×31 像素大小的碎片化图像, 再利用这些碎片化图像训练和测试所提出的模型。这种算法根据碎片化图像中可见的植被对数据集进行分类, 以提高分类效果, 可以达到 96.7 的成功率; Julie J^[90]等人针对芝麻杂草检测问题, 将 R-CNN 于支持向量机结合运用。首先使用了 R-CNN 作为特征提取器对芝麻与杂草的图像进行特征提取, 再将提取到的图像特征使用支持向量机来进行分类以达成检测芝麻与杂草的目的。所提出的方法对杂草检测的准确率可以达到 95.88%; Vivek K K^[91]等人制造了一台芝麻田除虫除草自主机器人。在目标检测方面, 该机器人使用了深度学习算法来对芝麻与杂草进行检测。算法以 TensorFlow 为框架, 以 Mobilenet SSD 模型为主体所设计。在芝麻田中对杂草检测的准确率可达到 85%。

1.3 亟待解决的问题

由上述机器视觉在芝麻、杂草检测方面的研究可知, 科研人员对芝麻与杂草的区分和检测有一定的进展。这些研究可以一定程度实现芝麻作物与杂草检测, 但仍存在一些不足。

(1)检测分类的精度较低。从上述研究中看出, 对芝麻杂草的检测精度还有待提高。其原因在于实际芝麻田间, 芝麻与杂草之间不仅有形态的差异, 杂草之间本身也是各有差异。特别是某些杂草形态不同, 其规格大小也有较大差异。此外还存在着较难检测的小规格目标。杂草之间的差异以及规格小等特点会给杂草的精确检测造成较大的影响。

(2)检测分类的速度较慢, 难以满足实时化的需求。对杂草检测的要求不仅有精度要求, 而且会有一定的速度需求。对杂草的检测主要是为了精确施药。对芝麻田中杂草的检测速度要跟得上行间施药装置的速度, 否则会影响除草效率。

(3)算法的鲁棒性不足。实际田间情况之下, 作物与杂草分布可能会出现重叠情况, 而且背景较为混杂。此外, 不同的天气、不同的光照条件下, 所获取的田间芝麻作物与杂草的图像也有区别。不同光照条件下对杂草的准确检测也会造成影响。若检测杂草的算法鲁棒性不足, 面对上述情况可能会出现检测效果差的情况。

1.4 本文主要研究内容和技术路线

本文以芝麻田中的芝麻幼苗和同时期存在的杂草作为研究对象, 旨在研究以

YOLOv4 模型为基础上能达到的检测效果更好、检测速度更快的芝麻杂草检测方案。针对实际芝麻田地中的复杂条件,在实地获取图像的同时人为增加干扰并以此建立数据集。然后通过改进现有目标检测模型,增强检测效果与效率,达到更快更准地检测复杂背景下的芝麻苗与杂草。本文的主要研究内容如下:

(1)实地采集芝麻田中芝麻苗与杂草图像;并根据实际可能出现复杂场景之下的干扰对图像进行图像增强处理,包括翻转、旋转、随机裁剪、噪声、模糊、亮度调整等。(2)以 YOLOv4 模型为基础,针对检测精度较低的问题在模型的 SPP 结构中提出了一种改进的带有逻辑模块注意力机制的池化方式。(3)为了解决杂草大小规格不一带来的检测精度降低问题,结合了 ASFF 结构改进了 YOLOv4 模型的特征融合结构。(4)在保证检测精度的同时提升检测速度,试验多种深度可分离卷积运用在特征融合结构的效果。

本课题的主要研究路线如图 1-3 所示,从当前芝麻杂草检测面临的主要问题出发,研究相应的算法,最后通过实验验证所提方法的可行性。




图 1-3 本文的研究路线图

Fig. 1-3 The research route of this paper

1.5 论文内容安排

结合本文的研究内容,整体章节安排如下,全文组织结构如图 1-4 所示。

第一章为绪论。首先介绍了选题的目的、研究背景和研究意义;接着介绍机器视觉技术;然后介绍了机器视觉算法无论是基于传统机器学习还是基于深度学习在杂草检测领域的国内外研究现状;随后介绍了机器视觉算法在芝麻杂草检测的研究现状,并基于目前方案的优缺点确定本文了的研究理论;最后回顾芝麻杂草检测相关研究成果存在的不足,并介绍了本文的主要研究内容和技术路线。

第二章采集图像制作数据集,并分析介绍了目标检测的各项性能评估指标。首先介绍了数据图像的采集工作;然后分析实际农田作业情况,如光照变化和运动模糊情况等

提出相对应的数据增强手段，制作了研究所需的数据集；最后分析介绍了目标检测的性能评估指标，包括检测精准度指标与速度指标，为下文实验操作的检测性能对比提供了便利。

第三章研究了模型检测精度优化方案。首先介绍了 YOLOv4 模型的结构与作用；然后分析注意力机制的优点以及目标规格大小的不一会对模型检测精度造成的影响；根据注意力机制的优点提出了基于局部注意力池化对模型进行检测精度优化方案，并在局部注意力池化的逻辑模块方面提出改进方案，使用结构更为复杂的逻辑模块并进行实验对比，根据实验效果对比挑选最佳逻辑模块；根据目标规格大小不一的情况提出了基于自适应空间特征融合结构对模型进行多维度检测精度优化方案。

第四章研究了模型轻量化方案。首先介绍了对模型进行轻量化的多种方式；然后基于迁移学习的模型权重提出了简化卷积计算对模型进行轻量化的方案；基于原始 YOLOv4 模型分析了普通卷积的操作产生的参数与运算量；提出了多种用于简化卷积计算的卷积、包括分组卷积、深度可分离卷积和条件参数化卷积；最后比对了各类不同卷积进行轻量化的模型参数、运算量与检测速度，根据实际检测的硬件条件选择使用不同卷积的模型轻量化方案。

第五章研究了芝麻杂草综合检测方案与芝麻杂草检测平台的搭建。首先结合了第三章与第四章中的精度优化以及轻量化对检测模型优化；将综合优化前后的模型进行检测实验，分析比对检测精度、检测速度、参数量等方面，提出了 YOLO-sesame-G 与 YOLO-sesame-G 两种芝麻杂草识别模型；将所提出的识别模型与经典模型对比体现优越性；其次搭建了芝麻杂草检测平台，硬件设备的搭建包括了图像采集设备、图像处理设备以及平台行走机构方面，软件设计方面主要为人机交互界面的设计；最后对芝麻杂草检测平台进行图像及视频检测实验，验证其可行性。

第六章对整篇论文的研究内容和创新点进行了总结，并以本论文的研究内容为基础，对本研究中存在的不足和未来研究做出了展望。




图 1-4 论文结构组织

Fig. 1-4 Structure of this paper

第二章 目标检测数据集制作与检测性能评估指标

数据集的质量是深度学习模型对目标准确检测的基础。深度学习模型通过喂入大量的所需要被检测目标的图像来获取目标图像的高低维度各类特征以达到检测出目标的结果。本研究所需的数据集在实地拍摄获取图像的同时,对这些图像进行数据增强处理,包括了翻转、旋转、噪声、模糊、亮度调整等方式。本章交代了本研究所使用到的数据集的制作,以及根据实际检测杂草过程中会受到光照的影响而采取了关于图像亮度的调整还有其他方面的数据增强手段。

2.1 田间芝麻幼苗及其同期杂草图像采集

本文主要研究芝麻苗期杂草检测方法,通过深度学习模型来检测并定位目标杂草或者作物来确定它们的分布。本文的研究对象是芝麻苗期田中的芝麻苗与同期存在的杂草。本研究所实地采集的图像来源于广西南宁市西乡塘区一农家种植田地,拍摄地点如图 2-1 所示。本研究选用大恒 MER-132-30UC-L 型工业相机及其配套镜头来采集图像,其外形如图 2-2 所示,相机参数如表 2-1 所示。采集的图像主要包括芝麻苗期的芝麻苗、同期存在的杂草以及田地的复杂背景。由于本研究后续部分计划将杂草检测平台搭建在施药机器小车上,故田间采集的图像应与搭载在施药机器人上的位置角度类似。采集图像人员通过手持相机的方式,镜头距离地面 50cm 的高度,与地面呈 80° 到 90° 的角度拍摄芝麻杂草图像。本次共计拍摄获得 866 张原始图像。



图 2-1 图像采集地点

Fig. 2-1 Image acquisition location



图 2-2 大恒 MER-132-30UC-L 型工业相机

Fig. 2-2 Daheng MER-132-30UC-L industrial camera

表 2-1 大恒 MER-132-30UC-L 型工业相机参数

Table 2-1 Parameters of Daheng MER-132-30UC-L industrial camera

规格	参数
分辨率	1292×964
帧率(fps)	43
传感器	1/3" RJ33J Global shutter CCD
像元尺寸	3.75 μm
像素深度	8 bit, 12 bit
图像数据格式	Bayer RG8, Bayer RG12
信噪比	49 dB
机械尺寸(W×H×L)	29 mm×29 mm×29 mm

2.2 图像数据预处理

将图像采集过程中所获得的 866 张原始图像经过 Photoshop 软件进行人为裁剪与筛选，将部分背景占比较大的图片分割，共储存 JPEG 格式图像 900 张。为了增强数据的多样性、加强模型的鲁棒性，对所收集到的图像进行数据增强处理，包括翻转、旋转、噪声、模糊、亮度调整等。具体方法如 2.2.1-2.2.3 所述。通过以下使用的数据增强技术，将 900 张图像扩展为 5400 张图像。而后将这些数据增强后的图像按照 8:1:1 的比例分别生成训练数据集 4320 张、验证数据集 540 张，测试数据集 540 张。训练数据集主要用于训练模型的主要参数，验证数据集一般用于调试结构的超参数以及观察模型是否发生过拟合现象，测试数据集的作用是用于验收已经训练完毕模型的泛化能力。训练数据集和验证数据集不能有任何交集。

2.2.1 图像亮度调整的数据增强

由于采集图像当天的天气为阴转多云，早晚光线变化不大，区分度较小。而实际农业杂草检测除草过程中，天气的变化和当日内时段的变化会影响芝麻杂草受到的光照强度，从而呈现到所获取的芝麻杂草图像上亮度变化问题。使用图像亮度调整的数据增强方式可以补偿由于阴天天气带来的所采集图像光照强度不够全面的问题。鉴于采集图像的天气为阴转多云，实际中还存在着亮度更高条件下的晴天和多云，以及亮度更低条件下的阴天。本研究采取两种图像亮度调整方式，一个对应晴天和多云条件下将亮度调整为 1.4 倍，另一个则对应阴天条件下将亮度调整为 0.8 倍。图 2-3 为采取的图像亮度调整。



(a)原始亮度

(b)1.4 倍亮度

(c)0.8 倍亮度

图 2-3 图像亮度调整

Fig. 2-3 Image brightness adjustment

2.2.2 图像模糊的数据增强

本研究考虑到实际杂草检测环境下，用于采集图像的工业相机或摄像头会与农药喷洒装置一起整合在同一施药机器小车上。施药机器小车在田间行驶时会有以下情形会污染工业镜头表面：路面扬尘、路面溅起的水珠、农药喷洒的水雾。上述几种情形对镜头造成污染，使镜头沾上粉尘或者水珠，影响采集图像的质量。施药机器小车在田间行驶，由于田间土地属于非铺装路面，行驶过程中会有颠簸情况发生。颠簸状态下，相机采集的图像较正常行驶状态下采集的图像会产生更多的动态模糊。动态模糊是图像中的物体快速移动所造成明显的拖动模糊轨迹。颠簸状态下相机位置高频率起伏不定，相较于被采集目标进行了快速移动。为了弥补实际采集图像情况下会出现的图片模糊问题，本研究采取了图像模糊方式来扩增数据集，如图 2-4 所示。



(a)原始图像

(b) 高斯模糊

(c)动态模糊

图 2-4 图像模糊处理

Fig. 2-4 Image blur processing

2.2.3 图像旋转、翻转和噪声的数据增强

一般情况下，在芝麻田中的芝麻幼苗与杂草的生长情况各异，叶片的方向也是多样化的，不囿于统一的方向。本研究将原始图像左右旋转 90° 来模拟叶片方向多样的情况。在此之上，还使用翻转方法，分别使用水平翻转和垂直翻转来得到芝麻杂草图像的两个反向的镜像，扩充了检测目标的姿态多样性，同时也扩增了所采集到的数据，增加了模型训练的样本。如图 2-5、图 2-6 所示。



(a)原始图像

(b)向左旋转 90° (c)向右旋转 90°

图 2-5 图像旋转处理

Fig. 2-5 Image rotation processing



(a)原始图像

(b)水平翻转

(c)垂直翻转

图 2-6 图像翻转处理

Fig. 2-6Image flip processing

除此之外，为了扩充数据集、人为增加图像中的干扰以增强模型检测训练中的鲁棒性，本研究在原始图像之中加入高斯噪声来扩充数据集，如图 2-7 所示。



(a)原始图像

(b)高斯噪声

图 2-7 图像噪声处理

Fig. 2-7 Image noise processing

本研究的图像数据经过亮度、模糊、旋转、翻转与噪声等数据增强手段处理过后，各类型处理图像数量如表 2-2 所示。

表 2-2 芝麻、杂草数据增强数量数量统计表

Table 2-2 Statistics of sesame and weed data enhancement quantity

原始图像	亮度	模糊	旋转	翻转	噪声	共计/张
900	900	900	900	900	900	5400

2.3 图像标注与数据集制作

芝麻与杂草图像采用 LabelIMG 软件手动标记，标签的形状为矩形，带标签的图片统一存储为 PASCAL VOC 格式。在本研究中所采集、制作的图像中的所有植株均被打上了标签，包括芝麻苗作物与杂草。除了芝麻苗作物之外的任何植株均被视为杂草。此外，在标记过程中，没有选用由于像素模糊不清晰的、难以界定的图像画面，防止深度学习模型在训练过程中出现过拟合现象。图 2-8 展示了为所采集图像中的植株绘制边界框的过程。




图 2-8 数据集标注

Fig. 2-8 Dataset dimensions

2.4 目标检测的性能评估指标

目标检测性能的评估主要从两方面入手，一是目标检测的检测精确与否，二是目标检测所需的时间快慢。二者均有相对应的评价指标。 mAP 与 $F1$ 得分一般用于神经网络模型在目标检测过程中对检测结果的评价，FPS 则是用于检测速度的评价。以下为性能评价的相关指标：

(1) 交并比(Intersection over Union, IoU):

目标检测过程中，目标本身的真值框与模型检测的检测框一般为矩形，这两个矩形的交集与并集之比称之为交并比。如图 2-9 所示，方框 A 与方框 B 的交集与并集之比即为交并比。通常情况下，交并比大于等于 0.5 的结果是令人可以接受的程度，即检测正确。交并比一般用于判断算法对目标检测定位的准确程度，交并比越高，代表检测框与真值框的重合程度越高，从而检测性能更强。交并比的最大值为 1，即检测框与真值框完全重合。




图 2-9 交并比概念

Fig. 2-9 Concept of IoU

(2) 检测正确的正样本(True Positive, TP):

在目标检测中,若要算法检测检测出某一目标时,该目标即为检测的正样本,其他样本视为负样本。算法要将所检测的正样本标记出来,负样本则不会有所体现。检测正确的正样本是算法检测为正样本,实际也是正样本的数量。即为正样本被正确检测出来的数量。

(3) 检测错误的正样本(False Positive, FP):

检测错误的正样本是算法检测为正样本,实际却是负样本的数量。负样本被错误检测出来,算法检测出了错的目标,即为错检。

(4) 检测正确的负样本(True Negative, TN):

检测正确的负样本是算法检测为负样本,实际也是负样本的数量。即为负样本被正确检测出来的数量,一般不会有所体现。

(5) 检测错误的负样本(False Negative, FN):

检测错误的负样本是算法检测为负样本,实际却是正样本的数量。正样本被检测为负样本,即算法没有将正样本检测标记出来,即为漏检。

关于 TP、FP、TN、FN 四个指标之间的的关系,如图 2-10 混淆矩阵所示。

预测值 \ 真值	正样本	负样本
正样本	TP	FN
负样本	FP	TN

图 2-10 TP、FP、TN、FN 之间的关系

Fig. 2-10 Relationship between TP, FP, TN and FN

(6) 精确率(Precision):

精确率又称为查准率,其定义是检测正确的正样本数量在所有检测为正样本中数量的占比,精确率越高,说明算法错检的数量越少。其计算公式为:

$$Precision = \frac{TP}{TP + FP} \quad (2-1)$$

(7) 召回率(Recall):

召回率又称为查全率,其定义是检测正确的正样本数量在所有正样本真值数量的占比,召回率越高,说明算法漏检的数量越少。其计算公式为:

$$Recall = \frac{TP}{TP + FN} \quad (2-2)$$

(8) 准确率(Accuracy):

准确率的定义是检测正确的样本比例,即为检测正确的正样本与负样本数量与总样本数量之比。一般来说,准确率越高代表模型分类效果越好,但是在正负样本不平衡的情况下,准确率指标会有较大的缺陷。其计算公式为:

$$Accuracy = \frac{TP + TN}{TP + FP + TN + FN} \quad (2-3)$$

(9) F1 分数(F1-Score):

F1 分数是兼顾了精确率和召回率的一个指标,它可以视为精确率与准确率的一种调和平均。一般情况下,一个模型的精确率越高,其召回率就会越低,反之亦然。F1 分数用于兼顾二者之间的平衡。其计算公式为:

$$F1-Score = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (2-4)$$

(10) 平均精度(Average precision, AP):

平均精度被定义为正确检测的目标数量占总目标数量的比例,其计算方式为对单一目标的 P-R 曲线求积分,一般算法检测性能越高,AP 值越高。其计算公式为:

$$AP = \int_0^1 P(R) dR \quad (2-5)$$

(11) 平均精度均值(mean Average precision, mAP):

平均精度是对单一类型目标进行检测时的一个性能指标,当检测任务需要检测不止一类目标时,便需要运用到平均精度均值。平均精度均值是将各类目标的平均精度取平均值,其计算公式为:

$$mAP = \frac{\sum_{i=1}^n AP(i)}{n} \quad (2-6)$$

其中 i 代表当前的种类, $AP(i)$ 代表当前种类的 AP 值, n 代表目标检测任务中所需要检测的总目标类别。

(12) 浮点运算次数(floating-point operations, FLOPs):

浮点运算次数, 即为网络模型的计算量, 可以用于衡量一个网络模型的复杂度。FLOPs 在卷积层的计算公式为:

$$FLOPs = H \times W \times (C_{in} \times K^2 + 1) \times C_{out} \quad (2-7)$$

其中 H 为输出特征图的高, W 为输出特征图的宽, C_{in} 为输入通道数, C_{out} 为输出的通道数, K 为卷积核的大小。FLOPs 在全连接层的计算公式为:

$$FLOPs = (2 \times I - 1) \times O \quad (2-8)$$

其中 I 为输入维度, O 为输出维度。

(13) 每秒传输帧数(Frames Per Second, FPS):

每秒传输帧率是指视频、图像等画面每秒钟传输的帧数, 就是一秒钟之内传输画面的数量。每秒传输帧数越高, 就代表画面越流畅。常见媒体设备的每秒传输帧率如电影的 FPS 为 24, 电视的 FPS 为 30。在目标检测过程中, FPS 越高, 则代表算法模型一秒钟内能检测的图像数量越多, 即检测速度越快。

2.5 本章小结

本章介绍了本研究中所使用数据集的采集与制作, 包括图像的拍摄以及制作数据集前图像的预处理。同时介绍了目标检测算法相关的性能指标, 方便下文的实验操作可以进行效果比对。

(1)首先介绍了本研究所使用的数据集的图像采集工作, 包括所使用的图像采集设备、采集方式以及进行图像采集当天的天气情况。

(2)对采集到的图像进行预处理。在考虑到实际农田光照条件以及施药小车作业时的路况条件, 对图像进行了光照调整和模糊处理。在光照调整中, 为了模拟晴天条件和阴天条件, 将图像光照调整为 1.4 倍和 0.8 倍; 在模糊处理中, 考虑到了镜头模糊以及动态模糊, 分别给图像增加了模糊以及运动模糊处理。此外, 在扩充数据集的过程中采用了旋转、翻转、噪声等数据增强手段。使用 LabelIMG 软件制作了本研究所使用的数据集。

(3)介绍了目标检测效果的性能指标, 包括了评价检测准确性的 mAP 和 F1 分数等, 和评价检测速度的 FPS。所提及的目标检测性能参数在方便下文的实验操作可以进行检测准确性和检测速度的效果比对。

第三章 基于 YOLOv4 模型芝麻苗与杂草检测精度研究

综合考虑实验硬件与芝麻杂草检测精度要求,本研究基于 YOLOv4(You Only Look Once v4)模型对芝麻苗与杂草进行了目标检测研究。在 YOLOv4 模型检测的精度方面,本研究对 YOLOv4 的空间金字塔池化(SPP)结构进行改进,引入了注意力机制来改善检测精度问题,包括了小目标杂草的检测。此外,针对杂草规格大小不一致而引发的精度下降问题,本研究将适用于处理不同维度特征的自适应空间特征融合(ASFF)结构与 YOLOv4 的特征融合部分相结合来处理这一问题。

3.1 YOLOv4 算法模型分析

目前可用于目标检测的模型可以分为两大类:一阶段模型和二阶段模型。顾名思义,二阶段模型在进行目标检测时分为两个阶段,首先将建议区域与背景分离,再对对象进行分类与定位。这种检测方式的精准度较高,但是同时所耗费的时间也较多,不能满足实时性要求。较为典型的模型包括 Faster R-CNN^[92]、Mask R-CNN^[93]等。而一阶段模型利用初始的锚定框去定位目标区域,直接对目标类型进行预测,大大缩短了目标检测所需的时间。较为典型的算法包括 SSD^[94]、RetinaNet^[95]以及 YOLO 系列^[96]算法。YOLOv4 是 YOLO 系列算法中较为成熟的版本,其在多种检测检测任务中可以较好地达到精度与速度之间的平衡。YOLOv4 的结构如图 3-1 所示,主要包括的三个部分:主干网络层(Backbone),特征融合层(Neck)和检测头(Head)。在三个主要部分之前还有一个输入端的操作。进行目标检测任务时,若向 YOLOv4 模型输入像素为 416×416 像素,RGB 格式的图像时,即输入的图像数据大小为 $416 \times 416 \times 3$,图像经过输入端的操作后进入模型主体,首先经过主干网络层进行多次卷积提取特征,然后经过空间金字塔结构进行池化后到特征融合结构进行多维特征融合,特征融合后输出 $52 \times 52 \times 256$, $26 \times 26 \times 512$, $13 \times 13 \times 1024$ 三个维度的特征,而后这三个维度的特征被送入到检测头进行分类回归从而得出检测结果。




图 3-1 YOLOv4 网络结构图
Fig. 3-1 YOLOv4 network structure diagram

3.1.1 输入端

YOLOv4 模型的输入端操作包括了 Mosaic 数据增强、自对抗训练(SAT)、标签平滑。Mosaic 数据增强方式是主要参考了 2019 年底提出的 CutMix 数据增强技术^[97]。Mosaic 数据增强使用了四张数据集中的照片采用随机缩放、随机裁剪、随机排布的方式进行拼接。这种数据增强方式极大丰富了数据集，增强模型的鲁棒性。此外由于一次计算四张图像的数据，节省了 GPU 的计算成本。自对抗训练也是一种数据增强方式，它分为两个阶段：一阶段是经由神经网络改变原始数据图像；二阶段则是训练神经网络正常地在修改过后的数据图像上执行目标检测任务。标签平滑则是一种分类问题下的正则化方式，即在模型训练时假设标签不是完全正确的，存在错误的可能性。这种方式可以避免模型过分依赖训练样本的标签，在一定程度上防止了过拟合的发生。

3.1.2 主干网络层

在 YOLOv3 主干网络的 DarkNet53 的基础之上，YOLOv4 将 DarkNet53 与 CSPNet 结构相融合提出了 CSPDarkNet53 结构作为主干网络。CSPDarkNet53 结构首先以卷积-批量标准化-Mish 激活函数(CBM)模块开始，而后接着是堆叠次数分别为 1、2、8、8、4 的五个残差模块。如图 3-1 所示，CSP 模块本身由 CBM 模块与残差模块构成，在各个小型模块之间又构成了一个大的残差结构。残差结构的设计可以使网络使模型的卷积层增加的同时还能继续提升模型的准确率。其优点是在卷积层堆叠时保证前向信息流的通常，不会丢失信息，在反向梯度流中解决梯度消失问题。CSPDarkNet53 利用这种残差结构，一部分进行卷积操作的同时，另一部分与上一部分进行卷积操作过后的特征再融合，在经过 CSP 模块后能够将输出的特征快速降维。这种方式使得网络在没有损失精度的情况下提高了网络的检测速度。SPP 结构处于网络的主干层和特征融合层之间，均有被划分到主干网络部分或是划分到特征融合部分的情况。SPP 结构是将主干网络层输出的数据特征图进行四种规格的池化操作后进行堆叠，达到扩大算法模型感受野的目的。

3.1.3 特征融合层

YOLOv4 模型的特征融合层由 FPN(Feature Pyramid Networks)结构和 PAN(Path Aggregation Network)结构构成，如图 3-2 所示。FPN^[98]结构是一种具有横向连接的自高维度向低维度进行数据流通的体系结构，同时利用了低维特征高分辨率信息和高维特征的高语义信息。其通过上采样的方式传递深层次的语义信息，与浅层的信息逐层相加，在多尺度层面构建特征金字塔结构。PAN^[99]结构则是在较低维度的层面中，利用了低维度层面的精确定位信号来增强特征金字塔结构，将位置信息与从 FPN 结构传来的高级语义特征相结合。FPN 结构与 PAN 结构的结合操作，即使用了 FPN 结构自深层传达的高级语义特征，还保留了 PAN 结构从低维度传达的强定位特征，进一步提高了特征融合的能力。




图 3-2 YOLOv4 模型的特征融合部分

Fig. 3-2 Neck part of YOLOv4 model

3.1.4 检测头

YOLOv4 预测头部分包括了 CIOU_损失函数(CIOU_Loss)以及 DIOU 非极大值抑制(DIOU_NMS)组成。CIOU_Loss 以 IoU_Loss 为基础发展而来。IoU_Loss 的计算公式为:

$$IoU_Loss = 1 - IoU \quad (3-1)$$

其中 IoU 为检测框与真值框的 IoU 值。IoU_Loss 存在两个方面的问题, 一是当 IoU 为 0 时, 即检测框与真值框不相交的情况下, 由于损失函数不可导所以无法优化这种情况; 二是当有两个大小相同的检测框所产生的 IoU 也是相同的情况下, 无法区别两种相交情况的不同。优秀的损失函数应该同时考虑到重叠面积、中心点距离和长宽比。在解决如何最小化检测框与真值框之间的归一化距离问题时, 出现了 DIOU_Loss。其中 DIOU_Loss 的计算公式为:

$$DIOU_Loss = 1 - DIOU = 1 - (IoU - \frac{Distance_C^2}{Distance_R^2}) \quad (3-2)$$

其中 $Distance_C$ 为检测框中心点与真值框中心点的欧氏距离, $Distance_R$ 为检测框与真值框的最小外接矩形的对角线距离。DIOU_Loss 考虑到了重叠面积和中心点距离, 没有考虑到长宽比。针对这一问题, CIOU_Loss 被提出。CIOU_Loss 的计算公式为:

$$CIoU_Loss = 1 - CIoU = 1 - (IoU - \frac{Distance_C^2}{Distance_R^2} - \frac{v^2}{(1 - IoU) + v}) \quad (3-3)$$

其中的 $Distance_C$ 和 $Distance_R$ 与上文 $DIoU_Loss$ 的一致, v 为考虑到检测框与真值框长宽比的影响因子, 定义为:

$$v = \frac{4}{\pi^2} (\arctan \frac{w^t}{h^t} - \arctan \frac{w^p}{h^p}) \quad (3-4)$$

其中 w^t 、 h^t 为真值框的宽和高, w^p 、 h^p 为预测值的宽和高。 $CIoU_Loss$ 包括了重叠面积、中心点距离和长宽比三方面, 使得检测框的回归速度和精度更好。

非极大值抑制一般用于检测框的筛选。在目标检测当中, 在同一个目标上可能产生大量的候选框, 大量的候选框之间存在着重叠现象, 非极大值抑制就是将冗余的候选框去除, 只留下一个效果最佳的候选框作为检测框输出。其算法流程是在检测某一目标的众多候选框中, 将置信度得分最高的候选框作为检测框输出, 其他候选框计算与该检测框的 IoU , 当 IoU 超过阈值时, 这些候选框就会被抑制。YOLOv4 中选用的 $DIoU_NMS$ 就是将 NMS 中对 IoU 的计算改为 $DIoU$ 的计算。 $DIoU$ 相对 IoU 的计算更为准确, 而由于在测试的过程中没有真值的使用, 故不需要使用带有真值信息的 $CIoU$ 。

3.2 YOLOv4 模型注意力机制的引入

注意力机制源自人类对视觉的研究。人的注意力机制是当人类在收到视觉信息时, 会选择性地去关注其中一部分信息, 同时忽略其他信息。在深度学习领域, 深度学习模型在运行时需要接收和处理大量的信息。而一般来说, 在大量冗余的数据当中只有小部分的信息是需要特别关注的。这种情况很适合注意力机制的使用。注意力机制可以视为一种资源重新分配机制, 根据所检测目标的重要性来分配资源, 重要性大的目标可以得到较多的资源, 反之亦然。机器视觉的注意力机制包括自注意力、软注意力、硬注意力等。自注意力也称为内部注意力, 是一个与单个序列的不同位置相关的注意力机制, 目的是计算序列的表达形式, 因为解码器的位置不变性, 以及在 DETR 中, 每个像素不仅仅包含数值信息, 并且每个像素的位置信息也很重要; 软注意力是一个 $[0,1]$ 间的连续分布问题, 更加关注区域或者通道, 软注意力是确定性注意力, 学习完成后可以通过网络生成, 并且是可微的, 可以通过神经网络计算出梯度并且可以前向传播和后向反馈来学习得到注意力的权重; 硬注意力根据注意力分布选择输入向量中的一个作为输出, 其选择方式其一为选择注意力分布中, 分数最大的那一项对应的输入向量作为注意力机制的输出, 其二为根据注意力分布进行随机采样, 采样结果作为注意力机制的输出。硬性注意力通过以上两种方式选择 Attention 的输出, 这会使得最终的损失函数与注意力分布之间的函数关系不可导, 导致无法使用反向传播算法训练模型, 硬性注意力通常需要使用强化学

习来进行训练。

如本章所述，在 YOLOv4 模型中，SPP 结构处于模型的主干网络层和特征融合层之间，是一个承上启下的关键部位。从 SPP 结构向后传递的特征会传遍整个特征融合层，那么在 SPP 结构上即使做出细微改进也会对后续特征融合效果造成可观的影响。在 SPP 结构上引入注意力机制可以帮助模型在提取的特征中更进一步聚焦于所感兴趣的目标区域。

3.2.1 SPP 结构

SPP 结构是空间金字塔池化结构，其结构如图 3-3(a)所示。SPP 使用卷积核大小为 1×1 、 5×5 、 9×9 和 13×13 的卷积核进行最大池化运算，再将得到的 4 个不同尺度的特征映射进行堆叠输出。最大池化如图 3-3(b)所示，其原理是将卷积核滑过的最大数值进行输出。无论输入的数据尺寸如何，SPP 可以输出固定尺寸大小的数据。此外，由于使用了多个大小不同的卷积核进行池化操作，SPP 结构具有较大感受野的同时，输出的数据具有较好的鲁棒性。




图 3-3 SPP 结构(a)与最大池化(b)示意图


Fig. 3-3 Schematic diagram of SPP structure (a) and maximum pooling (b)

在 SPP 结构中引入注意力机制，需要使用带有注意力机制的池化方式来替代最大池化。本研究在此使用了局部注意力池化来优化 SPP 结构。


3.2.2 局部注意力池化

局部注意力池化与一般使用到的池化方式不同。通常一般使用到的池化方式比如最小池化和平均池化，最小池化与最大池化对应，是选择卷积核对应的最小数值进行输出；平均池化则是将卷积核所对应的数值取平均后输出。这些池化方式是人为提前设置的，无法根据图像中出现的某些特征而改变权重。而局部注意力池化通过可学习的逻辑模块去自适应地改变卷积核的权重，不再局限于人为制作的形式，并且能够自主学习特征的

判别标准,分析在下采样过程中哪些特征比附近的其他特征更为重要。此外,在使用自主学习的逻辑模块改变卷积核权重的同时,可以人为选择其中的逻辑模块来侧重于某一些特征的表达。局部注意力池化如图 3-4 所示,图 3-4(a)展示了局部注意力池化的操作,局部注意力池化中的卷积核根据图像中对应特征的不同改变自身权重,得出特有的池化结果;图 3-4(b)展示了局部注意力池化的运算框架,其中的 G 为逻辑模块。在局部注意力运算中,为了使注意力权重非负且易于优化,对 G 进行了 $\exp(\cdot)$ 运算,即自适应注意力函数 $F(\text{Input}) = \exp(G(\text{Input}))$ 。局部重要性池化的自适应注意力函数 $F(I)$ 通过学习得到图像特征,从而在下采样过程中完成对自适应注意力权重的分配。



(a) 局部注意力池化操作



(b) 局部注意力池化框架

图 3-4 局部注意力池化示意图

Fig. 3-4 Schematic diagram of local importance pooling

3.2.3 局部注意力池化中的逻辑模块

通过逻辑模块改变自身下采样过程中的卷积核权重是局部注意力池化的特点。逻辑模块的不同,在下采样过程中会产生不同的结果。在局部注意力池化的逻辑模块可变更的条件下,可以使用多种逻辑模块来进行实验,验证不同逻辑模块的局部注意力池化对芝麻杂草检测效果的影响。本研究使用了如下几种逻辑模块验证不同逻辑模块的局部注意力池化对芝麻杂草检测效果的影响:

(1) projection 逻辑模块

Projection 逻辑模块是局部注意力池化的初始两个逻辑模块之一,其结构形式如图 3-5 所示。Projection 逻辑模块是一个最为简单的逻辑模块,它由 1×1 卷积、仿射实例

归一化和具有放大系数的 Sigmoid 函数组成。



图 3-5 Projection 逻辑模块

Fig. 3-5 Projection logic module

(2) bottleneck 逻辑模块

Bottleneck 逻辑模块也是局部注意力池化的初始两个模块之一，其结构形式如图 3-6 所示。Bottleneck 逻辑模块与 Projection 逻辑模块类似，主要部分均为卷积、归一化和激活函数构成。与 Projection 逻辑模块不同的是，bottleneck 逻辑模块使用了三个卷积、归一化、激活函数的相连，第二次使用的卷积核大小为 3×3 ，且前两次使用到的激活函数不再是具有放大系数的 sigmoid 函数，而是使用了更为简单的 ReLU 函数。




图 3-6 Bottleneck 逻辑模块

Fig. 3-6 Bottleneck logic module

(3) SE 逻辑模块

局部注意力池化的两个初始逻辑模块结构较为简单单一，对感兴趣区域的特征提取能力可能有限。本研究将其他较为复杂的注意力机制模块引入局部注意力池化中发挥逻辑模块的作用。SE 模块^[100]是一个注重通道特征信息的注意力模块，其可分为两个部分，分别是挤压和激励(Squeeze and Excitation)，其结构形式如图 3-7 所示。挤压部分包括了全局池化，这个部分使用全局平均池化生成信道统计信息，将全局空间信息压缩到信道描述符中，解决了全局信息嵌入的问题。激励部分包括了全连接层、ReLU 激活函数和 Sigmoid 激活函数，这个部分则利用了挤压操作中聚合的信息去捕获通道之间的依赖关系，使用了门控机制和 Sigmoid 激活函数去学习通道间的非线性相关作用。激励部分的两个全连接层的作用是降低模型的复杂度并提升泛化能力，第一个全连接层用于降低特征的维度，第二个全连接层用于恢复特征的维度。最后经由 Sigmoid 激活函数后得到了特征映射的通道间的权重。每一个通道都有其对应的权重。将原始输入特征与通道间特征权重相乘即得到了最终输出的特征。SE 模块在计算方面稍微增加了一点模型的复杂度和计算代价，但是其应用简单，可以直接应用到模型框架上增强其效果。本研究将 SE 模块作为逻辑模块嵌入局部注意力池化中检验其效果。图 3-7 中的 r 为降维系数，一般情况下设定为 16。





图 3-7SE 逻辑模块


Fig. 3-7SE logic module

(4) CBAM 逻辑模块


CBAM 模块^[101]是一个兼顾通道和空间的注意力模块，由两个模块构成：通道模块和空间模块，如图 3-8(a)所示。输入 CBAM 模块的特征经由通道模块卷积后与原图相乘，作为输入与空间模块再次进行卷积，得到的结果与原图相乘后输出。CBAM 的通道模块主要将注意力放在图像中有意义的信息上。在通道模块中，特征的通道维度不变，空间维度被压缩。如图 3-8(b)所示为 CBAM 的通道模块，特征 F 输入后，经过两个并列的最大池化和平均池化，分别送入 Shared MLP 层中。在 Shared MLP 层中，特征通道数被压缩为原来的若干倍后又扩张到原来的通道数，而后经过 ReLU 激活函数输出两个特征。从 Shared MLP 层输出的两个特征逐层相加之后通过 Sigmoid 激活函数输出就是通道模块所输出的特征。将通道模块输出的特征与原图相乘得到了特征 F'。CBAM 的空间模块主要是将注意力放在图像中目标的位置信息上。在空间模块中，特征的空间维度不变，通道维度被压缩。如图 3-8(c)所示为 CBAM 的空间模块，经由 CBAM 通道模块处理过后得到的特征 F' 输入后，经过并行的最大池化和平均池化后进行 Concat 拼接操作，而后通过 7×7 的卷积将特征通道数变为 1，最后通过 Sigmoid 激活函数输出，将空间模块输出的结果与特征 F' 相乘即为 CBAM 模块的输出。



(a) CBAM 模块概念



(b) CBAM 模块中的通道模块



(c) CBAM 中的空间模块

图 3-8CBAM 逻辑模块

Fig. 3-8CBAM logic module

3.3 自适应空间特征融合结构

在芝麻杂草检测过程当中，芝麻和杂草的规格不是固定大小的，不同规格的大小会给检测带来一定的困难。在机器学习过程中，规格差异较大的芝麻与杂草可能由于其个体大小而不会被正确划分。对于这种检测目标规格差异较大的问题，我们引入了空间自适应的思想。在一般情况下，一个特征图中包含着不同大小的检测对象，虽然一般的特征融合方式可以丰富整体的特征信息，但是往往会存在着不同维度之间的预测冲突。为了应对这个问题，本文引入了自适应空间特征融合结构(ASFF 结构)。

图 3-9 为 ASFF 结构。ASFF 结构可以自适应地学习不同维度特征层的权值大小，功能实现主要分为两个步骤。以维度最深的 13×13 的特征层为例，首先是调整特征大小。在图 3-9 中，需要将 26×26 的特征层和 52×52 的特征层通过最大池化来进行降采样以达到 13×13 的规格。图中蓝色指示线代表降采样。若需要从高维度特征调整为低维度特征则使用上采样操作完成，图中红色指示线代表上采样。第二步是自适应融合。通过 softmax 函数得到调整大小后特征所对应的权重，将三个特征与之对应的权重相乘后再相加，最终输出了负责大目标预测的有效特征。将 $x_{ij}^{n \rightarrow l}$ 表示在特征图上从 n 级调整到 l 级的位置 (i, j) 处的特征向量。对应的 l 级特征融合如下所示：

$$y_{ij}^l = \alpha_{ij}^l \cdot x_{ij}^{1 \rightarrow l} + \beta_{ij}^l \cdot x_{ij}^{2 \rightarrow l} + \gamma_{ij}^l \cdot x_{ij}^{3 \rightarrow l} \quad (3-1)$$

其中 y_{ij}^l 代表了输出特征映射的第 (i, j) 个向量在通道之间的映射 y^l 。 α_{ij}^l , β_{ij}^l 和 γ_{ij}^l 是三个

不同层次到层次 l 的特征图的空间重要性权重, 由网络自适应学习。 α_{ij}^l , β_{ij}^l 和 γ_{ij}^l 可以是简单的标量变量, 在所有通道中共享。此外, $\alpha_{ij}^l + \beta_{ij}^l + \gamma_{ij}^l = 1$, $\alpha_{ij}^l, \beta_{ij}^l, \gamma_{ij}^l \in [0, 1]$, α_{ij}^l 被定义为:

$$\alpha_{ij}^l = \frac{e^{\lambda_{\alpha_{ij}}^l}}{e^{\lambda_{\alpha_{ij}}^l} + e^{\lambda_{\beta_{ij}}^l} + e^{\lambda_{\gamma_{ij}}^l}} \quad (3-2)$$

其中分别以 $\lambda_{\alpha_{ij}}^l$, $\lambda_{\beta_{ij}}^l$ 和 $\lambda_{\gamma_{ij}}^l$ 作为对照参数, 利用 softmax 函数求得去定义 α_{ij}^l , β_{ij}^l 和 γ_{ij}^l 。

利用 1×1 卷积层分别从 $x^{1 \rightarrow l}$ 、 $x^{2 \rightarrow l}$ 和 $x^{3 \rightarrow l}$ 计算权重标量图 λ_{α}^l , λ_{β}^l 和 λ_{γ}^l , 并通过标准反向传播学习。该方法在每个尺度上对各个层次的特征进行自适应聚合。输出 $\{y1, y2, y3\}$ 用于按照模型的相同通道进行对象检测。




图 3-9ASFF 结构

Fig. 3-9 Adaptive Spatial Feature Fusion structure

3.4 算法模型实验环境与实验参数

本研究所使用的模型训练均在个人电脑上运行。在硬件方面, 个人电脑的操作系统为 Windows 10; 中央处理器为英特尔处理器 I5-10400F, 运行频率为 2.90GHz; 主要进行模型运算的图形处理器的型号为 Nvidia GTX 2060 SUPER, 显存容量为 8G; 个人电脑的随机存储存储器为 8G。在软件方面, 模型的运行环境为 CUDA10.2 和 CUDNN7.6.0, 开发环境为 Pycharm2020.1, 编程语言为 Python3.8, 深度学习框架为 Pytorch1.8.0。本研究的实验环境如图 3-1 所示。

表 3-1 本研究的实验硬件环境

Table 3-1 Experimental environment of this study

硬软件环境	规格型号
操作系统	Windows 10
中央处理器(CPU)	Intel core I5-10400F
图形处理器(GPU)	Nvidia GTX 2060 SUPER
随机存储存储器(RAM)	16G
运行环境	CUDA10.2 CUDNN7.6.0
开发环境	Pycharm2020.1

本研究对模型的参数进行了以下设置：输入模型图像像素大小设置为 416×416 ，Batch size 设置为 8，训练的总批次控制在 200epoch。模型训练时，保留每一代的模型权重，使用冻结训练前 100 代，初始学习率为 0.01，后 100 代训练的初始学习率为 0.001，所有 200 代的学习率均使用了余弦退火衰减法。

3.5 实验结果与分析

本章 3.2 小节介绍了将注意力机制通过局部注意力池化从 SPP 结构中引入到 YOLOv4 网络之中，并介绍了多种可发挥逻辑模块作用的注意力模块。3.3 小节介绍了适用于处理维度冲突的 ASFF 结构。将 3.2 小节的实验分为一组，将 3.3 小节的实验分为另一组，使用第 2 章所制备的数据集进行训练，并使用第 2 章所介绍的评估指标来评价改进方案的检测精度变化。

3.5.1 基于局部注意力池化在不同逻辑模块表达下对芝麻杂草检测精度的影响

本研究使用了局部注意力池化优化了 SPP 结构中的最大池化，为 YOLOv4 网络模型引入了注意力机制。将带有各不同逻辑模块的局部注意力池化 YOLOv4 模型在本研究所制备的数据集上进行训练，训练参数如 3.4 小节所述。图 3-10 是使用了不同逻辑模块局部注意力池化的 YOLOv4 模型训练过程中的 Loss 曲线，original 代表了原始未改动的 YOLOv4 模型、projection 代表使用了含有 projection 逻辑模块局部注意力池化的 YOLOv4 模型、simple 代表使用了含有 simple 逻辑模块局部注意力池化的 YOLOv4 模型、bottleneck 代表使用了含有 bottleneck 逻辑模块局部注意力池化的 YOLOv4 模型，SE 代表使用了含有 SE 逻辑模块局部注意力池化的 YOLOv4 模型，CBAM 代表使用了含有 CBAM 逻辑模块局部注意力池化的 YOLOv4 模型。这五个模型在 30epoch 之后的 Loss 值趋向稳定，在 200 个 epoch 的训练过程中均达到了收敛状态。此外，在图 3-10 中，使用了 SE 逻辑模块和 CBAM 逻辑模块的 YOLOv4 模型的 Loss 曲线在图中放大位置处比其他模型更低，说明使用了 SE 逻辑模块和 CBAM 逻辑模块的模型收敛得更快，收敛效果较好。




图 3-10 不同逻辑模块的局部注意力池化对芝麻杂草的检测效果

Fig. 3-10 Detection effect of local importance pooling of different logic modules on sesame and its weeds

图 3-11 展示了带有各不同逻辑模块的局部注意力池化 YOLOv4 模型对芝麻与杂草的检测效果，各模型对杂草的检测效果均优于对芝麻苗的检测效果。未经改动的 YOLOv4 模型对芝麻和杂草检测的平均精度分别为 86.75%和 93.64%，模型对芝麻与杂草检测的平均精度均值为 90.19%。在引入局部重要性池化后，两个局部重要性初始逻辑模块 projection 和 bottleneck 分别将模型对芝麻和杂草检测的平均精度提高至 91.97%和 90.24%，较 YOLOv4 模型提升了 1.78%的平均精度均值。精度的提升代表着通过在 SPP 结构上使用局部注意力池化引入注意力机制的方法提升了模型对芝麻与杂草的检测效果，这意味着这个方法是有效的。

而在使用额外引入的 SE 模块和 CBAM 模块作为逻辑模块之后，局部注意力池化模型可以将 YOLOv4 模型对芝麻和杂草的检测平均精度均值分别提高到 93.12%和 94.01%，相较局部注意力池化的两个初始逻辑模块有了 1%以上的提升效果。在额外引入的 SE 模块与 CBAM 模块之间，CBAM 模块作为局部注意力池化的逻辑模块达到了更好的效果，对杂草的检测平均精度 96.66%和对芝麻与杂草的检测平均精度均值 94.04%，为 5 个模型之中最高的。相较于 SE 模块只侧重与通道特征，CBAM 模块同时注重通道特征与空间特征，在检测效果上发挥了注重多种特征的优势，达到了最佳的检测效果。此外，YOLOv4 模型的参数总量为 64,363,101，参数大小为 245.53MB；带有使用 CBAM 逻辑模块局部注意力池化的 YOLOv4 模型参数总量为 64,428,735，参数大小为 245.78MB，改进后的 YOLOv4 模型参数量提升了 0.01%，计算成本的提高可以忽略不计。




图 3-11 使用不同逻辑模块局部注意力池化的 YOLOv4 模型对芝麻杂草的检测效果


Fig. 3-11 Detection effect of YOLOv4 model using local importance pooling of different logic modules on sesame and weeds

3.5.2 引入自适应空间特征融合结构 YOLOv4 模型对芝麻杂草检测精度的影响


本研究引入自适应空间特征融合结构用于解决芝麻苗与杂草规格差异过大带来的检测精度下降问题。芝麻苗与杂草规格大小差异情况如图 3-12(a)所示, 图 3-12 最左列为芝麻苗, 中间列为杂草, 最右列也为杂草。在中间列与最右列的杂草中。中间列的杂草规格较小, 在图像中小而散; 最右列的图像正中是一株规格较大的杂草, 其余则是规格一般的杂草。如图 3-12(b)所示为 YOLOv4 模型对目标规格差异大的芝麻苗与杂草的检测效果, 红色方框代表检测出来的芝麻苗, 蓝色方框代表检测出来的杂草, 黄色方框为漏检的目标。图 3-12(b)中间列图像规格较小的杂草被检测出了 11 株, 漏检了 8 株; 最右列的杂草图像也出现了 1 株漏检的情况。由此说明 YOLOv4 模型在面对目标规格差异大的任务时检测效果并不太理想。



(a) 所检测的芝麻苗与杂草目标规格差异大



(b) 引入 ASFF 结构前的检测效果



(c) 引入 ASFF 结构后的检测效果

图 3-12 模型引入 ASFF 结构前后对规格差异大的芝麻苗与杂草检测的变化

Fig. 3-12 Changes in the detection of sesame seedlings and weeds with large differences in size before and after the introduction of ASFF structure into the model

图 3-12(c)为引入自适应空间特征融合结构 YOLOv4 模型对规格差异大的芝麻苗与杂草的检测效果，图中的目标几乎都被检测出来，只有中间列图像右侧的不完整杂草株被漏检。相较图 3-12(b)中总共 10 个漏检目标，图 3-12(c)中的漏检目标只有 1 个，在引入 ASFF 结构后漏检的情况有了明显地改善，大部分规格较小的目标可以被成功检测出来。表 3-2 为 YOLOv4 模型添加自适应空间特征融合结构前后的芝麻杂草检测数据对比。添加了自适应空间特征融合结构之后的 YOLOv4 模型对芝麻苗的检测平均精度从 86.75% 上升到 90.67%，对杂草的检测平均精度从 93.64% 上升到 94.87%，总的 mAP 值从 90.19% 上升至 92.77%。虽然图 3-12 中演示了引入自适应空间特征融合结构提升了模型规模较

小的杂草目标检测精度，但是从表 3-2 数据得出自适应空间特征融合结构帮助模型对芝麻苗的检测效果提升得更高。引入了空间自适应特征融合结构的 YOLOv4 模型对检测芝麻苗的 AP 值与检测杂草的 AP 的提高，同样代表着这一用于提高精度的改进方案的有效性。此外，随着空间自适应特征融合结构的加入，YOLOv4 的参数量从 64,363,101 增至 69,802,550，参数大小从 245.53MB 增至 266.28MB，增幅为 8.45%，是一个可以接受的程度。

表 3-2 YOLOv4 模型引入自适应空间特征融合结构前后的芝麻和杂草检测数据

Table 3-2 Sesame and weed detection data before and after adding adaptive spatial feature fusion structure to YOLOv4 model

模型	检测芝麻苗的 AP 值(%)	检测杂草的 AP 值(%)	mAP(%)
YOLOv4	86.75	93.64	90.19
YOLOv4-ASFF	90.67	94.87	92.77

3.5.3 综合局部注意力池化与自适应空间特征融合模型对芝麻与杂草检测效果

本章节从提升 YOLOv4 模型对芝麻杂草检测精度入手，分别研究了局部注意力池化及不同逻辑模块对检测效果的影响以及空间自适应特征融合结构的引入对目标规格差异较大问题的优化。局部注意力池化的加入有效提高了模型对芝麻苗与杂草的检测精度，在此基础之上选用特征提取能力更为出色的 CBAM 模块作为逻辑模块可以将模型的检测精度再次提高。自适应空间特征融合结构解决了目标大小差异大带来的检测精度下降问题，在提升检测精度的同时也兼顾了对小规格目标的检测效果。本研究将两个方案结合同时引入 YOLOv4 模型，新的模型结构如图 3-13 所示，绿色方框为本研究所使用的结合局部注意力池化的 SPP 结构，蓝色方框为本研究采用的自适应空间特征融合结构。




图 3-13 针对芝麻杂草检测精度进行优化后的 YOLOv4 模型结构图

Fig. 3-13 Structure diagram of YOLOv4 model optimized for sesame and weed detection accuracy

本研究将模型各部分对检测精度进行优化的检测效果影响如表 3-3、3-4 所示，其中 SPP-LI 栏下方的 prec 代表使用了 precision 逻辑模块；bott 代表使用了 bottleneck 逻辑模块；SE 代表使用了 SE 逻辑模块；CBAM 代表了使用 CBAM 逻辑模块。原版 YOLOv4 模型对杂草和芝麻苗的平均检测精度为 93.64%和 86.75%；在使用局部注意力池化改进 SPP 结构并选用了效果最好的 CBAM 模块作为逻辑模块之后，模型对杂草和芝麻苗检测的平均精度分别提高到 96.66%和 91.35%；在原始 YOLOv4 模型上单独添加了 ASFF 结构后，模型对杂草和芝麻苗检测的平均精度分别提高到 94.87%和 90.67%。综合局部注意力机制改进与自适应特征融合结构的改进之后，模型对杂草与芝麻苗的检测平均精度可以达到最高的 97.09%和 96.50%。对 SPP 结构进行局部注意力机制优化和对模型的自适应空间特征融合优化，这两部分优化结合使用的检测性能比两部分分别进行优化的检测平均精度更高，检测效果更好。这进一步说明了本研究所提出对模型精度优化的

方案之间能够相互促进，成功提高了模型对芝麻杂草的检测性能。

表 3-3 模型各部分的优化对杂草检测性能的影响
Table 3-3 Effect of optimization of each part of the model on weed detection performance

YOLOv4	SPP-LI					Precision (%)	Recall (%)	F1	AP (%)
	prec	bott	SE	CBAM	ASFF				
√						90.70	91.41	0.91	93.64
√	√					93.47	89.45	0.91	95.07
√		√				93.85	89.45	0.92	93.32
√			√			90.30	94.53	0.92	95.00
√				√		91.73	91.02	0.91	96.66
√					√	91.41	89.31	0.90	94.87
√				√	√	95.02	96.88	0.96	97.09

表 3-4 模型各部分的优化对芝麻苗检测性能的影响
Table 3-4 Effect of optimization of each part of the model on the detection performance of sesame seedlings

YOLOv4	SPP-LI					Precision (%)	Recall (%)	F1	AP (%)
	prec	bott	SE	CBAM	ASFF				
√						86.98	75.69	0.81	86.75
√	√					87.08	78.18	0.82	88.87
√		√				85.49	76.52	0.81	87.17
√			√			87.83	81.77	0.85	91.24
√				√		87.50	83.15	0.85	91.35
√					√	82.16	83.98	0.83	90.67
√				√	√	89.27	94.20	0.92	96.50

3.6 本章小结

为了提高 YOLOv4 对芝麻苗与杂草的检测精度，本章提出了对 YOLOv4 检测精度的两个优化方案，分别在 SPP 结构和特征融合结构对模型检测精度进行优化，并实验验证了所提模型优化方案的可行性。

(1) 首先对 YOLOv4 网络结构进行了概述，分别介绍了网络各个部分的组成结构语功能。在此基础之上在网络的不同部位提出了精度改进方案。

(2) 基于注意力机制的优点、SPP 结构中信息流的重要性以及局部注意力池化的应用,提出了通过局部注意力池化将局部注意力机制从 SPP 结构中引入到 YOLOv4 模型；

并在此基础上，提出了改进局部注意力池化中逻辑模块以此来提高检测效果的方法。

(3) 分析了芝麻杂草规格差异大会导致模型检测精度下降问题，提出了选用善于处理不同维度预测冲突的自适应特征融合结构来优化模型特征融合结构的方法。

(4) 分别研究了不同逻辑模块表现下局部注意力池化对模型检测效果的影响以及是否使用自适应特征融合对模型检测效果的影响，比较了模型进行优化前后的平均检测精度以及平均检测精度均值，最后将使用了 CBAM 作为逻辑模块的局部注意力池化与自适应特征融合同时优化模型得出了最优的检测效果，成为最终模型优化选用方案。

第四章 芝麻杂草检测模型轻量化研究

深度学习模型一般来说有着较为庞大的参数量与运算量，高参数量与高运算量对搭载设备的内存与算力是一个不小的考验。为了降低网络模型的复杂度，通常的做法有轻量化网络结构与简化卷积计算方式。轻量化网络结构是对网络结构重新进行简化设计，或是将已有的模型进行剪枝与稀疏约束；简化卷积计算的方式则是在卷积层面上选用运算量较小的卷积方式。

轻量化网络结构操作通常来说会使网络结构发生改变，网络结构改变之后无法使用迁移学习的方式给网络一个较为成熟的初始权重。故本研究保留了主干网络的成熟权重，将使用简化卷积计算的方式来降低模型的复杂度。本章使用了分组卷积、深度可分离卷积和条件参数化卷积对 YOLOv4 主干网络之后的结构进行轻量化研究，在减少网络参数和运算量的同时保持网络的检测性能。

4.1 普通卷积

卷积是神经网络中最常见的操作，几乎在网络模型的任何都能发挥作用地方。卷积操作相当于是输入的特征与卷积核之间的加权求和的过程，卷积核从左到右，从上到下沿着输入特征滑动进行元素乘法，最后进行元素加法。卷积核通常大小是指定的，且是有权重的。卷积核堆叠在一起后，从二维升到了三维，便成了过滤器。在深度学习网络中，特征输入或输出的规格通常为 (N, C, H, W) 的多通道特征，对单一批次中的每一个特征映射来说，它们都是规格为 (C, H, W) 的三维数据。通过对这批数据进行卷积操作的不同，可以分为三维卷积与二维卷积：

(1) 三维卷积：

当过滤器所含的卷积核个数小于输入特征的通道数时，即进行三维卷积。三维的过滤器可以在输入特征的高、宽、通道数三个维度中移动，每次移动的卷积结果即输出一个值，当过滤器在输入特征中移动一遍之后，所有的卷积结果输出以三维的形式呈现。三维卷积操作如图 4-1 所示，紫色长方体为输入特征，蓝色正方体为 2 个 2×2 的卷积核堆叠而成的过滤器，蓝色的过滤器可以在紫色的输入特征的高、宽和通道三个维度移动，每次移动的卷积结果输出的值对应黄色长方体中的一个元素，黄色长方体即为每个过滤器操作后得到的三维输出特征。




图 4-1 三维卷积示意图

Fig. 4-1 3D convolution diagram

(2) 二维卷积:

当过滤器所含的卷积核个数等于输入特征的通道数时，即进行二维卷积。二维的过滤器仅可以在输入特征的高、宽两个维度中移动，同样将每次移动的卷积结果输出，过滤器在输入特征中移动一遍之后，所有卷积输出结果为一个单通道数据，即为二维数据。由于过滤器只能在输入的三维特征中沿高、宽两个维度进行移动，因此得名二维卷积，也就是图像处理中最为常用的标准二维卷积。二维卷积操作如图 4-2 所示，紫色长方体为输入特征，蓝色长方体为过滤器，其中所含的卷积核个数与输入特征的通道数一致。蓝色的过滤器仅可以在紫色的输入特征的高、宽两个维度移动，每次移动的卷积结果输出的值对应黄色长方体中的一个元素，黄色长方体即为每个过滤器操作后得到的二维输出特征。




图 4-2 二维卷积示意图

Fig. 4-2 2D convolution diagram

在普通卷积层中，卷积操作通常是使用标准二维卷积操作。普通卷积层的参数量如公式 4-1 所示:

$$params-Conv = C_{out} \times (C_{in} \times K^2 + 1) \quad (4-1)$$

其中 C_{in} 为输入通道数, C_{out} 为输出的通道数, K 为卷积核的大小, 卷积核形状应为正方形, 否则 K^2 应为卷积核的宽乘以卷积核的高。若此时有一大小为 9×9 , 通道数为 3 的图像, 卷积核大小是 4×4 , 输出的通道数为 12, 那么经过卷积操作过后的输出特征图的规格为 $6 \times 6 \times 12$ 。此时该卷积层的参数值为 $12 \times (3 \times 4^2 + 1) = 588$ 。

普通卷积层的运算量通常使用 FLOPs 来衡量, 即用浮点运算量来衡量一个卷积层的运算量。通常来说, 一个普通卷积层的 FLOPs 如公式 4-2 所示:

$$FLOPs-Conv = H \times W \times (C_{in} \times K^2 + 1) \times C_{out} \quad (4-2)$$

其中 H 为输出特征图的高, W 为输出特征图的宽, C_{in} 为输入通道数, C_{out} 为输出的通道数, K 为卷积核的大小, 卷积核形状为正方形。若此时与上文一致条件下, 则该卷积层的 FLOPs 值为 $6 \times 6 \times (3 \times 4^2 + 1) \times 12 = 21168$ 。

4.2 分组卷积

分局卷积是在普通卷积的基础之上, 对特征的输入和输出的关系之间进行了改善了一种卷积方式, 其与普通卷积的区别如图 4-3 所示。分组卷积与普通卷积的最大局别在于普通卷积每一幅输出特征图像均由所有的输入特征图像卷积得来, 而分组卷积将输入特征图像经过预先划分为 g 组, 然后在每一组之间进行普通卷积操作。经过分组后再单独进行运算之后, 卷积层的参数量与运算量会有明显的下降, 如图 4-3 所示两种卷积方式中, 输入特征与输出特征之间的连线便可视为一次运算, 分局卷积当中的连接线相较普通卷积中的连接线来说疏密程度有一个明显的稀疏, 运算量在直观感受上出现了明显的下降。

分组卷积在卷积层上的运用, 在输入特征与输出特征的规格相同的情况之下, 减少了参数量与运算量, 根据所分的组数 g , 可以减少到近乎于原来的 $\frac{1}{g}$ 。分组卷积的卷积层参数量如公式 4-3 所示:

$$params-GConv = C_{out} \times \left(\frac{C_{in}}{g} \times K^2 + 1 \right) \quad (4-3)$$

其中 C_{in} 为输入通道数, C_{out} 为输出的通道数, g 为分组卷积所划分的组数, K 为卷积核的大小, 卷积核形状应为正方形, 否则 K^2 应为卷积核的宽乘以卷积核的高。若此时有一大小为 9×9 , 通道数为 3 的图像, 卷积核大小是 4×4 , 输出的通道数为 12, 分组卷积划分为 3 组, 经过此卷积操作过后的输出特征图的规格为 $6 \times 6 \times 12$ 。此时该分组卷积层的参数值为 $12 \times \left(\frac{3}{3} \times 4^2 + 1 \right) = 196$ 。

分组卷积层的 FLOPs 计算如公式 4-4 所示:

$$FLOPs-GConv = H \times W \times \left(\frac{C_{in}}{g} \times K^2 + 1 \right) \times C_{out} \quad (4-4)$$

其中 H 为输出特征图的高, W 为输出特征图的宽, C_{in} 为输入通道数, C_{out} 为输出的通道数, g 为分组卷积所划分的组数, K 为卷积核的大小, 卷积核形状为正方形。若此时与上文一致条件下, 则该卷积层的 FLOPs 值为 $6 \times 6 \times \left(\frac{3}{3} \times 4^2 + 1 \right) \times 12 = 7344$ 。




图 4-3 普通卷积(左)与分组卷积(右)示意图

Fig. 4-3 General convolution (left) and group convolution (right)

4.3 深度可分离卷积

深度可分离卷积具体操作如图 4-4 所示, 该卷积过程可分为两部分, 逐通道卷积与逐点卷积。逐通道卷积可以视为一种情况特殊的分组卷积。在逐通道卷积中, 记输入的特征图像的通道数为 C_{in} , 被分为 g 组, 输出的特征图像通道数为 C_{out} , 其中 $C_{in} = C_{out} = g$, 即为在逐通道卷积过程中分组数等于输入通道数等于输出通道数。输入特征图像在特征通道维度方向由有 C_{in} 个通道数的多通道数据拆分为 C_{in} 个单通道数据, 每一个单通道数据再由一个卷积核进行卷积操作过后得到相对应的单通道数据。在逐通道卷积的最后, 将这 C_{in} 个单通道数据叠加之后还原回有 C_{in} 个通道数的多通道数据。在逐通道卷积过后, 输入特征图像的高、宽两个维度已经发生了改变, 要将输入特征图像的通道数达到输出图像的通道数仅需要将逐通道卷积过后得到的特征图像进行逐点卷积。逐点卷积是使用若干个 1×1 的卷积来改变输入特征的通道数。将逐通道卷积得出的输出特征与 1×1 的卷积核进行标准二维卷积, 其中 1×1 的卷积核个数为 C_{out} 个, 既能得到有 C_{out} 个通道数的多通道数据。




图 4-4 深度可分离卷积示意图

Fig. 4-4 Schematic diagram of depthwise separable convolution

由于深度可分离卷积的过程由两部分组成，所以其参数量与运算量是由两部分相加得来。深度可分离卷积的参数量如公式 4-5 所示：

$$params-DSConv = C_{in} \times (K^2 + C_{out}) \quad (4-5)$$

其中其中 C_{in} 为输入通道数， C_{out} 为输出的通道数， K 为卷积核的大小，卷积核形状应为正方形，否则 K^2 应为卷积核的宽乘以卷积核的高。深度可分离卷积的参数量近乎等于普通卷积参数量的 $\frac{1}{C_{out}} + \frac{1}{K^2}$ 倍。若此时有一大小为 9×9 ，通道数为 3 的图像，卷积核大小是 4×4 ，输出的通道数为 12，经过此卷积操作过后的输出特征图的规格为 $6 \times 6 \times 12$ 。此时该深度可分离卷积层的参数值为 $4^2 \times 3 + 3 \times 12 = 84$ 。

深度可分离卷积层的 FLOPs 计算如公式 4-6 所示：

$$FLOPs-DSConv = H \times W \times C_{in} \times (K^2 + C_{out}) \quad (4-6)$$

其中 H 为输出特征图的高， W 为输出特征图的宽， C_{in} 为输入通道数， C_{out} 为输出的通道数， K 为卷积核的大小，卷积核形状为正方形。若此时与上文一致条件下，则该卷积层的 FLOPs 值为 $6 \times 6 \times 3 \times (4^2 + 12) = 3024$ 。

4.4 条件参数化卷积

普通卷积对所有输入的特征使用了相同的卷积核参数，当算法模型规模较大、通道数较多时，普通卷积的操作会使算法模型的计算量增多。条件参数化卷积^[102]可以针对

每一批次中的每个输入特征来定制卷积核,使得模型在规模较大时能保持快速的运算速度。如图 4-5(a)所示,卷积核作为输入示例的函数被计算。参数化卷积的卷积核参数根据输入特征进行动态变换,卷积核参数化如公式 4-7 所示:

$$Output(x) = \sigma((\alpha_1 \cdot W_1 + \dots + \alpha_n \cdot W_n) * x) \quad (4-7)$$

其中 $\alpha_i = r_i(x)$ 是使用了学习参数的路由函数计算得出相关于实例的权重函数, n 为专家数, σ 是激活函数。当调整卷积层以使用条件参数化卷积时,每个卷积核 W_i 与普通卷积中的卷积核具有相同的维度数。




图 4-5 条件参数化卷积与其卷积层

Fig. 4-5 Conditional parametric convolution and its convolution layer

普通卷积层的体积会随着输入通道数、输出通道数和卷积核规格的增大而增大,参数也会随之成比例扩大。在条件参数化卷积层进行卷积之前,将每个示例的卷积核计算为 n 个专家的线性组合,每个卷积核只需要被计算一次便可应用到输入图像中的多个部位。 n 增加的同时,网络模型体积增加,但是增加的每个参数的运算量下降,只需 1 的额外的 FLOPs。

条件参数化卷积层在数学层面上等同于计算成本较多的专家线性混合公式,其中每个专家对应于静态卷积,如图 4-5(b)所示。条件参数化卷积层在数学层面的表达为公式 4-8 所示:

$$\sigma((\alpha_1 \cdot W_1 + \dots + \alpha_n \cdot W_n) * x) = \sigma(\alpha_1 (W_1 * x) + \dots + \alpha_n (W_n * x)) \quad (4-8)$$

条件参数化卷积与 n 个专家的线性混合专家公式具有相同的参数量,但是计算效率

更高，因为只需要计算一个计算成本较多的公式。此外，路由函数对条件参数化卷积的性能影响较大，如果路由函数对于所有示例均为常数时，则条件参数化卷积与普通卷积层有相同的容量。路由函数由全局平均池化、完全连接层与 Sigmoid 激活函数组成，如公式 4-9 所示：

$$r(x) = \text{Sigmoid}(\text{GlobalAveragePool}(x)R) \quad (4-9)$$

其中 R 为汇集的输入特征映射到 n 个专家权重的学习路由权重的矩阵。该路由函数允许使用全局上下文对局部运算进行自适应。

4.5 简化卷积计算的轻量化实验

本章从 4.1 节到 4.4 节分别介绍了普通卷积、分组卷积、深度可分离卷积与条件参数化卷积的运作形式、参数量与计算量。其中分组卷积、深度可分离卷积和条件参数化卷积相较普通卷积来说在参数量或计算量层面上占有优势。本研究将分组卷积、深度可分离卷积和条件参数化卷积分别引入 YOLOv4 模型的特征融合结构进行实验，利用上述卷积方式完成模型的卷积工作，并使用第 2 章所介绍的评估指标来评价改进方案的模型轻量化效果。

如图 4-6 所示为本章针对卷积计算简化后的 YOLOv4 模型结构图，其中红色方框的区域为本章进行卷积计算简化的部位。进行卷积计算简化改进的部位均为卷积-标准化-激活函数模块的多次连用，在这类体积较为庞大的结构中进行计算简化可以节省较大部分的参数量与计算量。此外，进行卷积计算简化的部位均处于主干网络之外，不会对模型主干网络的成熟初始权重产生影响。




图 4-6 针对卷积计算简化后的 YOLOv4 模型结构图

Fig. 4-6 Structure diagram of YOLOv4 model after simplified convolution calculation

4.6 实验结果与讨论

使用不同卷积对模型进行卷积计算简化改进的实验结果如表 4-1 所示。使用了普通卷积的网络模型，即原始的 YOLOv4 模型，在本研究使用的训练集上训练后的模型权重大小为 243.92MB，浮点运算数为 29.98GB。

使用分组卷积($g=2、4、8$)简化模型的卷积计算方式之后,模型参数权重大小分别降低了 22.9%、34.3%和 40.1%,模型的浮点运算数也分别减少了 15.9%、23.7%和 27.7%。模型运算量的减少提高了模型的检测速度,使得模型芝麻苗与杂草检测的 FPS 分别提升了 15.8%、17.1%和 19.3%。组数 $g=8$ 为分组卷积对模型轻量化效果最佳的值。

使用深度可分离卷积去简化模型的卷积计算方式后，模型参数权重大小降低了 33.5%，模型的浮点运算数减少了 23.6%。模型的检测速度提高，模型对芝麻苗与杂草检测的 FPS 也分别提升了 13.3%。分组卷积和深度可分离卷积的实验结果与理论分析一致，降低了模型的参数量与运算量，以此提高了模型的检测速度。

使用条件参数化卷积去简化模型计算方式之后，模型参数权重大小增加了 91.7%。但是由于条件参数化卷积的特性，在参数量增加的同时拥有了更为高效的计算效率，使得模型的浮点运算数只有原始 YOLOv4 模型的 68.4%。得益于运算量的大幅降低，使用条件参数化卷积优化模型之后的 FPS 较原先提升了 25.5%，达到了 46.2。

表 4-1 不同卷积对模型卷积计算简化的影响

Table 4-1 Effect of different convolutions on simplification of model convolution calculation

Conv type	Params	Weight(MB)	FLOPs(G)	FPS
普通卷积	63,943,071	243.92	29.98	36.8
分组卷积($g=2$)	49,312,159	188.11	25.24	42.6
分组卷积($g=4$)	41,996,703	160.20	22.87	43.1
分组卷积($g=8$)	38,338,975	146.25	21.68	43.9
深度可分离卷积	42,516,767	162.19	22.91	41.7
条件参数化卷积	122,559,035	467.53	20.50	46.2

此外，使用各类卷积去简化模型卷积计算的优化方式在降低了模型的运算量后，同样保持了原先的检测性能。图 4-7 展示使用了不同卷积方式进行卷积计算简化之后的 YOLOv4 模型对芝麻杂草的检测效果，图中的绿色虚线为原始 YOLOv4 对作物的检测平均精度、橙色虚线为原始 YOLOv4 模型对杂草的检测平均精度、紫色虚线为原始 YOLOv4 模型对芝麻苗与杂草的检测平均精度均值。使用分组卷积、深度可分离卷积和条件参数化卷积之后的模型对芝麻与杂草的检测性能与原始 YOLOv4 模型差距较小，mAP 的最大差值仅为 1.38%，且改进的 5 个模型中有 4 个模型的 mAP 值大于原始 YOLOv4 的 mAP 值。

综合以上实验数据，在本章轻量化实验中，分组卷积($g=8$)对模型的参数量的轻量化效果最佳大幅减少模型参数量的同时也减少了运算量；条件参数化卷积对模型运算量的降低以及检测速度的提高两方面达到最佳的效果，而代价是增加了近乎一倍的参数量。实际检测时可以根据硬件条件来选择使用分组卷积($g=8$)或是条件参数化卷积来对模型进行轻量化处理。




图 4-7 使用了不同卷积方式优化的 YOLOv4 模型对芝麻杂草的检测效果

Fig. 4-7 Detection effect of YOLOv4 model with different convolution methods on sesame weeds

4.7 本章小结

为了降低网络复杂度，提升算法运算速度，本章研究了在卷积层面上进行简化的模型轻量化实验。通过分析普通卷积、分组卷积、深度可分离卷积和条件参数化卷积的理论计算方式，结合了实际情况，提出了将上述卷积方式对模型的主干网络之外的结构进行卷积简化方案，并进行实验验证了所提出卷积简化方案的可行性。

(1)首先对原始模型中的普通卷积进行分析，并在此基础之上分析了分组卷积、深度可分离卷积和条件参数化卷积相较于普通卷积在参数量、运算量和计算效率层面上的优势。并以此提出了使用上述卷积方式对算法模型进行卷积计算方式的简化，达到模型轻量化的效果。

(2)基于本研究所使用的算法模型，结合了迁移学习给模型带来的益处，提出了使用上述卷积方式在算法模型上进行改进的部位。

(3)以四种不同卷积方式的算法模型对芝麻杂草的检测进行实验，比较各个算法直接的参数量、运算量与检测性能。最终可以根据实际检测的侧重点来选择使用分组卷积 ($g=8$)或者条件参数化卷积作为最终模型轻量化的简化方式。

第五章 芝麻杂草检测方案实验分析与平台搭建

在前面的章节中分别对芝麻杂草检测模型进行了检测精度研究和轻量化研究，提出了局部注意力池化和自适应空间特征融合结构的精度优化方案以及简化卷积计算的模型轻量化方案。本章结合了精度优化方案和轻量化方案，对 YOLOv4 改进模型进行实验分析，对算法模型进行验证与比对；并使用改进算法从硬件和软件两个方面搭建芝麻杂草检测平台。

5.1 芝麻杂草检测方案实验分析

5.1.1 检测模型精度改进与轻量化前后实验对比

在上文中，局部注意力池化与自适应空间特征融合结构的联合使用提升了模型对芝麻苗与杂草的检测精度；分组卷积和条件参数化卷积分别在参数量和运算量对模型进行了轻量化优化。综合上述精度优化和轻量化的芝麻杂草检测模型如图 5-1 所示。




图 5-1 精度优化和轻量化后的芝麻杂草检测模型

Fig. 5-1 Sesame seedling and weed detection model after precision optimization and lightweight

相较于原始 YOLOv4 模型，图 5-1 中绿色方框代表本研究所改进的带有局部注意力

机制的 SPP 结构,红色方框代表简化卷积计算方式,蓝色方框代表引入自适应空间特征融合结构。

表 5-1 为精度优化和轻量化后芝麻杂草检测模型与原始 YOLOv4 模型的检测性能对比。其中 YOLO-sesame 代表经过精度优化后的 YOLOv4 模型, YOLO-sesame-G 代表使用了分组卷积的精度优化模型, YOLO-sesame-C 代表使用了条件参数化卷积的精度优化模型。YOLO-sesame 模型是原始 YOLOv4 模型进行本文第三章所述精度优化后的改进模型,其相较于原始 YOLOv4 模型对芝麻苗与杂草的检测 AP 值、F1 值和 mAP 值均有提升,代价是增加了模型的参数量和运算量; YOLO-sesame-G 模型和 YOLO-sesame-C 模型是在 YOLO-sesame 模型的基础上,使用了分组卷积和条件参数化卷积进行轻量化改进的模型。分组卷积和条件参数化卷积在第四章中对原始 YOLOv4 模型的改进达到了轻量化的效果,可以达到降低模型参数量、运算量和提升模型检测 FPS 值的效果。YOLO-sesame-G 模型在 YOLO-sesame 模型的基础上使用分组卷积对模型进行了轻量化改进,模型权重从 264.92MB 降低到 167.25MB,减少了 36.9%的权重;运算量从 31.76G 降低到 23.47G,减少了 26.1%的运算量;FPS 从 35.9 提升至 41.5,提高了 15.6%的检测速度。YOLO-sesame-C 模型在 YOLO-sesame 模型的基础上使用条件参数化卷积对模型进行了轻量化改进,运算量从 31.76G 降低到 22.28G,减少了 29.9%的运算量;FPS 从 35.9 提升至 42.7,提高了 19.0%的检测速度;由于条件参数化卷积的特性,模型权重从 264.92MB 增加到 488.53MB,增加了 84.4%的参数量。

表 5-1 精度优化和轻量化前后的 YOLOv4 检测性能对比

Table 5-1 Comparison of YOLOv4 detection performance before and after precision optimization and lightweight

模型	AP(%)		F1		mAP(%)	Weight(MB)	FLOPs(G)	FPS
	Crop	Weed	Crop	Weed				
YOLOv4	86.75	93.64	0.81	0.91	90.19	243.92	29.98	36.8
YOLO-sesame	96.50	97.09	0.92	0.96	96.79	264.92	31.76	35.9
YOLO-sesame-G	95.37	96.27	0.90	0.97	95.82	167.25	23.47	41.5
YOLO-sesame-C	95.81	98.45	0.91	0.98	97.13	488.53	22.28	42.7

对表 5-1 中的数据进行了雷达图分析,分析结果图 5-2 所示。YOLOv4-sesame-C 模型在 mAP、F1 均值、FLOPs 和 FPS 四个方面表现最佳,但是在模型权重方面表现较差; YOLOv4-sesame-G 模型在这五个方面的表现较为均衡,在各项指标达到优秀的情况下没有短板。YOLOv4-sesame-G 模型在原始 YOLOv4 模型基础上就芝麻苗与杂草的检测上来说,提升了各方面的性能,可以适用于大部分对芝麻苗与杂草的检测场景;相较于 YOLOv4-sesame-G 模型来说, YOLOv4-sesame-C 可以达成更好的检测效果,以及更少的运算量,但是代价是更多的模型参数量,其适用于设备条件较好,且需要追求更快的检测速度以及更准确的检测效果的检测场景。




图 5-2 精度优化和轻量化前后的 YOLOv4 检测性能对比雷达图

Fig. 5-2 Comparison radar chart of YOLOv4 detection performance before and after precision optimization and lightweight

5.1.2 与其他模型检测效果对比


将本研究改进的算法模型与其他经典算法进行比较,例如 Fast R-CNN、SSD、EfficientNet-d0、YOLOv3 等。各个模型的训练均使用了统一训练集与测试集,经过相同世代的训练后进行芝麻与杂草的检测。表 5-2 为各个不同模型对芝麻与杂草的检测效果,表中展示了本研究改进的算法和其他经典算法在芝麻与杂草检测中的准确率、召回率、AP、F1、mAP 和 FPS 上的对比。其中 Fast R-CNN 和 SSD 的 mAP 小于 80%,检测精度尚且不足。EfficientDet-d0 检测的 mAP 为 80.64%,FPS 为 25.6,检测精度尚可,检测速度有待提高,整体表现平庸。在 YOLO 系列中,YOLOv3 的 mAP 仅为 65.81%,是所有模型中表现最差的。YOLOv4 和 YOLOv4-tiny 的 mAP 分别为 90.49%和 81.71%,表现较为出色。这两个模型的 FPS 分别为 36.8 和 160.5。由于 YOLOv4-tiny 是轻量化模型,达到了较快的检测速度同时舍弃了特征提取效果较好的复杂主干网络。本研究改进的 YOLO-sesame-G 和 YOLO-sesame-C 模型的 mAP 值分别为 95.82%和 97.13%,在所有模型之中达到了最佳的检测精度。而 FPS 分别为 41.5 和 42.7,虽然比不过 YOLOv4-tiny 轻量化模型的检测速度,但是由于镜头与相机获取图像的帧数限制,也足够运用于实际中作物与杂草的检测之中。

表 5-2 不同算法模型对芝麻与杂草的检测效果


Table 5-2 Detection effect of different algorithm models on sesame and weeds

模型	Precision(%)		Recall(%)		AP(%)		F1		mAP (%)	FPS
	Crop	Weed	Crop	Weed	Crop	Weed	Crop	Weed		
Fast R-CNN	50.86	71.29	78.07	87.80	65.74	80.18	0.62	0.79	72.96	11.3
EfficientDet-d0	75.70	88.61	71.05	85.37	73.42	84.23	0.73	0.87	78.83	79.7
SSD	64.43	90.00	84.21	76.83	78.82	82.46	0.73	0.83	80.64	25.6
YOLOv3	91.67	88.17	45.58	64.06	60.44	71.18	0.61	0.74	65.81	47.5
YOLOv4	86.98	90.70	75.69	91.41	86.75	93.64	0.81	0.91	90.19	36.8
YOLOv4-tiny	72.97	83.54	71.05	80.49	76.59	86.83	0.72	0.82	81.71	160.5
YOLO-sesame-G	90.34	90.11	92.98	94.23	95.37	96.27	0.90	0.97	95.82	41.5
YOLO-sesame-C	90.65	90.80	92.86	95.11	95.81	98.45	0.91	0.98	97.13	42.7

图 5-3 为不同算法模型对芝麻与杂草的检测 P-R 曲线图，本研究提出的改进模型 YOLO-sesame-G 和 YOLO-sesame-C 的 P-R 曲线可以包络其他模型的 P-R 曲线，改进模型的 P-R 曲线与坐标轴围成的面积与其他模型相比较大。P-R 曲线与坐标轴围成的面积为算法检测的 mAP 值，图 5-3 中改进模型的表现也符合表 5-2 中改进模型 YOLO-sesame-G 与 YOLO-sesame-C 的 mAP 值与其他算法模型相比更为优秀。因此，YOLO-sesame-G 模型与 YOLO-sesame-C 模型与上述经典模型相比具有更高的平均精度。



(a)不同模型算法检测芝麻的 P-R 图像



(b)不同模型算法检测杂草的 P-R 图像

图 5-3 不同模型算法检测芝麻与杂草的 P-R 图像

Fig. 5-3 P-R image detection of sesame and weeds using different model algorithms

图 5-4 为不同模型算法对一张同时存在较多小目标杂草的复杂图像进行检测的效果图，表 5-3 为不同模型算法对该图检测得到的目标置信度与检测框的顶点坐标。




图 5-4 不同模型算法对一张同时存在较多小目标杂草的复杂图像进行检测的效果

Fig. 5-4 The detection effect of different model algorithms on a complex image with multiple small target weeds simultaneously

图 5-4 中的红色方框为模型检测出的小目标杂草，黄色方框为模型在检测中遗漏的小目标杂草。同一个红色方框中包括了多株临近的小目标杂草也被视为检测成功。在这种复杂环境的小目标检测中，各类模型表现各有差异。Fast R-CNN 模型检测出了绝大部分目标，仅遗漏的一个目标，且置信度较高，但是由于其为二阶段模型，检测所需时间较长，不能满足实时检测的需求；SSD 模型遗漏了将近一半的目标，检测出了 7 个目标，遗漏了 5 个目标；EfficientDet-d0 模型检测出的目标齐全，但是置信度较低，检测出的平均置信度为 0.70；YOLOv3 模型在这复杂环境下的小目标检测任务是失败的，不但仅检测出一个目标，而且置信度只有 0.56；YOLOv4 模型在这种复杂场景的小目标检测效果也不佳，遗漏了 8 个目标；令人意外的是 YOLOv4-tiny 在这种复杂场景的小目标检测任务中表现得比 YOLOv4 效果好，在检测中仅遗漏了 4 个目标，但是由于其为轻量化模型，检测表现的置信度较低，检测出的平均置信度仅为 0.63；YOLO-sesame-G 和 YOLO-sesame-C 模型由于采取了相同的精度优化方案，两个模型检测效果相仿，在此次检测中遗漏了 3 个小目标杂草，但是它们检测的平均置信度分别为 0.93 和 0.94，达到了最优表现。

表 5-3 不同模型对小目标检测得到的目标置信度与检测框顶点坐标

Table 5-3 Target confidence and detection frame vertex coordinates obtained by different models for small target detection

模型	置信度、检测框顶点坐标(左上、右下)
Fast R-CNN	0.99,(74,126),(193,197);0.99,(450,55),(502,139);0.99,(140,361),(196,405); 0.97,(426,379),(466,417);0.95(331,183),(366,211);0.93(221,71),(256,138); 0.84,(357,324),(390,356);0.83,(119,429),(160,465);0.83,(5,355),(21,406); 0.75,(391,63),(483,131);0.68,(3,436),(18,486);0.64,(10,361),(37,398); 0.63,(384,7),(419,45);0.55,(75,139),(116,185);0.52,(147,129),(190,184)
SSD	0.84,(220,73),(252,136);0.82,(425,378),(468,425);0.81,(399,60),(500,130); 0.81,(141,362),(193,399);0.78,(119,123),(187,194);0.64,(447,63),(492,132); 0.61,(325,182),(364,223)
EfficientDet-d0	0.85,(330,184),(362,220);0.78,(220,71),(253,139);0.76,(118,436),(147,466); 0.76,(430,382),(465,428);0.76,(442,57),(496,126);0.75,(139,364),(193,404); 0.73,(76,141),(114,180);0.68,(132,125),(184,193);0.63,(358,329),(386,357); 0.63,(393,8),(418,45);0.62,(174,423),(203,450);0.61,(4,366),(31,396); 0.56,(397,88),(427,116)
YOLOv3	0.56,(74,138),(115,181)
YOLOv4	0.78,(444,55),(497,130);0.76,(68,135),(121,186);0.75,(327,178),(366,226); 0.67,(424,375),(470,438);0.65,(133,357),(194,405);0.59,(114,429),(153,471)
YOLOv4-tiny	0.92,(331,184),(362,220);0.88,(441,51),(495,129);0.81,(137,362),(191,407); 0.68,(119,436),(148,464);0.68,(351,327),(390,361);0.66,(424,378),(467,432); 0.65,(176,423),(203,451);0.63,(3,363),(29,403);0.57,(216,74),(251,107); 0.53,(120,133),(181,197)
YOLO-sesame-G	1.00,(389,58),(498,134);0.98,(68,129),(121,186);0.98,(139,354),(202,408); 0.98,(419,377),(470,433);0.97,(213,66),(202,143);0.97,(325,180),(367,225); 0.96,(349,320),(393,363);0.56,(0,358),(34,402)
YOLO-sesame-C	0.99,(326,179),(365,225);0.99,(68,124),(189,195);0.99,(389,54),(511,134); 0.99,(139,354),(198,408);0.99,(419,376),(470,430);0.94,(213,66),(262,143); 0.93,(349,318),(395,365);0.67,(0,361),(35,402)

5.1.3 芝麻杂草检测方案总结

基于以上分析对比,本研究提出改进 YOLOv4 模型方案,对模型进行了精度优化与轻量化的改进研究,提出的 YOLO-sesame-G 与 YOLO-sesame-C 模型对芝麻与杂草的检测效果优于大部分经典目标检测模型,能够达到较高的检测精度和较快的检测速度,对芝麻与杂草的检测 mAP 值可以达到 97.13%、检测速度可以达到 42.7FPS。本研究提出

的模型可以在芝麻杂草实时检测系统中发挥较好的作用。

5.2 芝麻杂草检测平台搭建

上文通过实验比对,验证了本研究提出芝麻杂草检测方案相较其他经典模型对芝麻杂草检测的优越性。本小节基于本研究的芝麻杂草检测方案搭建了一个芝麻杂草检测平台,该检测平台由硬件和软件两个方面组成。通过所搭建的芝麻杂草检测平台的实验进一步验证本研究芝麻杂草检测方案的可行性。

5.2.1 图像采集硬件设备

在芝麻杂草检测中,平台采集到的图像质量对检测结果有较大的影响,优质的图像可以帮助检测平台得出较为准确的结果。由于工业相机有着性能稳定、不易损坏、帧率高、可长时间工作等优点可以满足本研究所需的采集图像工作,故本研究使用工业相机作为图像采集硬件设备。工业相机的传感器有 CCD(Charge Coupled Device)和 CMOS(Complementary Metal Oxide Semiconductor)两大类,而 CCD 工业相机相较于 CMOS 工业相机有更高的灵敏度、更高的分辨率以及更低的噪声干扰。综合上述考量,本研究选用大恒 MER-132-30UC-L 型工业相机及其配套的 M1224-MPW2 型镜头作为本研究的图像采集硬件设备。工业相机及其配套镜头如图 5-5 所示,相机参数如表 2-1 所示,镜头参数如表 5-4 所示。



图 5-5 大恒 MER-132-30UC-L 型工业相机(左)与 M1224-MPW2 型镜头(右)

Fig. 5-5 Daheng MER-132-30UC-L industrial camera (left) and M1224-MPW2 lens (right)

表 5-4M1224-MPW2 型镜头参数
Table 5-4 Parameters of M1224-MPW2 lens

规格	参数
品牌	Computer
焦距	12 mm
最大光圈比	1:2.4
最大画面尺寸	8.8 mm×6.6 mm(Φ11 mm)
光圈工作范围	F2.4~F16C
聚焦工作范围	0.1m~Inf.
工作温度	-10°C~+50°C
后焦距	14.4 mm(WD=300 mm)
后法兰长度	17.526mm
外观尺寸	Φ29 mm×42.68 mm
重量	72g

5.2.2 图像处理平台

图像处理平台是芝麻杂草检测平台的核心。图像处理平台通过 USB 接口与图像采集硬件设备连接,在获取工业相机所采集图像的同时,对这些图像进行实时处理分析,动态检测出芝麻苗与杂草的位置。本研究使用的图像处理平台如图 5-6 所示的笔记本电脑。该笔记本电脑的处理器为 Intel(R) Core(TM) i5-6300HQ CPU @2.30GHz,运行内存 12GB,操作系统为 Windows 10。该笔记本电脑装载了芝麻杂草检测系统所需的图像采集和图像处理软件。




图 5-6 图像处理平台

Fig. 5-6 Image processing platform

5.2.3 检测平台行走机构

芝麻作物通常为行垄种植,在机械起垄双行种植的方式下,垄面宽 55cm,且垄高一般为 10-15cm^[103]。除此之外,在实际农田环境中土的壤路面不平整,行走机构的行进

环境较差，因此需要检测平台行走机构拥有较强的稳定性。本研究采用履带式小车作为检测平台行走机构，如图 5-7 所示，其具体性能参数如表 5-5 所示。



图 5-7 履带式小车

Fig. 5-7 Crawler type traveling mechanism



图 5-8 遥控器

Fig. 5-8 Remote control

表 5-5 履带式小车性能参数

Table 5-5 Performance parameters of crawler traveling mechanism

规格	参数
型号	TR500 重量级履带式坦克底盘车
外形尺寸(L × W ×H)	68 cm×44.5 cm×20.5 cm
内仓尺寸(L × W ×H)	38 cm×25 cm×12.5 cm
平台自重	15.8 kg
运行速度	0-1 m/s
电机	永磁直流电机(JCF76L-24120-210R)
电机额定功率	120 W
电机额定电压	DC24 V
电机转速	210 rpm
额定电流	启动电流为 10A，运行电流为 5A
履带宽度	8 cm
履带材质	橡胶履带，内置拉力层
最大爬坡度	40°
最大载重	50 kg
最大越障	13 cm
续航时常	60 min
减震设计	10 组独立悬挂减震件

履带式小车宽 44.5cm 小于垄面宽度 55cm，不会与芝麻作物发生碰撞；行进速度 0-1m/s 可以保证采集图像的清晰度；履带宽度 8cm，且有减震结构，可以保证小车行进的稳定性；小车额定功率 120W，最大爬坡度 40°，适用于绝大部分行垄坡度；小车最大载重 50kg，满足作为图像处理平台的笔记本电脑与图像采集设备的重量。履带式小车

可以通过设置定速向前行驶，也可以通过遥控器来控制履带式小车的行动。遥控器如图 5-8 所示。将图像采集硬件设备、图像处理平台以及检测平台行走机构搭建在一起后效果如图 5-9 所示。



图 5-9 芝麻杂草检测平台硬件机构

Fig. 5-9 Hardware structure of sesame and weed detection platform

5.2.4 检测软件系统设计

本研究基于 Qt Designer 和 pyqt5 开发了芝麻杂草检测平台的检测软件系统，检测软件系统的人机交互界面如图 5-10 所示。芝麻杂草检测系统的人机交互界面主要由 5 个模块构成：

(1) 算法模型选择模块：有两个算法模型可供选择：YOLO-sesame-C 和 YOLO-sesame-G。YOLO-sesame-C 的泛用性较强，各方面表现平衡；YOLO-sesame-G 运算量小、检测时间短，但是参数量较大。

(2) 检测方式选择模块：支持三种检测方式，包括图像检测、视频检测与摄像头检测。图像与视频均为本地文件，摄像头检测需要设备连接上摄像头后方可进行实时检测，否则会提示摄像头不存在。

(3) 本地文件选择模块：当用户在检测方式选择中选择了图像或者视频检测后，需要在该模块中选择检测所需的图片或者视频，这些文件均为本地文件。选择文件之后会在该模块底部显示当前选择文件的路径。

(4) 检测操作模块：该模块用于控制芝麻杂草检测系统的工作过程，在上述模块均正确操作后，点击开始检测进行检测过程；在检测过程中点击暂停检测会暂停系统的工作；点击结束检测会结束当前检测过程并关闭检测系统。在检测过程当中点击保存当前图片/视频可以将当前检测的图片、视频结果保存到本地。

(5)检测结果显示模块：右侧的白色区域为检测结果显示模块，在检测系统工作时显示当前系统所检测的实时画面。

用户使用该芝麻杂草检测系统时，按照从上到下的顺序，首先应选择所使用的算法模型，选择后点击初始化模型；在算法模型选择完毕后选择本次检测的检测方式；若选择图像检测或者视频检测之后，应按照所需检测的文件点击图像选择或者视频选择，选择完成之后，会显示出所选择的本地文件路径；若选择摄像头检测则跳过上述环节；然后点击开始检测按钮开始本次的检测，系统检测的实时结果显示在界面右侧窗口；在检测开始后，用户可以点击暂停检测来暂停本次检测过程，取消暂停则点击开始检测；在检测过程中，用户点击保存当前图片/视频可以将本次图片检测、视频检测的结果保存在本地；点击结束检测按钮结束本次检测，检测软件关闭。芝麻杂草检测系统工作流程如图 5-11 所示。




图 5-10 芝麻杂草检测系统人机交互界面

Fig. 5-10 Human machine interface for sesame and weed detectionsystem




图 5-11 芝麻杂草检测系统工作流程

Fig. 5-11 Workflow of sesame and weed detection system

5.3 芝麻杂草检测平台实验结果与分析

芝麻杂草检测平台的图像输入分为图像与视频两种类型。当输入为图像时，检测平台直接对所输入的图像进行芝麻杂草的检测；当输入为视频时，检测平台将视频按帧拆分为独立的图像进行检测。图 5-12 所示的是芝麻杂草检测平台的选择本地文件图像或者视频进行检测的界面。




图 5-12 选择本地图像或视频

Fig. 5-12 Select a local image or video

图 5-13 为芝麻杂草检测平台对图像的检测的效果，所检测的图像目标较为清晰。检测平台对该目标做出了正确的检测结果，同时给予了 0.99 和 1.00 的较高置信度，符合芝麻杂草检测模型的预期效果。图 5-14 为芝麻杂草检测平台对视频的检测效果，由于所检测的视频非静止拍摄，在视觉效果上略有模糊，然而检测平台仍正确将其检测为杂草，并给予了 0.98 的高置信度，同样符合芝麻杂草检测模型的预期效果。且在视频检测的过程中，检测工作进行得较为流畅，符合了对芝麻杂草检测平台的实时性要求。

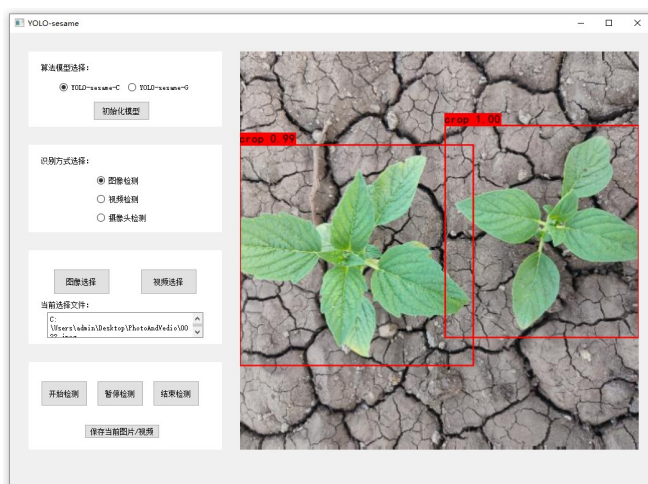


图 5-13 图像检测

Fig. 5-13 Results of image detection




图 5-14 视频检测

Fig. 5-14 Results of video detection

图 5-15 为芝麻杂草检测平台对不同光照以及模糊条件下的小目标图像检测的效果。图 5-15(a)、图 5-15(b)、图 5-15(c)、图 5-15(d)分别为待检查的原始图像、亮度增强图像、亮度减弱图像以及动态模糊处理图像。图 5-15(e)、图 5-15(f)、图 5-15(g)、图 5-15(h)分别为芝麻杂草检测平台对原始图像、亮度增强图像、亮度减弱图像以及动态模糊处理图像进行检测的检测结果。对原始图像的检测效果与图 5-4(g)的检测效果相同，芝麻杂草检测平台检测出了绝大部分目标，仅遗漏了 3 个小目标杂草，且保持了较高水平的置信度；芝麻杂草检测平台对亮度增强图像和亮度减弱图像的检测效果与原始图像的检测效果相似，检测出的小目标杂草位置一致；在动态模糊处理的图像上，芝麻杂草检测平台同样检测出了大部分的小目标杂草，但检测效果相较原始图像有所下降，检测出的小目标杂草少了 2 个，置信度也略有降低。

根据以上实验结果表明，芝麻杂草检测平台可以有效检测出原始图像、亮度调整图像和模糊处理图像中的杂草目标，并且对于较难检测出的小目标也有效果，达到了芝麻杂草检测平台的预期检测效果。除此之外，芝麻杂草检测平台在检测精度方面与检测速度方面达到了平衡。




图 5-15 芝麻杂草检测平台对不同光照及模糊效果下的小目标图像检测效果

Fig. 5-15 The detection effect of sesame weed detection platform on small target images under different lighting and blurring effects

5.4 本章小结

本章综合前两章对芝麻杂草检测模型的检测精度研究及轻量化研究，提出了芝麻杂草检测方案，并进行实验验证检测方案的效果。而后根据所提出的芝麻杂草检测方案，搭建了芝麻杂草检测平台，其中包括了检测平台的硬件部分与软件部分。

(1)首先将第三章提出了检测精度优化改进与第四章提出的轻量化改进相结合，对其进行实验验证这两部分优化操作结合后检测模型的性能变化；对比实验结果，提出了 YOLO-sesame-G 和 YOLO-sesame-C 两种芝麻杂草检测方案；其中 YOLO-sesame-G 各项性能较为均衡，YOLO-sesame-C 检测速度快、模型运算量小，但是模型参数量大；将所提出的两个方案与其他经典模型的检测效果相对比得出其自身的优越性。

(2)根据实际芝麻杂草检测的工作环境选定芝麻杂草检测平台的图像采集硬件设备、图像处理平台与检测平台行走机构，搭建检测平台；基于 Qt Designer 和 pyqt5 开发了芝麻杂草检测平台的检测软件系统，并介绍了人际交互页面各个模块功能以及检测流程。

(3)根据芝麻杂草检测平台的输入形式，使用图像和视频的方式输入到检测平台中进行检测实验；验证芝麻杂草检测平台对图像和视频检测过程中的检测精度以及检测速度对芝麻杂草检测平台的图像、视频识别效果进行评估，验证检测方案的可行性。

第六章 总结与展望

6.1 总结

本文以机器视觉和深度学习为基础,对芝麻苗与杂草的检测方法进行研究。基于 YOLOv4 算法模型实现了对芝麻与杂草的检测。并在 YOLOv4 模型的基础上进行了精度优化与轻量化设计,而后将精度优化与轻量化两者相结合一同优化 YOLOv4 模型;最终对其进行实验对比分析,根据实验分析结果提出了两个芝麻杂草检测模型;研究设计了芝麻杂草检测平台,包含了软件与硬件两个方面;本论文得出的主要研究结论如下:

(1)采集芝麻苗与杂草的图像制作数据集,并根据实际农田作业环境对其做出动态模糊、光照强度等方式的图像增强。构建了总计 5400 张图像的数据集,其中包括 4320 张图像组成的训练集、540 张图像组成的验证集和 540 张图像组成的测试集。用此自制数据集来满足神经网络模型的训练和测试需求。

(2)基于注意力机制改进的 YOLOv4 模型以实现检测精度优化的效果。由于 SPP 结构处于模型结构中承上启下的节点,于是将其作为引入注意力机制的部位;在 SPP 结构中使用局部注意力池化替代最大池化;局部注意力池化中的逻辑模块可以起到注意力机制的作用;在现有的逻辑模块 projection 块和 bottleneck 块基础之上额外将 SE 块和 CBAM 块作为逻辑模块运用到局部注意力池化之中。实验结果表明使用了 CBAM 作为逻辑模块的改进模型检测芝麻与杂草的 mAP 值为 94.01%,比原始 YOLOv4 模型高了 3.82%;检测芝麻的 AP 值为 91.35%,检测杂草的 AP 值为 96.66%,分别比原始 YOLOv4 模型高了 4.60%和 3.02%。

(3)基于多尺度特征融合结构改进的 YOLOv4 模型进一步实现精度优化的效果。检测目标大小规格不一造成模型检测精度下降,使用自适应空间特征融合结构来应对这一维度冲突问题。在 YOLOv4 的特征融合层与检测头之间引入了自适应特征融合结构。实验结果表明,使用了自适应空间特征融合结构改进的模型检测芝麻与杂草的 mAP 值为 92.77%,比原始 YOLOv4 模型提高了 2.58%,且对于存在目标大小差异较大的图像有了更优秀的检测效果。综合了注意力机制和多尺度特征融合结构改进的 YOLO-sesame 模型,对芝麻与杂草检测的 mAP 值达到 96.79%,比原始 YOLOv4 模型高了 6.6%。

(4)对算法模型进行轻量化以达到更快的检测速度。利用简化卷积计算的方式来减少神经网络中的卷积产生的计算量,从而提升检测速度。在原始 YOLOv4 使用普通卷积的基础之上,分别使用分组卷积、深度可分离卷积和条件参数化卷积三种卷积方式去替换网络模型中的普通卷积。实验结果表明,使用了条件参数化卷积的模型 FPS 值为 46.2,比原始 YOLOv4 模型提高了 25.5%;使用了分组卷积($g=8$)的模型 FPS 值为 43.9,比原始 YOLOv4 模型提高了 19.3%。且使用条件参数化卷积与分组卷积($g=8$)进行模型轻量化后,模型的检测精度并未下降。

综合了模型精度优化与模型轻量化后,提出 YOLO-sesame-G 和 YOLO-sesame-C 模型。其中 YOLO-sesame-G 模型检测芝麻与杂草的 mAP 值为 95.82%,比原始 YOLOv4 模型高了 5.63%;FPS 值为 41.5,比原始 YOLOv4 模型提高了 12.8%。YOLO-sesame-C 模型检测芝麻与杂草的 mAP 值为 97.13%,比原始 YOLOv4 模型高了 6.94%;FPS 值为 42.7,比原始 YOLOv4 模型提高了 16%。

6.2 论文主要创新点

(1)在引入注意力机制方面,本文提出在 YOLOv4 模型的 SPP 结构上使用局部注意力池化替代最大池化的方案,在完成池化操作的同时引入注意力机制。除此之外,在局部注意力池化的现有逻辑模块 projection 块和 bottleneck 块的基础上,将 SE 块和 CBAM 块作为逻辑模块运用到局部注意力池化之中,有效提升了检测精度。

(2)针对目标大小规格不一所导致的检测精度下降问题,本文将自适应特征融合结构与 YOLOv4 模型的特征融合层相结合,在改善维度冲突的同时有效提升了在目标规格大小不一情况下的检测精度。

(3)将简化卷积计算作为模型轻量化的方式,在模型使用普通卷积的基础之上运用了分组卷积、深度可分离卷积和条件参数卷积分别对模型进行了轻量化改进。进行轻量化改进后模型的运算量、参数量下降,从而使模型的检测速度提升。

6.3 展望

芝麻杂草检测平台的研究是对芝麻田间杂草进行精确施药的前提,对杂草的精确识别有助于对其进行精确施药。研究和开发芝麻杂草检测平台,对降低生产成本、保护环境等面均有重大意义,可以为我国农业机械化和智能化发展提供理论依据。本研究利用机器视觉对杂草目标进行检测与定位,未来的研究工作还可能包括:

(1)本研究将芝麻农田中所有品类的杂草没有进行区分,统一视为一类。在未来的工作中,可以将杂草品类进行细分,实现不同的杂草使用不同的除草剂进行处理。这种方式可以增强处理不同种类杂草的针对性。

(2)本研究对芝麻苗与杂草均进行了检测,其中杂草检测为了精确施药,芝麻苗的检测目前还没有明确应用。在未来的工作中,可以在对芝麻苗的检测过程中增加一个流程,即对检测出的芝麻苗再检测其是否存在缺陷,并根据检测结果采取纠正措施。

(3)本研究对算法模型进行了轻量化,但轻量化程度不够。在未来的工作中,可以对算法模型进行更深层次的轻量化处理,使其在保持一定检测精度的同时可以在较低级别的硬件上工作。

参考文献

- [1] Anilakumar,K. R., Pal, A., Khanum, F., Bawa, A. S. Nutritional, medicinal and industrial uses of sesame (*Sesamum indicum* L.) seeds-an overview[J]. *Agriculturae Conspectus Scientificus*, 2010, 75(4), 159-168.
- [2] 宋高翔,张艳,陶宇,王杰梅.芝麻生理功效研究综述[J].粮食与食品工业,2017,24(03):38-40+44.
- [3] 兰福森 ,兰玺彬.芝麻虽小功效大[J].福建农业,2004(02):33.
- [4] 华经产业研究院.2022-2027 年中国芝麻行业市场运行现状及投资规划建议报告[R/OL].(2021-11-08)[2023-01-01].
<https://www.huaon.com/channel/agriculture/761049.html>.
- [5] 赵爱民.浅析农田杂草的危害及其分类[J].农业与技术,2013,33(07):140.
- [6] 金环宇,田平.农田杂草的危害及防除措施[J].种业导刊,2008(06):30-31.
- [7] 王勇,姚沁,任亚峰等.茶园杂草危害的防控现状及治理策略的探讨[J].中国农学通报,2018,34(18):138-150.
- [8] 杨绍才 . 耿马县贺派乡蔗园杂草危害状况及防除措施 [J]. 广西糖业,2018,No.100(03):8-11.
- [9] 王喜民.夏玉米田杂草危害及综合防治分析[J].农业与技术,2016,36(16):103.
- [10] 张琨,王新宇,王志强.田间杂草的危害及防治技术[J].现代农业,2011(09):40-41.
- [11] Bhadauria, Nisha, Arora, Asha, Yadav, K.S. Effect of weed management practices on seed yield and nutrient uptake in sesame[J]. *Indian Journal of Weed Science*, 2012.
- [12] Zhu J , Wang J , Ditommaso A , et al. Weed research status, challenges, and opportunities in China[J]. *Crop Protection*, 2018:S0261219418300255.
- [13] 马克明.机械式苗间除草装置与技术研究[J].河北农机,2021,274(04):5-6.
- [14] 吕威 ,董黎 ,孙宇涵 ,李云 . 浅谈国内外杂草控制方法 [J]. 中国农学通报,2018,34(11):34-39.
- [15] 吴兰兰. 基于数字图像处理的玉米苗期田间杂草的识别研究[D].华中农业大学,2010.
- [16] 隋海霞.杂草化感作用对粮食作物影响的研究进展[J].吉林农业,2014(23):16.
- [17] 李清涵,王姣,敖若寅.玉米地杂草出苗规律及化学除草方法[J].植物医生,2018,31(09):54-55.
- [18] Ueji, M., & Inao, K. Rice paddy field herbicides and their effects on the environment and ecosystems. *Weed Biology and Management*, 2001, 1(1), 71-79.
- [19] Dcr A , Rw B , Mw B , et al. Agriculture 4.0: Making it work for people, production, and the planet[J]. *Land Use Policy*,2021(100), 104933.
- [20] 柴颖 ,宋伟 ,陈红丹 . 分析我国精准农业推广现状 [J]. 农机使用与维修

- 修,2021,No.298(06):55-56.
- [21] 王华,王建东.何谓精准农业[J].山东农机化,2003(01):23.
- [22] 颜秉忠.机器视觉技术在玉米苗期杂草识别中的应用[J].农机化研究,2018,40(03):212-216.
- [23] 蒙继华,吴炳方,杜鑫等.遥感在精准农业中的应用进展及展望[J].国土资源遥感,2011,No.90(03):1-7.
- [24] 兰玉彬,邓小玲,曾国亮.无人机农业遥感在农作物病虫害诊断应用研究进展[J].智慧农业,2019,1(02):1-19.
- [25] 杨涛,李晓晓.机器视觉技术在现代农业生产中的研究进展[J].中国农机化学报,2021,42(03):171-181.DOI:10.13733/j.jcam.issn.2095-5553.2021.03.024.
- [26] 赵娜.基于机器视觉的田间杂草识别技术研究[J].无线互联科技,2016(23):141-142.
- [27] F LÓPEZ-GRANADOS. Weed detection for site-specific weed management: mapping and real-time approaches[J]. Weed Research, 2011, 51(1):1-11.
- [28] Adrian C , Carlos S , Alejandro R R , et al. A Review of Deep Learning Methods and Applications for Unmanned Aerial Vehicles[J]. Journal of Sensors, 2017, 2017:1-13.
- [29] 段峰,王耀南,雷晓峰,吴立钊,谭文.机器视觉技术及其应用综述[J].自动化博览,2002(03):62-64.
- [30] 陈建能,张国凤.计算机视觉技术在农业中的应用及展望[J].甘肃农业大学学报,2003(02):248-253.
- [31] 邓继忠,张泰岭,石江.机器视觉技术在农业机械中的应用[J].农机化研究,2001(02):91-93.
- [32] Wang A , Zhang W , Wei X . A review on weed detection using ground-based machine vision and image processing techniques[J]. Computers and Electronics in Agriculture, 2019, 158(2019):226-240.
- [33] Cheng H D , Jiang X H , Sun Y , et al. Color image segmentation: Advances and prospects[J]. Pattern Recognition, 2001, 34(12):2259-2281.
- [34] Tang J L , Chen X Q , Miao R H , et al. Weed detection using image processing under different illumination for site-specific areas spraying[J]. Computers & Electronics in Agriculture, 2016, 122:103-111.
- [35] Hamuda E , Ginley B M , Glavin M , et al. Automatic crop detection under field conditions using the HSV colour space and morphological operations[J]. Computers & Electronics in Agriculture, 2017, 133(Complete):97-107.
- [36] Li N , Grift T E , Yuan T , et al. Image processing for crop/weed discrimination in fields with high weed pressure[C]// 2016.
- [37] Liu. DEVELOPMENT OF A MACHINE VISION SYSTEM FOR WEED DETECTION

- DURING BOTH OF OFF-SEASON AND IN-SEASON IN BROADACRE NO-TILLAGE CROPPING LANDS[J]. American Journal of Agricultural & Biological Sciences, 2014, 9(2):174-193.
- [38] Sabzi S , Abbaspour-Gilandeh Y , G García-Mateos. A fast and accurate expert system for weed identification in potato crops using metaheuristic algorithms[J]. Computers in Industry, 2018, 98:80-89.
- [39] Xiaodong, Bai, Zhiguo, et al. Vegetation segmentation robust to illumination variations based on clustering and morphology modelling[J]. Biosystems Engineering, 2014.
- [40] Yu Z , Li C , Shi G . Environmentally adaptive crop extraction for agricultural automation using super-pixel and LAB Gaussian model[C]// Pattern Recognition and Computer Vision. 2018.
- [41] 朱伟兴,金飞剑,谈蓉蓉.综合颜色和形态特征的小麦田杂草识别方法[J].计算机应用,2007(11):2870-2872+2876.
- [42] Slaughter D C , Giles D K , Downey D . Autonomous robotic weed control systems: A review[J]. Computers & Electronics in Agriculture, 2008, 61(1):63-78..
- [43] Weis, Martin and Sökefeld, Markus. Detection and Identification of Weeds[J]. FRAM-ZIRAL, 2010.
- [44] Brown R B , Noble S D . Site-specific weed management: sensing requirements— what do we need to see?[J]. Weed Science, 2005, 53(2):252-258.
- [45] Ahmed F , Al-Mamun H A , Bari A , et al. Classification of crops and weeds from digital images: A support vector machine approach[J]. Crop Protection, 2012, 40(3):98–104.
- [46] Lottes P , Hoeferlin M , Sander S , et al. An effective classification system for separating sugar beets and weeds for precision farming applications[C]// IEEE International Conference on Robotics and Automation. IEEE, 2016.
- [47] Mathanker S K , Weckler P R , Taylor R K , et al. Adaboost and Support Vector Machine Classifiers for Automatic Weed Control: Canola and Wheat[C]// Pittsburgh, Pennsylvania, June 20-june. 2010.
- [48] Bakhshipour A , Jafari A . Evaluation of support vector machine and artificial neural networks in weed detection using shape features[J]. Computers & Electronics in Agriculture, 2018, 145:153-160.
- [49] Hu M K . Visual Pattern Recognition by Moment Invariants[J]. Information Theory, IRE Transactions on, 1962, 8(2):179-187.
- [50] Luís A.M. Pereira, Nakamura R Y M , Souza G F S D , et al. Aquatic weed automatic classification using machine learning techniques[J]. Computers & Electronics in

- Agriculture, 2012, 87(none):56-63.
- [51] Tannouche A , Sbai K , Rahmoune M , et al. A Fast and Efficient Shape Descriptor for an Advanced Weed Type Classification Approach[J]. International Journal of Electrical and Computer Engineering, 2016, 6(3):1168.
- [52] Materka A , Strzelecki M . Texture Analysis Methods - A Review[J]. institute of electronics technical university of lodz, 1998.
- [53] Prema P , Murugan D . A Novel Angular Texture Pattern (ATP) Extraction Method for Crop and Weed Discrimination Using Curvelet Transformation[J]. Electronic Letters on Computer Vision and Image Analysis, 2016, 15(1):27.
- [54] Chaki J , Parekh R , Bhattacharya S . Plant leaf recognition using texture and shape features with neural classifiers[J]. Pattern Recognition Letters, 2015, 58(Complete):61-68.
- [55] Adel, Bakhshipour, Abdolabbas, et al. Weed segmentation using texture features extracted from wavelet sub-images[J]. Biosystems Engineering, 2017, 157:1-12.
- [56] Sujaritha M , Annadurai S , Satheeshkumar J , et al. Weed detecting robot in sugarcane fields using fuzzy real time classifier[J]. Computers & Electronics in Agriculture, 2017, 134:160-171.
- [57] Kumar D A , Prema P . A NOVEL WRAPPING CURVELET TRANSFORMATION BASED ANGULAR TEXTURE PATTERN (WCTATP) EXTRACTION METHOD FOR WEED IDENTIFICATION[J]. Ictact Journal on Image & Video Processing, 2016, 06(03):1192-1206.
- [58] Ishak A J , Hussain A , Mustafa M M . Weed image classification using Gabor wavelet and gradient field distribution[J]. Computers & Electronics in Agriculture, 2009, 66(1):53-61.
- [59] Midtby H S , ?strand, Bj?rn, J?Rgensen O , et al. Upper limit for context-based crop classification in robotic weeding applications[J]. Biosystems Engineering, 2016:183-192.
- [60] Wu X , Xu W , Song Y , et al. A Detection Method of Weed in Wheat Field on Machine Vision[J]. Procedia Engineering, 2011, 15(none):1998-2003.
- [61] Liu. DEVELOPMENT OF A MACHINE VISION SYSTEM FOR WEED DETECTION DURING BOTH OF OFF-SEASON AND IN-SEASON IN BROADACRE NO-TILLAGE CROPPING LANDS[J]. American Journal of Agricultural & Biological Sciences, 2014, 9(2):174-193.
- [62] Jones G , C Gée, Truchetet F . Assessment of an inter-row weed infestation rate on simulated agronomic images[J]. Computers & Electronics in Agriculture, 2018, 67(1-2):43-50.

- [63] Romeo J , Pajares G , Montalvo M , et al. Crop Row Detection in Maize Fields Inspired on the Human Visual Perception[J]. The Scientific World Journal, 2012, 2012(1):484390.
- [64] Ch. Gée, Bossu J , Jones G , et al. Crop/weed discrimination in perspective agronomic images[J]. Computers & Electronics in Agriculture, 2008, 60(1):49-59.
- [65] Ji R , Qi L . Crop-row detection algorithm based on Random Hough Transformation[J]. Mathematical and Computer Modelling, 2011, 54(3-4):1016-1020.
- [66] 李慧,祁力钧,张建华,冀荣华.基于PCA-SVM的棉花出苗期杂草类型识别[J].农业机械学报,2012,43(09):184-189+196.
- [67] 唐晶磊, 何东健, 景旭,等. 基于 SVM 的可见/近红外光的玉米和杂草的多类识别[J]. 红外与毫米波学报, 2011, 30(2):7.
- [68] Wu L L , Wen Y X , Deng X Y , et al. Identification of weed/corn using BP network based on wavelet features and fractal dimension[J]. Scientific Research & Essays, 2009, 4(11):1194-1200.
- [69] Ahmad I , Siddiqi M H , Fatima I , et al. Weed classification based on Haar wavelet transform via k-Nearest Neighbor (k-NN) for real-time automatic sprayer control system[C]// International Conference on Ubiquitous Information Management & Communication. ACM, 2011.
- [70] 赵川源, 何东健, 乔永亮. 基于多光谱图像和数据挖掘的多特征杂草识别方法[J]. 农业工程学报, 2013, 29(2):7.
- [71] Potena C , Nardi D , Pretto A . Fast and Accurate Crop and Weed Identification with Summarized Train Sets for Precision Agriculture[C]// International Conference on Intelligent Autonomous Systems. 2017.
- [72] Milioto A , Lottes P , Stachniss C . Real-time Semantic Segmentation of Crop and Weed for Precision Agriculture Robots Leveraging Background Knowledge in CNNs[C]// 2018 IEEE International Conference on Robotics and Automation (ICRA). IEEE, 2018.
- [73] Dyrmann M , J?rgensen R N , Midtby H S . RoboWeedSupport - Detection of weed locations in leaf occluded cereal crops using a fully convolutional neural network[J]. Advances in Animal Biosciences, 2017, 8(02):842-847.
- [74] Jiang Y , Li C , Paterson A H , et al. DeepSeedling: deep convolutional network and Kalman filter for plant seedling detection and counting in the field[J]. Plant Methods, 2019, 15(1).
- [75] Yu J , Sharpe S M , Schumann A W , et al. Deep learning for image-based weed detection in turfgrass[J]. European Journal of Agronomy, 2019, 104:78-84.
- [76] 王术波, 韩宇, 陈建,等. 基于深度学习的无人机遥感生态灌区杂草分类[J]. 排灌机

- 械工程学报, 2018, 036(011):1137-1141.
- [77] 孙俊, 何小飞, 谭文军, 等. 空洞卷积结合全局池化的卷积神经网络识别作物幼苗与杂草[J]. 农业工程学报, 2018, 34(11):159-165.
- [78] Huang H, Deng J, Lan Y, et al. A fully convolutional network for weed mapping of unmanned aerial vehicle (UAV) imagery[J]. PLoS ONE, 2018, 13(4):e0196302.
- [79] 张乐, 金秀, 傅雷扬, 等. 基于 Faster R-CNN 深度网络的油菜田间杂草识别方法[J]. 激光与光电子学进展, 2020, 57(2):9.
- [80] 彭明霞, 夏俊芳, 彭辉. 融合 FPN 的 Faster R-CNN 复杂背景下棉田杂草高效识别方法[J]. 农业工程学报, 2019, 35(20):8.
- [81] 王红, 陈功平. 基于 PCAW-UNet 的田间杂草实时分割[J]. 西安文理学院学报(自然科学版), 2021, 24(02):27-37.
- [82] 权龙哲, 吴冰, 毛首人. 基于 Mask R-CNN 农田杂草实例分割与叶龄识别方法[J]. 东北农业大学学报, 2021, 52(04):65-76. DOI:10.19720/j.cnki.issn.1005-9369.2021.04.008.
- [83] 王宇. 基于改进 yolov5s 模型的小麦田间杂草检测研究[D]. 安徽农业大学, 2022.
- [84] 李戡, 余心杰, 郭俊先. 基于全卷积神经网络方法的玉米田间杂草识别[J]. 江苏农业科学, 2022, 50(06):93-100.
- [85] 刘港. 基于卷积神经网络的杂草检测算法研究[D]. 陕西科技大学, 2022.
- [86] 宋珂. 基于改进 YOLOv3 的北方旱作农田杂草检测研究及应用[D]. 山西农业大学, 2021.
- [87] 尚文卿, 齐红波. 基于改进 Faster R-CNN 与迁移学习的农田杂草识别算法[J]. 中国农机化学报, 2022, 43(10):176-182.
- [88] 杨承林. 基于 Transformer 的农业图像分类方法研究[D]. 长春工业大学, 2022.
- [89] Moazzam S I, Khan U S, Qureshi W S, et al. Patch-wise weed coarse segmentation mask from aerial imagery of sesame crop[J]. Computers and Electronics in Agriculture, 2022, 203: 107458.
- [90] Julie J, Athaniosious J J, Santhosh T, et al. Novel weed detection algorithm for sesame crop using Region-Based CNN with Support Vector Machine[C]//2021 4th International Conference on Computing and Communications Technologies (ICCCT). IEEE, 2021: 247-251.
- [91] Vivek K K, Sidharth R, Rohit P, et al. Pests & weed control autonomous robot using machine vision[C]//2021 Second International Conference on Electronics and Sustainable Communication Systems (ICESC). IEEE, 2021: 1319-1326.
- [92] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2017, 39(6):1137-1149.

- [93] He K, Gkioxari G, Dollár P, et al. Mask r-cnn[C]//Proceedings of the IEEE international conference on computer vision. 2017: 2961-2969.
- [94] Liu W, Anguelov D, Erhan D, et al. Ssd: Single shot multibox detector[C]//Computer Vision–ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11–14, 2016, Proceedings, Part I 14. Springer International Publishing, 2016: 21-37.
- [95] Lin T Y, Goyal P, Girshick R, et al. Focal loss for dense object detection[C]//Proceedings of the IEEE international conference on computer vision. 2017: 2980-2988.
- [96] Bochkovskiy A , Wang C Y , Liao H . YOLOv4: Optimal Speed and Accuracy of Object Detection[J]. 2020.
- [97] Yun S, Han D, Oh S J, et al. Cutmix: Regularization strategy to train strong classifiers with localizable features[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2019: 6023-6032.
- [98] Lin T Y , Dollar P , Girshick R , et al. Feature Pyramid Networks for Object Detection[J]. IEEE Computer Society, 2017.
- [99] Liu S, Qi L, Qin H, et al. Path aggregation network for instance segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 8759-8768.
- [100] Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 7132-7141.
- [101] Woo S, Park J, Lee J Y, et al. Cbam: Convolutional block attention module[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 3-19.
- [102] Yang B, Bender G, Le Q V, et al. Condconv: Conditionally parameterized convolutions for efficient inference[J]. Advances in Neural Information Processing Systems, 2019, 32.
- [103] 河北省农林科学院粮油作物研究所.芝麻起垄双行栽培技术规程 :DB13/T 5281-2020[S/OL].(2020-11-19)[2023-01-01].
<https://www.docin.com/p-2602822662.html>.

致谢

学位论文的完成，代表着生活一个阶段的结束。不知不觉来到广西大学竟然已有一千多天，心中颇有感触。三年来的学习生活说长也不长，说短也算不上短。在这不长不短的时间中，我也倒是从中收获了不少。

在此，首先要感谢我的导师陈继清副教授。导师无论是在学业上或者生活上都给予了我们莫大的帮助，可以说是亦师亦友的存在。在学业上，如果没有导师如此循循善诱的指导，想必我也不能如此顺利地完成科研目标。在生活中，面对生活中的难题也能和导师互相交流。总之，能够成为导师的学生是一种幸运。

其次要感谢的是机械楼 419 的所有同门，虽然现在已经改成 424 了，但是 419 在我们心中的地位是不变的。实验室能保持如此优秀的环境与氛围少不了大家各出一份力。其中特别感谢同届的同门们，在互相鼓励科研之余，也能够一块吃喝玩乐，让我保持了十分健康良好的心态。

还想感谢的是我本科时期的班主任，如果不是他极力劝我来考研的话，大概我现在已经成为了成熟的打工人了。

当然在这还要感谢一下的我女朋友考拉，我们相互促进相互成长，有福同享有难同当，争做好典范。

最后要感谢我的家人们，感谢他们全力的支持。没有他们的支持，也就没有了现今的我。

好了，三年之期已到，各位有缘再见。

攻读硕士学位期间的主要科研成果

一、已发表的论文：

1. Chen J, **Wang H**, Zhang H, et al. Weed detection in sesame fields using a YOLO model with an enhanced attention mechanism and feature fusion[J]. Computers and Electronics in Agriculture, 2022, 202: 107412.