

分类号: s237

密 级: 公开

单位代码: 10433

学 号: 20503030287

山东理工大学

机械硕士学位论文

基于深度学习的玉米幼苗与杂草检测算法研究
与应用

Research and Application of Corn Seedlings and Weeds Detection
Algorithm Based on Deep Learning

研 究 生: 李东升

指 导 教 师: 朱俊科 教授

申请学位门类级别: 机械硕士


学 科 专 业 名 称: 机械

研 究 方 向: 农作物智能检测

论 文 完 成 日 期: 2023 年 3 月 20 日

独 创 性 声 明

本人声明所呈交的论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得山东理工大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

研究生签名: 

时间: 2023 年 6 月 4 日

关于论文使用授权的说明

本人完全了解山东理工大学有关保留、使用学位论文的规定，即：学校有权保留送交论文的复印件和磁盘，允许论文被查阅和借阅；学校可以用不同方式在不同媒体上发表、传播学位论文的全部或部分内容，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。

(保密的学位论文在解密后应遵守此协议)

研究生签名: 

时间: 2023 年 6 月 4 日

导师签名: 

时间: 2023 年 6 月 4 日

摘要

精确识别农业中有害杂草，并在最小剂量下高效使用化学农药，以实现提高作物产量而不对环境造成不良影响，是未来农业发展的必然趋势。玉米作物作为我国粮食主要的来源之一，幼苗能够健康、大量的生长对我国粮食安全以及工业生产都起到不可小视的作用。本文以粮食作物玉米及伴生杂草的识别问题展开研究，以伴生杂草为主要研究对象，依据实际田间杂草的类别特征以及农药特性，通过提高目标检测算法对单科杂草的识别精度和减小导出模型的文件大小以适应性能较差的移动硬件设备，进而实现针对性杂草管理(Site-specific weed management, SSWM)，为实现后续杂草精准化清除研究提供参考。本文的主要研究工作如下：

第一，针对数据集缺少问题。在玉米的最佳除草期的三至五叶期期间，于不同环境条件下采集数据，利用数据增强以增加图像的多样性提升目标算法的鲁棒性，最终得到图像 12000 张，采用 LabelImg 软件标注并以 YOLO 和 VOC 格式储存；采用科属的分类方式，有效减小同类但表型特征不同的识别错误的可能性。

第二，研究基于单阶段目标检测算法的玉米杂草检测算法模型。对轻量型特征提取网络和 YOLO 系列的 dataset、backbone、neck、head 进行分析，为后续的算法改进提供理论支持。利用玉米杂草测试数据集和拍摄的田间复杂情况下杂草数据集，对原始的 YOLO-Fastestv2 以及轻量化模型 YOLO-v4tiny, YOLO-v4 MobileNetv3, YOLO-v5s 进行比较试验，确立以轻量化、实时性强的 YOLO-Fastestv2 模型为应用算法。

第三，针对 YOLO-Fastestv2 模型对杂草的识别精度相对较低以及对小目标杂草识别不到的问题，提出 YOLO-Fastestv2 的改进算法。使用 K-Means++与 Moscia 增强的方式对输入数据进行预处理，保证模型的数据稳定性；使用 SoftPooling 替代原有 MaxPooling，同时将 backbone 的下采样中步长为 2 的卷积改进替换为 SPD 卷积，以便于模型提取特征；在 FPN 特征融合部分添加 SimAM 无参注意力机制，使模型在不明显增加计算负担的情况下，保证识别性能的提升；使用 Focal Loss 与 SIOU Loss 改进原损失函数，使算法收敛更平滑，对难识别的物体有良好的性能；使用 Nadam 优化器，约束学习率的变化，使拟合时更快速的向最优处靠近。本文提出的改进 YOLO-Fastestv2 网络，在达到 YOLO-v5s 识别效果的同时模型文件较原 YOLO-Fastestv2 仅增加 0.87M。结果表明，改进 YOLO-Fastestv2 模型检测精确率和召回率分别为 93.97%和 90.02%，相比改进之前分别提高 1.76%和 19.69%。F1 值比 YOLO-v4tiny、YOLO-v4MobileNetv3、YOLO-v5s 模型分别提高 10.28%、5.55%和 0.29%，比原模型提升约 12.16%。mAP 值比 YOLO-v4tiny、YOLO-v4MobileNetv3、YOLO-v5s 模型分别提高 5.57%、3.56%和 0.03%，比原模型提升约 6.36%，输出模型大小仅为 3

种网络模型的 22.8%、47.9%、36.4%。在检测速度上，YOLO-Fastestv2 追求最快的速度，参数较少，改进后识别精度有所提升，但相应的模型文件大小随之增加，检测速度也随之减慢，为 200 帧/s，比原来减慢 45 帧/s。但相比其他几种轻量化 YOLO 目标检测模型仍高出有 79 帧/s，65 帧/s，75 帧/s。试验表明该方法的 mAP 为 94.28%。在数据为背景复杂、高光、小目标、雨后、遮光、遮挡、同科但未在训练数据集等的情况下，测试不同的算法模型，得出改进后的 YOLO-Fastestv2 有良好的泛化效果。

第四，针对采用科属的分类方式的玉米杂草算法模型进行应用研究。选用选择性化学除草剂作为喷施药液，工业数字摄像头作为信息采集设备，NVIDIA AGX 作为精准识别的处理器，STM32 作为变量喷施的控制器，带有圆锥形喷嘴压力式喷头作为喷施机构，对田间杂草的精准喷施作业试验。对玉米识别准确率为 96.5%，阔叶科杂草与禾本科杂草的识别准确率分别为 95%和 85.7%，验证模型对玉米杂草的识别性能。本试验喷施效果中单类别数量较少杂草农药雾滴覆盖密度为 45 个/cm²，多类别数量较少杂草农药雾滴覆盖密度为 87 个/cm²，多类别数量较多杂草农药雾滴覆盖密度过多难以查证，实际可满足除草剂变量喷施的控制要求。为缓解农药要害残留，农药漂移，过量使用农药，从事农业管理人员减少等问题提供解决思路。

关键词：杂草；目标检测；YOLO-Fastestv2；实时性；精准变量喷施

Abstract

Accurately identifying harmful weeds in agriculture and efficiently using chemical pesticides at the minimum dose to achieve increased crop yield without causing adverse effects on the environment is an inevitable trend in future agricultural development. As one of the main sources of food in China, the healthy and abundant growth of maize seedlings plays an important role in food security and industrial production. This article focuses on the identification of grain crops such as corn and associated weeds, with associated weeds as the main research object. Based on the actual category characteristics and pesticide characteristics of weeds in the field, by improving the accuracy of target detection algorithms for identifying single family weeds and reducing the file size of exported models to adapt to mobile hardware devices with poor performance, Site specific weed management (SSWM) is achieved, Provide reference for achieving precise weed removal research in the future. The main research work of this paper is as follows:

First, the data set is missing. Collect data under different environmental conditions during the best weeding period of corn from three to five leaves, and use data enhancement to increase the diversity of the image and improve the robustness of the target algorithm. Finally, more than 10000 images are obtained, which are labeled with Labeling software and stored in YOLO and VOC formats; The classification of families and genera can effectively reduce the possibility of recognition errors of the same kind but with slightly different phenotypic characteristics.

Second, study the corn weed detection algorithm model based on the single-stage target detection algorithm. Analyze the lightweight feature extraction network and the dataset, backbone, Neck, and head of the YOLO series to provide theoretical support for subsequent algorithm improvements. Using the corn weed test data set and the field weed data set taken in complex situations, the original YOLO-Fastestv2 and the lightweight YOLO-v4tiny, YOLO-v4 MobileNetv3, YOLO-v5s were tested Through comparative experiments, the lightweight and real-time YOLO-Fastestv2 model was established as the application algorithm.

Third, in view of the relatively low recognition accuracy of the YOLO-Fastestv2 model for weeds and the lack of recognition of small target weeds, an improved algorithm for YOLO-Fastestv2 is proposed. Use K-Means++ and Moscia enhanced methods to preprocess the input data to ensure the data stability of the model; use SoftPooling to

replace the original MaxPooling, and replace the convolution improvement with a step size of 2 in the downsampling stage of the backbone with SPD volume. In order to facilitate the model to extract features; add SimAM non-parameter attention mechanism to the FPN feature fusion part, so that the model can ensure the improvement of recognition performance without significantly increasing the calculation burden; use Focal Loss and SIOU Loss to improve the original loss function, Make the algorithm converge more smoothly and have good performance on objects that are difficult to recognize; use the Nadam optimizer to constrain the change of the learning rate, so that the fitting can be closer to the optimal point more quickly. The improved YOLO-Fastestv2 network proposed in this paper, while achieving the recognition effect of YOLO-v5s, the model file is only increased by 0.87M compared with the original YOLO-Fastestv2. The results show that the detection precision and recall of the improved YOLO-Fastestv2 model are 93.97% and 90.02%, respectively, which are 1.76% and 19.69% higher than before the improvement. The F1 value is 10.28%, 5.55% and 0.29% higher than the YOLO-v4tiny, YOLO-v4MobileNetv3, and YOLO-v5s models, respectively, and about 12.16% higher than the original model. The mAP value is 5.57%, 3.56% and 0.03% higher than that of the YOLO-v4tiny, YOLO-v4MobileNetv3, and YOLO-v5s models, respectively, and about 6.36% higher than the original model. The output model size is only 22.8%, 47.9%, 36.4% of the three network models. In terms of detection speed, YOLO-Fastestv2 pursues the fastest speed and has fewer parameters. After the improvement, the recognition accuracy has improved, but the corresponding model file size has also increased, and the detection speed has also slowed down to 200 frames/s. , 45 frames/s slower than the original. However, compared with several other lightweight YOLO target detection models, it is still 79frames/s , 65frames/s , and 75 frames/s higher. Experiments show that the mAP of this method is 94.28%. In the case of data with complex background, high light, small target, rain, shading, occlusion, and the same subject but not in the training data set, different algorithm models were tested, and the improved YOLO-Fastestv2 has good generalization effect.

Fourth, apply research on the corn weed algorithm model for the classification of families and genus. Choose selective chemical herbicides as the spraying liquid, industrial digital cameras as the information collection equipment, NVIDIA AGX as the processor for precise identification, STM32 as the controller for variable spraying, and pressure nozzles with conical nozzles as the spraying mechanism , the precision spraying operation experiment on field weeds. The recognition accuracy of corn was 96.5%, and the

recognition accuracy of broad-leaved weeds and gramineous weeds were 95% and 85.7%, respectively, which verified the recognition performance of the model for corn weeds. In the spraying effect of this experiment, the single-category weed pesticide droplet coverage density is $45/\text{cm}^2$, and the multi-category small weed pesticide droplet coverage density is $87/\text{cm}^2$, and the multi-category quantity is large. Too much droplet coverage density is difficult to verify, and it can actually meet the control requirements of herbicide variable spraying. The research provides solutions to alleviate the problems of pesticide residues, pesticide drift, excessive use of pesticides, and the reduction of agricultural management personnel.

Keywords: Weeds; Target detection; YOLO-Fastestv2; Real-time; Precise variable spraying

目录

摘要	I
Abstract	III
目录	VI
第一章 绪论	1
1.1 研究背景与意义	1
1.2 国内外深度学习杂草检测算法研究现状	2
1.2.1 经济作物	2
1.2.2 粮食作物	4
1.3 基于深度学习杂草检测算法的研究内容	5
1.4 技术路线	7
1.5 本章小结	7
第二章 数据集采集及处理	8
2.1 引言	8
2.2 数据采集	8
2.3 数据扩充	9
2.4 数据集构建	13
2.5 本章小结	13
第三章 基于深度学习的玉米幼苗与杂草检测算法	14
3.1 引言	14
3.2 深度学习简述	14
3.3 YOLO 算法简述	17
3.4 轻量化网络模型	19
3.4.1 CSPdarknet53tiny	19
3.4.2 深度宽度剪枝	20
3.4.3 MobileNetv3	21
3.4.4 ShuffleNetv2	21
3.5 YOLO 目标检测模型	23
3.5.1 YOLO-v4tiny	23
3.5.2 YOLO-v5s	24
3.5.3 YOLO-v4MobileNetv3	25
3.5.4 YOLO-Fastestv2	26
3.6 模型对比	27
3.7 本章小结	28
第四章 基于 YOLO-Fastestv2 玉米幼苗与杂草检测算法改进	29
4.1 数据预处理改进	29
4.1.1 K-Means++ 聚类	29

4.1.2 Moscia 增强	30
4.2 损失函数改进	30
4.2.1 Focal Loss	30
4.2.2 SIOU Loss	31
4.3 优化器改进	34
4.4 基础网络改进	35
4.4.1 下采样层	36
4.4.2 池化层	38
4.5 FPN 改进	38
4.5.1 引入注意力机制	39
4.6 试验参数	41
4.6.1 试验平台	41
4.6.2 超参数设置	41
4.6.3 评价指标	41
4.7 模型效果分析	42
4.8 本章小结	46
第五章 基于深度学习检测算法的变量喷施系统	48
5.1 引言	48
5.2 除草剂选择	48
5.3 喷施系统的设计与设备选择	49
5.3.1 摄像头	49
5.3.2 开发板 NVIDIA JESON AGX	51
5.3.3 STM32	52
5.3.4 泵	54
5.3.5 喷嘴	54
5.4 室内标定试验	56
5.5 行进速度模拟	56
5.6 变量喷施测试	57
5.7 本章小结	59
第六章 总结与展望	60
6.1 引言	60
6.2 工作总结	60
6.3 展望	61
参考文献	63
在读期间公开发表的论文	69
致谢	70

第一章 绪论

1.1 研究背景与意义

现代农业大国评判标准是农业投入与产出比，而我国与美国等一些农业大国比相差较大，只能说是一个农业生产大国。但是近年来国家对于农业技术的大力支持，我国粮食总产量也在连年增长。在现代农业生产活动中，因为当前科技的限制，我国仍需要大量从事农业劳动的人员。如在农田管理方面，我国的科技研究仍处于基础阶段。

到 2050 年，全球人口预计将达到 90 亿，农业生产必须满足日益增长的需求^[1]。然而，农业正面临着巨大的挑战，包括气候变化、可耕地和水资源的严重短缺，以及来自疾病、害虫和杂草的威胁^[2]。几十年来，研究人员和农民在杂草控制方面付出大量努力，以克服杂草带来的棘手挑战。

杂草会和作物争夺生存资源^[3]，我国田园杂草有 1454 种，其中对作物有严重危害的杂草有 130 多种^[4]。据农业植保站官网统计，我国耗费高达 20 至 30 亿个工作日进行除草工作，除草工作在田间总劳动量中占比 30%至 50%，造成大量劳动力的浪费，在如此大的除草工作量下，我国因杂草危害影响带来的粮食损耗平均达到 13.4%，全国每年因杂草造成主要粮食作物损失约 300 万吨^[5]。据统计，农作物遭受杂草危害的土地面积超过 0.73 亿公顷，间接造成经济损失超过 900 亿元。目前解决杂草问题的方法可分为生物、物理和化学除草^[6]，自 20 世纪 40 年代以来，化学除草一直是最广泛使用的杂草控制方法^[7]。传统的化学除草是将除草剂均匀地喷施到整个田地中，而不管田地的某处是否存在杂草，这不仅会导致除草剂的高成本。在农业中过度使用除草剂也已经引起灾难性的环境污染问题^[8]。为解决这些问题，许多国家已经限制除草剂在农业中的使用。

农业是基础，是“压舱石”，是国民经济和社会发展的基础。现阶段从事农业管理的人员越来越少，化学农药便成为保障农业生产过程中的最重要的生产资料之一，农药生产也因此在整个化工产业链中处于特殊地位。改革开放以来，中国农药行业取得了巨大的进步，已从原来农药供给不足、依赖进口的情况，逐渐形成创制、生产、加工等整套的农药的生产体系，并发展成为全球第一大生产国和出口国，可生产农药 600 多种。近 5 年来，平均每年有 60%左右的农药产品会出口到全球约 180 个国家和地区，每年创汇 80 亿美元左右^[9]。随着新《农药管理条例》政策出台，老旧农药、同质化产品等落伍的农药产品被市场淘汰，已实现整个农药行业高质量的发展。但是我国基础农药研究仍处于初级阶段，农药行业依旧保持以化学农药为主，较为环保的生物农药发展还需要一定时间和空间的沉淀。因此如何高效地使用化学农药提升农业生产，是当前研究者研究的最重要的目的。

虽然现在国家高度重视农药的使用和残留问题,但是市面上依旧可能出现农药超标的现象^[10],而精准农业或数字农业可以提供缓解这些问题的策略^[11,12]。在这种情况下,针对性杂草管理(Site-specific weed management, SSWM)随之出现。SSWM 的主要思想是只喷洒杂草块和/或根据杂草密度或杂草种类组成调整除草剂施用量^[13]。

国内外很多学者^[14]都在研究如何实现精准化,不仅仅是用量精准化还要目标精准化,因此针对杂草的识别^[15]并应用于自动化精准除草是未来农业发展必须要走的一步。

深度学习可在农业生产的各个方面促进生产效率。例如品种鉴定,作物部位和果实识别,作物及杂草检测与分类,作物表型及病虫害检测等都是当下研究的热门,另外动物面部、行为识别也在新兴起来,可见其在农业领域的广泛应用^[16,17]。

玉米作为我国粮食主要的来源之一,幼苗能够健康大量地生长对我国粮食安全甚至工业生产都起到非常不可小视的作用。目标检测作为计算机视觉重要的领域之一,受到很多学者的关注,在行人检测、人脸识别都已经有很大的突破。基于深度学习的目标检测要解决的核心问题就是:目标出现在图像中的位置、目标的大小、目标的形状,而这些问题正是精准喷施作业的关键所在。基于深度学习的幼苗玉米与田间杂草的识别研究将会为精准喷施提供很大的帮助,技术也会越来越成熟和完善,这也是农业发展的趋势,对我国未来农业的发展具有重大意义。

1.2 国内外深度学习杂草检测算法研究现状

1.2.1 经济作物

1.2.1.1 蔬菜与杂草

我国是世界蔬菜生产消耗第一大国,蔬菜已经成为我国农业种植中仅次于粮食作物的第二大农作物,解决由杂草导致的蔬菜产量下降问题十分重要^[18]。Osorio 等^[19]为精确估算生菜杂草覆盖度,拍摄数据集并设计 3 种分别以 SVM-HOG, YOLO-v3, MaskR-CNN 识别检测算法为基础的杂草提取算法,将检测算法得出的被检测作物转化为二元掩模,并与 NDVI 背景减法器混合,以间接检测杂草获得杂草图像,然后运用经典图像处理方法计算杂草的覆盖率,试验得出每种方法较人工计算准确率都有不同程度的提高,且指出每种检测算法的最佳使用场景,为以后探究提供新的思路。Gao 等^[20]使用尼康相机在不同照明条件下拍摄甜菜和杂草(打碗花)的图像,并通过数据扩张的形式,解决收集和标签的劳动密集型和耗时问题,使用改进的 YOLO-v4tiny 目标检测网络对数据集进行测试,对比 YOLO-v3 和传统的 YOLO-v4tiny 网络,结果表明改进的 YOLO-v4tiny 目标检测网络既能降低检测速度也能保证准确率。尚建伟等^[21]以农田信息采集机器人 BoniRob 采集甜菜与杂草图像作为数据集,通过使用改进的 Res-UNet 模型进行图像分割,识别准确率达到 98.67%,高于 UNet 和 SegNet 具有较高的分割识别精度。喻刚等^[22]提出将 MaskR-CNN 网络应用到幼苗期白菜和杂草的图

像识别中,与基于 OTSU 阈值分割对杂草进行识别的方法对比,结果表明 MaskR-CNN 网络达到较好的效果有 81%的合格率。Espejo-Garcia 等^[23]使用少量番茄与杂草(龙葵)数据集,通过使用 DCGAN 网络扩张数据以及迁移学习的方法对识别算法提升精度,期间设计对比试验,从 GAN、迁移学习参数、迭代次数、特征提取网络等方面,不同搭配以选取最优识别算法,得出使用 Imagenet 预训练,GAN-Xception 识别算法效果最好,测试集上的 F1 为 99.07%。

1.2.1.2 油料与杂草

油菜和向日葵是我国重要的食用油来源,其中油菜居油料作物之首,是我国种植地区分布最广的油料作物。但在杂草会伴随着油菜生长一直存在,导致油菜籽产量下降约 15.8%,情况严峻时可能减产一半以上^[24,25]。张乐等^[26]为自动识别自然环境下油菜田间的杂草,在采集油菜与杂草数据集后,对比其在 VGG-16、ResNet-50 和 ResNet-101 这 3 种特征提取网络下 Faster R-CNN 模型的目标检测效果,结果表明,基于 VGG-16 的 Faster R-CNN 最好,目标识别精确度可达 83.90%,召回率达到 78.86%,F1 值达 81.30%。Abdalla 等^[27]为在高密度杂草条件下更好的识别分割出油菜,使用便携式数码相机拍摄高密度杂草下油菜田数据集,设计用微调过的 SegNet 网络模型的编码器提取深度特征与使用机器学习的分类器结合的方法实现对油菜杂草的图像分割,对比几种机器学习分类器的准确率,得出使用 SVM 效果最好,可实现对油菜和背景的分割,结果表明最高精度可达 96%。Asad 等^[28]开发一种加速手动标记像素的过程的方法,使用尼康相机采集两个不同生长阶段的油菜田数据集,对比分别使用 VGG-16 和 ResNet-50 作为编码器的 UNet 和 SegNet 来训练实现杂草和油菜的分割,试验得出基于 ResNet-50 的 SegNet 模型效果最好 MIOU 和 FWIOU 分别达到 82.88% 和 98.69%。Partel 等^[29]以向日葵与杂草,胡椒与杂草(马齿苋)为数据集训练 3 种基于 YOLO-v3 的目标检测网络来实现精准智能喷雾器对杂草的识别,整个喷雾系统的准确率和召回率可分别达到为 95%和 89%。

1.2.1.3 棉花与杂草

棉花,是世界上重要的经济作物。但是由于棉花生产程序复杂,种植管理、控害除草复杂,生产人工成本高,导致部分地区种植意愿降低,因此深度学习解决棉花杂草问题,以提高种植意愿与棉花产量尤为重要^[30]。Borja Espejo-Garcia 等^[31]将深度学习的卷积神经网络与传统机器学习的分类器结合起来分别识别作物(番茄和棉花)和杂草(龙葵和天鹅绒草),试验得出 DenseNet 和支持向量机结合 F1 值达到 99.29%。许燕等^[32]针对新疆棉田杂草识别率低的问题,试验通过自采集不同角度、不同自然环境和不同密集程度混合生长的棉花幼苗与杂草数据集,然后对比 4 种特征提取网络的 Faster R-CNN 模型的识别效果,最终选择 VGG16 为特征提取网络训练,设计最佳锚尺度,得出最佳 mAP 值为 91.49%,平均识别时间 262ms。为实现田间条件能快速、精准识别棉花幼苗与杂草,彭明霞等^[33]设计采集小车,采用垂直向下拍摄的方式获取

棉花与杂草的视频，按照每秒一帧取图片建立数据集，对比 Faster R-CNN 和 YOLO-v3 这 2 种典型目标检测模型，最终选取优化后的 Faster R-CNN 进行试验，得出平均目标识别准确率达 95.5%。Dong Chen 等^[34]通过迁移学习建立综合基准，用于棉花生产系统中常见杂草的多类识别。创建棉田 15 类杂草数据集用于模型训练，对于训练样本较少的少数杂草类识别较差的问题，采用加权交叉熵(WCE)损失函数，以及将基于深度学习的余弦相似度指标用于分析杂草类间的相似度，大大提高杂草分类的准确性，对比 27 个(卷积神经网络)深度学习模型，得出参数优化后的 ResNet-101 的 F1 值最高达到 99.1%，其中模型中有 14 款超过 98%。

1.2.2 粮食作物

1.2.2.1 水稻与杂草

我国对水稻的生产极为重视，全国以稻米为主食的人超过65%。水稻种植中盲目用药除草的情况屡次发生，不仅防治效果差，还会对水稻的生长造成一定的影响，导致水稻产量下降^[35]。邓向武^[36]等，提出一种基于卷积神经网络(CNN)与迁移学习相结合的稻田苗期杂草识别方法采集6种稻田苗期杂草(野慈姑和稗草等)数据集，将预训练 CNN 图像分类模型(AlexNet、VGG16和GoogleNet)的参数 迁移到杂草识别的任务上来使用VGG16网络模型的杂草正确识别率达97.48%。彭文等^[37]用CCD感光相机采集6种水稻田杂草(鬼针草、鹅肠草等)，构建水稻田杂草数据集PFWM，通过对比VGGNet、ResNet-50、MobileNet等8种深度学习网络模型，再对比选取网络模型的优化器(SGD、Adam和RMS)最终 VGG16-SGD模型取得最高精度，其平均F1值达到97.7%。Huang等^[38]用无人机在不同的稻田上拍摄图像建立数据集，通过对比基于对象的图像分析(OBIA)的传统机器学习的不同分类器和深度学习方法的卷积神经网络，得出深度学习方法VGGNet网络模型在准确率和效率上明显优于OBIA法和其他深度学习卷积网络。Zhang等^[39]用无人机低空飞行采集冬小麦数据，研究测试YOLO-v3和YOLO-v3tiny的性能，发现YOLO-v3tiny更适合移动设备，且mAP可到72.5%，IOU为 80.12%。Kumar等^[40]采集水稻与杂草数据集对比不同的机器学习分类器(SVM, CNN)与R-CNN和Faster R-CNN的目标检测算法，得出Faster R-CNN准确率最高达到94%。且为降低GPU的需求，选择更加专用的加法器(adder)提高硬件性能，最后硬件部分选择FPGA芯片处理图片，既降低延时，又缩小占用面积。Ma等^[41]使用佳能相机采集稻米杂草幼苗水稻和杂草(慈姑)数据集，在解决类别标记和类别数量不平衡问题后使用迁移学习和基于全卷积的 SegNet图像分割网络来实现对杂草的识别分割，与经典语义分割模型 FCN 和UNet对比，平均精度为92.7% 高于二者。

1.2.2.2 玉米与杂草

玉米是世界上分布最广泛的粮食作物之一，在我国种植产量超过水稻和小麦，位居我国三大粮食作物之首，是人类和畜禽的重要食物来源，也是重要的工业和医

药原料^[42]，玉米的 3~5 叶期是除草的最佳时期。

徐艳蕾等^[43]拍摄 8 种田间杂草(鬼针草、翅果菊等)和玉米苗期的数据集，针对复杂自然环境下杂草图像的特性构建一种基于Xception卷积网络的轻量卷积网络的改进杂草识别模型，相同试验条件下对比其他几种基础识别网络模型(VGG-16、VGG-19、ResNet-50和Inception-v3)，结果显示设计的识别模型平均测试识别准确率达98.36%。Champl等^[44]设计一款电除草的机器人，其中识别定位杂草是采用视觉方式，通过嵌入深度学习 MaskR-CNN算法，识别检测杂草，在训练两种作物(玉米和大豆)和四种杂草(黑麦草和藜等)数据集时选定 ResNet-50为特征主干网络，对输入图像大小，锚框比例等超参数进行调整来提高准确率，通过植物的重心对植物定位实现精准除草。虽然小目标杂草检测精度较低，但也验证实施电气化除草的可能。Mads等^[45]通过自搭建卷积神经网络对包含22种(小麦、玉米、甜菜等7种作物，阔叶草、狭叶草、藜等15种)处于早期生长阶段的作物和杂草数据集对进行识别检测，模拟土壤背景上的重叠植物的自上而下图像来克服植物树叶重叠问题，最终网络能够达到86.2%的分类准确率。因叶龄是植物重要表型性状，不同叶龄杂草所需除草剂剂量不同，权龙哲等^[46]采集不同天气和不同角度下的2~5叶期玉米和杂草(稗草、打碗花等)数据集，采用MaskR-CNN网络模型检测杂草，通过更换3个特征提取网络(ResNet-50、ResNet-101、MobileNetv2)、搭建多种不同尺寸区域建议框等方法提高模型精度，结果显示ResNet-101为特征提取网络识别率最高为90.3%。Wang等^[47]使用玉米和大豆生产系统中4种常见杂草(苍耳、狐尾草、红根苋菜和三裂叶豚草)数据集，研究图像分类模型和目标检测模型对数据集中杂草的识别效果，通过评估 VGG-16、ResNet-50和Inception-v3三种不同的预训练图像分类模型得出基于Pytorch框架的VGG16识别精度最高，F1值为99%。评估用于定位和识别杂草种类的 YOLO-3目标检测模型，得出总体mAP得分为54.3%，红根苋菜的识别精度最高89%，由于狐尾草样本较少且难以识别，AP仅为26%。当评估由于框架选择而产生的性能差异时，得出相同条件下pytorch优于keras。

1.3 基于深度学习杂草检测算法的研究内容

检测领域的技术任务主要有图像分类、目标检测、语义分割、实例分割。其中基于深度学习的杂草识别在分类识别任务中，由于作物与杂草种类不同，以及测试数据集不同，得出的不同算法的识别精度不同，并无某一算法明显优于其他算法。在目标检测和图像分割任务中由于田间植物的小物体杂草和遮挡重叠现象和移动设备很难达到实验室设备的高算力和实时性，也由于目标检测和图像分割的表现形式不同，研究者们可从获得作物面积来选择图像分割，从获得类别与位置来选择目标检测，从部署移动设备来选择单阶段的目标检测或实例分割，也可根据实际需要选择准确度高的Faster R-CNN，或实时性强的YOLO、SSD。研究人员对于深度学习算法技术准确率

的提升手段主要有针对不同的算法模型、模型本身、迁移学习、加入注意力机制等方法。现阶段分类识别任务中在不同数据集、不同选用参数下达到的准确度不同，但是均能达到准确率94%以上，有甚者可达99%，是因为此时数据中均为单个易识别物体。而目标检测和图像分割任务中准确率普遍低于95%是因为需要得到物体所在的区域，而算法模型对数据中存在不同尺度、重叠、遮挡的物体的检测能力不同，易出现漏检错检现象。

针对玉米田间伴生杂草的识别、定位问题，以玉米及伴生杂草为研究对象，以提高杂草的定位识别准确率为目标，并通过田间杂草变量喷施试验进行验证，主要研究内容分为两个部分：

(1)基于深度学习的玉米杂草检测算法研究

为更加轻量精准识别田间的玉米杂草，通过对轻量化网络模型、注意力机制等深度学习相关算法的研究，提出一种基于深度学习的玉米杂草目标检测方法。在原始 YOLO-Fastestv2 特征提取网络中融入无参注意力机制 SimAM，不增加网络模型计算量的同时利用更多的特征提升网络性能；使用 SPD-Conv 代替原 ShuffleNet 步长为二的下采样分支的卷积，以提升特征提取中对小物体识别的准确度。使用 SoftPooling 取代原 MaxPooling，减少信息损失并使网络反向传播梯度能连续；采用 SIOU 作为边界框回归的损失函数，提高目标框回归的稳定性，引入 Focal 损失来提高对难分禾本杂草的识别准确度，进而提升模型的检测性能。通过以上改进使之更精准轻量更容易部署到移动嵌入式设备上，更能适应田间复杂的实时地况。对比改进 YOLO 检测算法选用 mAP，模型导出文件大小和检测时间评价模型性能，进行定量与定性分析，验证所提出方法的性能优势。

(2)基于检测算法的应用研究

为响应减量增效的使用化学除草剂，更好的将深度学习目标检测算法应用到农业生产中，根据玉米田间杂草的实际情况，研发基于田间杂草检测算法的变量喷施系统。USB 数字摄像头获取图像信息输出到嵌入式移动设备 NVIDIA AGX，移动设备根据玉米杂草检测算法模型计算出杂草类别、位置区域，数量，通过串口通讯将处理的类别信息，位置信息，数量信息发送到 STM32 单片机，由单片机 PWM 控制两种类别的杂草对应无刷泵电调的开启和电压大小，以控制泵的流速，进而控制压力式喷头的喷液量，实现杂草的对靶按类按需精准变量喷施。

1.4 技术路线

本文实际与理论相结合，从基础逐渐深入修改，技术路线如下：




图 1.1 技术路线

Fig. 1.1 Technical route

1.5 本章小结

本章主要描述当前社会对精准除草的需求以及总结国内外将深度学习应用到农业除草领域的研究现状，指出玉米精准除草的必要性以及减少农药使用的方针政策。最后指出本研究的实际工作内容。

第二章 数据集采集及处理

2.1 引言

根据实地观察玉米幼苗期杂草类别,发现可分为禾本科,阔叶科,桑科(蓼草)等。市面上的阔叶科除草剂亦可对蓼草有效果。因此本章主要介绍本研究所用玉米幼苗与杂草数据集的采集和制作。以采集、扩充、构建为顺序对数据集制作进行展示。试验使用 LabelImg 软件标注,构建 YOLO、VOC 格式数据集。

2.2 数据采集

拍摄于 2021 年 7 月 14 日至 7 月 20 日与 2022 年 7 月 10 日至 7 月 15 日。为取得更全面的玉米苗和杂草图像,选取拍摄时间为 7:30-9:30、12:00-13:00、16:00-17:00 三个时间段,拍摄农场内的玉米与杂草。按照不同拍摄高度,不同拍摄角度,使用挡板进行不同光照强度,晴天雨天的不同背景等进行随机采集。



图 2.1 田间可用阔叶科除草剂清除杂草

Fig. 2.1 Weeds that can be removed with broadleaf herbicides




图 2.2 田间可用禾本科除草剂清除杂草

Fig. 2.2 Weeds can be removed with grass herbicides

2.3 数据扩充

在玉米与杂草数据采集过程中，虽然可以控制拍摄时间，角度等来使数据呈现多样性，但是自然环境下各种作物生长不均，如马唐等杂草生存能力强，几乎每块地都有，其样本数据就多，而菰草、苋菜等都是片状区域，每块地分布不均可能出现较少，其样本数据就少。而且玉米幼苗 3-5 叶期时马唐等禾本科个体较小，较难识别但却是除草的最佳时期，为提升和平衡数据集，以提取禾本科与阔叶科的最广泛的特征，泛化模型，同时也减少人工拍摄与标注的工作量，运用 Python 程序对已经标注完成的图像数据集数据增强。对数据集进行图像增强处理的方式，采取旋转图像、平移图像、镜像图像，加噪声，加高光，添加遮挡的方式等预处理方式扩充数据集，提高数据真实的模拟效果。由于 Python 程序代码简单，有丰富的 Python 库，因此图像预处理方面直接调用 Python 库：用 tensorlayer 库进行图像的裁剪，平移，镜像，旋转；imgaug 库添加噪声和高光；使用 xml.etree.ElementTree 模块获取原图的标注文件，使用 opencv 库在读取到的图像数据中，按照标注文件中目标框的位置，在图像上随机添加不同方向白色遮挡块实现图像的遮挡处理。

由于田间杂草与玉米生长姿态多样，但又对于拍摄方式来说简单重复，因此使用上述图像增强的方式扩充原数据集中 9652 张图片，选取玉米图像 1000 张，阔叶 1000 张，禾本 1000 张。随机增强至 12000 张。其中玉米目标 5600 个，禾本目标 7320 个，阔叶目标 6200 个。

由于是对整体图像进行旋转，因此旋转之后被旋转却没有其他像素填充的像素点会被置零呈现黑色。



a 旋转



A 原图

由于是对整体图像进行平移，因此平移之后被平移的没有平移像素填充的像素点会被置零呈现黑色。



b 平移




B 原图

以图像左右的中心轴为对称中心，交换对称轴两边的像素位置。



c 镜像



C 原图

随机选取图像数据区域裁剪并填充整个图像大小



d 裁剪



D 原图

由于训练过程采集数据过程与实际应用摄像头采集效果不同，实际应用过程外界环境难以选择控制，而且对模型本身泛化性要求要高，因此采用添加噪声，加入高光，等像素操作的方式进行模拟。



e 高光



E 原图



f 噪声



F 原图

虽然数据集中目标物体越干净越完整对物体的识别精度越高，但也会因此陷入过拟合的现象，而田间杂草玉米幼苗互相遮挡的现象较为广泛，所以使用添加遮挡的方式模拟田间情况和提升目标检测模型的鲁棒性。




图 2.3 数据扩充效果图

Fig. 2.3 Effect of data expansion

在整个图 2.3 数据扩充效果图中，右侧为原数据集图像，左侧为扩充图像。a 图为旋转图像，对原图进行角度 30、60 度变换，缺失部分填充 0 像素；b 图为平移图像将图片向右平移，缺失部分填充 0 像素；c 图为镜像图像，对原图进行水平镜像，d 图为裁剪图像，对原图进行随机裁剪，并填充至原图大小；e 图改变亮度图像，对原图进行亮度增加；f 图为添加椒盐噪声图像；g 图为添加遮挡，对原图目标填充白色色块遮挡；

以上各种增强方式都是随机选取已经挑选出来杂草形状特征较好的数据集集中的数据，每一次增强的原图采取有放回的方式，例如取出 100 张，放回 50 张原图 50 张处理图，再进行下一种增强方式，这样随机叠加增强。对标注文件中的目标框进行对应调整后，将扩充的图像数据和标注文件检查后存入源文件夹下。

2.4 数据集构建




图 2.4 LabelImg 标注

Fig. 2.4 Labeled by LabelImg

数据标注后选择 PASCAL VOC 格式会生成对应的 xml 文件，xml 文件主要记录图片的名称 filename，目标的类别 name，目标框的左上角与右下角的坐标 bndbox。将图片与标注 xml 文件按照 8:2 随机分成训练集 train 与测试集 val，两个文件集中按照 Annotations、JPEGImages 分别放入 xml 文件、图像文件。数据标注后选择 YOLO 格式会生成相对应的 txt 文件，txt 文件主要记录目标的类别，目标框归一化后中心的坐标与宽高。将图片与标注 txt 文件按照 8:2 随机分成训练集 train 与测试集 val，两个文件集中按照 labels、images 分别放入 txt 文件、图像文件。

本文试验所用的 3-5 叶期玉米及伴生杂草图像是在山东理工大学生态无人农场拍摄。图像采集设备为佳能 Canon EOS 80D 相机，相机有效像素为 2420 万。拍摄试验数据为正面、侧面、遮挡等图像。

2.5 本章小结

本章主要介绍实现玉米苗期杂草检测所需数据集的采集、预处理以及标注过程。对田间的阔叶科与禾本科杂草图像进行采集，并根据原始图像采用数据增强的方式对数据集进行扩充，LabelImg 软件对采集到的图像标注，并以 PASCAL VOC 数据集与 YOLO 格式进行存储。为后续识别检测算法的研究提供数据支撑。

第三章 基于深度学习的玉米幼苗与杂草检测算法

3.1 引言

将深度学习应用到计算机视觉的目标检测算法领域已经是一个趋势,其被广泛应用于信息采集,图像数据分析等方面。使用深度学习目标检测算法提取数据特征在简单、高维等各方面的都优于传统的人工提取特征的目标检测算法,但是其结构复杂,且准确率往往与模型大小有着密切关系,所以对所需的设备性能有较高的要求。而应用在农业精准除草领域,面对田间杂草目标遮挡,光照,土地不平坦等复杂情况,对模型的鲁棒性、轻量性、实时性、准确性都有一定的要求。因此本文选取单阶段目标检测算法 YOLO 进行研究分析。

3.2 深度学习简述

机器学习是机器通过大量数据寻找某种规律,不断拟合当前数据来推算出某种模型,用以预测未来数据或者分类当前数据的机器运算方法。机器学习按照目前广泛认可的分类方式,可以根据处理数据方式,训练样本及反馈方式的不同,将机器学习算法分为监督学习、无监督学习^[48]和强化学习 3 种类型^[49]。监督学习是目前主要的研究方向,常用于解决分类和回归问题,监督学习典型的算法有反向神经网络(BP)、支持向量机(SVM)、K 近邻法(KNN)、朴素贝叶斯(NB)、随机森林(RF),部分深度学习算法。深度学习是人们在机器学习以及对人类神经元了解的基础上从简单的浅层神经网络(如 BP 神经网络)到复杂的深层神经网络(如卷积神经网络)数据处理方法,通过对采集到的大量数据进行特征学习得出高层次的特征规律从而对目标对象进行分类或预测,属于更高级的机器学习^[50]。深度学习不用人工进行数据特征提取(可以提取更高维度的可以被计算机识别的特征信息),因此可以被广泛应用在不同领域。目前深度学习在计算机视觉、自然语言处理等领域展现出良好的发展前景也不断被证明优于传统的机器学习^[51]。深度学习常见的网络有如:深层信念网络(DBN)、卷积神经网络(CNN)、生成式对抗网络(GAN)、胶囊网络(CapsNet)、循环神经网络(RNN)等^[52],本节就常用于农业信息采集的前三种网络进行简单阐述。

(1)深度信念网络

2006 年 Hinton^[53]提出深度信念网络,是基于神经网络提出的,由多层受限玻尔兹曼机(RBM)和一层分类器组合而成的一个概率生成模型,DBN 网络结构限制为两层:可视层和隐层,而受限玻尔兹曼机(RBM)只有两层神经元,一层叫做可视层(Visible layer),由可视元(visible units)组成,用于输入训练数据。另一层叫做隐层(Hidden layer),由隐元(hidden units)组成,用作特征检测,层与层之间是双向连接

的，但层内的单元间互不连接。DBN 实际是由多层神经元构成，所以也可称为随机神经网络。




图 3.1 玻尔兹曼机和受限玻尔兹曼机

Fig. 3.1 Boltzmann machine and restricted Boltzmann machine

邓向武等^[54]在自然背景下和不同光照条件下采集稻田的 6 种杂草(包括空心莲子草、丁香蓼、鳢肠、野慈姑、稗草和千金子)图像共 928 幅，提取杂草图像的颜色，形状，纹理特征等共 101 维特征为输入特征向量，通过研究深度置信网络层数，然后与 SVM，BP 神经网络分类器对比，试验得出，研究的改进 DBN 网络模型识别率最高，而且彼此消耗的时间相差不明显。

(2)生成式对抗网络(GAN)

生成对抗网络(GAN)是由 GOODFELLOW 等^[55]2014 年基于零和博弈论提出的由生成器和判别器组成的，是在对抗训练过程中生成新模型的深度学习算法。生成器寻找真实样本数据的分布规律，并生成新的样本数据；判别器用来判别输入的数据是真实数据还是生成的数据。即样本输入至生成器后，生成器根据输入的图片不断生成样本数据外新的图片，将生成的图片和已有的样本数据输入判别器进行判定真假。这样由生成器生成图片去欺骗判别器，判别器判断是真实数据还是生成数据，在二者互相对抗中，寻找二者之间的一个纳什均衡。生成对抗网络的生成器和判别器都是由卷积、反卷积、全连接神经网络构成。生成对抗网络是针对数据集样本数量少，但是网络精度、网络适用性的提高需要大量数据的问题，其可以根据小样本数据分布生成海量且高质量的图像数据，这样就能解决采集过程费时费力的问题。Fawakherji 等^[56]设计一套 GAN 网络，通过将获得的原图像掩膜随机生成噪声掩膜数据然后再上采样到原图像大小实现生成器生成植物图片，再插入原图形成合成图像，然后将最终生成的图片输入判别器进行判断。如图 3.2 所示，可以看到生成对抗网络生成出极为相似的图像。




图 3.2 通过在原始图像中插入使用 GAN 生成的合成植物样本与原图像的不同，引自[56]

Fig. 3.2 Diffence between the original image and the synthetic one obtained by inserting in the original image a plant sample generated using the GAN,from[56]

(3)卷积神经网络 (CNN)^[57]

卷积神经网络(CNN)是传统神经网络的改进。主要包含数据输入层，卷积层，激活函数层，池化层，全连接层，输出层。输入层是输入样本数据的层级，负责将数据传输到网络中；卷积层是进行卷积操作的层级，通过卷积核(多个确定的权重，一般卷积核有 1×1 ， 3×3 ， 5×5 ， 7×7 的，还有深度可分离卷积核)，对一区域内的像素进行内积运算，输出提取的特征结果。神经元只与邻层的神经元连接，同一平面内的特征神经元权重共享。池化层是用于减少网络参数和占用数据大小的层级，一般有均值池化和最大池化两种，既能够压缩图像，也能保证该图像特征的不变性。经典的网络模型包括 LeNet、AlexNet、VGGNet、GoogleNet 和 Xception 和 ResNet 等。表 3.1 是对卷积网络的总结。

表 3.1 卷积神经网络对比
Tab. 3.1 Comparison of convolutional neural networks

卷积神经网络	特点	参考文献
LeNet	引入卷积的概念，快速部署，高效解决小规模图像识别问题。	[58]
AlexNet	引入池化层，Dropout 和 relu 函数处理数据的 AlexNet 类似于 LeNet5，但它更深，每层包含更多的过滤器，并使用堆叠卷积层。	[59]
VGG16	改进通过在所有层中使用 1*1，3 * 3 的小卷积滤波器来增加模型的深度，提高其精度。	[60]
GoogleNet (inception)	采用模块化的结构，引入 inception 的多尺度融合概念。更深更宽的结构，不同的感受野大小和几个非常小的回旋。	[61]
Xnception	在 inception 的基础上引入可分离卷积进行运算。	[62]
ResNet	residual 结构(残差结构)的概念，使用归一化取代 dropout。一种具有跳跃连接和大量批处理规范化的新颖体系结构	[63]
DenseNet	所有层以前馈方式直接相互连接。它减少消失梯度问题，并且需要很少的参数。	[64]
MobileNet	引入可分离卷积的概念，通过使用较少数量的过滤器来减少参数数量。	[65]

3.3 YOLO 算法简述

YOLO(You only look once)是一种单阶段目标检测算法，包含两个功能：识别，定位。实质是一种回归算法。接下来从 YOLO 在特征提取后如何对提取出的图像进行分析进行介绍：

(1)网格点预测

图像在输入前被reshape成一个等长宽，shape尺寸为32倍数的图像。经过特征提取后生成(shape//32)*(shape//32)的特征图，此时一副图片就可以被(shape//32)*(shape//32)个1*1网格划分，每个1*1网格点负责预测如果这个物体的中心落在这个网格中，则由这个网格负责预测该物体。

(2)预测内容

预测 N 个边界框坐标 x 、 y 、 w 、 h ，类别 c ，置信度 Confidence 。 (x, y) 表示的是框的中心点坐标，和方格的边界有关。 (w, h) 表示的是框的宽度和高度，和整个图片有关。 Confidence 代表此时框住的物体是否为目标对象的概率和是否完全框住目标对象。

$$\begin{aligned} b_x &= \sigma(t_x + c_x) \\ b_y &= \sigma(t_y + c_y) \\ b_w &= p_w e^{t_w} \\ b_h &= p_h e^{t_h} \\ \text{confidence} &= \text{Pr}(\text{object}) * IOU_{pre}^{true} \end{aligned} \quad (3.1)$$

(c_x, c_y) :该点所在网格的左上角距离最左上角相差的格子数。

(p_w, p_h) :先验框的边长。

(t_x, t_y) :目标中心点相对于该点所在网格左上角的偏移量。

(t_w, t_h) :预测边框的宽和高。

Confidence :预测的置信度。

σ : 激活函数，YOLOv1 用的是 sigmoid 函数。

最终得到的边框坐标值是 b_x, b_y, b_w, b_h 而网络学习目标是 t_x, t_y, t_w, t_h 。经过 sigmoid 激活函数处理过的偏移量大小始终在 0-1 之间，再加上单个网格长度为 1，因此预测目标的中心点所在位置就被限制在 $1*1$ 的方格中，因此每个网格可以预测目标框的位置与大小。

(3)实现过程

①卷积/全连接预测头

全连接：将得到的预测数据处理成 $(\text{shape} // 32) * (\text{shape} // 32) * (N * 5(x, y, w, h, \text{Confidence}) + c)$ 大小的张量，reshape 成这个大小的矩阵。

卷积：通过改变卷积核的数量来对特征图进行处理得到 $(\text{shape} // 32) * (\text{shape} // 32) * (N * 5(x, y, w, h, \text{confidence}) + c)$ 的矩阵。

②非极大值抑制(NMS)

不同大小的特征层的网格预测出的目标可能相似，同一个目标可能存在很多预测框，因此使用非极大值抑制的方式在一堆预测框中选择预测置信度最高的预测框。

③损失函数

总体损失函数包括位置损失，类别损失和置信度损失 $\text{Loss} = \text{loc_loss} + \text{conf_loss} + \text{cls_loss}$ 。

$$\begin{aligned}
 LOSS = & \lambda_{cood} \sum_{i=0}^{S^2} \sum_{j=0}^N I_{ij}^{obj} [(x - \hat{x}_i)^2 + (y - \hat{y}_i)^2] + \lambda_{cood} \sum_{i=0}^{S^2} \sum_{j=0}^N I_{ij}^{obj} [(\sqrt{w_i} - \sqrt{\hat{w}_i})^2 + (\sqrt{h_i} - \sqrt{\hat{h}_i})^2] \\
 & + \sum_{i=0}^{S^2} \sum_{j=0}^N I_{ij}^{obj} (C_i - \hat{C}_i)^2 + \lambda_{noobj} \sum_{i=0}^{S^2} \sum_{j=0}^N (C_i - \hat{C}_i)^2 + \sum_{i=0}^{S^2} I_i^{obj} \sum_{c \in \text{Classes}} (P_i(c) - \hat{P}_i(c))
 \end{aligned} \quad (3.2)$$

式中

$$\lambda_{cood} \sum_{i=0}^{S^2} \sum_{j=0}^N I_{ij}^{obj} [(x - \hat{x}_i)^2 + (y - \hat{y}_i)^2] + \lambda_{cood} \sum_{i=0}^{S^2} \sum_{j=0}^N I_{ij}^{obj} [(\sqrt{w_i} - \sqrt{\hat{w}_i})^2 + (\sqrt{h_i} - \sqrt{\hat{h}_i})^2] \quad (3.3)$$

是针对位置预测主要回归预测出的坐标值，其中 I_{ij}^{obj} 判断是否符合第*i*个网格的第*j*个目标框。

$$\sum_{i=0}^{S^2} \sum_{j=0}^N I_{ij}^{obj} (C_i - \hat{C}_i)^2 + \lambda_{noobj} \sum_{i=0}^{S^2} \sum_{j=0}^N (C_i - \hat{C}_i)^2 \quad (3.4)$$

是针对置信度预测，主要回归包含和不包含目标的预测框的置信度。

$$\sum_{i=0}^{S^2} I_i^{obj} \sum_{c \in \text{Classes}} (P_i(c) - \hat{P}_i(c)) \quad (3.5)$$

是针对类别预测，主要回归预测框内物体的类别，其中 I_i^{obj} 是判断是否有目标落在网格中。

表 3.2 YOLO-v1-YOLO-v5 目标检测模型发展

Tab. 3.2 Development of YOLO-v1-YOLO-v5 object detection model

模型	数据处理	Backbone	Neck	Head	文献
v1	调整输入尺寸	类似 Googlenet	-	全连接层	[66]
V2	多尺度训练	Darknet-19	-	卷积+anchorbox	[67]
V3	基础数据增强技术 (尺寸, 颜色, 噪声 等)	Darknet-53	FPN	V2 基础上引入多尺度 检测逻辑+多标签分类	[68]
V4	使用 mosaic、cutmix 高阶数据增强	CSP-darknet53	SPP+PANet	与 YOLOv3 相同, 并 引入 CIUO 和 DIUO 损 失	[69]
V5	高阶数据增强以及自 适应图像调整	可调整 CSPdarknet	SPP+CSPP ANet	在 YOLOv4 基础上引 入自适应 anchorbox 和 领域正负样本分配策略	-

3.4 轻量化网络模型

3.4.1 CSPdarknet53tiny

继承原CSPdarknet53的ResBlock 模块的残差边堆叠，同时另一条残差边不同于原CSPdarknet53的通道split分割，其通道数不变。建立新的轻量ResBlock模块，通过

减少ResBlock数量以及使用LeaklyRelu取代mish激活函数来增大网络的稀疏性，减少参数计算以得到轻量化特征检测模型并提高模型的泛化能力。它由4个BasicConv块、1个MaxPooling块构成，输入数据经过BasicConv后，被split成两部分，一部分经过第二个BasicConv计算后，得到特征1，特征1进一步经过第三个BasicConv，计算得到结果特征2，然后再将特征2和特征1进行Concat拼接，经过第四个BasicConv，计算得到特征图3，然后将特征图3和另一部分进行拼接，得到的特征图4输入MaxPooling后得到最终的输出特征图。

3.4.2 深度宽度剪枝

实际上 YOLO-v5s、YOLO-v5m、YOLO-v5l、YOLO-v5x 的骨架网络都是相同的 backbone，其区别在于深度系数和宽度系数。

```
backbone:
# [from, number, module, args]
[[-1, 1, Focus, [64] 3]], # 0-P1/2
[-1, 1, Conv, [128] 3, 2]], # 1-P2/4
[-1, 3, C3, [128]],
[-1, 1, Conv, [256] 3, 2]], # 3-P3/8
[-1, 9, C3, [256]],
[-1, 1, Conv, [512] 3, 2]], # 5-P4/16
[-1, 9, C3, [512]],
[-1, 1, Conv, [1024] 3, 2]], # 7-P5/32
[-1, 1, SPP, [1024] [5, 9, 13]],
[-1, 3, C3, [1024] False]], # 9
]
```

图 3.3 yolov5s 模型文件

Fig. 3.3 yolov5s model file

首先看 YOLO-v5s 深度系数 $\text{depth_multiple}=0.33$ ，其源代码参与运算的是：

$$n = \max(\text{round}(n * \text{gd}), 1) \text{ if } n > 1 \text{ else } n$$

这里的 n 表示结构的个数，也就是说， n 是个 ≥ 1 的整数(起码得有一个，否则不存在)， depth_multiple 越大，那么模型结构的个数也越多，因此网络就更“深”。如图红框标出的 C3 结构的数量，当 $n=3$ 时， $\max(0.33*3, 1)=1$ ，第二个 C3 结构 $n=9$ 时， $\max(0.33*9, 1)=3$ 。

再看宽度系数 $\text{width_multiple}=0.5$ ，参与运算的是这行代码：

```
if c2 != no:
    c2 = make_divisible(c2 * gw, 8)
```

这个 $c2$ 代表当前层的输出的通道(Channel)数，也就是说， width_multiple 越大，那么模型结构的通道数越多，因此看起来就更“宽”。如图蓝框标出的卷积核的数量，在 Focus 结构中，标准的 $c2=64$ ， $c2=\text{make_divisible}(64*0.5, 8)=32$ ，以下结构卷积核计算同理。

3.4.3 MobileNetv3

MobileNet^[65]模型是由Google的研究员Andrew Howard在2017年提出的，为将深度学习应用到移动设备而提出的一种轻量型的深度卷积神经网络模型。其使用的主要思想是引入称为深度可分离卷积(Depthwise Separable Convolution)的技术，以获得更小的模型和更快的训练时间。包含两个卷积层次一个是Depthwise(DW)卷积另一个Pointwise(PW)卷积。Depthwise(DW)卷积主要负责提取特征，它会在每个通道上单独运行卷积核，而不像传统的卷积层一样在所有通道上运行卷积核。一个卷积核负责一个通道，一个通道只被一个卷积核进行数据提取，而没有进行数据组合的操作，所以没有利用通道间相互的关联信息。Pointwise(PW)负责将特征数据映射到输出特征图，它使用 $1*1$ 的卷积核来把深度卷积后的特征图转换成输出特征图。通俗的讲，普通卷积层的特征提取与特征组合一次完成并输出，而深度可分离卷积先用深度为1的 $3*3$ 的卷积核(Depthwise卷积)提取特征，再用 $1*1$ 的卷积核(Pointwise卷积)调整通道数，将特征提取与特征组合分开进行^[70]。原理与矩阵乘法相似。在MobileNetv3^[71]中的Inverted Residuals正好与ResNet的bottleneck residual block相反，其结构形状是中间胖两头窄。引入注意力机制SENet，提升网络上下层之间的信息联系，使模型更加注重感兴趣区域。h-swish替换swish，在量化模式下回提高大约15%的效率，使用ReLU6来替代sigmoid，降低在其移动端的耗时。以上可以看出，深度可分离卷积可大大减少模型的参数的同时也有很好的识别性能。

3.4.4 ShuffleNetv2

ShuffleNet^[72]是2007年提出的一种计算高效的深度学习网络模型，主要是应用在移动端与MobileNet类似。ShuffleNet的核心是两种操作：分组逐点卷积(Pointwise Group Convolution)和通道洗牌(Channel Shuffle)，这它们分别控制着网络中参数的分组和通道数，使得网络更加紧凑，更加高效。因为Group Convolution组卷积是将输入层的不同特征图进行分组，然后采用不同的卷积核再对各个组进行卷积，这样会降低卷积的计算量，但是堆积Group Convolution组卷积层后的一个问题是不同组之间的特征

图是不通信的。所以 ShuffleNet 的理念逻辑是通过对不同的 Channel 通道进行 Shuffle 打乱洗牌来解决 Group Convolution 组卷积带来的不通信弊端。

一般的卷积都是在所有的输入特征图上做卷积，可以说是全通道卷积，这是一种通道密集连接方式(Channel dense connection)。而 Group Convolution 组卷积相比则是一种通道稀疏连接方式(Channel sparse connection)。Pointwise Group Convolutions 分组逐点卷积是既带有 Group 分组且卷积核为 1×1 的卷积，Group 的概念早在 AlexNet 创建时作者为解决使用的 GTX 580 显存太小，没法放下整个网络而采取分组的操作。MobileNet 采用 Depthwise Convolution，分组数恰好等于通道数，所以也是一种比较特殊的 Group Convolution。ShuffleNet 算法模型的整体结构，也是分成几个 Stage 阶段然后在每个 Stage 阶段中用 ShuffleNet unit 单元进行堆叠，所以也与 ResNet 的结构类似。ShuffleNet unit 单元的主要结构主要由四个部分组成：

(1)卷积层：ShuffleNet 的卷积层主要由 1×1 卷积层和 Group Convolution 层组成， 1×1 卷积层用于将特征图的通道数进行变换，Group Convolution 层则用于将特征图进行分组，以降低计算量。

(2)深度可分离卷积层：深度可分离卷积是一种特殊的卷积操作，它将普通卷积运算分成深度卷积和空间卷积两部分，从而将特征图的通道分组，从而降低计算量。

(3)平均池化层：ShuffleNet 的采用步长为 2 的平均池化运算，下采样提取特征。

(4)Shuffle 操作：Shuffle 操作是 ShuffleNet 的核心技术，它将多个特征图进行混合，从而更好地提取特征。

要实现高模型容量和高效率，最重要的是如何在不密集堆叠卷积和不过多分组的情况下，保持大量的、同样宽的通道，所以 ShuffleNetv2 在 ShuffleNet 的基础上做出改进。ShuffleNetv2^[73]基于实证研究认为一个高效的网络架构应该

(1)使用等通道宽度的卷积，以最小化内存访问成本 (MAC)；

(2)了解使用过度使用组卷积，会增加内存访问成本；

(3)降低碎片化程度，保证并行度；

(4)减少元素操作。

ShuffleNetv2 所以在每个 block 模块的开始，将特征通道的输入分为两个分支(在 ShuffleNetv2 中这里是对 Channels 均分成两半)。根据 3，不能使用太多的分支，所以结构中一个分支不做任何操作，另外的一个分支由三个卷积组成，与深度可分离卷积操作相似，它们具有相同的输入和输出通道(满足 1)。考虑到组的代价，两个 1×1 卷积不再是组卷积，而改变为普通的 1×1 卷积操作(满足 2)。然后两个分支被 contact 连接起来，而不是相加(满足 4)。因此，单元前后通道的数量保持不变(满足 1)。最后使用 “Channels Shuffle” 操作来启用两个分支之间的信息通信。不再使用 “Add” 操作。

使用轻量化模型作为特征提取层的 YOLO 网络可以提升检测时间，而且模型文件较小对于进行数据处理硬件的性能要求不高，可以很好的部署到嵌入式设备上接下来就使用上述轻量化网络模型的 YOLO 目标检测算法进行简要介绍。

3.5 YOLO 目标检测模型

3.5.1 YOLO-v4tiny




图 3.4 YOLO-v4tiny 网络结构

Fig. 3.4 Network structure of YOLO-v4tiny

如图所示，YOLO-v4 的轻量版 YOLO-v4tiny^[74]主要是在特征提取层使用 CSPDarknet53-tiny 取代 CSPDarknet53，由于去掉大量的堆叠层的简化版，参数只有原来的十分之一。在特征融合层使用金字塔模块 FPN 舍掉 PANet 路径连接，减少大量冗余参数，特征预测层使用继承 YOLO-v4 的两个检测头 YOLO-Head。使用 K-means 聚类算法生成 6 个不同宽高的锚框作为预测时参考的标准框。在引入 CIoU 损失代替 IOU 损失计算边界框定位损失，边界框的回归预测更加准确稳定。

3.5.2 YOLO-v5s




图 3.5 YOLO-v5s 网络结构

Fig. 3.5 Network structure of YOLO-v5s

YOLO-v5 有 l, m, x, s 的 4 个版本。其中 YOLO-v5s 是轻量版，主要是由特征提取层：下采样层：Focus+C3 模块，特征融合层：空间金字塔 SPP 和用 C3 改进的路径聚合网络 PANet^[75]以及三个检测头 YOLO-Head。YOLO-v5 通过改变网络结构的深度：C3 模块的数量和改变 C3 中网络结构的宽度：卷积核的数量来控制模型的大小。YOLO-Head 在结构上是延续 YOLO-v4 及 YOLO-v3 通过对融合后的后特征进行预测，在数据输入时使用 Mosaic 增强丰富了图片的背景，并且四张图片拼接在一起变相地提高 batch_size，提高小目标和少样本的计算频次，提升结果的准确性。

3.5.3 YOLO-v4MobileNetv3




图 3.6 YOLO-v4MobileNetv3 网络结构

Fig. 3.6 Network structure of YOLO-v4MobileNetv3

YOLO-v4在输入端的数据处理中开始引入 Mosaic 数据增强。同时在 backbone 中使用 CSPDarknet53网络模型提取特征，提高网络的深度学习能力但是由于 CSPDarknet53 模型深度较高，参数量较大，检测速率较慢因此本文采取使用 MobileNetv3作为特征提取层，减少参数，提高检测速率。此外，对于网络训练的方式、激活函数的使用和损失函数也进行优化，使 YOLO-v4更快，以达到准确性和速度之间的平衡。如图3.6所示，YOLO-v4网络利用深度学习网络框架 MobileNetv3作为训练和提取图像特征的主干网络，然后使用 MobileNet 方式改进 PANet，YOLO-head，以减少参数，提高检测速率。

3.5.4 YOLO-Fastestv2




图 3.7 YOLO-Fastestv2 网络结构

Fig. 3.7 Network structure of YOLO-Fastestv2

YOLO-Fastestv2 目标就是提高单核的实时推理性能，首先模型的 backbone 替换为 ShuffleNetv2，相比原先的 backbone: ShuffleNetv1，满足实时的条件下的低 CPU 占用，并减少访存。neck 部分与 YOLO-v4tiny 类似使用 lightFPN 进行简单的特征融合，检测头参考 YOLO-X 的解耦头分别预测目标的类别与位置。之前的工作是共享检测头结构，而解耦头就是将分类和回归解耦，使得不同的任务分支关注不同的特征以提高性能。

解耦头(Decoupled Head): Song 在文献^[76]中提出, 在目标检测的定位和分类任务中, 存在空间错位(spatial misalignment)的问题, 即这两个任务所关注的感兴趣区域不同。作者认为因为分类(识别物体是什么)和回归(定位物体的位置)关注的特征不一样。分类任务更加聚焦于提取的特征的类别, 而定位任务更关注真实标注框(ground truth box)的位置坐标与预测边界框(predicate bounding box), 从而对预测框参数修正, 最终由非极大值抑制(NMS)处理后得出边界框(bounding box)。因此如果采取用同一个特征图进行分类和定位, 效果会不好, 即所谓的错位(misalignment)的问题。作者在改进 YOLO-v3 的 baseline 将 YOLO-Head 修改为 Decoupled Head, 发现 AP 值从 38.5%, 增加到 39.6%。不单单是精度上的提高, 替换为 Decoupled Head 后, 网络的收敛速度也加快。于是得到一个关键结论: 目前 YOLO 系列使用的检测头表达能力可能有所欠缺,

没有 Decoupled Head 表达能力强。下图为输入图像大小为 640，ShuffleNetv2 1.0x 结构下解耦头的计算过程：




图 3.8 解耦头
Fig. 3.8 Decoupled Head

- (1)类别预测输出：主要预测物体中心点落在 20*20 特征图上单元格的类别分数。因为玉米数据集总共有 3 个类别，且主要是 20*20 个网格进行分类判断，因此经过 Sigmoid 激活函数处理，变为 20*20*3 大小。
- (2)置信度预测输出：主要判断中心点落在 20*20 特征图上单元格的物体是前景还是背景，因此经过 Sigmoid 处理，变为 20*20*1 大小。
- (3)边界框预测输出：主要根据锚框对中心点落在 20x20 特征图上单元格的物体的坐标信息(x, y, w, h)进行预测，因此大小为 20*20*4。
- 最后三个输出，经过 Concat 融合到一起，得到 20*20*8 的特征信息。

3.6 模型对比

表 3.1 各模型对比
Tab. 3.1 Model comparison

模型	指标		
	精确率%	召回率%	模型大小 M
YOLO-v4tiny	91.33	73.86	22.4
YOLO-v4MobileNetv3	93.26	80.49	10.68
YOLO-v5s	93.98	89.45	14.05
YOLO-FastestV2	92.21	70.33	4.25

由上表中可以得出：在本试验的数据集上识别效果最好的是 YOLO-v5s 算法，其次是使用 MobileNetv3 结构改进的 YOLO-v4MobileNetv3，然后是 YOLO-v4tiny，最后是 YOLO-Fastestv2，但是对硬件性能要求最低，识别性能与其他算法效果不相差巨大的条件下，YOLO-Fastestv2 相对于其他目标检测模型有更好的性价比，下文在不明显增加参数与输出模型大小的基础上提高识别准确度，提升模型的性能。

3.7 本章小结

本章主要研究深度学习算法，然后根据研究需求对目前主流的单阶段目标检测网络进行研究，并对轻量级基础网络的结构和特点进行具体研究，为提升杂草检测精度奠定基础。使用检测数据集对不同目标检测网络的检测性能进行研究对比。最终使用 YOLO-Fastestv2 算法进行研究，为精准变量喷施的研发提供保证。

第四章 基于 YOLO-Fastestv2 玉米幼苗与杂草检测算法改进

4.1 数据预处理改进

4.1.1 K-Means++聚类

预测框的准确率与先验框的大小息息相关。为更好地设计先验框的大小，本研究从标注的数据集中归纳出所需要的先验框。通过聚类学习的方式，将相似的对象归入一个集合中，集合中心通过集合中所有点的平均值来计算。常见的聚类算法有：均值漂移聚类算法，K-Means(k 均值)算法，K-Means++等。本文选用 K-Means++算法。

聚类算法属于无监督学习，所以标注数据集中的样本点难以确定自己所属的样本簇，聚类中心就更难以确定，为解决这一问题，K-Means 算法通过随机选择确定聚类中心，但由于无法保证随机选择的 k 个质心就恰好是完成聚类后的 k 个簇的中心点，所以算法通过求均值的方式不断地调整质心，例如每个聚类簇都有若干个样本点，对这些样本点的坐标值求均值，就得到新质心的坐标点，这样不断调整。k-Means++算法用于改善 K-Means 的聚类效果，是采用划分法的 K-Means 算法的优化版本，主要是为选择出更优的初始聚类中心。

K-Means++算法是对 K-Means 算法的改进。它采用概率模型来选择每个点成为中心点的概率，从而避免簇的中心点陷入局部最优解的问题。使得最初选择的质心更加合理，从而减少 K-Means 算法的迭代次数，提高算法的效率。

但是 K-Means 算法在选择不同的初始中心点可能导致不同的聚类结果。而且在迭代过程中，簇的中心点可能会陷入局部最优解，这样的取值方式得到的聚类中心不确定性较高，可能对聚类效果产生很大的影响。K-Means++算法选择初始聚类中心的准则是：选取彼此之间距离最远的聚类中心。其基本过程如下：

(1)初始点选择：

在数据集的初始聚类中心的选择上，有放回的抽样方式随机选择一个样本作为第一个初始中心点；

(2)选择出其余的中心点：

计算数据集中的每一个样本点到已选择出的中心点之间的最短的距离，保存在一个数组中。比较数组内距离大小，以概率选择距离最大的样本作为新的中心点，如距离值越大表示被选取作为中心点的概率较大。继续上述过程，直到确定 k 个中心点。

(3)K-Means 聚类

对这 k 个选择出的聚类中心，利用 K-Means 算法计算出最终聚类的中心点。

4.1.2 Mosaic 增强

对于提升小目标的识别准确率，可以使用超分辨率技术、基于上下文的信息、多尺度表示学习、锚机制、训练策略、数据增强和基于损失函数等方案来实现。本试验通过使用上述多个方案来实现，本章介绍使用 Mosaic 数据增强的方式。

它是参考 Cutmix 增强扩充原始数据集，来增强模型的准确性和稳定性。该技术由于是从原始数据中抽取信息填充所以不会产生其他的非信息像素，其次通过裁剪的方式使缩小目标所处区域，要求网络从局部识别目标对象，进一步提升网络的定位能力。然后只是物理拼接，不会出现像素叠加改变目标特征，不会影响网络分类表现。

具体实现是从数据集中取出一个 batch 的图片数据，随机从 batch 内取得四张图片进行裁剪拼接合成新的图片，这样重复 batch_size 次，得到一个 batch 的包含 batch_size 个 Mosaic 增强后图片的新数据。

Mosaic 增强不仅丰富样本的数量还丰富了检测物体的背景，增加训练数据中小物体的数量，对模型面对真实场景中物体的识别有很大的帮助。但是根据 YOLO-X 这篇论文中指出，训练结束前的 15 个 epoch 关掉 Mosaic 和 Mixup 增强，因为 Mosaic+Mixup 生成的训练图片，可能与实际场景图片偏差较大，并且 Mosaic 大量的如旋转，裁剪等物理增强操作会带来很多不准确的标注框，所以本研究在训练结束前的 15 个 epoch 关掉 Mosaic 增强。

4.2 损失函数改进

4.2.1 Focal Loss

Focal Loss^[77]是一种用于解决分类问题中类别不平衡问题的损失函数，它是在交叉熵损失函数的基础上改进而来的。针对样本不均衡问题，从 loss 角度提供的另外一种解决方法。

Focal loss 的具体形式为：

$$L_{focalloss} = \begin{cases} -\alpha(1-p)^{\gamma} \log(p), & y = 1 \\ -\alpha p^{\gamma} \log(1-p), & y = 0 \end{cases} \quad (4.1)$$

$$\text{令 } p_t = \begin{cases} p, & y = 1; \\ 1-p, & y = 0 \end{cases}$$

将 Focal Loss 表达式(4.1)统一为一个表达式：

$$L_{focalloss} = -\alpha(1-p_t)^{\gamma} \log(p_t) \quad (4.2)$$

pt 反映与 ground truth 即类别 y 的接近程度，pt 越大说明越接近类别 y，即分类越准确。 γ 为可调节因子。 α 用于平衡不同类别样本的重要性。

由于单阶段目标检测存在正负样本极不平衡的问题，所以需要引入平衡交叉熵

损失(cross entropy loss), 但是真实田间情况中存在一些长势较好的禾本科杂草与玉米幼苗外形相似, 而且大部分属于小目标, 所以训练数据中会存在一些难分的样本, 实际预测中大量数据并未对识别效果有提升, 而 Focal Loss 损失函数更加注重难分样本在损失函数的权重, 使得整体更倾向于识别难分的样本, 有利于提高深度学习网络算法模型对难分样本的识别准确度。pt 大小也对应分类的难易程度, pt 越大, 说明该样本分类的置信度越高, 代表样本越易分; pt 越小, 越难分。Focal Loss 损失函数在设计时增加系数惩罚项, 由于分类准确的样本 pt 接近于 1, 所以惩罚项接近于零。相反对于难以分辨的样本 pt 接近于 0, 惩罚项会趋近于 1, 实现对难分样本的聚焦。

4.2.2 SIOU Loss

IOU (交并比) 是预测框和真实框相交区域面积和合并区域面积的比值, 有着能够很好地反映重合度以及具有尺度不变性的优点, 因此被用来解决边界框的回归问题。IOU 的值代表预测框与真实框的重叠程度, 值越大越接近重叠, 反之相反。当 IOU 的值为 1 时两个框完全重合, 但是当预测框与真实框不相交时, 其比值为 0, 当 IOU=0 时则无法反映两者的中心距离, IOU 损失函数在 bounding box 没有重叠时不提供滑动梯度, 便无法判断控制预测框向真实框方向靠近。所以通常会先确定一个阈值, 来判断此时预测框是正确的还是错误的。如设定阈值为 0.5, 则当两个框的 IOU 大于 0.5 时, 认为这是一个包含物体的正确的框, 否则是没有物体错误的框。

(1) DIOU 损失函数

GIOU^[78]使用外接矩形的方法不仅反应重叠区域的面积, 还可以计算非重叠区域的比例, 但是当目标框与预测框水平、竖直方向重叠时, 外接矩形的面积等价于交集面积, 计算得到的 IOU 相等, 损失函数值与 IOU 损失一样, 无法很好地衡量其相对的位置关系。GIOU 是通过不断增大和移动预测框, 直到与真实框有重叠, 需要进行几何计算, 这会消耗大量的时间, 降低边界框损失的收敛速度。所以为更好地衡量两个框的相对位置, DIOU^[79]在 GIOU 的基础上考虑中心点的距离。DIOU 损失函数引入一个惩罚项, 用于进一步惩罚目标框之间的差异, 从而提高目标检测的准确性。具体来说, DIOU 损失函数中的惩罚项是两个目标框的中心点距离, 这个惩罚项的加入可以使目标框更好地匹配真实目标框, 从而提高检测准确率。公式为:

$$DIOU_{loss} = 1 - IOU + \frac{\rho^2(b_{pre}, b_{gt})}{c^2} \quad (4.3)$$

式中(b_{pred} , b_{gt})分别为真实框和预测框的中心点坐标; $\rho^2(b_{pred}, b_{gt})$ 为两框中心位置的欧式距离; c 为真实框和预测框最小包围框的对角线长度。

(2) CIOU 损失函数

DIOU 损失一方面存在预测框被错误放大的问题。另一方面只包含边界框与预

测框重叠面积和中心点距离，并没有考虑两框的长宽比所以破坏了尺度不变性，因此可能导致小尺度样本检测精度失准的问题出现。

所以对重叠面积、中心点距离、长宽比三个几何因素进行综合考量，论文又提出 CIOU^[79]以更加稳定目标框回归。公式定义为：

$$CIOU_{loss} = 1 - IOU + \frac{\rho^2(b_{pre}, b_{gt})}{c^2} + \alpha v \quad (4.4)$$

其中，

$$\alpha = \frac{v}{(1 - IOU) + v} \quad (4.5)$$

$$v = \frac{4}{\pi^2} \left[\left(\arctan \frac{w^{gt}}{h^{gt}} \right) - \arctan \frac{w}{h} \right]^2$$

其中 α 为权重系数，根据定义可知损失函数会向重叠区域大的方向优化， v 衡量预测框与目标框长宽比的相似性。当预测的宽 w 和高 h 与真实框的宽 w^{gt} 和高 h^{gt} 相等时， v 值为 0，惩罚项不发挥作用。

(3) SIOU 损失函数

传统的 IOU 损失函数依赖于边界框回归的指标准确性，例如预测框和真实框的距离、重叠区域和宽高比。然而，目前提出的几种算法都没有考虑真实框与预测框之间匹配方向的问题，都是随机预测框的位置。预测框是随机预测的，结果难以确定，所以最终可能产生更差的模型，这种缺点也可能导致预测时收敛速度减慢且效率降低。本文选择损失函数 SIOU，该损失函数考虑到真实框与预测框之间的向量角度，重新定义惩罚项。SIOU 损失函数^[80]由 4 个损失函数组成：角度损失，距离损失，形状损失，IOU 损失。

$$SIOU_{loss} = 1 - IOU + \frac{\text{Distance_cost} + \text{Shape_cost}}{2} \quad (4.6)$$




图 4.1 角度损失计算原理图

Fig. 4.1 Schematic for calculating angular loss

①角度损失

如图，角度损失由预测框到真实框中心点之间的直线距离、垂直距离、水平距离与水平方向的角度 α ，与垂直方向角度 β 组成。基本上，模型将尝试首先将预测带入到 X 或 Y 轴(以最接近者为准)，然后沿着相关轴继续接近。如果 $\alpha \leq \pi/4$ ，收敛过程将首先最小化 α ，反之最小化 β 。因此引出角度损失公式：

$$\text{Angle_cost} = 1 - 2\sin^2(\arcsin(x) - \frac{\pi}{4}) \quad (4.7)$$

其中 $x = \frac{C_h}{\sigma} = \sin(\alpha)$,

$$\begin{aligned} \sigma &= \sqrt{(b_{C_x}^{gt} - b_{C_x})^2 - (b_{C_y}^{gt} - b_{C_y})^2} \\ C_h &= \max(b_C^{gt} - b_C) - \min(b_C^{gt} - b_C) \end{aligned} \quad (4.8)$$

②距离损失

根据考虑的角度损失定义 Distance cost:

$$\text{Distance_cost} = \sum 1 - e^{-\gamma p_i} \quad (4.9)$$

其中

$$\begin{aligned} \gamma &= 2 - \text{angle_cost} \\ \rho_x &= \left(\frac{b_{C_x}^{gt} - b_{C_x}}{C_w}\right)^2, \rho_y = \left(\frac{b_{C_y}^{gt} - b_{C_y}}{C_h}\right)^2 \end{aligned} \quad (4.10)$$

可以看出， $\gamma \cdot \rho$ 与 Distance cost 值呈正相关，所以当 α 趋于 0 时，angle cost 越小， γ 越来越小，Distance cost 的值越来越低，此时 Distance cost 的贡献越来越小。相反， α 越接近 $\pi/4$ ，angle cost 越大， γ 越来越大，Distance cost 值越大 Distance cost 的贡献越来越大。随着角度的增大，问题变得越来越难。




图 4.2 距离损失计算原理图，引自[80]

Fig. 4.2 Distance loss calculation schematic, from [80]

③形状损失

$$\text{shape_cost} = \sum (1 - e^{-\omega_i})^\theta \quad (4.11)$$

$$\omega_w = \frac{|w - w^{gt}|}{\max(w, w^{gt})}, \omega_h = \frac{|h - h^{gt}|}{\max(h, h^{gt})} \quad (4.12)$$

式 4.12 的值定义每个数据集的 Shape cost 且是这个等式中非常重要的一项，其值是唯一值，它掌控 Shape cost 的关注程度。




图 4.3 IOU 形状损失原理图，引自[80]

Fig. 4.3 IOU shape loss schematic, from[80]

4.3 优化器改进

优化器即梯度下降算法，主要是优化求损失函数极小值的收敛速度，梯度下降就是寻找极小值的方向，梯度上升是寻找极大值的方向。选用不同的梯度下降算法损失函数拟合与收敛的速率也会不同。本研究选用 Nadam 算法^[81]。

Nadam 算法，是添加 NAG 的自适应运动估计的 Adam 优化算法。Adam 可以有效地处理稀疏梯度和较大的梯度噪声，并且可以适应非凸优化问题，有效地处理参数的非平稳性和不可导优化问题，并且有效地抑制高阶矩阵的衰减率。可以加快收敛速度，达到更高的精度。将 momentum 和 RMSprop 梯度下降算法融合，增添参数 β_1 和 β_2 ，其一阶和二阶动量公式为：

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t \quad (4.13)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \quad (4.14)$$

β_1 , β_2 为指数衰减率， β_1 控制动量和当前梯度的权重分配， β_2 控制之前梯度平方的影响情况。Gt 是目标函数对于所求参数 θ 求导所得梯度。

由于动量初始值 m , v 很小，接近为 0，因此时 β 值很大，因此需要一个偏差来校正

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t} \quad (4.15)$$

$$\hat{v}_t = \frac{v_t}{1 - \beta_2^t} \quad (4.16)$$

所以最终 Adam 梯度更新方程为：

$$\theta_{t+1} = \theta_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t + \varepsilon}} \quad (4.17)$$

η 是学习率， ε 是为维持数值稳定性而添加的常数。

由于使用动量进行梯度下降时遇到极值附近并不会减弱更新的幅度，而 NAG(Nesterov accelerated gradient)梯度下降算法解决这个问题，由于加速度方向会考虑上一步的状态，所以 NAG 算法具有一定的“预判”能力，可以更准确地预测下一步的位置，从而加速收敛。

$$m_t = \beta m_{t-1} + (1 - \beta) \frac{\partial(Loss)}{\partial(\theta_t - \eta \beta m_{t-1})} \quad (4.18)$$

$$\theta_{t+1} = \theta_t - \eta m_t \quad (4.19)$$

NAG 算法在每次迭代中，首先根据当前位置的梯度计算一个“加速度方向”，然后在这个方向上向前走一步，得到一个“预测位置”。接着，算法会在预测位置处计算梯度，并根据这个梯度来调整加速度方向和预测位置。

对梯度求偏导 NAG 梯度更新公式可变为：

$$g_t = \frac{\partial(loss)}{\partial(\theta_t)} \quad (4.20)$$

$$m_t = \beta m_{t-1} + (1 - \beta) g_t \quad (4.21)$$

$$\theta_{t+1} = \theta_t - \eta \beta m_{t-1} + (1 - \beta) g_t \quad (4.22)$$

Nadam 算法与 adam 相似对 m 做一个规范：

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t} \quad (4.23)$$

最终得出 Nadam 的参数更新表达式：

$$\theta_{t+1} = \theta_t - \eta \frac{(\beta_1 \hat{m}_t + \frac{(1 - \beta_1) g_t}{1 - \beta_1^t})}{\sqrt{\hat{v}_t + \varepsilon}} \quad (4.24)$$

4.4 基础网络改进

由于大多数被研究的场景物体都比较容易辨认，现有 CNN 的一个常见的设计缺陷带来的负面影响通常不会表现出来，特别是在 CNN 体系结构的早期层中图像有良好的分辨率，模型也因此仍然可以很好地学习特征。但是当处理图像分辨率较低或对象较小的任务时，由于图像的信息量减少或者对象变得更加微小，算法可能会失去必要的上下文和细节信息，从而导致性能下降。此外，当图像分辨率较低时，可能会出现像素模糊或失真，从而给算法带来额外的挑战。

4.4.1 下采样层

使用跨跃卷积(Strided Convolution)或池化(pooling)，浅层信息存在大量的冗余像素信息，跨跃卷积和池化可以方便地跳过，同时这也产生一些信息的丢失和对特征的较低效率的学习。因此新的CNN模块被提出，称为SPD-Conv，以取代每个使用步长为2的卷积和每个池化层。

SPD-Conv^[82]由space-to-depth (SPD)层和non-strided Convolution(Conv)层组成，可以应用于大多数CNN架构。

本研究将特征提取层中步长为 2 的 Depthwise(DW)卷积换成 SPD-Conv。

SPD-Conv 由一个 SPD 层和一个步长为 1 的非跨步卷积层组成，SPD 组件将(原始)图像转换技术推广到对 CNN 内部和整个 CNN 中的特征图进行下采样，考虑任何大小为 $S \times S \times C_1$ 的中间特征图 X ，切出一系列子特征图为

$$\begin{aligned} f_{0,0} &= X[0:S:scale, 0:S:scale], f_{1,0} = X[1:S:scale, 0:S:scale], \dots, f_{scale-1,0} = X[scale-1:S:scale, 0:S:scale] \\ f_{0,1} &= X[0:S:scale, 1:S:scale], f_{1,1} = X[1:S:scale, 1:S:scale], \dots, f_{scale-1,1} = X[scale-1:S:scale, 1:S:scale] \\ &\vdots \\ &\vdots \\ f_{0,scale-1} &= X[0:S:scale, scale-1:S:scale], f_{1,scale-1} = X[1:S:scale, scale-1:S:scale], \\ &\dots, f_{scale-1,scale-1} = X[scale-1:S:scale, scale-1:S:scale] \end{aligned} \quad (4.25)$$

接下来，沿着通道维度连接这些子特征图，从而获得一个特征图，它的空间维度减少一个比例因子，通道维度增加一个比例因子。即 SPD 将特征图 $X(S, S, C)$ 转换为中间特征图 $X'(S/scale, S/scale, S/scale^2C)$ 。




图 4.4 SPD 使用实例，引自[82]

Fig. 4.4 Example of SPD usage, from [82]

在 SPD 特征变换层之后，添加一个带有 C_2 过滤器的非跨步(即 $\text{stride}=1$)卷积层，

其中 $C2 < \text{scale}^2 C1$ ，并进一步变换 $X'(S/\text{scale}, S/\text{scale}, S/\text{scale}^2 C1) \rightarrow X''(S/\text{scale}, S/\text{scale}, C2)$ 。使用非跨步卷积的原因是为尽可能地保留原有的判别特征的图像信息。否则，如果使用 $\text{stride}=2$ 的 3×3 卷积，偶数和奇数行/列的采样时间不同，会有不对称采样的可能。一般情况下，步长大于 1 会出现信息的非歧视性丢失，尽管在表面上，它转换特征图 $X'(S/\text{scale}, S/\text{scale}, S/\text{scale}^2 C1) \rightarrow X''(S/\text{scale}, S/\text{scale}, C2)$ 。




图 4.5 shufflenetv1 与 shufflenetv2 模块结构，引自[73]

Fig. 4.5 Shufflenetv1 and Shufflenetv2 module structure, from [73]




图 4.6 改进后的模块结构

Fig. 4.6 Improved module structure

如图本文提出的模块是将原 ShuffleNetV2 的下采样分支的 DW 卷积更换成 SPD 卷积，应用批量归一化(BN)和 ReLu 激活函数；另一个分支继续保持原卷积不变，

然后两个分支 Concat 操作，最后是通道 Shuffle。

4.4.2 池化层

卷积神经网络使用 Pooling 操作来降低特征图的大小，实现减少计算量，降低特征冗余。这一操作对于取得局部空间不变性和后续卷积的感受野至关重要。但是最大值池化 MaxPooling 和平均池化 AvgPooling 这两种池化操作在降低计算量的同时会丢失图像中的大多数信息，降低整个网络的性能。所以，池化 Pooling 应当尽量在减少数据信息的丢失的同时，计算高效。SoftPooling^[83]可以在保持池化层功能的同时尽可能捕捉到输入数据中的重要特征，并保留更多的信息。其基于深度学习的池化技术，与传统的最大池化和平均池化不同，研究表明优于其他类的池化层。

不同于目前基于这两种池化的不同组合的一些池化方法，SoftPooling 网络在反向过程中根据前向时的激活值比例进行计算，可以对每个输入给予一个梯度，可以平滑地提升训练效果，因为 SoftPooling 是可微的。另一方面，使用 Softmax 加权，在不改变原有数据的分布属性的基础上实现更强的特征激活。

SoftPooling 与其他池化实现方式类似：

- (1)使用滑动窗口对特征图进行框选局部的数值；
- (2)对框选的数值进行数学计算，MaxPooling 是取最大值，SoftPooling 是经过 Softmax 指数计算，得出每个值对应的权重并与之相乘；
- (3)进行加总和。

SoftPooling 的核心操作是对 Softmax 函数的使用，根据特征值使用连续可微的函数来计算池化区域 R 的特征值权重。在得到权重之后通过加权区域内的特征值得到最终输出。因此 SoftPool 能反映池化区域 R 内的特征值的分布，更加精确地计算出池化区域内的重要信息，服从一定的概率，而其他两种池化层则没有。

本文将 ShuffleNetv2 浅层网络中 MaxPooling 替换成能保留更多信息特征的 SoftPooling，在不增加计算量的同时使得特征提取性能更加优化。

4.5 FPN 改进

深层网络容易响应语义特征，浅层网络容易响应图像特征。然而，在目标检测中往往因为卷积神经网络的这个特性带来不少麻烦。深层卷积神经网络对图像特征进行提取时，通常情况下浅层的网络提取出的信息多包含目标图像的几何特征，而语义信息较少不利于分类性能，而深层的网络提取出的信息多包含语义特征，相反却缺少几何特征不利于目标位置的检测。

因此在多次卷积进行提取特征后，小目标的几何特征可能会被忽略，而对于 3-5 叶期玉米幼苗伴生的杂草而言相比较下几何特征较小，在特征提取过程后可能会丢失。

所以 FPN(Feature Pyramid Networks 特征金字塔)^[84]通过简单的网络特征层的连接改变,对深层的特征进行上采样并与底层特征连接,使得具有高分辨率的浅层和具有丰富语义信息的深层融合,然后对多个不同尺度的特征层进行预测,这样就实现具有语义信息与几何信息的特征金字塔,同时也没有增添明显的负担。

4.5.1 引入注意力机制

注意力机制是根据人类对于目标物体的关注程度而提出的一种优化特征提取的技术。实际上是权重赋予的问题,将注意力机制引入到深度学习网络模型,有利于模型在非线性的训练中保证在数据不足、数据偏差的情况下,能够聚焦于目标的特征位置,提高模型的性能。由于实际田间杂草分布情况复杂,目标杂草较小,目标杂草被石块、玉米等遮挡等对模型的实际应用有较大的挑战,因此引入注意力机制。目前,软注意力是深度学习常用的注意力机制,主要的研究方向是在通道和空间两个方面。对小型网络优化使用的注意力机制为 SE 和 CBAM。中山大学在注意力机制方面的尝试,提出不同于现有的通道/空间注意力,无参数 3D 注意力模块——SimAM^[85],输出 3D 注意力权值。

CBAM^[86]是将空间注意力与通道注意力进行串行组合。但是人脑的两种注意力往往是协同工作,因此 SimAM 提出统一权值。基于神经科学理论的神经元的重要性,该文提出优化能量函数以探索。用不超过 10 行代码就可以实现导出的能量函数的快速解析解。该模块的另一个优点是,能量函数主导大多数操作,避免结构上过度的调整。为获得更好的注意力,需要评估所有神经元的重要性。在神经科学中,被激活的信息丰富的神经元会抑制外周神经元,即空间抑制。换言之,具有空间抑制的神经元应该得到更高的重要性。找到重要神经元的最简单方法是测量神经元之间的线性可分性。因此,能量函数如下:

$$e_t(w_t, b_t, y, x_i) = (y_t - \hat{t})^2 + \frac{1}{M-1} \sum_{i=1}^{M-1} (y_0 - \hat{x}_i)^2 \quad (4.26)$$

$$\hat{t} = w_t + b_t, \hat{x}_i = w_i x_i + b_i$$

最小化上述公式等价于训练同一通道内神经元 t 与其他神经元之间线性可分性。为简单起见,其采用二值化标签,并添加正则项最终得到如下。理论上每个通道有 $M=H \times W$ 个能量函数。

$$e_t(w_t, b_t, y, x_i) = \frac{1}{M-1} \sum_{i=1}^{M-1} (-1 - (w_i x_i + b_i))^2 + (1 - (w_t + b_t))^2 + \lambda w_t^2 \quad (4.27)$$

上述公式存在如下解析解:

$$w_t = -\frac{2(t - u_t)}{(t - u_t)^2 + 2\sigma_t^2 + 2\lambda}, b_t = -\frac{1}{2}(t + u_t)w_t \quad (4.28)$$

其中,

$$\sigma_t^2 = \frac{1}{M-1} \sum_{i=1}^{M-1} (x_i - u_t)^2, u_t = \frac{1}{M-1} \sum_{i=1}^{M-1} x_i \quad (4.29)$$

因此最小能量可以得到

$$e_t^* = \frac{4(\hat{\sigma}^2 + \lambda)}{(t - \hat{u})^2 + 2\hat{\sigma}^2 + 2\lambda} \quad (4.30)$$

上述公式意味着能量越低神经元与周围神经元的区别越大重要性越高，因此神经元的重要性可以从 $1/e_t^*$ 得到。本文在特征提取后设置 SimAM 注意力在不增加参数量影响计算时间的情况下，增强 FPN 模块对目标特征的信息融合。如图 4.7 添加 SimAM 注意力模块后生成的特征图感兴趣区域更加宽泛，覆盖位置更加精确。




图 4.7 添加(左)与不添加(右)注意力模块特征图对比

Fig. 4.7 Comparison of feature maps of adding or not adding attention module




图 4.8 改进 YOLO-Fastestv2 网络结构

Fig. 4.8 network structure of improved YOLO-Fastestv2

如图 4.8 即为改进后的 yoloFastestv2 模型结构图。

4. 6 试验参数

4. 6. 1 试验平台

为验证本文提出改进方法的有效性，配置参数如表 4.1 所示，本试验基于 Ubuntu22.04 操作系统，采用深度学习库 Pytorch 框架搭建，编程语言使用 Python，软件平台为 Ubuntu+ Pytorch3.8.1 + CUDA11.0。硬件平台为 Intel(R)Core(TM)i7-10700F 2.9GHz CPU+32GB 内存+NVIDIA GeForce RTX3090 24GB GPU 和 3.0TB 的存储容量。

为验证论文方法的有效性，本文进行充分对比试验，利用玉米杂草测试数据集和拍摄的田间复杂情况下杂草数据集，对原始的YOLO-Fastestv2、改进后的YOLO-Fastestv2以及改进后的YOLO-v4MobileNetv3，YOLO-v4tiny，YOLO-v5s进行比较试验。表4.2给出原始的YOLO-Fastestv2、改进后的YOLO-Fastestv2，YOLO-v4 MobileNetv3，YOLO-v4tiny，YOLO-v5s检测算法的各项性能指标的对比结果。评估指标为平均精度均值mAP、精确率Precision、召回率Recall、F1、模型大小、检测速度等。

4. 6. 2 超参数设置

表 4.1 试验参数设置

Tab. 4.1 Test parameter settings

超参数	值
LR(Learning rate)	0.002
EPOCH	300
Batchsize	16
Iou 阈值	0.65
Class 类别	3
optimizer 优化器	Nadam

4. 6. 3 评价指标

评价模型性能指标有多种，常见的有 Precision(精确率，P)、Recall(召回率，R)和 Mean Average Precision(平均精确度，mAP)，F1 值，top1，top5 等本文选取前四个方面作为本模型算法的评估标准。这些标准皆由最基础的识别结果得出。有 TP(true positive)，TN(true negative)，FP(false positive)，FN(false negative)。positive 即为真实

正例，negative 为真实负例。

精确率 P 是模型识别结果中模型认为是正例，事实上也是正例的部分占有所有正例的比例，计算公式为

$$P = \frac{TP}{TP + FP} \quad (4.31)$$

召回率 R 是模型识别结果中模型认为是正例，事实上也是正类的部分占有所有事实上是正例的比例(正确正例，错误负例)，召回率越高，表示我们准确确诊的能力就越强，计算公式为

$$R = \frac{TP}{TP + FN} \quad (4.32)$$

F1 值是精确率和召回率的调和平均(倒数之和的平均值的倒数)，最大为 1，最小为 0。F1 值越高代表模型性能越好。

$$F1 = 2 \times \frac{1}{\frac{P}{R} + \frac{R}{P}} = \frac{2 \times P \times R}{P + R} \quad (4.33)$$

平均精确度 mAP 为各类别 AP 的平均值， AP 通过 Precision 和 Recall 的点的组合，画出来的曲线下面的面积，通常来说 MAP 值越高，识别率越高，模型性能越好。计算公式为

$$AP = \int_0^1 P(R)$$

$$mAP = \frac{\sum_{c=1}^C AP(c)}{C} \quad (4.34)$$

4.7 模型效果分析




图 4.9 改进模型训练损失曲线

Fig. 4.9 Improve YOLOv4 model training loss curve

如图 4.9 所示为改进 YOLO-Fastestv2 训练过程中的损失随迭代次数的相应的变化曲线。其中，红色曲线代表训练损失，橘红为验证损失，绿色与紫色代表运用标签平滑训练的损失结果。从图中可以看出，训练损失在前 50 轮训练时，损失下降幅度并不大，是由于阔叶样本类型多样外观特征不同，被分为一类，所以拟合较慢，当训练轮次较多时，改进 YOLO-Fastestv2 判别出此类的高级语义特征拟合出相应的权重趋势，损失值下降迅速，并在 150 轮后震荡，逐渐平稳。验证损失在 50 轮，145 轮左右出现较大幅度的震荡，之后跟随训练损失变化趋势，最终趋于平稳。使用标签平滑后的损失函数相比更加平滑，震荡幅度较小。

表 4.2 各模型测试结果对比
Tab. 4.2 Comparison of test result of each model

模型	指标					
	精确率(%)	召回率(%)	F1(%)	mAP(%)	模型大小(M)	检测速度(帧/s)
YOLO-v4tiny	91.33	73.86	81.67	88.68	22.41	121
YOLO-v4MobileNetv3	93.26	80.49	86.40	90.72	10.68	135
YOLO-v5s	93.98	89.45	91.66	94.25	14.05	125
YOLO-Fastestv2	92.21	70.33	79.79	87.92	4.25	245
改进 YOLO-Fastestv2	93.97	90.02	91.95	94.28	5.12	200

如表所示，在没有改进前，YOLO-v4tiny 和 YOLO-v4MobileNetv3 对于玉米杂草的检测效果大致相同，其中 YOLO-v4MobileNetv3 略优于 YOLO-v4tiny。YOLO-v5s 检测效果最好，YOLO-Fastestv2 检测效果最差，但是 YOLO-Fastestv2 模型大小以及检测速度远超过其他几种。

本文提出的改进 YOLO-Fastestv2 网络，在达到 YOLO-v5 识别效果的同时模型文件较原 YOLO-Fastestv2 仅增加 0.87M。对比结果表明，改进 YOLO-Fastestv2 模型检测精确率和召回率分别为 93.97%和 90.02%，相比改进之前分别提高 1.76%和 19.69%。F1 值比 YOLO-v4tiny、YOLO-v4MobileNetv3、YOLO-v5s 模型分别提高 10.28%、5.55%和 0.29%，比原模型提升约 12.16%。输出模型大小仅为 3 种网络模型的 22.8%、47.9%、36.4%。mAP 值比 YOLO-v4tiny、YOLO-v4MobileNetv3、YOLO-v5s 模型分别提高 5.57%、3.56%和 0.03%，比原模型提升约 6.36%。在检测速度上，YOLO-Fastestv2 追求最快的速度，参数较少，改进后识别精度有所提升，但相应的模型文件大小也随之增加，检测速度也随之减慢，为 200 帧/s，比原来减慢 45 帧/s。但相比其他几种轻量化 YOLO 目标检测模型仍高出有 79 帧/s，65 帧/s，75 帧/s。改进的模型有

较高的 mAP 值与较小的模型大小，较快的检测速度。更适合在嵌入式设备上轻量化模型部署。

表 4.3 各模型在模拟复杂真实情况下识别对比

Tab. 4.3 Comparison of models in simulated complex real-world situations

模型	指标 mAP							正确识别未出现类别数
	背景复杂 %	高光 %	遮光 %	小目标 %	雨后 %	遮挡 %	模糊 %	
YOLO-v4tiny	61	70	80	68	85	60	73	3
YOLO-v4MobileNetv3	65	68	88	72	90	80	85	4
YOLO-v5s	66	72	93	76	92	81	89	5
YOLO-Fastestv2	60	66	83	70	83	58	69	3
改进 YOLO-Fastestv2	65	73	94	76	92	80	88	5



图 4.10 模拟复杂真实情况数据集

Fig. 4.10 simulates a complex real-world dataset

为验证实际田间复杂场景的识别效果，本文整理 7 种可能出现的场景图片，其中背景复杂 18 张，高光 18 张，小目标 18 张，雨后 18 张，遮光 18 张，遮挡 18 张，模糊 18 张，还有 1 种未出现类别 8 张。使用模型进行对比试验，部分数据如图 4.10。

对于背景复杂的数据来说，5 种 YOLO 检测算法 mAP 均低于 67%，是由于各种杂草、麦茬等聚集导致特征难以识别，如存在整张图像为杂草的聚集，则识别率很低，是因为各个杂草之间联通成片难以识别出完整的杂草特征。雨后数据识别效果较好，5 种 YOLO 检测算法 mAP 均高于 80%，主要是因土壤背景与杂草颜色反差较大，杂草

特征更加明显。遮挡效果中 YOLO-v4MobileNetv3、YOLO-v5s，改进后的 YOLO-Fastestv2 较好是因为数据集中目标单一仅有一到两个被土块或玉米遮挡的杂草，叶片的特征识别明显，而由于 YOLO-v4tiny、原 YOLO-Fastestv2 自身识别精度较低，对目标的识别有限，所以被遮挡的情况下识别率很低。遮光与高光数据识别效果相差较大，主要是因高光情况下叶片表型特征与土壤背景有些许重叠，拍摄时降低曝光可能对识别效果有提升，遮光与雨后识别效果类似有较高的识别准确率，因此田间应用时应选取杂草与土壤背景颜色反差较大，饱和度较低的情况下使用算法进行精准识别。对于未出现在数据集中的杂草选用同科属的杂草禾本科 4 张阔叶科 4 张，采用按科属分类时能够正确识别部分杂草类别，为未来清除杂草减少从事农业专业人员的标注负担以及识别田间可能出现的其他类杂草问题提供思路。

试验证明改进后的 YOLO-Fastestv2 算法模型有较好的识别准确率与识别速度，可以应用到田间试验中。下图为数据中部分识别效果



图 4.11 背景复杂

Fig. 4.11 Complex background



图 4.12 模糊

Fig. 4.12 Blurry



图 4.13 小目标

Fig. 4.13 Small target




图 4.14 遮光

Fig. 4.14 Shading



图 4.15 遮挡

Fig. 4.15 Occlusion




图 4.16 未出现

Fig. 4.16 Does not appear

4.8 本章小结

玉米杂草精准识别检测是实现精准除草决策的前提，提升杂草检测速度与准确率对杂草管理有很重要的作用。

本章主要提出一种改进的 YOLO-Fastestv2 玉米杂草检测方法。使用 K-Means++ 算法得到最适合的先验框，使用 Moscia 增强对图像进行预处理。在 YOLO-Fastestv2 基础网络框架中使用 SoftPooling 取代 MaxPooling，保留更多的图像信息，使网络反向传播时仍保留连续的梯度传播，下采样层加入 SPD-Conv 增强对小目标的识别能力，引入 SimAM 无参注意力机制，添加在特征提取主干网络的最后一层在不增加网络模型计算量的情况下，获得更多信息以提升网络性能，选用 Focal 损失函数与 SIOU 损失函数来改进整体损失函数，Nadam 作为优化器实现对 YOLO-Fastestv2 的优化提升。下一章节，将改进的 YOLO-Fastestv2 模型应用在实际田间管理进行试验研究。

第五章 基于深度学习检测算法的变量喷施系统

5.1 引言

目前,对于杂草的精准智能化清除问题,依然是利用视觉传感器(摄像头)等采集杂草图像,通过移动设备进行目标检测或者图像分割,根据检测或分割的杂草位置喷施化学除草剂,以求对杂草的防治清理。但是在实际应用时,模型的大小对于移动设备的要求,田间环境状况复杂对于摄像头稳定性的要求,作物、杂草之间相互遮挡对于模型识别能力的要求,仅依靠目前相关技术在除草领域已经不能解决复杂背景下的杂草识别与应用问题。

本研究根据学者研究及真实田间杂草复杂环境的问题,总结实际应用中杂草精准识别存在的困难之处:

(1)互相遮挡现象严重。作物与杂草,杂草与杂草之间分布长势不同导致作物可能完全遮挡杂草,阔叶科杂草遮挡禾本科杂草,以至于难以精确识别出杂草;

(2)设备要求高。实验室中单纯地对精确度有较大的追求往往忽略掉网络模型的大小,但是移动设备计算能力有限,要想部署到设备上还需要模型大小与准确率有对立与统一。

(3)无法定量。对杂草进行检测与识别,忽略杂草数量,只是识别到喷施,无法精准根据杂草生物量确定防控的药物喷施量,易产生少喷过喷现象。

(4)除草剂使用浪费。目前杂草防除药剂一种是选择性除草剂,一种是灭杀型除草剂还有就是混用型除草剂,这几种药剂各有优势劣势,但是都难免会造成除草剂的浪费。

基于上述问题,本文提出构建基于改进 YOLO-Fastestv2 田间杂草变量喷施系统。模型运行于 CUDA 加速的 AGX 中,将处于视频帧下方的杂草识别加和,识别结果经由异步串行端口并通过协议与实时性更高的 STM32 进行通信,STM32 单片机通过 AGX 输出的信息控制农机喷施和精确的变量喷药,运用单片机 PWM 技术实现不同药箱下喷头的变量喷施。

5.2 除草剂选择

整个玉米的生长时期雨水多、温度高,因此也有助于杂草生长。玉米处于幼苗期时,伴生杂草个体较小,容易清除,而如果不及时清除杂草,会导致杂草过度繁殖争夺玉米的营养甚至阳光,进而使玉米产量下降,所以此时农民为抓紧时间且省时省力,通常使用化学除草剂防除杂草,但目前除草剂品种繁多,而且大多是对作物本身有一定抑制作用的阔叶禾本双除除草剂^[87]。但是实际上田间杂草分布方式可能为一种

单株，一种多株，多种多株，所以一方面容易造成化学药剂的浪费，另一方面对作物本身，环境土壤也有一定的危害。因此，玉米田化学除草要选择合适的除草剂，最大程度减量增效，防止化学除草剂产生药害。山东理工大学生态无人农场玉米地杂草主要有马唐、狗尾、苋、藜、马齿苋，铁苋菜、反枝苋，小蓟，芥菜，刺儿草，小飞蓬等禾本科和阔叶科杂草。桑科杂草葎草等。

表 5.1 选择性除草剂

Tab. 5.1 Selective herbicide

类型	类别	适用作物	作用杂草	染色剂
二甲四氯	选择性激素型除草剂	适用于水稻、小麦、玉米、高粱、青稞以及旱地作物	莎草，菵草，三棱草、鸭舌草、泽泻、野慈姑、牛毛草、扁干草以及其他阔叶杂草	柠檬黄
精喹禾灵	高度选择性的新型旱田茎叶处理剂	阔叶作物田	稗草、狗尾草、马唐、牛筋草、看麦娘、千金子、雀麦、毒麦、早熟禾、狗牙根等禾本科杂草	诱惑红

为验证基于深度学习的变量喷施系统的可行性采用自搭建铝型材框架进行试验研究。实验田玉米植株行间隙 60cm，种植密度间隔 25cm，植株高度 8cm。玉米除草的最佳喷药时期是玉米 3-5 叶期，如果错过这个时间，杂草个体成熟一般除草剂难以将其清除。作业时间为 2022 年 7 月 19 日下午 15 时。

基于深度学习的变量喷施系统的设计是主要包括机器视觉系统，嵌入式边缘计算机(处理平台)、执行机构等组成，实现系统功能的模块有摄像头，NVIDIA AGX 开发板，STM32 单片机，直流无刷水泵，圆锥形喷嘴的压力式喷头。

5.3 喷施系统的设计与设备选择

5.3.1 摄像头

本文是通过对摄像头采集到的玉米杂草数据进行识别检测进而进行杂草变量喷施。因此作为整个研究的开端摄像头质量的好坏也对试验结果产生一定的影响。

表 5.2 摄像头类别

Tab. 5.2 Camera categories

类别	输出	清晰度	优点	缺点
模拟摄像头	输出模拟信号。须经一定的视频捕捉卡转换成数字模式，输出模拟视频信号给后端 DVR 等设备	1. 感光器将光信号转成模拟电信号；2. 采用隔行扫描 3. 只能以 CIF、D1 的图像输出约 40 万像素。	-	远距离传输信号易衰减，也易受到电磁干扰，导致图像质量受到影响；使用的隔行扫描会产生行间的闪烁、边沿锯齿化现象等不良效应。
数字摄像头	传输数字信号，输出给后端混合 DVR\PDVR\NVR\PC	1. 多数采用 CMOS 感光器 2. 采用逐行扫描；3 已经可达百万，甚至千万像素	可以远程管理和图像查看，信号传输过程中不容易被干扰，无损伤传输视频	监控系统成本价格较高，对网络带宽的要求较高等使得其在多数情况下难以使用；各厂家配套设备兼容性差。

模拟摄像头^[88]捕捉到的视频信号传输到后端 DVR 等设备时，DVR 的 Video decoder 视频采集芯片，不仅要模数转换，还要亮色分离，然后进行压缩后才可以转换到计算机上运用。数字摄像头不需要视频采集芯片进行模数 A/D 转换，通过串、并口或者 USB 接口将采集的图像信号传到计算机里。选用免驱动的传输速度优于串口或并口的 USB 数字摄像头。但实际情况中实时采集的数据容易受来自外界和自身等多因素的影响，最终成像的质量不能保证，在田间风速，光影，颠簸等不可控因素影响下，可能产生噪声和成像不均匀。

在距离地面 50 厘米的喷头的左上方安装 500W 无畸变 DF500-1944P 型数字摄像头，摄像头分辨率为 2592x1944 像素，帧频为 15fps，摄像头及其详细参数如表 5.3。



图 5.1 USB 工业数字摄像头

Fig. 5.1 USB industrial digital camera




图 5.2 模拟真实场景下摄像头标定
Fig. 5.2 Camera calibration in simulated real scene

表 5.3 摄像头规格

Tab. 5.3 Camera specifications

参数	规格
Sensor 规格	1/4inchCMOS
像素尺寸	Pixel size 1.4um*1.4um
硬件	工业级高清 500 万像素
帧频	15fps
供电方式	USB bus power
工作电压	5V
对焦	手动对焦(旋转镜头)
图像处理	自动曝光/自动增益/自动白平衡

5. 3. 2 开发板 NVIDIA JESON AGX

Jetson AGX Xavier 是 NVIDIA 专为严苛环境中的智能视频分析、计算机视觉、AI 等打造的一款工业级模组，主要针对应用在工业、航空航天、国防、建筑、农业、库存管理、医疗等领域。核心模组没有独立的显存和内存，CPU 和 GPU 公用同一存

存储器，不需要进行拷贝，真正的零传输时间。Xavier 内还设计有深度学习加速器和可编程视觉加速器单元。

表 5.4 Jetson AGX Xavie 硬件参数

Tab. 5.4 Jetson AGX Xavie Hardware Parameters

配件	参数
CPU	8 核 ARM v8.2 64 位 CPU、8 MB L2 +4 MB L3
GPU	搭载 Tensor Core 的 512 核 Volta GPU
内存	32 GB 256 位 LPDDR4x 137 GB/秒
储存	32 GB eMMC 5.1 PCIe X16
PCIe X 16	X8 PCIe Gen4/x8 SLVS-EC
USB-C	2 个 USB 3.1 接口、DP 接口(可选)、PD 接口(可选)可通过同一端口支持封闭系统调试和烧写
摄像头接口	CSI-2 通道
M.2 Key E	PClex1 +USB 2.0 + UART (for Wi-Fi/LTE) / I2S + DMIC + GPIOs
40 针接头	UART + SPI + CAN + 12 C + 12 S + DMIC + GPIOs
高清音频接头	高清音频
USB3.0 Type A	借助 PCIe x1 桥接器的 SATA 接口 (PD+适用于 2.5 英寸 USB3.0 Type A SATA 接口的数据)

将训练调试好的深度学习网络模型在尽可能保证效果的情况下，部署到开发板上才可以使用其对采集到的图像进行处理。在 AGX 上搭建的 YOLO-Fastestv2 网络算法运行环境。

5.3.3 STM32

选取 STM32 单片机作为系统执行端控制核心。STM32 系列单片机是目前世界上使用最广泛的单片机，应用于生活中的多种场合例如各种便携式设备，自动化控制系统，各种警报、探测设备等。STM32 单片机是基于 ARM Cortex M 处理器内核，32 位闪存微控制器，其通讯速度和运算速度快且控制精度高，具有实时性、低功耗、低电压、成本低的优点。系统响应时间、功耗等方面，优于 PLC 和数据采集卡。STM32 单片机的定时器可以用来产生 PWM 输出；通用定时器也能同时产生 4 路的 PWM 输出；其中的高级定时器可以同时产生 7 路的 PWM 输出；使用 STM32F103ZET6 单片机作为系统控制核心，其具体性能包括：

- (1)CPU 速度 72 MHz，闪存: 1MB，电源：2 V 至 3.6 V；
- (2)采用 32 位 ARM Cortex-M3 处理器，使用串行线调试和 JTAG 调试模式；
- (3)存储器包括 512K 字节的 FLASH 和 64K 字节的 SRAM；
- (4)有 8MHz 的高速 RC 振荡器和两个看门狗时钟；
- (5)支持定时器、CAN，LIN，UART/USART，ADC、SPI、I2C 等多种外设；

本研究采用 PWM 技术控制无刷泵的转速来实现针对杂草数量的精准变量喷施。PWM(Pulse Width Modulation)脉宽调制，是一种常用的模拟控制原理。它通过调节脉冲宽度来控制电压输出，从而控制目标设备比如电机或者电灯的开关。PWM 是通过一系列的正弦波信号，构成一种控制信号，其周期性变化，在每一个周期内，正弦波信号会被分成若干正半周期和负半周期，并且通过改变占空比，来改变正半周期的比例。根据占空比的变化，可以控制脉冲的宽度，从而控制电压的输出^[89]。占空比是指在一个脉冲周期内，高电平时间所占整个周期的比例。




图 5.3 PWM 原理图

Fig. 5.3 PWM schematic diagram

PWM 原理如图 5.3 所示：使用计数器进行计数，计数器采用向上计数 PWM 模式，图中横坐标为时间，纵坐标为计数器，ARR 为自动重装值，CCR 为比较寄存器，在一个脉冲周期内，比较寄存器的值大于计数器的值时为低电平处于脉冲低处，当比较寄存器的值小于计数器的值时为高电平处于脉冲高处；当定时器计数器的值达到 ARR 时，定时器溢出，重新从 0 开始向上计数，如此循环。通过改变比较寄存器的值就可以改变 PWM 输出的占空比，系统在保证频率一定的情况下，通过调节比较寄存器的值来调节高电平的时间从而改变占空比，进而调节无刷泵两端电压的大小以改变泵的转速实现变量喷施。

将 NVIDIA AGX 与 STM32f103zet6 使用 USB 转 TTL 串口连接，在 NVIDIA 端使用 pyserial 库打开 USB 挂载设备的串口并调整相对应的波特率，然后将处理的检测信息发送 4 位有效数据“0000”。前两位控制两个泵电调的所接引脚的使能，后两位控制两个引脚的占空比，用以控制泵的开启以及泵的喷液量。如“0000”代表两者皆不开，“0100”代表二号泵开启，等级为 1 此时图像中两类杂草总数为 5 以

下，“1101”代表两者开启，一号泵等级为1，二号泵等级为2此时阔叶杂草总数高于5。

以此达到使用深度学习目标检测算法计算出目标的类别位置，并计算图像 3/4 位置下方杂草的数量实现变化学药剂，变喷液量的效果，最终实现减量增效的目的，为以后杂草的精准喷施，化肥农药的减量使用提供思路。

5.3.4 泵

目前市场上有各式各样的泵，使用较多的有柱塞泵、隔膜泵、离心泵等，无刷泵结构简单成本低且故障少，无刷直流水泵(磁力隔离泵)由泵体(隔离件)，电机定子，轴，轴承和转子水叶(磁体和叶轮)几部分组成。

工作前，电调上电，将吸入管与泵内腔充满溶液。STM32 获取开发板识别到杂草的类别、数量信息，控制电调启动泵，泵的叶轮高速旋转，带动其中的液体，向叶轮外侧射出，在泵壳扩散室内快速堆积，压力逐渐增加，然后从泵出口挤压排出。此时，由于叶轮内液体被甩出，形成真空区域，药箱内液体在大气压的作用下，经吸入管流入泵内。通过电调实现 PWM 对泵内直流无刷电机进行调节，实现变量喷施。泵的参数如表 5.5。

表 5.5 无刷直流水泵规格
Tab. 5.5 Specifications of brushless DC water pumps

参数	规格
重量	263g
尺寸	103*73*51mm
适用水管内径	10mm
支持锂电池	6S
压力	0.5MPA-0.8MPA
流量	1L-5L/min
适用电调	WA3510 6S

另外水管的软硬程度，以及布局长度也对泵的喷液量造成一定的影响，使用时挑选质地较硬的水管，在药箱与泵之间的距离应较长，泵与喷头之间的距离较短这样泵工作时压力喷头受到的压力较大，喷液更为集中，所受风力影响较小。

5.3.5 喷嘴

目前市面上农业农药喷施的喷嘴多使用扇形和圆锥形喷嘴。本研究应用就这两种喷嘴进行选型。

表 5.6 喷嘴类型对比

Tab. 5.6 Comparison of nozzle types

类型	规格	喷射区域	应用
扇形喷嘴	LICHENG/KZ8006	扇形的喷雾直线型的打击面，使得在单位面积上能提供更大的打击力	同等压力，流量下扇形喷嘴是更适合用于强冲击的清洗应用
锥形喷嘴	LICHENG/KZ8006	实心锥形喷雾形状，喷射区域呈圆形能在大范围流量和压力下产生分布均匀、液滴大小为中等到偏大的喷雾	能够在覆盖一个区域的喷流应用领域发挥良好的效果

扇形喷嘴形成笔直的液体打击面，使得单位面积上打击力较大。锥形喷嘴的主要作用是分散液体，达到雾化液体的效果。锥形喷嘴能产生实心锥形喷雾形状，喷射区域呈圆形。扇形喷嘴是一种喷雾形状为多种角度的扇形的喷嘴^[90]。




图 5.4 模拟真实场景喷施效果图

Fig. 5.4 Spraying effect picture of simulated real scene

由图可以看出圆锥形喷液区域更加集中，实际应用中减小喷射到作物的叶子或株芯的可能性。




图 5.5 简易连接图

Fig. 5.5 Simple Connection Diagram

图 5.5 为去除输入输出设备的简单系统连接图。

5.4 室内标定试验

根据药箱尺寸，试验田玉米种植密度，高度对整套试验器材进行选型标定。

表 5.7 试验平台位置尺寸标定

Tab. 5.7 Position and dimension calibration of experimental platform

材料	尺寸 cm	位置标定
药箱	40*30*25	最上方
铝型材	70*25*80	-
摄像头	5*5*1	铝型材正前方 15cm 高度 50cm
喷头	-	铝型材下方高度 40cm

5.5 行进速度模拟

经过测试从开发板发送数据到单片机接收数据再到单片机的 PWM 控制泵转动的快慢，以及喷头喷出液体的总体时间来对行进速度进行模拟

表 5.8 泵为一级转速

Tab. 5.8 The pump is at the first speed

试验	发送接收数据 时间 s	泵工作时间 s	喷头喷液 s	喷液量 ml	喷幅(横竖)cm	作业喷幅 (横竖)cm
0	0.1	1	1.08	9	70*72	40*50
1	0.1	2	1.59	13	71*75	43*55
2	0.1	3	2.88	20	73*79	43*57

表 5.9 泵为二级转速

Tab. 5.9 The pump is at the second speed

试验	发送接收数据 时间 s	泵工作时间 s	喷头喷液 s	喷液量 ml	喷幅(横竖)cm	作业喷幅 (横竖)cm
0	0.1	1s	2.05	18	79*85	60*80
1	0.1	2s	3.07	26	80*88	65*83
2	0.1	3s	4.82	37	84*90	63*86

已知玉米植株行间隙 60cm，种植密度间隔 25cm，由试验得出压力喷头在泵停止工作后还会工作一段时间，当出现杂草较多的情况下，泵 2 级转速会泵工作持续较长时间，以最大时间和最大距离为准，选取泵工作时间一秒，行进速度 0.25m/s 此时 1s 内行走 25cm 泵停止工作，但喷头会工作延时 1s，总共喷施 50cm 的距离。

5.6 变量喷施测试



图 5.6 田间试验平台样机

Fig. 5.6 Prototype of the field experiment platform

选取 50 个有代表性的区域，使用变量喷施系统进行测试。将系统放置到待测区域后方启动系统，通过人为控制行进速度，当摄像头采集到图像中包含的杂草时，模型预测出杂草的类别信息以及数量信息，随后发送数据给单片机从而控制两个直流无刷泵工作，从药箱抽出药液由喷头进行喷雾。数据统计结果如下：

表 5.10 试验样本数据
Tab. 5.10 Test statistics

玉米/株	单植株杂草/区域	多植株杂草/区域	无杂草/区域
200	20	20	10

表 5.11 各类别识别喷施统计
Tab. 5.11 Identification spray statistics by category

名称	总数量/株	正确识别/株	识别率/%
玉米	200	193	96.5
阔叶	42	40	95.2
禾本	135	116	85.7

雾滴覆盖密度是影响雾滴变量喷施效果的重要参数，是雾滴收集装置单位面积上所承受的雾滴个数，采用文献[91]相同的软件及方法获取水敏纸上的总雾滴个数。



图 5.7 田间喷施效果图
Fig. 5.7 Field spraying effect

根据田间实际喷施的统计结果，本试验准确喷施的单类别数量较少杂草农药雾滴平均覆盖密度为 45 个/cm²，准确喷施的多类别数量较少杂草农药雾滴平均覆盖密度为 87 个/cm²，本试验准确喷施的多类别数量较多杂草农药雾滴覆盖密度过多难以查证。对于雾滴覆盖密度与农药防治效果的研究表明农药雾滴覆盖密度大于 28 个/cm² 可以达到理想的防治效果。试验喷施结果证明，本方法可满足农药变量喷施的控制标准。在变量喷施系统中，模型在田间检测阔叶科杂草的识别准确率为 95.2%，禾本科杂草的识别准确率为 85.7%，对玉米的检测识别准确率为 96.5%，由以上数据可以看出，基于深度学习的变量喷施系统在田间的实际作业是可行的，取得较好的杂草喷施效果，也进一步证明精准变量喷施的可行性。

5.7 本章小结

本章设计算法的应用试验，验证改进后算法的实际应用的可能性。搭建变量喷施平台，通过硬件选型机器视觉系统，嵌入式边缘计算机(处理平台)、设计执行框架等对田间试验进行基础准备。改进后的模型在田间检测玉米的识别准确率为96.5%，对阔叶科杂草的检测识别准确率为 95.2%，识别出禾本科杂草并准确喷施的概率为 85.7%，使用改进的算法满足以较高的准确率在田间识别玉米和不同种类的杂草，同时也验证精准识别不同类别杂草并变量喷施的系统可行性。

第六章 总结与展望

6.1 引言

在不影响玉米产量下，有效减少化学农药使用实现精准除草，是本文最终目标。所以本文以生态无人农场幼苗期玉米与其伴生杂草为试验对象，通过改进深度学习单阶段目标检测算法，使算法模型内存更小，识别精度更高，以玉米以及玉米田内阔叶科与禾本科杂草为分类目标加以识别定位，使用两种选择性除草剂(阔叶科与禾本科)进行选择性的喷施农药实现变种类，通过分析当前画面内杂草数量进行变量喷施实现变喷液量。本文的算法与应用实现，为其它作物与其伴生杂草的识别定位和杂草精准化清除研究提供参考。

6.2 工作总结

为实现精准化除草减少农药的使用以及解决无人机化学药剂除草带来的漂移问题，本文的研究内容如下：

(1)构建玉米与杂草数据集。以生态无人农场玉米苗期伴生杂草为主要研究对象，对种类和群落分布进行分析，使用相机实地采集 3-5 叶期玉米苗以及杂草数据。然后通过数据扩充的形式增强数据集的鲁棒性。最后通过 LabelImg 进行目标框的标注，以玉米、阔叶科、禾本科为类别构建 YOLO 以及 VOC 格式的数据集。针对小目标，遮挡，高光，背景复杂等田间真实情况分别构建测试数据集。

(2)提出改进的 YOLO-Fastestv2 目标检测模型。解决模型在占用内存较小、识别速率较快的情况下识别精度较低的问题。首先对比单阶段目标检测的几款经典模型 YOLO-v4tiny，YOLO-v5s，YOLO-v4MobileNet，YOLO-Fastestv2，选择的 YOLO-Fastestv2 仅有 4.25M，然后对其进行改进提升。通过引入 SIOU 损失来提高其对目标定位的准确性，引入 Focal 损失来提高对难分禾本杂草的识别准确度，使用 Nadam 优化器，使拟合时更快速的向最优处靠近。将特征提取网络中的 MaxPooling 层换成 SoftPooling 来减少信息丢失，将特征提取网络的下采样 Stage 阶段中步长为 2 的卷积改进替换为 SPD 卷积，以便于模型提取关键特征，引入 SimAM 无参注意力机制改进简单的 FPN 特征金字塔来提高对物体的识别精度，改进后仅为 5.1M。远远小于其他模型。最终在构建的复杂情况数据集上进行测试，发现改进的 YOLO-Fastestv2 可以满足实际需要。

(3)构建基于改进 YOLO-Fastestv2 田间杂草变量喷施系统。模型运行于 CUDA 加速的 AGX 中，将识别结果经异步串行端口并通过协议与实时性更高的 STM32 进行通信，STM32 负责控制执行机构喷施和精确的变量喷药，运用单片机 PWM 技术实现不

同药箱下喷头的变量喷施。可以实现开启摄像头检测后进行 PWM 变量喷施。

单类别数量较少杂草农药雾滴覆盖密度为 45 个/cm²，准确喷施的多类别数量较少杂草农药雾滴覆盖密度为 87 个/cm²，本试验准确喷施的多类别数量较多杂草农药雾滴覆盖密度较大难以查实，实际可满足除草剂变量喷施的控制要求。

(4)使用对玉米本身无药害作用的不同类型的选择性除草剂进行变种类变量喷施，为节省农药使用、减少农药残留、作物增产、解决农药远距离漂移问题等精准无害化除草提供参考。

试验中还存在着不足之处：

(1)试验中变量喷施系统未与机动车连接，纯使用人力模拟，所以验证数据稀疏，并不能完全评价此系统的适用程度，下一步将可以与真实机动车连接，使用更高级的摄像头，离心喷头等设备进行测试。

(2)结构设计时未考虑风速与喷施速度的关系，导致药液喷到作物对试验造成影响。

(3)数据集数量较少，导致识别精度未达到理想中的识别效果，希望接下来可以真实拍摄扩充到两万甚至三万张数据，另外增加可通过采集移动状态摄像头拍摄的视频的帧图像制作数据集，利于在动态下提高识别精确度。

6.3 展望

深度学习应用于杂草识别领域的研究还处于起步阶段，存在不少的问题。

(1)数据集建立费时、不通用。现阶段杂草数据集仅仅是针对一种作物生长期间生长的杂草不具备通用性，而且数据建立可能出现类别不平衡现象、处于不同生长阶段存在不同的特征，拍照时的光影变化等都影响着训练最终效果。

(2)田间作业环境复杂实际识别率较低。真实田间地况复杂总会出现颠簸，大风，遮挡等情况，这些是实际应用过程中存在的必须解决的问题。

(3)识别效果与硬件好坏有关。现阶段硬件本身的算力与价格和外型挂钩，一个算法模型是否能部署在移动端不仅要求算法具有实时的检测速率，还要有较高的识别精度。

因此未来在杂草识别领域的一个重要的研究方向是对于数据集的处理，如何减少人工注释，解决类不平衡，扩容数据，实现简易、准确、通用。另一方向是深度学习算法模型的最优化，解决由于田间外界因素造成的视觉采集的数据模糊、光影变化，遮挡重叠等带来的识别准确率降低的问题和如何减少对硬件性能的需求问题。在深度学习杂草识别的应用方面是：

(1)使用多种视觉设备与传感器协调作业。由中央系统调控各个设备视觉传递的数据，获得更加精准的定位，以解决存在遮挡的行间行内杂草不能完全识别定位的问题并且利用多传感器与机器视觉融合综合提取的信息，分析作物与杂草长势针对性除草。

(2)可以达到精准识别杂草的类别、生长周期、轮廓面积后，可以使用小型无人机搭载触杀式除草剂，使用机器人搭载激光、高压电等对杂草实现定点式物理清除，实时地给出最精确的除草计划。

参考文献

- [1] Cheng, B., Matson, E.T., 2015. A Feature-Based Machine Learning Agent for Automatic Rice and Weed Discrimination. Springer, Cham, pp. 517–527.
- [2] Lee, W.S., Alchanatis, V., Yang, C., Hirafuji, M., Moshou, D., Li, C., 2010. Sensing technologies for precision specialty crop production. *Comput. Electron. Agric.* 74, 2–33.
- [3] 陈德润,王书茂,王秀.农田杂草识别技术的现状与展望[J].中国农机化,2005(02):35-38.
- [4] 强胜.我国杂草学研究现状及其发展策略[J].植物保护,2010,36(04):1-5.
- [5] 李香菊.近年我国农田杂草防控中的突出问题与治理对策[J].植物保护,2018,44(05):77-84.
- [6] 马志艳,朱熠,杨磊.基于视觉的苗期作物株间除草关键技术研究现状[J].中国农机化学报, 2020,41(02): 32-38.
- [7] Hamuda, E., Glavin, M., Jones, E., 2016. A survey of image processing techniques for plant extraction and segmentation in the field. *Comput. Electron. Agric.* 125,184–199.
- [8] Rodrigo, M.A., Oturan, N., Oturan, M.A., 2014. Electrochemically assisted remediation of pesticides in soils and water: a review. *Chem. Rev.* 114, 8720–8745.
- [9] 农业农村部副部长张桃林在全国农药管理工作会议上的讲话[J].中国植保导刊, 2020, 40(01):5-11.
- [10] 杨峰山,孙丛,鲍霞霞等.5类化学除草剂在作物中残留分析的研究进展[J].中国农学通报, 2021,37(10):136-141.
- [11] Julien Champ, Adan Mora-Fallas, Hervé Goëau, et al. Instance segmentation for the fine detection of crop and weed plants by precision agricultural robots[J]. *Applications in Plant Sciences*, 8(7).
- [12] Mahmudul Hasan , Ferdous Sohel, Dean Diepeveen , et al. A Survey of Deep Learning Techniques for Weed Detection from Images[J]. *Computers and Electronics in Agriculture*, 184.
- [13] López - Granados F. Weed detection for site - specific weed management: mapping and real - time approaches[J]. *Weed Research*, 2011, 51(1): 1-11.
- [14] Jinbao Hong, Yubin Lan, Xuejun Yue, et al. Adaptive target spray system based on machine vision for plant protection UAV[J]. *International Journal of Precision Agricultural Aviation*, 2020, 3(3).
- [15] 李东升,胡文泽,兰玉彬,范明洪,李翠云,朱俊科.深度学习在杂草识别领域的研究现状与展望[J].中国农机化学报,2022,43(09):137-144.
- [16] 李扬.机器学习在农业领域应用现状与前景[J].安徽农学通报,2021,27(01):164-165+174.
- [17] 吕盛坪,李灯辉,冼荣亨.深度学习在我国农业中的应用研究现状[J].计算机工程与应用,2019, 55(20): 24-33+51.
- [18] 刘钦.乡村振兴战略背景下我国蔬菜产业发展分析[J].北方园艺,2020(04):142-147.

- [19] Kavar Osorio , Andrés Puerto , Cesar Pedraza, et al. A deep learning approach for weed detection in lettuce crops using multispectral images[J]. AgriEngineering, 2020, 2(3): 471-488.
- [20] Junfeng Gao, Andrew P. French, Michael P. Pound, et al. Deep convolutional neural networks for image-based *Convolvulus sepium* detection in sugar beet fields[J]. Plant Methods, 2020, 16(1): 1-12.
- [21] 尚建伟,蒋红海,喻刚等.基于深度学习的杂草识别系统[J]. 软件导刊, 2020, 19(07): 127-130.
- [22] 喻刚,蒋红海,孙腾飞等.基于深度学习的白菜田杂草分割[J]. 软件, 2020, 41(04): 211-215.
- [23] Borja Espejo-Garcia, Nikos Mylonas, Loukas Athanasakos, et al. Combining generative adversarial networks and agricultural transfer learning for weeds identification[J]. Biosystems Engineering, 2021, 204: 79-89.
- [24] Alessandro dos Santos Ferreira, Daniel Matte Freitas, Gercina Gonçalves da Silva, et al. Unsupervised deep learning and semi-automatic data labeling in weed discrimination-ScienceDirect[J]. Computers and Electronics in Agriculture, 165: 104963.
- [25] 张宋超,薛新宇,孙涛等.植保无人飞机油菜杂草防治与效果评估研究[J]. 中国农机化学报, 2019, 40(09): 48-53+59.
- [26] 张乐,金秀,傅雷扬等.基于 Faster R-CNN 深度网络的油菜田间杂草识别方法[J]. 激光与光电子学进展, 2020, 57(02): 304-312.
- [27] Alwaseela Abdallaa, Haiyan Cena, Liang Wana, et al. Fine-tuning convolutional neural network with transfer learning for semantic segmentation of ground-level oilseed rape images in a field with high weed pressure[J]. Computers and Electronics in Agriculture, 2019, 167: 105091.
- [28] Muhammad Hamza Asad, Abdul Bais. Weed Detection in Canola Fields Using Maximum Likelihood Classification and Deep Convolutional Neural Network [J]. Information Processing in Agriculture, 2019.
- [29] Victor Partel, Sri Charan Kakarla, Yiannis Ampatzidis. Development and evaluation of a low-cost and smart technology for precision weed management utilizing artificial intelligence[J]. Computers and Electronics in Agriculture, 2019, 157: 339-350.
- [30] 卢秀茹,贾肖月,牛佳慧.中国棉花产业发展现状及展望[J]. 中国农业科学, 2018, 51(01): 26-36.
- [31] Borja Espejo-Garciaa,, Nikos Mylonasa, Loukas Athanasakos, et al. Towards weeds identification assistance through transfer learning[J]. Computers and Electronics in Agriculture, 2020, 171: 105306.
- [32] 许燕,温德圣,周建平等.基于 Faster R-CNN 的新疆棉花幼苗与杂草识别方法[J]. 排灌机械工程学报, 2021, 39(06): 602-607.
- [33] 彭明霞,夏俊芳,彭辉. 融合 FPN 的 Faster R-CNN 复杂背景下棉田杂草高效识别方法[J]. 农业工程学报, 2019, 35(20): 202-209.
- [34] Dong Chena, Yuzhen Lub, Zhaojiang Lia, et al. Performance Evaluation of Deep Transfer Learning on Multiclass Identification of Common Weed Species in Cotton Production Systems[J]. arXiv

- preprint arXiv:2110.04960, 2021.
- [35] 武奕,易龙,曾维.我国水稻生产现状及发展对策研究[J].农业与技术,2015,35(18):143.
- [36] 邓向武,马旭,齐龙等.基于卷积神经网络与迁移学习的稻田苗期杂草识别[J].农机化研究, 2021, 43(10):167-171.
- [37] 彭文,兰玉彬,岳学军等.基于深度卷积神经网络的水稻田杂草识别研究[J].华南农业大学学报,2020,41(06):75-81.
- [38] Huasheng Huang, Yubin Lan, Aqing Yang, et al. Deep learning versus Object-based Image Analysis (OBIA) in weed mAPping of UAV imagery[J]. International Journal of Remote Sensing, 2020, 41(9): 3446-3479.
- [39] Rufe Zhang, Cong Wang, Xiaoping Hu, et al. Weed location and recognition based on UAV imaging and deep learning[J]. International Journal of Precision Agricultural Aviation, 2018, 1(1):25-31.
- [40] J.R. Dinesh Kumar , C. Ganesh Babu , K. Priyadharsini. An experimental investigation to spotting the weeds in rice field using deepnet[J]. Materials Today: Proceedings, 2021, 45: 8041-8053
- [41] Xu Ma, Xiangwu Deng, Long Qi , et al. Fully convolutional network for rice seedling and weed image segmentation at the seedling stage in paddy fields[J]. PLoS ONE, 2019, 14(4).
- [42] 崔爱民,张久刚,张虎等.我国玉米生产现状及发展变革[J].中国农业科技导报, 2020, 22(07): 10-19.
- [43] 徐艳蕾,何润,翟钰婷等.基于轻量卷积网络的田间自然环境杂草识别方法[J/OL].吉林大学学报(工学版):1-10[2021-09-03].
- [44] Julien Champl , Adan Mora-Fallas, Hervé Goau, et al. Instance segmentation for the fine detection of crop and weed plants by precision agricultural robots[J]. Applications in Plant Sciences, 8(7).
- [45] Dyrmann M, Karstoft H, Midtby H S. Plant species classification using deep convolutional neural network[J]. Biosystems engineering, 2016, 151: 72-80.
- [46] 权龙哲,吴冰,毛首人.基于 Mask R-CNN 农田杂草实例分割与叶龄识别方法[J].东北农业大学学报, 2021, 52(04):65-76.
- [47] Aichen Wang, Wen Zhang, Xinhua Wei. A review on weed detection using ground-based machine vision and image processing techniques[J]. Computers and Electronics in Agriculture, 2019, 158(2019):226-240.
- [48] 李志伟.机器学习发展及几种学习方式[J].产业与科技论坛,2016,15(10):198-199.
- [49] 陈嘉博.机器学习算法研究及前景展望[J].信息通信,2017(06):5-6.
- [50] 孙志军,薛磊,许阳明,王正.深度学习研究综述[J].计算机应用研究,2012,29(08):2806-2810.
- [51] 谭笑枫,李广帅.深度学习发展综述[A].中国地球物理学会国家安全地球物理专业委员会、陕西省地球物理学会军事地球物理专业委员会.国家安全地球物理丛书(十五)——丝路环境与地球物理[C].中国地球物理学会国家安全地球物理专业委员会、陕西省地球物理学会军事地

- 球物理专业委员会:中国地球物理学会,2019:9.
- [52] Yann LeCun ,Leon Bottou, Yoshua Bengio. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11):2278-2324.
- [53] Geoffrey E. Hinton ,Simon Osindero,Yee-Whye Teh . A Fast Learning Algorithm for Deep Belief Nets[J]. Neural Computation, 2014, 18(7):1527-1554.
- [54] 邓向武,齐龙,马旭,蒋郁,陈学深,刘海云,陈伟烽.基于多特征融合和深度置信网络的稻田苗期杂草识别[J].农业工程学报,2018,34(14):165-172.
- [55] J. Goodfellow, Jean Pouget-Abadie, Mehdi Mirza,et al.Generative adversarial nets[C]//Proceedings of the 27th International Conference on Neural Information Processing Systems.Montreal,Canada: MIT Press, 2014: 2672-2680.
- [56] Mulham Fawakherji,Ciro Potena,Ibis Prevedello, et al. Data Augmentation Using GANs for Crop/Weed Segmentation in Precision Farming[C]//2020 IEEE Conference on Control Technology and Applications (CCTA). IEEE, 2020.
- [57] 周飞燕,金林鹏,董军.卷积神经网络研究综述[J].计算机学报,2017,40(06):1229-1251.
- [58] Lecun Y , Bottou L . Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11):2278-2324.
- [59] Krizhevsky A , Sutskever I , Hinton G . ImageNet Classification with Deep Convolutional Neural Networks[J]. Advances in neural information processing systems, 2012, 25(2).
- [60] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:1409.1556, 2014.
- [61] Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 1-9.
- [62] Chollet F. Xception: Deep learning with depthwise separable convolutions[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 1251-1258.
- [63] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [64] Huang G, Liu Z, Van Der Maaten L, et al. Densely connected convolutional networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 4700-4708.
- [65] Howard A G, Zhu M, Chen B, et al. MobileNets: Efficient convolutional neural networks for mobile vision applications[J]. arXiv preprint arXiv:1704.04861, 2017.
- [66] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 779-788.
- [67] Redmon J, Farhadi A. YOLO-9000: better, faster, stronger[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 7263-7271.

- [68] Redmon J, Farhadi A. YOLO-v3: An incremental improvement[J]. arXiv preprint arXiv: 1804.02767, 2018.
- [69] Bochkovskiy A, Wang C Y, Liao HYM. YOLO-v4: Optimal speed and accuracy of object detection[J]. arXiv preprint arXiv:2004.10934, 2020.
- [70] 胡佳玲,施一萍,谢思雅等.基于 Jetson nano 的改进 MobileNet 人脸识别系统[J].传感器与微系统,2021,40(03):102-105.DOI:10.13873/J.1000-9787(2021)03-0102-04.
- [71] Howard A, Sandler M, Chu G, et al. Searching for MobileNetv3[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2019: 1314-1324.
- [72] Zhang X, Zhou X, Lin M, et al. ShuffleNet: An extremely efficient convolutional neural network for mobile devices[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 6848-6856.
- [73] Ma N, Zhang X, Zheng H T, et al. ShuffleNet V2: Practical guidelines for efficient cnn architecture design[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 116-131.
- [74] Jiang Z, Zhao L, Li S, et al. Real-time object detection method based on improved YOLO-v4-tiny [J]. arXiv preprint, 2020, arXiv: 2011.04244. doi: 10.48550/arXiv.2011.04244.
- [75] Wang K, Liew J H, Zou Y, et al. PANet: Few-Shot Image Semantic Segmentation with Prototype Alignment[J]. IEEE, 2019.
- [76] Song G, Liu Y, Wang X. Revisiting the sibling head in object detector[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 11563-11572.
- [77] Lin T Y, Goyal P, Girshick R, et al. Focal loss for dense object detection[C]//Proceedings of the IEEE international conference on computer vision. 2017: 2980-2988.
- [78] Rezaatofghi H, Tsoi N, Gwak J Y, et al. Generalized intersection over union: A metric and a loss for bounding box regression[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 658-666.
- [79] Zheng Z, Wang P, Liu W, et al. Distance-IoU loss: Faster and better learning for bounding box regression[C]//Proceedings of the AAAI conference on artificial intelligence.2020,34(07): 12993 - 13000.
- [80] Gevorgyan Z. SIoU loss: More powerful learning for bounding box regression[J]. arXiv preprint arXiv:2205.12740, 2022.
- [81] Zhao H, An J, Yu M, et al. Nesterov-accelerated adaptive momentum estimation-based wavefront distortion correction algorithm[J]. Applied Optics, 2021, 60(24): 7177-7185.
- [82] Sunkara R, Luo T. No More Strided Convolutions or Pooling: A New CNN Building Block for Low-Resolution Images and Small Objects[J]. arXiv preprint arXiv:2208.03641, 2022.

- [83] Stergiou A, Poppe R, Kalliatakis G. Refining activation downsampling with SoftPool[C]// Proceedings of the IEEE/CVF international conference on computer vision. 2021: 10357-10366.
- [84] Lin T Y, Dollár P, Girshick R, et al. Feature pyramid networks for object detection[C]// Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 2117-2125.
- [85] Yang L, Zhang R Y, Li L, et al. SimAM: A simple, parameter-free attention module for convolutional neural networks [C]//International conference on machine learning. PMLR, 2021: 11863-11874.
- [86] Woo S, Park J, Lee J Y, et al. CBAM: convolutional block attention module [C]//Proceedings of the European conference on computer vision (ECCV). 2018: 3-19.
- [87] 海艳菊.玉米除草剂选用及注意事项[J].河南农业,2015,No. 369(13):37.
- [88] 辛艳辉,袁合才.远程监控技术的应用研究进展[J].华北水利水电学院学报,2009,30(04):78-79.
- [89] 李英俊,何文静,李郝亮,郑昱.正弦脉宽调制(SPWM)技术的探讨[J].科技视界,2018(16):239-242.
- [90] 熊远远.外循环喷雾式反应器实心锥喷嘴的雾化性能研究[D].华东理工大学.
- [91] 张传银.基于深度学习的玉米田间杂草识别与分割技术研究[D].山东农业大学,2020.

在读期间公开发表的论文

[1]李东升,胡文泽,兰玉彬,范明洪,李翠云,朱俊科.深度学习在杂草识别领域的研究现状与展望[J].中国农机化学报,2022,43(09):137-144.

致谢

时光匆匆如白驹过隙，伴随着新冠疫情，三年的硕士研究生生涯马上结束。

在这长长的三年中，本人从一个思想天真，行为幼稚，难以经受打击的脆弱本科生成长为一个对学习努力认真，对生活百折不屈的坚强研究生，多谢恩师朱俊科的教诲与帮助，他言传身教，面朝黄土背朝天，把论文写在大地上，这些艰苦奋斗在一线的行为深深的感动着我；在生活上与慧敏姐关心我的思想状态教会我怎么面对人生的挫折，怎么适应未来的人生，把我从一个社恐内向的性格慢慢的变为开朗的人；在学习上与胡文泽师姐一起帮助我论文选题、论证、构思到研究方案设计，支持我的研究工作，让我实实在在的体会到老师说的这一生只有两种人希望你更优秀，一种是你的父母，另一种是你的老师。老师的艰苦奋斗不贪图享乐的优秀品质不仅影响着我们对于家国情怀，对于解决中国粮食安全问题的看法，还影响着我们对于学生身份的本职工作的态度。他全国劳模，人大代表的身份更凸显其标杆榜样的作用。在这里我祝愿恩师朱俊科奋斗的身心健康，奋斗的事业辉煌。

与此同时还要感谢王会征老师，对我生活学习上的帮助，学生没齿难忘，您带我像亲学生一般教导提点，您的话语一直刻在我脑海。愿您旧疾永不复发，新疾永不出现，文章年年出。

感谢在我想要改变自己的期间包容宽恕支持我的同门，同时实验室的各位哥哥姐姐。感谢帮助我做试验的师弟师妹。感谢所有的同学，和他们一起共同学习共同进步，使我的研究生生活充实而快乐。

王宝聚师兄是我科研道路上的指路人，走过的岔路口，皆会同我分享，使我学习上少走很多弯路。赵德楠师兄，单长峰师兄我与你们真是相识恨晚，你们让我感受到大师兄的气度与责任。

在这短短三年里，我仍有很多很多的缺点没有改进，很多封闭传统的思想没有转变过来，只是简简单单的过完研究生生涯，很不幸我与这些贵人相处时间太短，你们的优点我难以融汇贯通。

感谢我的父母，感谢他们的开明，宽容和我这个独子溢出的爱意。

感谢命运让我做了一场短短的却长长的梦，真希望不要醒来。

最后，对审阅学生我文章的专家致以如滔滔江水连绵不绝的敬意和最诚挚的感谢，如有不妥敬请批评指正！